

Fundamentos Matemáticos del Aprendizaje Automático

Teoría, demostraciones y formulación rigurosa de los métodos de regresión, clasificación y análisis de datos

MI Jesús Gilberto Rodríguez Escobedo

2026-07-31

Fundamentos Matemáticos del Aprendizaje Automático

Volumen teórico complementario

MI Jesús Gilberto Rodríguez Escobedo

$$\min_{\mathbf{w}} \frac{1}{m} \sum_{i=1}^m \ell(y_i, f_{\mathbf{w}}(\mathbf{x}_i)) + \lambda \|\mathbf{w}\|_2^2$$

$$\mathbb{R}^n$$

$$f: \mathbb{R}^n \rightarrow \mathbb{R}$$

$$\nabla f(\mathbf{x})$$

$$J = \mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}$$

$$\sum_{i=1}^m \ell(y_i, \hat{y}_i)$$

$$\|\mathbf{w}\|_2^2$$

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$

$$\mathbb{E}[y | \mathbf{x}]$$

$$\Sigma = \mathbb{E}[(\mathbf{x} - \mu)(\mathbf{x} - \mu)^T]$$

Contenido

1 Fundamentos Matemáticos del Aprendizaje Automático	6
Bienvenida	7
2 Presentación	8
3 Introducción	10
4 Notación general	11
I I. Fundamentos matemáticos	12
5 Lenguaje matemático, conjuntos y funciones	13
6 Álgebra lineal para aprendizaje automático	28
7 Probabilidad y estadística para aprendizaje automático	50
8 Cálculo multivariable y optimización	73
II II. Fundamentos del aprendizaje automático	94
9 Formulación matemática del aprendizaje supervisado	95
10 Teoría matemática de la clasificación	113
11 Evaluación, validación y selección de modelos	131
12 Regularización y control de la complejidad	149
III III. Modelos de regresión	166
13 Regresión lineal simple	167
14 Regresión lineal múltiple	187
15 Regresión logística	209
IV IV. Métodos de clasificación	226
16 Vecinos más cercanos, k-NN	227
17 Árboles de decisión	243
18 Random Forest	261
19 Máquinas de vectores de soporte, SVM	273

V V. Aprendizaje no supervisado	317
21 Análisis de Componentes Principales, PCA	318
22 Agrupamiento mediante K-means	335
23 Agrupamiento jerárquico	353
24 Reglas de asociación	366
 VI VI. Temas avanzados	 381
25 Teoría de generalización	382
26 Series de tiempo y aprendizaje automático	387
Referencias	405
Índice temático	410
Índice alfabético	411

1 Fundamentos Matemáticos del Aprendizaje Automático

Teoría, demostraciones y formulación rigurosa

Bienvenida

Este libro desarrolla los fundamentos matemáticos de los principales métodos de aprendizaje automático. Su propósito es explicar no solamente cómo se ejecutan los algoritmos, sino por qué funcionan, cuáles son sus supuestos y qué propiedades justifican su utilización.

La obra complementa el libro práctico *Aprendizaje y Clasificación Automática con R*. Ambos volúmenes pueden estudiarse por separado, aunque su lectura conjunta permite conectar la formulación matemática, el algoritmo y su implementación computacional.

Objetivos generales

Al finalizar el libro, el lector podrá:

- representar formalmente problemas de aprendizaje automático;
- comprender los fundamentos algebraicos, probabilísticos y estadísticos de los modelos;
- derivar los principales algoritmos de regresión, clasificación y agrupamiento;
- interpretar funciones de pérdida, criterios de optimización y métodos de regularización;
- analizar supuestos, limitaciones y propiedades de generalización;
- relacionar la teoría matemática con implementaciones en R.

2 Presentación

El aprendizaje automático se ha convertido en una de las áreas más importantes de la ciencia de datos, la inteligencia artificial, la estadística y la computación moderna. Sus métodos permiten construir sistemas capaces de identificar patrones, realizar predicciones, clasificar observaciones, descubrir estructuras ocultas y apoyar la toma de decisiones a partir de datos.

Sin embargo, el uso adecuado de estos métodos requiere algo más que aprender a ejecutar funciones en un lenguaje de programación. Detrás de cada algoritmo existen conceptos matemáticos que determinan su funcionamiento, sus alcances, sus limitaciones y las condiciones bajo las cuales sus resultados pueden considerarse confiables.

El presente libro tiene como propósito desarrollar, de manera rigurosa y progresiva, los fundamentos matemáticos de los principales métodos de aprendizaje automático. Se estudian los conceptos de álgebra lineal, probabilidad, estadística, cálculo multivariable y optimización que permiten formular y comprender los algoritmos de regresión, clasificación, reducción de dimensionalidad, agrupamiento y aprendizaje basado en reglas.

La obra ha sido concebida como el complemento teórico del libro *Aprendizaje y Clasificación Automática con R*. Mientras que aquel volumen se orienta principalmente a la aplicación de los algoritmos mediante datos reales, programación en R, visualización e interpretación de resultados, este segundo volumen se concentra en su formulación matemática, sus derivaciones, propiedades y fundamentos teóricos.

Ambos libros pueden estudiarse de manera independiente. No obstante, su utilización conjunta permitirá al lector relacionar tres niveles fundamentales del aprendizaje automático:

1. la formulación matemática del problema;
2. el procedimiento algorítmico utilizado para resolverlo;
3. su implementación computacional con datos reales.

El contenido se presenta de forma gradual. Cada capítulo comienza con una explicación conceptual del problema, seguida de la notación matemática necesaria, definiciones formales, proposiciones, teoremas, demostraciones y derivaciones. Posteriormente se desarrollan ejemplos numéricos manuales y se establece la conexión con los algoritmos estudiados en el volumen práctico.

Organización de la obra

La obra se organiza en seis partes:

1. fundamentos matemáticos;
2. fundamentos del aprendizaje automático;
3. modelos de regresión;
4. métodos de clasificación;
5. aprendizaje no supervisado;

6. temas avanzados.

Cada capítulo incluye referencias académicas específicas, mientras que la bibliografía consolidada aparece al final del libro.

3 Introducción

El aprendizaje automático estudia métodos capaces de construir reglas de predicción, clasificación o descripción a partir de datos. Desde el punto de vista matemático, aprender significa seleccionar una función dentro de una familia de modelos utilizando información contenida en una muestra.

Sea un conjunto de datos

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n,$$

donde cada vector $\mathbf{x}_i \in \mathbb{R}^p$ contiene las características de la observación i y y_i representa su respuesta.

El objetivo general del aprendizaje supervisado consiste en construir una función

$$f : \mathcal{X} \longrightarrow \mathcal{Y}$$

que produzca predicciones adecuadas para observaciones nuevas.

La construcción de esta función requiere responder preguntas fundamentales:

- ¿cómo se representa matemáticamente la información?
- ¿qué significa que dos observaciones sean semejantes?
- ¿cómo se mide el error de un modelo?
- ¿cómo se determina el mejor conjunto de parámetros?
- ¿qué condiciones permiten confiar en una predicción?
- ¿cómo se evita que un modelo memorice los datos de entrenamiento?

Estas preguntas requieren herramientas de álgebra lineal, probabilidad, estadística, cálculo y optimización. Los primeros capítulos del libro desarrollan dichas herramientas antes de aplicarlas a los principales algoritmos de aprendizaje automático.

4 Notación general

En esta obra se utilizarán las siguientes convenciones:

- Los escalares se representan mediante letras minúsculas: x, y, α, β .
- Los vectores se representan en negritas minúsculas: $\mathbf{x}, \mathbf{y}, \beta$.
- Las matrices se representan en negritas mayúsculas: $\mathbf{X}, \mathbf{A}, \Sigma$.
- Los conjuntos se representan mediante letras caligráficas o mayúsculas: $\mathcal{X}, \mathcal{Y}, \mathcal{D}$.
- El conjunto de los números reales se denota por $\mathbb{R}$.
- El espacio vectorial real de dimensión p se denota por $\mathbb{R}^p$.
- La transpuesta de una matriz o vector se representa mediante el superíndice T .
- La esperanza matemática se denota por $\mathbb{E}$.
- La varianza se denota por Var .
- La covarianza se denota por Cov .
- La norma euclidiana se denota por $\|\cdot\|_2$.
- La función indicadora se denota por $\mathbb{I}(\cdot)$.

Parte I

I. Fundamentos matemáticos

5 Lenguaje matemático, conjuntos y funciones

Introducción

El lenguaje de conjuntos, relaciones y funciones permite expresar con precisión los objetos que aparecen en aprendizaje automático: espacios de entrada, espacios de salida, muestras, hipótesis y funciones de pérdida. La presentación de este capítulo sigue la notación matemática habitual empleada en textos de reconocimiento de patrones y aprendizaje estadístico (Bishop 2006; Hastie et al. 2009).

El aprendizaje automático se construye sobre objetos matemáticos bien definidos: conjuntos de datos, espacios de características, funciones de predicción, reglas de decisión y medidas de error. Antes de estudiar algoritmos concretos, es necesario establecer un lenguaje común que permita expresar estos elementos con precisión.

En este capítulo se revisan los conceptos de conjuntos, relaciones y funciones, y se muestra cómo aparecen de manera natural en la formulación de problemas de aprendizaje automático.

! Idea central

Una **función** asigna a cada elemento del dominio exactamente un elemento del codominio.

Objetivos

Al finalizar el capítulo, el lector podrá:

1. reconocer y utilizar la notación básica de conjuntos;
2. distinguir entre elemento, subconjunto, unión, intersección y complemento;
3. interpretar el producto cartesiano;
4. definir formalmente una función;
5. distinguir dominio, codominio e imagen;
6. identificar funciones inyectivas, suprayectivas y biyectivas;
7. utilizar funciones indicadoras;
8. representar formalmente conjuntos de entrenamiento;
9. distinguir matemáticamente entre regresión y clasificación.

Convenciones y alcance matemático

En este libro se trabajará principalmente con conjuntos finitos, subconjuntos de espacios euclidianos y funciones entre espacios de dimensión finita. Salvo indicación contraria:

- $\mathbb{N} = \{1, 2, 3, \dots\}$;
- $\mathbb{R}^p$ representa el espacio de vectores reales de dimensión p ;
- una muestra de tamaño n se indexa mediante $i = 1, \dots, n$;

- las funciones se consideran bien definidas en todo su dominio;
- la igualdad entre funciones exige igualdad de dominio, codominio y valores.

Esta precisión evita identificar una función únicamente con su fórmula. Dos expresiones algebraicas iguales pueden representar funciones distintas si sus dominios o codominios son diferentes.

Conjuntos numéricos

Los conjuntos numéricos más utilizados son:

$$\mathbb{N} = \{1, 2, 3, \dots\},$$

$$\mathbb{Z} = \{\dots, -2, -1, 0, 1, 2, \dots\},$$

$$\mathbb{Q} = \left\{ \frac{a}{b} : a, b \in \mathbb{Z}, b \neq 0 \right\},$$

y

$$\mathbb{R},$$

que representa el conjunto de los números reales.

En aprendizaje automático también se utiliza frecuentemente el espacio

$$\mathbb{R}^p = \{(x_1, \dots, x_p) : x_j \in \mathbb{R}\}.$$

Cada elemento de $\mathbb{R}^p$ es un vector con p componentes.

Ejemplo 5.1. Una observación ambiental puede representarse mediante

$$\mathbf{x} = \begin{pmatrix} 42.3 \\ 18.7 \\ 61.0 \end{pmatrix} \in \mathbb{R}^3,$$

donde las componentes podrían corresponder a concentración de partículas, temperatura y humedad.

Concepto de conjunto

Definición 5.1. Un **conjunto** es una colección bien definida de objetos. Los objetos que forman parte del conjunto se denominan elementos.

Si x pertenece a un conjunto A , se escribe

$$x \in A.$$

Si no pertenece, se escribe

$$x \notin A.$$

Por ejemplo, si

$$A = \{2, 4, 6, 8\},$$

entonces

$$4 \in A$$

y

$$5 \notin A.$$

Formas de especificar conjuntos

Un conjunto puede describirse por extensión o por comprensión.

Por extensión

Se enumeran sus elementos:

$$A = \{1, 2, 3, 4, 5\}.$$

Por comprensión

Se especifica una propiedad que deben satisfacer sus elementos:

$$A = \{x \in \mathbb{N} : 1 \leq x \leq 5\}.$$

La expresión después de los dos puntos se interpreta como “tal que”.

Igualdad de conjuntos

Dos conjuntos A y B son iguales si contienen exactamente los mismos elementos:

$$A = B \iff (\forall x)(x \in A \iff x \in B).$$

El orden de los elementos no importa. Por ejemplo,

$$\{1, 2, 3\} = \{3, 1, 2\}.$$

La repetición tampoco modifica un conjunto:

$$\{1, 1, 2, 3\} = \{1, 2, 3\}.$$

Subconjuntos

Definición 5.2. Se dice que A es un subconjunto de B si cada elemento de A también pertenece a B .

Formalmente,

$$A \subseteq B \iff (\forall x)(x \in A \Rightarrow x \in B).$$

Si además $A \neq B$, entonces A es un subconjunto propio de B .

Ejemplo 5.2. Sean

$$A = \{1, 2\}, \quad B = \{1, 2, 3, 4\}.$$

Entonces

$$A \subseteq B.$$

Conjunto vacío

El conjunto que no contiene elementos se denomina conjunto vacío y se denota por

$$\emptyset.$$

El conjunto vacío es subconjunto de todo conjunto:

$$\emptyset \subseteq A.$$

Operaciones entre conjuntos

Unión

La unión de A y B es el conjunto de elementos que pertenecen a A , a B o a ambos:

$$A \cup B = \{x : x \in A \text{ o } x \in B\}.$$

Intersección

La intersección contiene los elementos comunes:

$$A \cap B = \{x : x \in A \text{ y } x \in B\}.$$

Diferencia

La diferencia $A \setminus B$ contiene los elementos de A que no pertenecen a B :

$$A \setminus B = \{x : x \in A \text{ y } x \notin B\}.$$

Complemento

Si U es el conjunto universal, el complemento de A es

$$A^c = U \setminus A.$$

Ejemplo 5.3. Sean

$$A = \{1, 2, 3, 4\}, \quad B = \{3, 4, 5, 6\}.$$

Entonces

$$A \cup B = \{1, 2, 3, 4, 5, 6\},$$

$$A \cap B = \{3, 4\},$$

$$A \setminus B = \{1, 2\},$$

y

$$B \setminus A = \{5, 6\}.$$

Propiedades fundamentales

Para cualesquiera conjuntos A , B y C se cumplen:

Conmutatividad

$$A \cup B = B \cup A,$$

$$A \cap B = B \cap A.$$

Asociatividad

$$(A \cup B) \cup C = A \cup (B \cup C),$$

$$(A \cap B) \cap C = A \cap (B \cap C).$$

Distributividad

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C),$$

$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C).$$

Leyes de De Morgan

$$(A \cup B)^c = A^c \cap B^c,$$

$$(A \cap B)^c = A^c \cup B^c.$$

Estas propiedades serán importantes posteriormente en probabilidad, reglas de asociación y teoría de clasificación.

Producto cartesiano

Definición 5.3. El producto cartesiano de dos conjuntos A y B se define como

$$A \times B = \{(a, b) : a \in A, b \in B\}.$$

Si

$$A = \{1, 2\}, \quad B = \{a, b\},$$

entonces

$$A \times B = \{(1, a), (1, b), (2, a), (2, b)\}.$$

El producto cartesiano permite representar observaciones con varias características. En general,

$$\mathbb{R}^p = \underbrace{\mathbb{R} \times \cdots \times \mathbb{R}}_{p \text{ veces}}.$$

Relaciones

Definición 5.4. Una relación entre los conjuntos A y B es cualquier subconjunto de $A \times B$.

Una relación R puede escribirse como

$$R \subseteq A \times B.$$

Si $(a, b) \in R$, se dice que a está relacionado con b .

En clasificación, una muestra etiquetada puede verse como un conjunto de pares ordenados que relaciona cada observación con una clase.

i Relación y función

Toda función es una relación, pero no toda relación es una función. Para que una relación $f \subseteq A \times B$ sea una función de A en B , cada elemento de A debe aparecer exactamente una vez como primera componente.

Funciones

Definición 5.5. Una función f de un conjunto A a un conjunto B es una regla que asigna a cada elemento de A exactamente un elemento de B .

Se escribe

$$f : A \longrightarrow B.$$

El conjunto A es el dominio y B es el codominio.

Si $x \in A$, el valor asignado se denota por $f(x)$.

Ejemplo 5.4. Sea

$$f : \mathbb{R} \longrightarrow \mathbb{R}$$

definida por

$$f(x) = 2x + 1.$$

Entonces

$$f(3) = 7.$$

Dominio, codominio e imagen

Para una función

$$f : A \rightarrow B,$$

el dominio es A y el codominio es B .

La imagen de f es

$$\text{Im}(f) = \{f(x) : x \in A\}.$$

Siempre se cumple

$$\text{Im}(f) \subseteq B.$$

El codominio y la imagen no necesariamente coinciden.

Imagen e imagen inversa de conjuntos

Si $C \subseteq A$, la imagen de C es

$$f(C) = \{f(x) : x \in C\}.$$

Si $D \subseteq B$, la imagen inversa de D es

$$f^{-1}(D) = \{x \in A : f(x) \in D\}.$$

La notación $f^{-1}(D)$ no exige que f sea invertible.

Funciones inyectivas, suprayectivas y biyectivas

Función inyectiva

Definición 5.6. Una función $f : A \rightarrow B$ es inyectiva si elementos distintos del dominio tienen imágenes distintas.

Equivalentemente,

$$f(x_1) = f(x_2) \Rightarrow x_1 = x_2.$$

Función suprayectiva

Definición 5.7. Una función $f : A \rightarrow B$ es suprayectiva si cada elemento de B es imagen de al menos un elemento de A .

Formalmente,

$$(\forall y \in B)(\exists x \in A) \quad f(x) = y.$$

Función biyectiva

Definición 5.8. Una función es biyectiva si es simultáneamente inyectiva y suprayectiva.

Las funciones biyectivas poseen una función inversa.

Composición de funciones

Sean

$$f : A \rightarrow B$$

y

$$g : B \rightarrow C.$$

La composición de g con f se define como

$$(g \circ f)(x) = g(f(x)).$$

La composición es esencial en redes neuronales, donde cada capa aplica una transformación a la salida de la capa anterior.

Ejemplo 5.5. Sean

$$f(x) = 2x + 1, \quad g(x) = x^2.$$

Entonces

$$(g \circ f)(x) = (2x + 1)^2.$$

En cambio,

$$(f \circ g)(x) = 2x^2 + 1.$$

En general,

$$g \circ f \neq f \circ g.$$

Función indicadora

Definición 5.9. Sea A un conjunto. La función indicadora de A se define por

$$\mathbb{I}_A(x) = \begin{cases} 1, & x \in A, \\ 0, & x \notin A. \end{cases}$$

También se utiliza la notación

$$\mathbb{I}(x \in A).$$

En clasificación, la función indicadora permite contar observaciones de una clase:

$$n_k = \sum_{i=1}^n \mathbb{I}(y_i = k).$$

La proporción de observaciones de la clase k es

$$\hat{p}_k = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(y_i = k).$$

Esta expresión aparecerá en árboles de decisión, matrices de confusión y medidas de evaluación.

Sumatorias y productorias

La sumatoria

$$\sum_{i=1}^n x_i$$

representa

$$x_1 + x_2 + \cdots + x_n.$$

La productoria

$$\prod_{i=1}^n x_i$$

representa

$$x_1 x_2 \cdots x_n.$$

La media aritmética de una muestra es

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

La productoria será especialmente importante en funciones de verosimilitud.

Representación formal de datos

Sea

$$\mathcal{X} \subseteq \mathbb{R}^p$$

el espacio de características y sea $\mathcal{Y}$ el espacio de respuestas.

Un conjunto de datos supervisado se representa como

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n \subseteq \mathcal{X} \times \mathcal{Y}.$$

Cada vector

$$\mathbf{x}_i = \begin{pmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{pmatrix}$$

contiene los valores de las p características de la observación i .

La matriz de datos se representa como

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix} \in \mathbb{R}^{n \times p}.$$

El vector de respuestas es

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}.$$

Regresión y clasificación

Regresión

En un problema de regresión, la respuesta es numérica:

$$\mathcal{Y} \subseteq \mathbb{R}.$$

Se busca una función

$$f : \mathcal{X} \rightarrow \mathbb{R}.$$

Por ejemplo, estimar la concentración de un contaminante:

$$f(\mathbf{x}) = \hat{y}.$$

Clasificación binaria

En clasificación binaria,

$$\mathcal{Y} = \{0, 1\}$$

o bien

$$\mathcal{Y} = \{-1, 1\}.$$

La función de clasificación tiene la forma

$$f : \mathcal{X} \rightarrow \{0, 1\}.$$

Clasificación multiclase

En clasificación multiclase,

$$\mathcal{Y} = \{1, 2, \dots, K\}.$$

Entonces

$$f : \mathcal{X} \rightarrow \{1, \dots, K\}.$$

Función objetivo desconocida

En aprendizaje supervisado se supone que existe una relación entre las características y la respuesta. Puede representarse idealmente mediante una función desconocida

$$f^* : \mathcal{X} \rightarrow \mathcal{Y}.$$

Los datos satisfacen aproximadamente

$$y_i = f^*(\mathbf{x}_i) + \varepsilon_i$$

en regresión, donde ε_i representa variación aleatoria o error.

El objetivo del aprendizaje consiste en construir una aproximación

$$\hat{f} \approx f^*.$$

! Función objetivo y datos observados

En aprendizaje supervisado se supone que existe alguna relación entre $\mathbf{X}$ y Y , pero normalmente no se observa una función objetivo determinista exacta. Una formulación más general utiliza una distribución conjunta $P_{\mathbf{X}, Y}$ y busca una función que minimice el riesgo esperado. Esta distinción se desarrollará en los capítulos de aprendizaje supervisado y teoría de generalización.

Ejemplo integrado

Supóngase que se desea clasificar la calidad del aire utilizando tres variables:

1. concentración de partículas PM10;
2. temperatura;
3. humedad relativa.

El espacio de características es

$$\mathcal{X} \subseteq \mathbb{R}^3.$$

La respuesta puede definirse como

$$\mathcal{Y} = \{\text{buena, regular, mala}\}.$$

Una observación es

$$\mathbf{x}_i = \begin{pmatrix} \text{PM10}_i \\ \text{temperatura}_i \\ \text{humedad}_i \end{pmatrix}.$$

El conjunto de entrenamiento es

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n.$$

El clasificador buscado es una función

$$\hat{f} : \mathbb{R}^3 \rightarrow \{\text{buena}, \text{regular}, \text{mala}\}.$$

Conexión con R

En R, una tabla de datos puede interpretarse como una representación computacional de la matriz $\mathbf{X}$ y del vector $\mathbf{y}$.

```
1 datos <- data.frame(
2   pm10 = c(38, 75, 112, 46),
3   temperatura = c(19, 23, 27, 21),
4   humedad = c(64, 52, 43, 58),
5   calidad = c("buena", "regular", "mala", "buena")
6 )
7
8 X <- as.matrix(datos[, c("pm10", "temperatura", "humedad")])
9 y <- datos$calidad
```

Matemáticamente,

$$\mathbf{X} \in \mathbb{R}^{4 \times 3}$$

y

$$\mathbf{y} = \begin{pmatrix} \text{buena} \\ \text{regular} \\ \text{mala} \\ \text{buena} \end{pmatrix}.$$

Errores frecuentes

1. Confundir un elemento con un subconjunto.
2. Suponer que el codominio y la imagen siempre son iguales.
3. Confundir $f^{-1}(D)$ con la función inversa.
4. Olvidar que una función debe asignar exactamente una salida a cada entrada.
5. Considerar que el orden de los elementos cambia un conjunto.
6. Confundir una observación $\mathbf{x}_i$ con toda la matriz $\mathbf{X}$.
7. Suponer que toda clasificación utiliza únicamente las etiquetas 0 y 1.

Ejercicios

Ejercicios conceptuales

1. Explique la diferencia entre $x \in A$ y $\{x\} \subseteq A$.
2. Explique la diferencia entre dominio, codominio e imagen.
3. ¿Por qué una función de clasificación puede considerarse una regla de decisión?
4. ¿Qué diferencia existe entre $\mathbb{R}^p$ y $\mathbb{R}^{n \times p}$?
5. ¿Por qué el conjunto de entrenamiento es un subconjunto de $\mathcal{X} \times \mathcal{Y}$?

Ejercicios de conjuntos

Sean

$$A = \{1, 2, 3, 4, 5\}$$

y

$$B = \{4, 5, 6, 7\}.$$

Determine:

1. $A \cup B$;
2. $A \cap B$;
3. $A \setminus B$;
4. $B \setminus A$.

Ejercicios de funciones

Sea

$$f : \mathbb{R} \rightarrow \mathbb{R}, \quad f(x) = 3x - 2.$$

1. Calcule $f(0)$, $f(2)$ y $f(-1)$.
2. Determine la imagen del conjunto $\{0, 1, 2\}$.
3. Determine $f^{-1}(\{1, 4\})$.
4. Analice si f es inyectiva.
5. Analice si f es suprayectiva.

Ejercicio de clasificación

Considere las observaciones:

$$\mathbf{x}_1 = (20, 60), \quad \mathbf{x}_2 = (45, 48), \quad \mathbf{x}_3 = (80, 35),$$

con etiquetas

$$y_1 = \text{baja}, \quad y_2 = \text{media}, \quad y_3 = \text{alta}.$$

1. Identifique $\mathcal{X}$ y $\mathcal{Y}$.

2. Escriba formalmente el conjunto de entrenamiento.
3. Construya la matriz $\mathbf{X}$.
4. Construya el vector $\mathbf{y}$.
5. Escriba el tipo de función que representaría al clasificador.

Resumen

En este capítulo se estableció el lenguaje matemático básico del libro. Se definieron conjuntos, subconjuntos, operaciones entre conjuntos, productos cartesianos, relaciones y funciones. También se introdujeron dominio, codominio, imagen, composición y función indicadora.

Finalmente, se formuló un conjunto de datos supervisado como

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n \subseteq \mathcal{X} \times \mathcal{Y},$$

y se distinguieron formalmente los problemas de regresión y clasificación. Esta notación será utilizada en todos los capítulos posteriores.

Referencias del capítulo

Los fundamentos y la notación de este capítulo se apoyan principalmente en Bishop (2006) y Hastie et al. (2009).

6 Álgebra lineal para aprendizaje automático

Introducción

El álgebra lineal proporciona la estructura matemática de los datos multivariados y de numerosos algoritmos. Vectores, matrices, productos internos, proyecciones, valores propios y descomposición en valores singulares aparecen directamente en regresión, PCA, SVM y redes neuronales (Strang 2016; Axler 2015; Bishop 2006).

El álgebra lineal constituye uno de los lenguajes fundamentales del aprendizaje automático. Los conjuntos de datos se representan mediante vectores y matrices; los modelos lineales utilizan combinaciones lineales; el análisis de componentes principales depende de valores y vectores propios; las redes neuronales realizan sucesivas transformaciones matriciales; y numerosos algoritmos se formulan como problemas de proyección, factorización u optimización en espacios vectoriales.

Este capítulo desarrolla los conceptos esenciales de álgebra lineal que se utilizarán a lo largo del libro. El objetivo no es presentar únicamente reglas de cálculo, sino explicar el significado geométrico y estadístico de cada operación.

! Idea central

El álgebra lineal permite representar datos, transformaciones, proyecciones y descomposiciones mediante vectores y matrices.

Objetivos

Al finalizar el capítulo, el lector podrá:

1. distinguir escalares, vectores y matrices;
2. realizar operaciones básicas con vectores y matrices;
3. interpretar una combinación lineal;
4. analizar independencia y dependencia lineal;
5. comprender los conceptos de espacio vectorial, subespacio, base y dimensión;
6. calcular y utilizar productos internos y normas;
7. interpretar ortogonalidad y proyección;
8. representar sistemas de ecuaciones mediante matrices;
9. comprender rango, espacio columna y espacio nulo;
10. interpretar valores y vectores propios;
11. comprender la descomposición espectral;
12. reconocer la función de la descomposición en valores singulares;
13. relacionar estos conceptos con algoritmos de aprendizaje automático.

Convenciones de dimensiones

En todo el capítulo se utilizarán las siguientes convenciones:

- los vectores se consideran columnas;
- $\mathbf{x} \in \mathbb{R}^p$ tiene dimensión $p \times 1$;
- una matriz de datos $\mathbf{X} \in \mathbb{R}^{n \times p}$ contiene observaciones en filas y variables en columnas;
- $\mathbf{X}^T \in \mathbb{R}^{p \times n}$;
- el producto $\mathbf{AB}$ existe únicamente si el número de columnas de $\mathbf{A}$ coincide con el número de filas de $\mathbf{B}$.

Antes de efectuar una operación matricial conviene verificar explícitamente sus dimensiones.

Escalares

Definición 6.1. Un **escalar** es un elemento de un campo numérico, normalmente el conjunto de los números reales $\mathbb{R}$.

Los escalares se representan mediante letras minúsculas:

$$a, \quad b, \quad x, \quad \alpha, \quad \beta.$$

Ejemplos de escalares en aprendizaje automático son:

- una observación individual;
- un coeficiente de regresión;
- una tasa de aprendizaje;
- una probabilidad;
- una función de pérdida;
- una distancia entre dos observaciones.

Vectores

Definición 6.2. Un **vector** de dimensión p es una lista ordenada de p escalares.

Un vector columna se escribe como

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{pmatrix} \in \mathbb{R}^p.$$

Su transpuesta es un vector fila:

$$\mathbf{x}^T = (x_1 \quad x_2 \quad \cdots \quad x_p).$$

Ejemplo 6.1. Una observación ambiental con concentración de PM10, temperatura y humedad puede representarse mediante

$$\mathbf{x} = \begin{pmatrix} 52.4 \\ 23.1 \\ 47.0 \end{pmatrix}.$$

En este caso,

$$\mathbf{x} \in \mathbb{R}^3.$$

Igualdad de vectores

Dos vectores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ son iguales si todas sus componentes correspondientes son iguales:

$$\mathbf{x} = \mathbf{y} \iff x_j = y_j \quad \text{para todo } j = 1, \dots, p.$$

Suma de vectores

Sean

$$\mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_p \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_p \end{pmatrix}.$$

La suma se define componente a componente:

$$\mathbf{x} + \mathbf{y} = \begin{pmatrix} x_1 + y_1 \\ \vdots \\ x_p + y_p \end{pmatrix}.$$

Ejemplo 6.2. Si

$$\mathbf{x} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 3 \\ 4 \end{pmatrix},$$

entonces

$$\mathbf{x} + \mathbf{y} = \begin{pmatrix} 5 \\ 5 \end{pmatrix}.$$

Multiplicación por un escalar

Si $\alpha \in \mathbb{R}$ y $\mathbf{x} \in \mathbb{R}^p$, entonces

$$\alpha \mathbf{x} = \begin{pmatrix} \alpha x_1 \\ \vdots \\ \alpha x_p \end{pmatrix}.$$

Geométicamente, la multiplicación por un escalar modifica la longitud del vector y, si $\alpha < 0$, también invierte su dirección.

Combinaciones lineales

Definición 6.3. Una **combinación lineal** de los vectores $\mathbf{v}_1, \dots, \mathbf{v}_k$ es cualquier vector de la forma

$$\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k,$$

donde $\alpha_1, \dots, \alpha_k \in \mathbb{R}$.

Las combinaciones lineales aparecen en prácticamente todos los modelos lineales.

Por ejemplo, en regresión lineal múltiple,

$$\hat{y} = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p.$$

La predicción es una combinación lineal de las características.

Combinación convexa

Una combinación lineal se denomina convexa si

$$\alpha_j \geq 0$$

para todo j , y

$$\sum_{j=1}^k \alpha_j = 1.$$

En ese caso,

$$\mathbf{z} = \sum_{j=1}^k \alpha_j \mathbf{v}_j$$

se encuentra dentro de la envolvente convexa de los vectores.

Este concepto será importante en optimización y teoría de clasificación.

Independencia lineal

Definición 6.4. Los vectores $\mathbf{v}_1, \dots, \mathbf{v}_k$ son linealmente independientes si la ecuación

$$\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k = \mathbf{0}$$

implica

$$\alpha_1 = \dots = \alpha_k = 0.$$

Si existe una solución no trivial, los vectores son linealmente dependientes.

Ejemplo 6.3. Los vectores

$$\mathbf{v}_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad \mathbf{v}_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

son linealmente independientes.

En cambio,

$$\mathbf{v}_3 = \begin{pmatrix} 2 \\ 4 \end{pmatrix}, \quad \mathbf{v}_4 = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$

son linealmente dependientes porque

$$\mathbf{v}_3 = 2\mathbf{v}_4.$$

Espacios vectoriales

Definición 6.5. Un **espacio vectorial** sobre $\mathbb{R}$ es un conjunto de objetos llamados vectores, equipado con operaciones de suma y multiplicación por escalares que satisfacen ciertas propiedades algebraicas.

El ejemplo principal es $\mathbb{R}^p$.

Las propiedades fundamentales incluyen:

1. cerradura bajo la suma;
2. asociatividad;
3. conmutatividad;
4. existencia del vector cero;
5. existencia del inverso aditivo;
6. cerradura bajo multiplicación por escalares;
7. distributividad;
8. compatibilidad de escalares;
9. identidad escalar.

Subespacios

Definición 6.6. Un subconjunto W de un espacio vectorial V es un **subespacio vectorial** si:

1. contiene al vector cero;
2. es cerrado bajo la suma;
3. es cerrado bajo la multiplicación por escalares.

Por ejemplo, el conjunto

$$W = \left\{ \begin{pmatrix} x \\ 2x \end{pmatrix} : x \in \mathbb{R} \right\}$$

es un subespacio de $\mathbb{R}^2$.

Espacio generado

Definición 6.7. El espacio generado por los vectores $\mathbf{v}_1, \dots, \mathbf{v}_k$ es el conjunto de todas sus combinaciones lineales.

Se denota por

$$\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}.$$

Por ejemplo,

$$\text{span}\left\{\begin{pmatrix} 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \end{pmatrix}\right\} = \mathbb{R}^2.$$

Base y dimensión

Definición 6.8. Una **base** de un espacio vectorial V es un conjunto de vectores linealmente independientes que genera todo el espacio.

La base canónica de $\mathbb{R}^p$ es

$$\mathbf{e}_1, \dots, \mathbf{e}_p,$$

donde

$$\mathbf{e}_1 = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}, \quad \mathbf{e}_2 = \begin{pmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{pmatrix}, \quad \dots$$

La dimensión de un espacio vectorial es el número de vectores de cualquier base.

Por tanto,

$$\dim(\mathbb{R}^p) = p.$$

Matrices

Definición 6.9. Una **matriz** de dimensión $n \times p$ es un arreglo rectangular de números con n filas y p columnas.

Se escribe

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1p} \\ a_{21} & a_{22} & \cdots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{np} \end{pmatrix} \in \mathbb{R}^{n \times p}.$$

En aprendizaje automático, una matriz de datos se representa habitualmente mediante

$$\mathbf{X} \in \mathbb{R}^{n \times p},$$

donde:

- n es el número de observaciones;
- p es el número de características.

Filas y columnas

La fila i de $\mathbf{X}$ representa la observación i :

$$\mathbf{x}_i^T = (x_{i1} \quad \cdots \quad x_{ip}).$$

La columna j representa la característica j :

$$\mathbf{x}_{.j} = \begin{pmatrix} x_{1j} \\ \vdots \\ x_{nj} \end{pmatrix}.$$

Matrices especiales

Matriz cero

$$\mathbf{0} = \begin{pmatrix} 0 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 0 \end{pmatrix}.$$

Matriz identidad

La matriz identidad de orden p es

$$\mathbf{I}_p = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix}.$$

Cumple

$$\mathbf{I}_p \mathbf{x} = \mathbf{x}.$$

Matriz diagonal

Una matriz diagonal tiene ceros fuera de la diagonal principal:

$$\mathbf{D} = \text{diag}(d_1, \dots, d_p).$$

Matriz simétrica

Definición 6.10. Una matriz cuadrada $\mathbf{A}$ es simétrica si

$$\mathbf{A}^T = \mathbf{A}.$$

Las matrices de covarianza son simétricas.

Suma de matrices

Si

$$\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times p},$$

entonces

$$\mathbf{A} + \mathbf{B} = (a_{ij} + b_{ij}).$$

La suma solamente está definida cuando ambas matrices tienen las mismas dimensiones.

Multiplicación de una matriz por un escalar

Si $\alpha \in \mathbb{R}$, entonces

$$\alpha \mathbf{A} = (\alpha a_{ij}).$$

Producto matricial

Sean

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

y

$$\mathbf{B} \in \mathbb{R}^{p \times m}.$$

El producto

$$\mathbf{C} = \mathbf{AB}$$

es una matriz de dimensión $n \times m$, cuyos elementos son

$$c_{ij} = \sum_{k=1}^p a_{ik} b_{kj}.$$

Ejemplo 6.4. Sean

$$\mathbf{A} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}, \quad \mathbf{B} = \begin{pmatrix} 2 & 0 \\ 1 & 5 \end{pmatrix}.$$

Entonces

$$\mathbf{AB} = \begin{pmatrix} 1(2) + 2(1) & 1(0) + 2(5) \\ 3(2) + 4(1) & 3(0) + 4(5) \end{pmatrix} = \begin{pmatrix} 4 & 10 \\ 10 & 20 \end{pmatrix}.$$

En general,

$$\mathbf{AB} \neq \mathbf{BA}.$$

Matriz transpuesta

La transpuesta de una matriz $\mathbf{A} \in \mathbb{R}^{n \times p}$ es la matriz

$$\mathbf{A}^T \in \mathbb{R}^{p \times n}$$

obtenida intercambiando filas por columnas.

Se cumplen las propiedades:

$$(\mathbf{A}^T)^T = \mathbf{A},$$

$$(\mathbf{A} + \mathbf{B})^T = \mathbf{A}^T + \mathbf{B}^T,$$

$$(\mathbf{AB})^T = \mathbf{B}^T \mathbf{A}^T.$$

Producto interno

Definición 6.11. El producto interno euclidiano de dos vectores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ se define como

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^T \mathbf{y} = \sum_{j=1}^p x_j y_j.$$

Ejemplo 6.5. Si

$$\mathbf{x} = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 4 \\ 0 \\ -1 \end{pmatrix},$$

entonces

$$\mathbf{x}^T \mathbf{y} = 1(4) + 2(0) + 3(-1) = 1.$$

Norma

Definición 6.12. La norma euclidiana de un vector $\mathbf{x} \in \mathbb{R}^p$ es

$$\|\mathbf{x}\|_2 = \sqrt{\mathbf{x}^\top \mathbf{x}} = \sqrt{\sum_{j=1}^p x_j^2}.$$

La norma representa la longitud del vector.

Se cumplen:

1. $\|\mathbf{x}\|_2 \geq 0$;
2. $\|\mathbf{x}\|_2 = 0$ si y solo si $\mathbf{x} = \mathbf{0}$;
3. $\|\alpha \mathbf{x}\|_2 = |\alpha| \|\mathbf{x}\|_2$;
4. $\|\mathbf{x} + \mathbf{y}\|_2 \leq \|\mathbf{x}\|_2 + \|\mathbf{y}\|_2$.

Distancia euclidiana

La distancia entre $\mathbf{x}$ y $\mathbf{y}$ se define como

$$d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2.$$

Esta distancia es la base del algoritmo k -NN y del método k -means.

Ejemplo 6.6. Sean

$$\mathbf{x} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 4 \\ 6 \end{pmatrix}.$$

Entonces

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{(1-4)^2 + (2-6)^2} = 5.$$

Desigualdad de Cauchy-Schwarz

Teorema 6.1. Para cualesquiera vectores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$,

$$|\mathbf{x}^\top \mathbf{y}| \leq \|\mathbf{x}\|_2 \|\mathbf{y}\|_2.$$

Esta desigualdad permite definir el ángulo entre dos vectores.

Ángulo entre vectores

Si $\mathbf{x} \neq \mathbf{0}$ y $\mathbf{y} \neq \mathbf{0}$, se define

$$\cos \theta = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\|_2 \|\mathbf{y}\|_2}.$$

Este concepto es relevante en similitud coseno y análisis de texto.

Ortogonalidad

Definición 6.13. Dos vectores $\mathbf{x}$ y $\mathbf{y}$ son ortogonales si

$$\mathbf{x}^\top \mathbf{y} = 0.$$

La ortogonalidad generaliza la idea geométrica de perpendicularidad.

Vectores ortonormales

Un conjunto de vectores $\mathbf{q}_1, \dots, \mathbf{q}_k$ es ortonormal si:

$$\mathbf{q}_i^\top \mathbf{q}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Si las columnas de una matriz cuadrada $\mathbf{Q}$ son ortonormales, entonces

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}.$$

Por tanto,

$$\mathbf{Q}^{-1} = \mathbf{Q}^\top.$$

Proyección ortogonal

Sea $\mathbf{u} \neq \mathbf{0}$. La proyección de $\mathbf{x}$ sobre $\mathbf{u}$ es

$$\text{proj}_{\mathbf{u}}(\mathbf{x}) = \frac{\mathbf{x}^\top \mathbf{u}}{\mathbf{u}^\top \mathbf{u}} \mathbf{u}.$$

Si $\|\mathbf{u}\|_2 = 1$, entonces

$$\text{proj}_{\mathbf{u}}(\mathbf{x}) = (\mathbf{x}^\top \mathbf{u}) \mathbf{u}.$$

La regresión lineal puede interpretarse geométicamente como una proyección del vector de respuestas sobre el espacio generado por las columnas de la matriz de diseño.

Sistemas de ecuaciones lineales

Un sistema de n ecuaciones con p incógnitas puede escribirse como

$$\mathbf{Ax} = \mathbf{b}.$$

Por ejemplo,

$$\begin{aligned} 2x_1 + x_2 &= 5, \\ x_1 - 3x_2 &= -4 \end{aligned}$$

se representa como

$$\begin{pmatrix} 2 & 1 \\ 1 & -3 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 5 \\ -4 \end{pmatrix}.$$

Matriz inversa

Definición 6.14. Una matriz cuadrada $\mathbf{A}$ es invertible si existe una matriz $\mathbf{A}^{-1}$ tal que

$$\mathbf{A}^{-1}\mathbf{A} = \mathbf{A}\mathbf{A}^{-1} = \mathbf{I}.$$

Si $\mathbf{A}$ es invertible, el sistema

$$\mathbf{Ax} = \mathbf{b}$$

tiene la solución única

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}.$$

En la práctica computacional, normalmente no se calcula la inversa explícita; se utilizan métodos numéricos para resolver el sistema.

Determinante

El determinante de una matriz cuadrada $\mathbf{A}$ se denota por

$$\det(\mathbf{A}).$$

Una matriz es invertible si y solo si

$$\det(\mathbf{A}) \neq 0.$$

El determinante también mide el factor de cambio de volumen inducido por una transformación lineal.

Rango

Definición 6.15. El rango de una matriz $\mathbf{A}$ es el número máximo de columnas linealmente independientes.

Se denota por

$$\text{rank}(\mathbf{A}).$$

Si

$$\mathbf{A} \in \mathbb{R}^{n \times p},$$

entonces

$$\text{rank}(\mathbf{A}) \leq \min(n, p).$$

Espacio columna

El espacio columna de $\mathbf{A}$ es

$$\text{Col}(\mathbf{A}) = \text{span}\{\mathbf{a}_1, \dots, \mathbf{a}_p\},$$

donde $\mathbf{a}_j$ es la columna j de $\mathbf{A}$.

Espacio nulo

El espacio nulo de $\mathbf{A}$ es

$$\text{Null}(\mathbf{A}) = \{\mathbf{x} : \mathbf{A}\mathbf{x} = \mathbf{0}\}.$$

Si el espacio nulo contiene vectores distintos de cero, las columnas de $\mathbf{A}$ son linealmente dependientes.

Transformaciones lineales

Definición 6.16. Una función

$$T : \mathbb{R}^p \rightarrow \mathbb{R}^m$$

es lineal si para todos $\mathbf{x}, \mathbf{y}$ y todos $\alpha, \beta \in \mathbb{R}$,

$$T(\alpha\mathbf{x} + \beta\mathbf{y}) = \alpha T(\mathbf{x}) + \beta T(\mathbf{y}).$$

Toda transformación lineal puede representarse mediante una matriz:

$$T(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

Formas cuadráticas

Definición 6.17. Una forma cuadrática es una expresión de la forma

$$q(\mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x},$$

donde $\mathbf{A}$ es una matriz cuadrada.

Las formas cuadráticas aparecen en:

- funciones de pérdida;
- distancias de Mahalanobis;

- regresión ridge;
- análisis de componentes principales;
- modelos gaussianos.

Matrices definidas positivas

Definición 6.18. Una matriz simétrica $\mathbf{A}$ es definida positiva si

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$$

para todo $\mathbf{x} \neq \mathbf{0}$.

Es semidefinida positiva si

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0.$$

Las matrices de covarianza son semidefinidas positivas.

Valores y vectores propios

Definición 6.19. Sea $\mathbf{A} \in \mathbb{R}^{p \times p}$. Un vector no nulo $\mathbf{v}$ es un vector propio de $\mathbf{A}$ si existe un escalar λ tal que

$$\mathbf{A} \mathbf{v} = \lambda \mathbf{v}.$$

El escalar λ se denomina valor propio asociado.

La ecuación puede escribirse como

$$(\mathbf{A} - \lambda \mathbf{I}) \mathbf{v} = \mathbf{0}.$$

Para que exista una solución no trivial, se requiere

$$\det(\mathbf{A} - \lambda \mathbf{I}) = 0.$$

Esta ecuación se denomina ecuación característica.

Ejemplo 6.7. Considere

$$\mathbf{A} = \begin{pmatrix} 2 & 0 \\ 0 & 5 \end{pmatrix}.$$

Entonces

$$\mathbf{A} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = 2 \begin{pmatrix} 1 \\ 0 \end{pmatrix},$$

y

$$\mathbf{A} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = 5 \begin{pmatrix} 0 \\ 1 \end{pmatrix}.$$

Por tanto, los valores propios son 2 y 5.

Interpretación geométrica

Un vector propio conserva su dirección bajo la transformación lineal $\mathbf{A}$. Únicamente cambia su escala mediante el factor λ .

Esta propiedad será esencial en PCA, donde los vectores propios de la matriz de covarianza determinan las direcciones principales de variabilidad.

i Hipótesis de la descomposición espectral

La descomposición ortogonal

$$\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^T$$

se garantiza para matrices reales simétricas. Una matriz real no simétrica puede no poseer una base ortonormal de vectores propios e incluso puede tener valores propios complejos.

Descomposición espectral

Teorema 6.2. *Toda matriz real simétrica $\mathbf{A}$ puede escribirse como*

$$\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^T,$$

donde:

- $\mathbf{Q}$ es una matriz ortogonal;
- las columnas de $\mathbf{Q}$ son vectores propios ortonormales;
- $\mathbf{\Lambda}$ es diagonal y contiene los valores propios.

Esta factorización permite comprender la acción de una matriz simétrica como:

1. un cambio de coordenadas;
2. un escalamiento;
3. un regreso al sistema original.

Matriz de covarianza

Sea una variable aleatoria vectorial

$$\mathbf{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix}.$$

Su matriz de covarianza es

$$\Sigma = \text{Cov}(\mathbf{X}) = \mathbb{E}[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^\top].$$

La matriz Σ es simétrica y semidefinida positiva.

! SVD y rango

Toda matriz real $\mathbf{X} \in \mathbb{R}^{n \times p}$ admite una descomposición en valores singulares. Si su rango es r , existen exactamente r valores singulares positivos. La SVD no requiere que la matriz sea cuadrada ni invertible (Strang 2016).

Descomposición en valores singulares

Definición 6.20. Toda matriz

$$\mathbf{A} \in \mathbb{R}^{n \times p}$$

puede escribirse como

$$\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^\top,$$

donde:

- $\mathbf{U}$ contiene los vectores singulares izquierdos;
- $\mathbf{V}$ contiene los vectores singulares derechos;
- Σ contiene los valores singulares.

Los valores singulares son no negativos y se relacionan con los valores propios de

$$\mathbf{A}^\top \mathbf{A}$$

y

$$\mathbf{A}\mathbf{A}^\top.$$

La SVD es fundamental para:

- reducción de dimensionalidad;
- compresión;
- cálculo estable de pseudoinversas;
- análisis de componentes principales;
- aproximación de matrices;
- sistemas de recomendación.

Aproximación de rango bajo

Si

$$\mathbf{A} = \sum_{j=1}^r \sigma_j \mathbf{u}_j \mathbf{v}_j^T,$$

donde

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0,$$

una aproximación de rango $k < r$ es

$$\mathbf{A}_k = \sum_{j=1}^k \sigma_j \mathbf{u}_j \mathbf{v}_j^T.$$

Esta aproximación conserva las direcciones más importantes de la matriz.

Pseudoinversa

Cuando una matriz no es cuadrada o no es invertible, puede utilizarse la pseudoinversa de Moore-Penrose:

$$\mathbf{A}^+.$$

Si

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T,$$

entonces

$$\mathbf{A}^+ = \mathbf{V}\mathbf{\Sigma}^+ \mathbf{U}^T.$$

La pseudoinversa permite obtener soluciones de mínimos cuadrados incluso cuando la matriz de diseño tiene dependencia lineal.

Relación con regresión lineal

El modelo de regresión lineal múltiple se escribe como

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}.$$

El estimador de mínimos cuadrados satisface

$$\mathbf{X}^T \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^T \mathbf{y}.$$

Si $\mathbf{X}^T \mathbf{X}$ es invertible,

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}.$$

Geométricamente,

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$$

es la proyección ortogonal de $\mathbf{y}$ sobre el espacio columna de $\mathbf{X}$.

Relación con PCA

En PCA se buscan direcciones unitarias $\mathbf{a}$ que maximicen la varianza proyectada:

$$\text{Var}(\mathbf{a}^T \mathbf{X}) = \mathbf{a}^T \Sigma \mathbf{a}.$$

El problema

$$\max_{\|\mathbf{a}\|_2=1} \mathbf{a}^T \Sigma \mathbf{a}$$

conduce al vector propio asociado al mayor valor propio de Σ .

Relación con redes neuronales

En una capa neuronal,

$$\mathbf{z} = \mathbf{W}\mathbf{x} + \mathbf{b}.$$

La matriz $\mathbf{W}$ realiza una transformación lineal y $\mathbf{b}$ agrega un desplazamiento. Posteriormente se aplica una función no lineal.

Por tanto, cada capa combina álgebra lineal y cálculo.

Conexión con R

```
1 x <- c(1, 2, 3)
2 y <- c(4, 0, -1)
3
4 # Producto interno
5 sum(x * y)
6
7 # Norma euclidiana
8 sqrt(sum(x^2))
9
10 # Matriz
11 A <- matrix(
12   c(1, 2,
13     3, 4),
14   nrow = 2,
15   byrow = TRUE
16 )
17
```

```

18 # Transpuesta
19 t(A)
20
21 # Valores y vectores propios
22 eigen(A)
23
24 # Descomposición en valores singulares
25 svd(A)

```

Ejemplo numérico integrado

Considere la matriz de datos centrados

$$\mathbf{X} = \begin{pmatrix} -1 & -2 \\ 0 & 0 \\ 1 & 2 \end{pmatrix}.$$

Las columnas son linealmente dependientes porque

$$\mathbf{x}_{.2} = 2\mathbf{x}_{.1}.$$

La matriz de covarianza muestral es proporcional a

$$\mathbf{X}^T \mathbf{X} = \begin{pmatrix} 2 & 4 \\ 4 & 8 \end{pmatrix}.$$

Esta matriz tiene rango uno. Uno de sus valores propios es cero, lo que indica que no existe variabilidad independiente en una de las direcciones.

Este ejemplo anticipa dos problemas importantes:

1. multicolinealidad en regresión;
2. reducción de dimensionalidad mediante PCA.

Errores frecuentes

1. Confundir producto matricial con multiplicación componente a componente.
2. Suponer que $\mathbf{AB} = \mathbf{BA}$.
3. Confundir vector fila con vector columna.
4. Suponer que toda matriz cuadrada es invertible.
5. Confundir independencia lineal con ortogonalidad.
6. Pensar que rango es simplemente el número de columnas.
7. Confundir valores propios con vectores propios.
8. Utilizar la inversa explícita innecesariamente en cálculos numéricos.
9. Interpretar una matriz de covarianza sin considerar el escalamiento de variables.
10. Suponer que una matriz semidefinida positiva debe ser invertible.

Ejercicios conceptuales

1. Explique la diferencia entre escalar, vector y matriz.
2. ¿Qué significa que un conjunto de vectores sea linealmente independiente?
3. ¿Qué representa geoméricamente el producto interno?
4. ¿Cuál es la diferencia entre norma y distancia?
5. ¿Qué significa que dos vectores sean ortogonales?
6. ¿Qué representa el rango de una matriz?
7. ¿Por qué una matriz de covarianza es simétrica?
8. ¿Qué interpretación geométrica tiene un vector propio?
9. ¿Por qué la SVD puede aplicarse a matrices no cuadradas?
10. Explique la relación entre proyección ortogonal y regresión lineal.

Ejercicios de cálculo

Sean

$$\mathbf{x} = \begin{pmatrix} 2 \\ -1 \\ 3 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 1 \\ 4 \\ 0 \end{pmatrix}.$$

Calcule:

1. $\mathbf{x} + \mathbf{y}$;
2. $3\mathbf{x}$;
3. $\mathbf{x}^T \mathbf{y}$;
4. $\|\mathbf{x}\|_2$;
5. $d(\mathbf{x}, \mathbf{y})$;
6. el ángulo entre ambos vectores.

Ejercicios de matrices

Sean

$$\mathbf{A} = \begin{pmatrix} 1 & 2 \\ 0 & 3 \end{pmatrix}, \quad \mathbf{B} = \begin{pmatrix} 4 & 1 \\ 2 & 5 \end{pmatrix}.$$

Calcule:

1. $\mathbf{A} + \mathbf{B}$;
2. $\mathbf{AB}$;
3. $\mathbf{BA}$;
4. $\mathbf{A}^T$;
5. $\det(\mathbf{A})$;
6. $\mathbf{A}^{-1}$, si existe.

Ejercicio de independencia lineal

Determine si los vectores

$$\mathbf{v}_1 = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \quad \mathbf{v}_2 = \begin{pmatrix} 2 \\ 4 \\ 6 \end{pmatrix}, \quad \mathbf{v}_3 = \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix}$$

son linealmente independientes.

Ejercicio de valores propios

Considere

$$\mathbf{A} = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}.$$

1. Determine la ecuación característica.
2. Calcule los valores propios.
3. Calcule un vector propio asociado a cada valor propio.
4. Normalice los vectores propios.
5. Construya la descomposición espectral.

Ejercicio aplicado

Una base de datos contiene las variables:

- PM10;
- temperatura;
- humedad;
- velocidad del viento.

1. Escriba una observación como vector.
2. Escriba la matriz de datos para n observaciones.
3. Indique las dimensiones de la matriz.
4. Explique qué significa que dos columnas sean linealmente dependientes.
5. Describa una posible consecuencia de esa dependencia en regresión.
6. Explique cómo PCA podría ayudar a resolver el problema.

Resumen

En este capítulo se desarrollaron los conceptos de escalares, vectores, matrices, combinaciones lineales, independencia, bases, espacios vectoriales, productos internos, normas, distancias y proyecciones.

También se estudiaron sistemas lineales, inversas, rango, espacios columna y nulo, transformaciones lineales, formas cuadráticas, matrices definidas positivas, valores propios, descomposición espectral y descomposición en valores singulares.

Estas herramientas constituyen la base matemática de numerosos algoritmos de aprendizaje automático, entre ellos regresión lineal, PCA, máquinas de vectores de soporte, redes neuronales, agrupamiento y métodos de reducción de dimensionalidad.

Referencias del capítulo

Los fundamentos se apoyan en Strang (2016), Axler (2015), Mardia et al. (1979) y Bishop (2006).

7 Probabilidad y estadística para aprendizaje automático

Introducción

La probabilidad modela incertidumbre y la estadística permite aprender a partir de muestras. En aprendizaje automático, las distribuciones representan poblaciones desconocidas, las pérdidas se interpretan como variables aleatorias y el entrenamiento produce estimadores dependientes de los datos (Ross 2019; Casella y Berger 2002; Murphy 2022).

La probabilidad y la estadística proporcionan el marco matemático para representar incertidumbre, variabilidad y aprendizaje a partir de datos. Los algoritmos de aprendizaje automático no trabajan con relaciones completamente deterministas: las observaciones contienen ruido, los patrones son incompletos y las predicciones siempre están sujetas a cierto grado de incertidumbre.

La teoría de la probabilidad permite modelar fenómenos aleatorios, mientras que la estadística proporciona herramientas para inferir propiedades de una población a partir de una muestra. Ambas disciplinas son esenciales para comprender la clasificación probabilística, la regresión, la estimación de parámetros, la selección de modelos, la validación y la evaluación de predicciones.

! Idea central

La probabilidad modela incertidumbre y la estadística permite aprender sobre una población usando una muestra.

Objetivos

Al finalizar el capítulo, el lector podrá:

1. definir un espacio de probabilidad;
2. interpretar eventos y operaciones entre eventos;
3. aplicar axiomas y propiedades de probabilidad;
4. utilizar probabilidad condicional e independencia;
5. comprender y aplicar el teorema de Bayes;
6. definir variables aleatorias discretas y continuas;
7. interpretar funciones de masa, densidad y distribución;
8. calcular esperanza, varianza y covarianza;
9. representar vectores aleatorios y matrices de covarianza;
10. comprender distribuciones conjuntas, marginales y condicionales;
11. interpretar la ley de los grandes números y el teorema central del límite;
12. comprender estimación puntual y por intervalos;
13. derivar estimadores por máxima verosimilitud;
14. relacionar estos conceptos con algoritmos de aprendizaje automático.

Experimentos aleatorios

Definición 7.1. Un **experimento aleatorio** es un procedimiento cuyo resultado no puede predecirse con certeza antes de realizarse, aunque sí puede describirse el conjunto de resultados posibles.

Ejemplos:

- observar si un paciente presenta o no una enfermedad;
- registrar la concentración de un contaminante;
- seleccionar una observación de una base de datos;
- clasificar un correo como deseado o no deseado.

Espacio muestral

Definición 7.2. El **espacio muestral** es el conjunto de todos los resultados posibles de un experimento aleatorio. Se denota por Ω .

Por ejemplo, para una clasificación binaria,

$$\Omega = \{0, 1\}.$$

Para una medición continua,

$$\Omega \subseteq \mathbb{R}.$$

Eventos

Definición 7.3. Un **evento** es cualquier subconjunto del espacio muestral.

Si $A \subseteq \Omega$, entonces A representa un evento.

Las operaciones entre eventos se expresan mediante conjuntos:

- unión: $A \cup B$;
- intersección: $A \cap B$;
- complemento: A^c ;
- diferencia: $A \setminus B$.

Sigma-álgebra

Definición 7.4. Una **sigma-álgebra** $\mathcal{F}$ sobre Ω es una colección de subconjuntos de Ω que satisface:

1. $\Omega \in \mathcal{F}$;
2. si $A \in \mathcal{F}$, entonces $A^c \in \mathcal{F}$;
3. si $A_1, A_2, \dots \in \mathcal{F}$, entonces

$$\bigcup_{i=1}^{\infty} A_i \in \mathcal{F}.$$

La sigma-álgebra contiene los eventos a los que puede asignarse probabilidad.

Espacio de probabilidad

Definición 7.5. Un espacio de probabilidad es una terna

$$(\Omega, \mathcal{F}, P),$$

donde:

- Ω es el espacio muestral;
- $\mathcal{F}$ es una sigma-álgebra;
- P es una medida de probabilidad.

i Modelo probabilístico

Un espacio de probabilidad es una terna

$$(\Omega, \mathcal{F}, P),$$

donde Ω es el espacio muestral, $\mathcal{F}$ una sigma-álgebra y P una medida de probabilidad. No todo subconjunto de un espacio muestral infinito tiene que pertenecer automáticamente a $\mathcal{F}$.

Axiomas de probabilidad

La función

$$P : \mathcal{F} \rightarrow [0, 1]$$

satisface:

1. No negatividad

$$P(A) \geq 0.$$

2. Normalización

$$P(\Omega) = 1.$$

3. Aditividad numerable

Si $A_1, A_2, \dots$ son mutuamente excluyentes, entonces

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i).$$

Propiedades fundamentales

De los axiomas se deduce:

$$P(\emptyset) = 0,$$

$$P(A^c) = 1 - P(A),$$

$$P(A \cup B) = P(A) + P(B) - P(A \cap B),$$

y si $A \subseteq B$,

$$P(A) \leq P(B).$$

Probabilidad condicional

Definición 7.6. Si $P(B) > 0$, la probabilidad condicional de A dado B se define como

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}.$$

La probabilidad condicional permite actualizar la incertidumbre cuando se dispone de nueva información.

Ejemplo 7.1. Supóngase que:

$$P(A) = 0.30, \quad P(B) = 0.50, \quad P(A \cap B) = 0.20.$$

Entonces

$$P(A \mid B) = \frac{0.20}{0.50} = 0.40.$$

Regla del producto

De la definición anterior,

$$P(A \cap B) = P(A \mid B)P(B).$$

También,

$$P(A \cap B) = P(B \mid A)P(A).$$

Para varios eventos,

$$P(A_1 \cap \cdots \cap A_n) = P(A_1) \prod_{i=2}^n P(A_i \mid A_1 \cap \cdots \cap A_{i-1}).$$

Independencia

Definición 7.7. Dos eventos A y B son independientes si

$$P(A \cap B) = P(A)P(B).$$

Si $P(B) > 0$, esta condición equivale a

$$P(A | B) = P(A).$$

La independencia significa que conocer la ocurrencia de un evento no modifica la probabilidad del otro.

Partición del espacio muestral

Los eventos $B_1, \dots, B_k$ forman una partición de Ω si:

1. $B_i \cap B_j = \emptyset$ para $i \neq j$;
2. $\bigcup_{j=1}^k B_j = \Omega$.

Teorema de probabilidad total

Teorema 7.1. Si $B_1, \dots, B_k$ forman una partición de Ω , entonces para cualquier evento A ,

$$P(A) = \sum_{j=1}^k P(A | B_j)P(B_j).$$

Teorema de Bayes

Teorema 7.2. Si $B_1, \dots, B_k$ forman una partición y $P(A) > 0$, entonces

$$P(B_j | A) = \frac{P(A | B_j)P(B_j)}{\sum_{\ell=1}^k P(A | B_\ell)P(B_\ell)}.$$

En clasificación, la regla de Bayes permite calcular la probabilidad posterior de una clase dado un vector de características.

Para clases $C_1, \dots, C_K$,

$$P(C_k | \mathbf{x}) = \frac{P(\mathbf{x} | C_k)P(C_k)}{\sum_{j=1}^K P(\mathbf{x} | C_j)P(C_j)}.$$

! Condición para aplicar Bayes

La expresión

$$P(A | B) = \frac{P(B | A)P(A)}{P(B)}$$

requiere que $P(B) > 0$. Cuando $P(B) = 0$, la probabilidad condicional elemental no está definida mediante este cociente.

Ejemplo de diagnóstico

Sea D el evento “el paciente tiene una enfermedad” y T^+ el evento “la prueba resulta positiva”. Supóngase:

$$P(D) = 0.02,$$

$$P(T^+ | D) = 0.95,$$

$$P(T^+ | D^c) = 0.08.$$

Entonces

$$P(T^+) = P(T^+ | D)P(D) + P(T^+ | D^c)P(D^c).$$

Por tanto,

$$P(T^+) = 0.95(0.02) + 0.08(0.98) = 0.0974.$$

La probabilidad posterior es

$$P(D | T^+) = \frac{0.95(0.02)}{0.0974} \approx 0.195.$$

Aunque la prueba sea sensible, la baja prevalencia influye de manera importante en la probabilidad posterior.

Variables aleatorias

Definición 7.8. Una **variable aleatoria** es una función

$$X : \Omega \rightarrow \mathbb{R}.$$

Una variable aleatoria asigna un número real a cada resultado del experimento.

Variables aleatorias discretas

Definición 7.9. Una variable aleatoria es discreta si toma valores en un conjunto finito o numerable.

Su función de masa de probabilidad es

$$p_X(x) = P(X = x).$$

Debe satisfacer:

$$p_X(x) \geq 0,$$

$$\sum_x p_X(x) = 1.$$

Distribución Bernoulli

Una variable Bernoulli con parámetro p satisface

$$X \sim \text{Bernoulli}(p),$$

con

$$P(X = 1) = p, \quad P(X = 0) = 1 - p.$$

Su esperanza y varianza son

$$\mathbb{E}(X) = p,$$

$$\text{Var}(X) = p(1 - p).$$

Esta distribución es central en clasificación binaria y regresión logística.

Distribución binomial

Si

$$X \sim \text{Binomial}(n, p),$$

entonces

$$P(X = x) = \binom{n}{x} p^x (1 - p)^{n-x},$$

para

$$x = 0, 1, \dots, n.$$

La esperanza y varianza son

$$\mathbb{E}(X) = np,$$

$$\text{Var}(X) = np(1 - p).$$

Variables aleatorias continuas

Definición 7.10. Una variable aleatoria continua posee una función de densidad $f_X(x)$ tal que

$$P(a \leq X \leq b) = \int_a^b f_X(x) dx.$$

La densidad satisface:

$$f_X(x) \geq 0,$$

$$\int_{-\infty}^{\infty} f_X(x) dx = 1.$$

Para una variable continua,

$$P(X = x) = 0.$$

Función de distribución acumulada

Definición 7.11. La función de distribución acumulada de X se define como

$$F_X(x) = P(X \leq x).$$

Para una variable continua,

$$F_X(x) = \int_{-\infty}^x f_X(t) dt.$$

Distribución normal

Una variable normal se denota por

$$X \sim N(\mu, \sigma^2).$$

Su densidad es

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right].$$

La distribución normal desempeña un papel fundamental en inferencia estadística, regresión y teoría asintótica.

Esperanza matemática

Definición 7.12. La esperanza de una variable aleatoria discreta es

$$\mathbb{E}(X) = \sum_x x p_X(x).$$

Para una variable continua,

$$\mathbb{E}(X) = \int_{-\infty}^{\infty} x f_X(x) dx.$$

La esperanza representa el valor promedio teórico de la variable aleatoria.

Esperanza de una función

Si g es una función,

para variables discretas:

$$\mathbb{E}[g(X)] = \sum_x g(x) p_X(x),$$

y para variables continuas:

$$\mathbb{E}[g(X)] = \int_{-\infty}^{\infty} g(x) f_X(x) dx.$$

Linealidad de la esperanza

Teorema 7.3. Para cualesquiera variables aleatorias X y Y y escalares a, b ,

$$\mathbb{E}(aX + bY) = a\mathbb{E}(X) + b\mathbb{E}(Y).$$

La linealidad no requiere independencia.

Varianza

Definición 7.13. La varianza de X se define como

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}X)^2].$$

Equivalentemente,

$$\text{Var}(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2.$$

La desviación estándar es

$$\sigma_X = \sqrt{\text{Var}(X)}.$$

Propiedades de la varianza

Para constantes a y b ,

$$\text{Var}(aX + b) = a^2 \text{Var}(X).$$

Además,

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y).$$

Si X y Y son independientes,

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y).$$

Covarianza

Definición 7.14. La covarianza entre X y Y es

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)].$$

Equivalentemente,

$$\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y).$$

Si X y Y son independientes, entonces

$$\text{Cov}(X, Y) = 0.$$

La recíproca no siempre es verdadera.

Correlación

La correlación lineal es

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}.$$

Se cumple

$$-1 \leq \rho_{XY} \leq 1.$$

La correlación mide asociación lineal, no causalidad.

Variables aleatorias conjuntas

Sean X y Y variables aleatorias.

En el caso discreto, la función de masa conjunta es

$$p_{X,Y}(x, y) = P(X = x, Y = y).$$

En el caso continuo, la densidad conjunta es

$$f_{X,Y}(x, y).$$

Debe cumplirse

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx dy = 1.$$

Distribuciones marginales

A partir de una densidad conjunta,

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy,$$

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx.$$

En el caso discreto se utilizan sumas.

Distribuciones condicionales

Si $f_Y(y) > 0$,

$$f_{X|Y}(x | y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}.$$

Esta relación generaliza la probabilidad condicional.

Independencia de variables aleatorias

Las variables X y Y son independientes si

$$f_{X,Y}(x, y) = f_X(x)f_Y(y)$$

para todos los valores posibles.

Vectores aleatorios

Definición 7.15. Un vector aleatorio de dimensión p es

$$\mathbf{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix}.$$

Su vector de medias es

$$\mu = \mathbb{E}(\mathbf{X}) = \begin{pmatrix} \mathbb{E}(X_1) \\ \vdots \\ \mathbb{E}(X_p) \end{pmatrix}.$$

Matriz de covarianza

Definición 7.16. La matriz de covarianza de $\mathbf{X}$ es

$$\Sigma = \text{Cov}(\mathbf{X}) = \mathbb{E}[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^\top].$$

Sus elementos son

$$\sigma_{ij} = \text{Cov}(X_i, X_j).$$

La diagonal contiene las varianzas:

$$\sigma_{ii} = \text{Var}(X_i).$$

La matriz de covarianza es simétrica y semidefinida positiva.

Distribución normal multivariada

Se escribe

$$\mathbf{X} \sim N_p(\mu, \Sigma).$$

Su densidad es

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left[-\frac{1}{2} (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \right].$$

La forma cuadrática

$$(\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu)$$

corresponde a la distancia de Mahalanobis al cuadrado.

Muestra aleatoria

Definición 7.17. Una muestra aleatoria

$$X_1, \dots, X_n$$

es un conjunto de variables aleatorias independientes e idénticamente distribuidas.

Se escribe

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} F.$$

Media muestral

La media muestral es

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Su esperanza es

$$\mathbb{E}(\bar{X}) = \mu.$$

Si las observaciones son independientes,

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

Varianza muestral

La varianza muestral es

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

El denominador $n-1$ permite que

$$\mathbb{E}(S^2) = \sigma^2.$$

Varianza poblacional y varianza muestral

La varianza de una variable aleatoria utiliza su distribución poblacional. En cambio, la varianza muestral insesgada emplea el divisor $n-1$:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

El divisor $n-1$ no es una convención arbitraria: corrige el sesgo producido al estimar la media con la misma muestra.

Supuestos de los resultados asintóticos

La ley de los grandes números y el teorema central del límite tienen distintas versiones. Las formulaciones elementales de este capítulo suponen observaciones independientes e idénticamente distribuidas y momentos finitos adecuados. En datos temporales, espaciales o dependientes se necesitan resultados adicionales.

Ley de los grandes números

Teorema 7.4. *Bajo condiciones regulares,*

$$\overline{X}_n \rightarrow \mu$$

cuando

$$n \rightarrow \infty.$$

La ley de los grandes números justifica el uso de promedios muestrales como aproximaciones de valores esperados.

Teorema central del límite

Teorema 7.5. *Si $X_1, \dots, X_n$ son iid con media μ y varianza finita σ^2 , entonces*

$$\frac{\sqrt{n}(\overline{X} - \mu)}{\sigma} \xrightarrow{d} N(0, 1).$$

Este resultado explica por qué la distribución normal aparece en numerosos procedimientos de inferencia.

Estadísticos y parámetros

Un **parámetro** es una cantidad fija pero desconocida de una población, por ejemplo:

$$\mu, \quad \sigma^2, \quad p, \quad \beta.$$

Un **estadístico** es una función de la muestra:

$$T = T(X_1, \dots, X_n).$$

Por ejemplo,

$$\overline{X}$$

es un estadístico utilizado para estimar μ .

Estimación puntual

Definición 7.18. Un estimador $\hat{\theta}$ es un estadístico utilizado para aproximar un parámetro desconocido θ .

Propiedades deseables:

- insesgadez;
- consistencia;

- eficiencia;
- suficiencia.

Sesgo

El sesgo de un estimador es

$$\text{Bias}(\hat{\theta}) = \mathbb{E}(\hat{\theta}) - \theta.$$

Si

$$\mathbb{E}(\hat{\theta}) = \theta,$$

el estimador es insesgado.

Error cuadrático medio

El error cuadrático medio es

$$\text{MSE}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2].$$

Se descompone como

$$\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) + \text{Bias}(\hat{\theta})^2.$$

Esta identidad anticipa el compromiso entre sesgo y varianza en aprendizaje automático.

Consistencia

Un estimador es consistente si

$$\hat{\theta}_n \xrightarrow{P} \theta.$$

Es decir, la probabilidad de alejarse del parámetro verdadero disminuye al aumentar el tamaño de muestra.

Función de verosimilitud

Definición 7.19. Sea una muestra

$$x_1, \dots, x_n$$

proveniente de una distribución con parámetro θ . La función de verosimilitud es

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta).$$

La verosimilitud se interpreta como una función del parámetro, manteniendo fija la muestra observada.

Log-verosimilitud

La log-verosimilitud es

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^n \log f(x_i; \theta).$$

Se utiliza porque transforma productos en sumas y facilita la derivación.

i Máxima verosimilitud

La verosimilitud se interpreta como función del parámetro con los datos observados fijos. No es una distribución de probabilidad sobre el parámetro, salvo que se normalice dentro de un modelo bayesiano con una distribución previa.

Estimación por máxima verosimilitud

Definición 7.20. El estimador de máxima verosimilitud se define como

$$\hat{\theta}_{MV} = \arg \max_{\theta} L(\theta),$$

o equivalentemente,

$$\hat{\theta}_{MV} = \arg \max_{\theta} \ell(\theta).$$

Ejemplo Bernoulli

Supóngase que

$$X_i \sim \text{Bernoulli}(p).$$

La función de masa es

$$P(X_i = x_i) = p^{x_i} (1 - p)^{1-x_i}.$$

La verosimilitud es

$$L(p) = \prod_{i=1}^n p^{x_i} (1 - p)^{1-x_i}.$$

Entonces

$$L(p) = p^{\sum x_i} (1 - p)^{n - \sum x_i}.$$

La log-verosimilitud es

$$\ell(p) = \left(\sum_{i=1}^n x_i \right) \log p + \left(n - \sum_{i=1}^n x_i \right) \log(1 - p).$$

Derivando:

$$\frac{d\ell}{dp} = \frac{\sum x_i}{p} - \frac{n - \sum x_i}{1 - p}.$$

Igualando a cero:

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$$

Por tanto, el estimador de máxima verosimilitud de p es la proporción muestral.

Estimación bayesiana

En el enfoque bayesiano, el parámetro se considera aleatorio.

Se combinan:

- distribución previa:

$$p(\theta);$$

- verosimilitud:

$$p(\mathbf{x} \mid \theta);$$

- distribución posterior:

$$p(\theta \mid \mathbf{x}).$$

Por el teorema de Bayes,

$$p(\theta \mid \mathbf{x}) = \frac{p(\mathbf{x} \mid \theta)p(\theta)}{p(\mathbf{x})}.$$

Equivalentemente,

$$p(\theta \mid \mathbf{x}) \propto p(\mathbf{x} \mid \theta)p(\theta).$$

Intervalos de confianza

Un intervalo de confianza para un parámetro θ tiene la forma

$$[L(\mathbf{X}), U(\mathbf{X})].$$

Un intervalo con nivel $1 - \alpha$ satisface

$$P[L(\mathbf{X}) \leq \theta \leq U(\mathbf{X})] = 1 - \alpha.$$

La interpretación correcta se refiere al procedimiento de construcción, no a una probabilidad posterior sobre un parámetro fijo.

Pruebas de hipótesis

Una prueba de hipótesis compara:

$$H_0 : \theta \in \Theta_0$$

contra

$$H_1 : \theta \in \Theta_1.$$

Los errores posibles son:

- error tipo I: rechazar H_0 cuando es verdadera;
- error tipo II: no rechazar H_0 cuando es falsa.

El nivel de significancia es

$$\alpha = P(\text{rechazar } H_0 \mid H_0 \text{ verdadera}).$$

Relación con clasificación

En clasificación probabilística se selecciona la clase con mayor probabilidad posterior:

$$\hat{y} = \arg \max_k P(Y = k \mid \mathbf{x}).$$

Esta regla minimiza el error esperado bajo pérdida 0-1.

Relación con regresión logística

En regresión logística,

$$P(Y = 1 \mid \mathbf{x}) = \pi(\mathbf{x}),$$

donde

$$\pi(\mathbf{x}) = \frac{\exp(\beta_0 + \beta^\top \mathbf{x})}{1 + \exp(\beta_0 + \beta^\top \mathbf{x})}.$$

Los parámetros se estiman maximizando la verosimilitud Bernoulli.

Relación con árboles de decisión

La proporción de observaciones de la clase k en un nodo es

$$\hat{p}_k = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(y_i = k).$$

Estas probabilidades se utilizan en medidas como entropía e impureza de Gini.

Relación con PCA

La matriz de covarianza

$$\Sigma$$

resume la variabilidad conjunta de las características. PCA utiliza sus valores y vectores propios para encontrar direcciones de máxima varianza.

Conexión con R

```
1 x <- c(4, 6, 8, 7, 5)
2
3 # Media
4 mean(x)
5
6 # Varianza muestral
7 var(x)
8
9 # Desviación estándar
10 sd(x)
11
12 # Probabilidad binomial
13 dbinom(3, size = 5, prob = 0.4)
14
15 # Probabilidad acumulada normal
16 pnorm(1.96)
17
18 # Cuantil normal
19 qnorm(0.975)
20
21 # Simulación Bernoulli
22 rbinom(10, size = 1, prob = 0.30)
23
24 # Matriz de covarianza
25 datos <- data.frame(
26   pm10 = c(40, 55, 68, 73),
27   temperatura = c(18, 21, 24, 26),
28   humedad = c(65, 58, 50, 45)
29 )
30
```

```
31 cov(datos)
32 cor(datos)
```

Ejemplo integrado de clasificación

Considere dos clases:

C_1 = calidad aceptable,

C_2 = calidad no aceptable.

Supóngase:

$$P(C_1) = 0.70, \quad P(C_2) = 0.30.$$

Para una observación $\mathbf{x}$,

$$P(\mathbf{x} \mid C_1) = 0.10,$$

$$P(\mathbf{x} \mid C_2) = 0.25.$$

Entonces,

$$P(C_1 \mid \mathbf{x}) = \frac{0.10(0.70)}{0.10(0.70) + 0.25(0.30)} \approx 0.483.$$

Además,

$$P(C_2 \mid \mathbf{x}) \approx 0.517.$$

La regla de Bayes clasifica la observación en C_2 .

Errores frecuentes

1. Confundir probabilidad conjunta con probabilidad condicional.
2. Suponer que eventos mutuamente excluyentes son independientes.
3. Interpretar una densidad como una probabilidad puntual.
4. Confundir independencia con covarianza cero.
5. Interpretar correlación como causalidad.
6. Confundir parámetro con estadístico.
7. Interpretar incorrectamente un intervalo de confianza.
8. Confundir verosimilitud con probabilidad del parámetro.
9. Suponer que una muestra grande corrige automáticamente sesgos de diseño.
10. Aplicar el teorema de Bayes sin considerar probabilidades previas.

Ejercicios conceptuales

1. Explique la diferencia entre experimento, espacio muestral y evento.
2. ¿Qué diferencia existe entre probabilidad conjunta y condicional?
3. Explique la diferencia entre independencia y exclusión mutua.
4. ¿Qué representa la esperanza matemática?
5. ¿Qué representa la varianza?
6. ¿Por qué covarianza cero no implica siempre independencia?
7. Explique la diferencia entre parámetro y estadístico.
8. ¿Qué significa que un estimador sea insesgado?
9. ¿Qué significa que un estimador sea consistente?
10. Explique la diferencia entre probabilidad y verosimilitud.

Ejercicios de probabilidad

Sean dos eventos A y B tales que

$$P(A) = 0.40, \quad P(B) = 0.55, \quad P(A \cap B) = 0.25.$$

Calcule:

1. $P(A \cup B)$;
2. $P(A^c)$;
3. $P(A | B)$;
4. $P(B | A)$;
5. determine si A y B son independientes.

Ejercicio de Bayes

Una enfermedad tiene prevalencia de 0.03. Una prueba tiene sensibilidad de 0.92 y especificidad de 0.90.

Calcule:

1. la probabilidad de un resultado positivo;
2. la probabilidad de enfermedad dado un resultado positivo;
3. la probabilidad de no enfermedad dado un resultado negativo;
4. interprete los resultados.

Ejercicio de esperanza y varianza

Sea X una variable aleatoria con distribución:

x	0	1	2	3
$P(X = x)$	0.10	0.25	0.40	0.25

Calcule:

1. $\mathbb{E}(X)$;

2. $\mathbb{E}(X^2)$;
3. $\text{Var}(X)$;
4. la desviación estándar.

Ejercicio de máxima verosimilitud

Considere la muestra Bernoulli:

1, 0, 1, 1, 0, 1, 1, 1, 0, 1.

1. Escriba la función de verosimilitud.
2. Escriba la log-verosimilitud.
3. Calcule el estimador de máxima verosimilitud de p .
4. Interprete el resultado.

Ejercicio aplicado

Una base de datos ambiental contiene:

- PM10;
 - temperatura;
 - humedad;
 - velocidad del viento.
1. Defina un vector aleatorio.
 2. Escriba el vector de medias.
 3. Describa la matriz de covarianza.
 4. Explique el significado de una covarianza positiva entre PM10 y temperatura.
 5. Explique qué información adicional proporciona la correlación.
 6. Indique cómo se relaciona esta matriz con PCA.

Resumen

En este capítulo se construyó el marco probabilístico y estadístico del aprendizaje automático. Se definieron espacios de probabilidad, eventos, probabilidad condicional, independencia y teorema de Bayes.

También se estudiaron variables aleatorias, funciones de masa y densidad, esperanza, varianza, covarianza, correlación, distribuciones conjuntas y vectores aleatorios.

Finalmente, se introdujeron conceptos de inferencia estadística, como estimadores, sesgo, consistencia, error cuadrático medio, máxima verosimilitud, estimación bayesiana, intervalos de confianza y pruebas de hipótesis.

Estos elementos serán utilizados posteriormente en regresión logística, clasificación bayesiana, árboles de decisión, PCA, validación y teoría de generalización.

Referencias del capítulo

Los fundamentos se apoyan en Ross (2019), Casella y Berger (2002), Murphy (2022) y Bishop (2006).

8 Cálculo multivariable y optimización

Introducción

El entrenamiento de numerosos modelos consiste en minimizar una función respecto de vectores o matrices de parámetros. El cálculo multivariable aporta gradientes, Jacobianas y Hessianas; la optimización convexa permite distinguir mínimos locales y globales y establecer condiciones de optimalidad (Apostol 1969; Boyd y Vandenberghe 2004; Bishop 2006).

El cálculo multivariable y la optimización permiten describir cómo cambia una función cuando cambian varios parámetros al mismo tiempo. En aprendizaje automático, los modelos dependen de vectores o matrices de parámetros, y su entrenamiento consiste casi siempre en minimizar una función de pérdida.

La regresión lineal minimiza una suma de errores cuadrados; la regresión logística maximiza una log-verosimilitud; las máquinas de vectores de soporte resuelven problemas de optimización convexa; las redes neuronales ajustan millones de parámetros mediante gradientes; y numerosos métodos utilizan restricciones, multiplicadores de Lagrange o aproximaciones de segundo orden.

Este capítulo desarrolla las herramientas necesarias para formular y analizar estos procesos.

! Idea central

Entrenar un modelo suele significar minimizar una función de pérdida respecto de sus parámetros.

Objetivos

Al finalizar el capítulo, el lector podrá:

1. interpretar funciones de varias variables;
2. calcular derivadas parciales;
3. construir gradientes y matrices Jacobianas;
4. calcular e interpretar matrices Hessianas;
5. aplicar la regla de la cadena multivariable;
6. utilizar expansiones de Taylor;
7. identificar puntos críticos;
8. distinguir mínimos, máximos y puntos silla;
9. comprender convexidad y funciones convexas;
10. resolver problemas de optimización sin restricciones;
11. formular problemas con restricciones;
12. aplicar multiplicadores de Lagrange;
13. comprender descenso por gradiente;
14. interpretar métodos de Newton y aproximaciones de segundo orden;

15. relacionar estos conceptos con algoritmos de aprendizaje automático.

Funciones de varias variables

Definición 8.1. Una función de varias variables es una aplicación

$$f : \mathbb{R}^p \rightarrow \mathbb{R}.$$

Para

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{pmatrix},$$

se escribe

$$f(\mathbf{x}) = f(x_1, \dots, x_p).$$

Ejemplo 8.1. Considere

$$f(x_1, x_2) = x_1^2 + 2x_1x_2 + 3x_2^2.$$

Esta función asigna un número real a cada punto de $\mathbb{R}^2$.

Superficies de nivel

Para una constante c , el conjunto de nivel de f es

$$L_c = \{\mathbf{x} \in \mathbb{R}^p : f(\mathbf{x}) = c\}.$$

En dos variables, los conjuntos de nivel pueden representarse mediante curvas de nivel.

En optimización, estas curvas ayudan a visualizar la geometría de la función objetivo.

Derivadas parciales

Definición 8.2. La derivada parcial de f respecto de x_j se define como

$$\frac{\partial f}{\partial x_j} = \lim_{h \rightarrow 0} \frac{f(x_1, \dots, x_j + h, \dots, x_p) - f(x_1, \dots, x_j, \dots, x_p)}{h},$$

si el límite existe.

La derivada parcial mide la tasa de cambio de f respecto de una variable, manteniendo las demás constantes.

Ejemplo 8.2. Sea

$$f(x_1, x_2) = x_1^2 + 3x_1x_2 + 2x_2^2.$$

Entonces

$$\frac{\partial f}{\partial x_1} = 2x_1 + 3x_2,$$

y

$$\frac{\partial f}{\partial x_2} = 3x_1 + 4x_2.$$

Derivadas parciales de orden superior

Las segundas derivadas parciales son

$$\frac{\partial^2 f}{\partial x_i^2}$$

y las derivadas cruzadas son

$$\frac{\partial^2 f}{\partial x_i \partial x_j}.$$

Si f es suficientemente suave, se cumple el teorema de Clairaut:

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i}.$$

Gradiente

Definición 8.3. El gradiente de una función

$$f : \mathbb{R}^p \rightarrow \mathbb{R}$$

es el vector

$$\nabla f(\mathbf{x}) = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_p} \end{pmatrix}.$$

El gradiente apunta en la dirección de máximo crecimiento local de la función.

La dirección opuesta,

$$-\nabla f(\mathbf{x}),$$

apunta en la dirección de máximo decrecimiento local.

Ejemplo 8.3. Para

$$f(x_1, x_2) = x_1^2 + 3x_1x_2 + 2x_2^2,$$

el gradiente es

$$\nabla f(x_1, x_2) = \begin{pmatrix} 2x_1 + 3x_2 \\ 3x_1 + 4x_2 \end{pmatrix}.$$

i Gradiente y sistema de coordenadas

El gradiente representa la dirección de máximo incremento local bajo el producto interno euclidiano. En geometrías o parametrizaciones diferentes, la noción de dirección más pronunciada puede cambiar.

Derivada direccional

Sea $\mathbf{u}$ un vector unitario. La derivada direccional de f en la dirección $\mathbf{u}$ es

$$D_{\mathbf{u}}f(\mathbf{x}) = \nabla f(\mathbf{x})^T \mathbf{u}.$$

Por la desigualdad de Cauchy-Schwarz,

$$D_{\mathbf{u}}f(\mathbf{x}) \leq \|\nabla f(\mathbf{x})\|_2.$$

La igualdad se alcanza cuando

$$\mathbf{u} = \frac{\nabla f(\mathbf{x})}{\|\nabla f(\mathbf{x})\|_2}.$$

Funciones vectoriales

Una función vectorial tiene la forma

$$\mathbf{f} : \mathbb{R}^p \rightarrow \mathbb{R}^m.$$

Se escribe

$$\mathbf{f}(\mathbf{x}) = \begin{pmatrix} f_1(\mathbf{x}) \\ \vdots \\ f_m(\mathbf{x}) \end{pmatrix}.$$

Matriz Jacobiana

Definición 8.4. La matriz Jacobiana de

$$\mathbf{f} : \mathbb{R}^p \rightarrow \mathbb{R}^m$$

es

$$\mathbf{J}_f(\mathbf{x}) = \begin{pmatrix} \frac{\partial f_1}{\partial x_1} & \cdots & \frac{\partial f_1}{\partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \cdots & \frac{\partial f_m}{\partial x_p} \end{pmatrix}.$$

Si $m = 1$, la Jacobiana coincide con el gradiente transpuesto.

Matriz Hessiana

Definición 8.5. La matriz Hessiana de una función escalar

$$f : \mathbb{R}^p \rightarrow \mathbb{R}$$

es

$$\mathbf{H}_f(\mathbf{x}) = \nabla^2 f(\mathbf{x}) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_p} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_p \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_p^2} \end{pmatrix}.$$

La Hessiana describe la curvatura local de la función.

Ejemplo 8.4. Para

$$f(x_1, x_2) = x_1^2 + 3x_1x_2 + 2x_2^2,$$

se tiene

$$\mathbf{H}_f = \begin{pmatrix} 2 & 3 \\ 3 & 4 \end{pmatrix}.$$

Diferenciales

La diferencial total de f es

$$df = \sum_{j=1}^p \frac{\partial f}{\partial x_j} dx_j.$$

En forma vectorial,

$$df = \nabla f(\mathbf{x})^\top d\mathbf{x}.$$

Regla de la cadena

Sea

$$\mathbf{z} = \mathbf{g}(\mathbf{x})$$

y

$$\mathbf{y} = \mathbf{f}(\mathbf{z}).$$

Entonces

$$\mathbf{J}_{\mathbf{f} \circ \mathbf{g}}(\mathbf{x}) = \mathbf{J}_{\mathbf{f}}(\mathbf{g}(\mathbf{x}))\mathbf{J}_{\mathbf{g}}(\mathbf{x}).$$

Esta regla es la base matemática de la retropropagación en redes neuronales.

Ejemplo de regla de la cadena

Sea

$$z = x_1^2 + x_2^2,$$

y

$$f(z) = e^z.$$

Entonces

$$\frac{\partial f}{\partial x_1} = \frac{df}{dz} \frac{\partial z}{\partial x_1} = e^z(2x_1).$$

Por tanto,

$$\frac{\partial f}{\partial x_1} = 2x_1 e^{x_1^2 + x_2^2}.$$

Análogamente,

$$\frac{\partial f}{\partial x_2} = 2x_2 e^{x_1^2 + x_2^2}.$$

Derivación matricial básica

En aprendizaje automático, conviene utilizar identidades de cálculo matricial.

Si

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

entonces

$$\nabla_{\mathbf{x}} f = \mathbf{a}.$$

Si

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x},$$

entonces

$$\nabla_{\mathbf{x}} f = 2\mathbf{x}.$$

Si

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x},$$

entonces

$$\nabla_{\mathbf{x}} f = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}.$$

Si $\mathbf{A}$ es simétrica,

$$\nabla_{\mathbf{x}} f = 2\mathbf{A} \mathbf{x}.$$

Expansión de Taylor de primer orden

Si f es diferenciable, cerca de $\mathbf{x}_0$ se aproxima por

$$f(\mathbf{x}) \approx f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0)^\top (\mathbf{x} - \mathbf{x}_0).$$

Esta es una aproximación lineal local.

Expansión de Taylor de segundo orden

Si f posee segundas derivadas,

$$f(\mathbf{x}) \approx f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0)^\top (\mathbf{x} - \mathbf{x}_0) + \frac{1}{2} (\mathbf{x} - \mathbf{x}_0)^\top \mathbf{H}_f(\mathbf{x}_0) (\mathbf{x} - \mathbf{x}_0).$$

Los métodos de Newton utilizan esta aproximación.

Puntos críticos

Definición 8.6. Un punto $\mathbf{x}^*$ es crítico si

$$\nabla f(\mathbf{x}^*) = \mathbf{0}.$$

Un punto crítico puede ser:

- mínimo local;
- máximo local;
- punto silla.

Clasificación mediante la Hessiana

Si

$$\nabla f(\mathbf{x}^*) = \mathbf{0},$$

entonces:

- si $\mathbf{H}_f(\mathbf{x}^*)$ es definida positiva, $\mathbf{x}^*$ es mínimo local;
- si es definida negativa, es máximo local;
- si es indefinida, es punto silla;
- si es semidefinida, la prueba puede ser inconclusa.

! Criterio de la Hessiana

En un punto crítico $\mathbf{x}^*$:

- si $\nabla^2 f(\mathbf{x}^*)$ es definida positiva, existe un mínimo local estricto;
- si es definida negativa, existe un máximo local estricto;
- si es indefinida, el punto es de silla;
- si es semidefinida, el criterio puede ser inconcluso.

Estas conclusiones requieren que las derivadas necesarias existan y sean continuas en un entorno del punto.

Ejemplo de mínimo

Sea

$$f(x_1, x_2) = (x_1 - 2)^2 + (x_2 + 1)^2.$$

El gradiente es

$$\nabla f = \begin{pmatrix} 2(x_1 - 2) \\ 2(x_2 + 1) \end{pmatrix}.$$

Igualando a cero:

$$x_1 = 2, \quad x_2 = -1.$$

La Hessiana es

$$\mathbf{H}_f = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix},$$

que es definida positiva. Por tanto,

$$(2, -1)$$

es un mínimo global.

Optimización sin restricciones

Un problema de optimización sin restricciones tiene la forma

$$\min_{\theta \in \mathbb{R}^p} J(\theta).$$

Una condición necesaria de primer orden para un mínimo interior es

$$\nabla J(\theta^*) = \mathbf{0}.$$

Si además la Hessiana es definida positiva, el punto es un mínimo local estricto.

Funciones convexas

Definición 8.7. Una función

$$f : \mathbb{R}^p \rightarrow \mathbb{R}$$

es convexa si para todos $\mathbf{x}, \mathbf{y}$ y todo $\lambda \in [0, 1]$,

$$f(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}) \leq \lambda f(\mathbf{x}) + (1 - \lambda) f(\mathbf{y}).$$

Geométricamente, el segmento entre dos puntos de la gráfica queda por encima de la gráfica.

Convexidad estricta

La función es estrictamente convexa si la desigualdad es estricta para

$$\mathbf{x} \neq \mathbf{y}$$

y

$$\lambda \in (0, 1).$$

Una función estrictamente convexa tiene a lo sumo un mínimo global.

Caracterización mediante el gradiente

Si f es diferenciable, es convexa si y solo si

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x})$$

para todos $\mathbf{x}, \mathbf{y}$.

Caracterización mediante la Hessiana

Si f es dos veces diferenciable, es convexa si

$$\mathbf{H}_f(\mathbf{x}) \succeq \mathbf{0}$$

para todo $\mathbf{x}$.

Es estrictamente convexa si la Hessiana es definida positiva.

Convexidad y mínimos globales

Si f es convexa sobre un conjunto convexo, todo mínimo local es global. Si además es estrictamente convexa, puede existir como máximo un minimizador global. La existencia del mínimo requiere condiciones adicionales, como continuidad y coercividad o compacidad del dominio.

Teorema del mínimo global

Teorema 8.1. Si f es convexa y diferenciable, cualquier punto $\mathbf{x}^*$ que satisfice

$$\nabla f(\mathbf{x}^*) = \mathbf{0}$$

es un mínimo global.

Este resultado es fundamental en regresión lineal, regresión logística y SVM.

Funciones cóncavas

Una función f es cóncava si $-f$ es convexa.

La maximización de una función cóncava equivale a la minimización de una función convexa.

La log-verosimilitud de muchos modelos estadísticos es cóncava.

Descenso por gradiente

Definición 8.8. El descenso por gradiente genera una sucesión

$$\theta^{(t+1)} = \theta^{(t)} - \eta_t \nabla J(\theta^{(t)}),$$

donde $\eta_t > 0$ es la tasa de aprendizaje.

El método avanza en dirección opuesta al gradiente.

Descenso por gradiente

La actualización

$$\theta_{t+1} = \theta_t - \eta_t \nabla f(\theta_t)$$

no garantiza descenso para cualquier tasa de aprendizaje. Las garantías usuales requieren regularidad de la función y una elección adecuada de η_t .

Elección de la tasa de aprendizaje

Si η_t es demasiado grande, el algoritmo puede:

- oscilar;
- divergir;
- saltar sobre el mínimo.

Si es demasiado pequeña, la convergencia puede ser muy lenta.

Criterios de parada

El algoritmo puede detenerse cuando:

$$\|\nabla J(\theta^{(t)})\|_2 < \varepsilon,$$

o cuando

$$|J(\theta^{(t+1)}) - J(\theta^{(t)})| < \varepsilon,$$

o cuando se alcanza un número máximo de iteraciones.

Descenso por gradiente para una función cuadrática

Considere

$$J(\theta) = (\theta - 3)^2.$$

Entonces

$$J'(\theta) = 2(\theta - 3).$$

La actualización es

$$\theta^{(t+1)} = \theta^{(t)} - 2\eta(\theta^{(t)} - 3).$$

El mínimo se encuentra en

$$\theta^* = 3.$$

Descenso por gradiente por lotes

En aprendizaje supervisado,

$$J(\theta) = \frac{1}{n} \sum_{i=1}^n L_i(\theta).$$

El descenso por gradiente por lotes utiliza

$$\nabla J(\theta) = \frac{1}{n} \sum_{i=1}^n \nabla L_i(\theta).$$

Cada actualización utiliza toda la muestra.

Descenso por gradiente estocástico

El descenso estocástico utiliza una observación a la vez:

$$\theta^{(t+1)} = \theta^{(t)} - \eta_t \nabla L_i(\theta^{(t)}).$$

Es más ruidoso, pero puede ser más eficiente para bases grandes.

Mini-lotes

Una variante intermedia utiliza un subconjunto B_t :

$$\theta^{(t+1)} = \theta^{(t)} - \eta_t \frac{1}{|B_t|} \sum_{i \in B_t} \nabla L_i(\theta^{(t)}).$$

Esta estrategia es habitual en redes neuronales.

Método de Newton

El método de Newton utiliza la Hessiana:

$$\theta^{(t+1)} = \theta^{(t)} - \mathbf{H}_J(\theta^{(t)})^{-1} \nabla J(\theta^{(t)}).$$

Puede converger más rápido que el descenso por gradiente, pero requiere calcular e invertir la Hessiana.

Método de Newton-Raphson

En máxima verosimilitud, si se maximiza

$$\ell(\theta),$$

la actualización es

$$\theta^{(t+1)} = \theta^{(t)} - \mathbf{H}_\ell(\theta^{(t)})^{-1} \nabla \ell(\theta^{(t)}).$$

Este método se utiliza en regresión logística.

Problemas con restricciones

Un problema restringido tiene la forma

$$\min_{\mathbf{x}} f(\mathbf{x})$$

sujeto a

$$g_j(\mathbf{x}) = 0, \quad j = 1, \dots, m.$$

También pueden existir restricciones de desigualdad:

$$h_k(\mathbf{x}) \leq 0.$$

Multiplicadores de Lagrange

Definición 8.9. Para el problema

$$\min_{\mathbf{x}} f(\mathbf{x})$$

sujeto a

$$g(\mathbf{x}) = 0,$$

se define el Lagrangiano

$$\mathcal{L}(\mathbf{x}, \lambda) = f(\mathbf{x}) + \lambda g(\mathbf{x}).$$

Las condiciones de primer orden son

$$\nabla_{\mathbf{x}} \mathcal{L} = \mathbf{0},$$

y

$$g(\mathbf{x}) = 0.$$

Ejemplo de Lagrange

Minimizar

$$f(x_1, x_2) = x_1^2 + x_2^2$$

sujeto a

$$x_1 + x_2 = 1.$$

El Lagrangiano es

$$\mathcal{L} = x_1^2 + x_2^2 + \lambda(x_1 + x_2 - 1).$$

Las condiciones son

$$2x_1 + \lambda = 0,$$

$$2x_2 + \lambda = 0,$$

$$x_1 + x_2 = 1.$$

De las dos primeras,

$$x_1 = x_2.$$

Por tanto,

$$x_1 = x_2 = \frac{1}{2}.$$

Relación con PCA

En PCA se resuelve

$$\max_{\mathbf{a}} \mathbf{a}^\top \Sigma \mathbf{a}$$

sujeto a

$$\mathbf{a}^\top \mathbf{a} = 1.$$

El Lagrangiano es

$$\mathcal{L} = \mathbf{a}^\top \Sigma \mathbf{a} - \lambda(\mathbf{a}^\top \mathbf{a} - 1).$$

Al derivar,

$$2\Sigma \mathbf{a} - 2\lambda \mathbf{a} = \mathbf{0}.$$

Por tanto,

$$\Sigma \mathbf{a} = \lambda \mathbf{a}.$$

Así, las direcciones principales son vectores propios de la matriz de covarianza.

Restricciones de desigualdad y condiciones KKT

Para un problema

$$\min_{\mathbf{x}} f(\mathbf{x})$$

sujeto a

$$g_i(\mathbf{x}) \leq 0,$$

las condiciones de Karush-Kuhn-Tucker incluyen:

1. estacionariedad;
2. factibilidad primal;
3. factibilidad dual;
4. complementariedad.

En forma simplificada:

$$\nabla f(\mathbf{x}) + \sum_i \lambda_i \nabla g_i(\mathbf{x}) = \mathbf{0},$$

$$g_i(\mathbf{x}) \leq 0,$$

$$\lambda_i \geq 0,$$

$$\lambda_i g_i(\mathbf{x}) = 0.$$

Estas condiciones son fundamentales en máquinas de vectores de soporte.

! Condiciones KKT

Las condiciones KKT son necesarias bajo condiciones de regularidad. En problemas convexos, con funciones diferenciables y una condición de factibilidad como Slater, también son suficientes para optimalidad global.

Funciones de pérdida

Una función de pérdida mide el error de una predicción.

Pérdida cuadrática

$$L(y, \hat{y}) = (y - \hat{y})^2.$$

Pérdida absoluta

$$L(y, \hat{y}) = |y - \hat{y}|.$$

Pérdida logística

Para $y \in \{0, 1\}$,

$$L(y, \pi) = -[y \log \pi + (1 - y) \log(1 - \pi)].$$

Pérdida hinge

Para $y \in \{-1, 1\}$,

$$L(y, f(\mathbf{x})) = \max\{0, 1 - yf(\mathbf{x})\}.$$

Riesgo empírico

La función objetivo habitual es

$$\widehat{R}_n(f) = \frac{1}{n} \sum_{i=1}^n L(y_i, f(\mathbf{x}_i)).$$

El entrenamiento consiste en resolver

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \widehat{R}_n(f).$$

Regularización

Para controlar la complejidad se añade una penalización:

$$\hat{\theta} = \arg \min_{\theta} \{J(\theta) + \lambda \Omega(\theta)\}.$$

Por ejemplo, con penalización cuadrática:

$$\Omega(\theta) = \|\theta\|_2^2.$$

Relación con regresión lineal

La función de pérdida es

$$J(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|_2^2.$$

Equivalentemente,

$$J(\beta) = (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta).$$

El gradiente es

$$\nabla_{\beta} J = -2\mathbf{X}^{\top}(\mathbf{y} - \mathbf{X}\beta).$$

Igualando a cero,

$$\mathbf{X}^{\top}\mathbf{X}\hat{\beta} = \mathbf{X}^{\top}\mathbf{y}.$$

Relación con regresión logística

La log-verosimilitud es

$$\ell(\beta) = \sum_{i=1}^n [y_i \log \pi_i + (1 - y_i) \log(1 - \pi_i)].$$

Su gradiente es

$$\nabla \ell(\beta) = \mathbf{X}^{\top}(\mathbf{y} - \pi).$$

La estimación se realiza mediante métodos iterativos.

Relación con redes neuronales

Una red neuronal compone funciones:

$$\mathbf{a}^{(l)} = \phi^{(l)}(\mathbf{W}^{(l)}\mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}).$$

La retropropagación aplica repetidamente la regla de la cadena para calcular gradientes respecto de todos los parámetros.

Conexión con R

```
1 # Función cuadrática
2 f <- function(theta) {
3   (theta - 3)^2
4 }
5
6 # Derivada
7 grad_f <- function(theta) {
8   2 * (theta - 3)
9 }
10
11 # Descenso por gradiente
12 theta <- 0
13 eta <- 0.1
14
15 for (iter in 1:50) {
```

```

16   theta <- theta - eta * grad_f(theta)
17 }
18
19 theta
20
21 # Optimización con optim()
22 resultado <- optim(
23   par = 0,
24   fn = f,
25   method = "BFGS"
26 )
27
28 resultado$par

```

Ejemplo integrado

Considere

$$J(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2.$$

Las derivadas parciales son

$$\frac{\partial J}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i),$$

y

$$\frac{\partial J}{\partial \beta_1} = -2 \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i).$$

Igualando ambas expresiones a cero se obtienen las ecuaciones normales de regresión lineal simple.

Este ejemplo muestra cómo una función de pérdida se transforma en un sistema de ecuaciones mediante cálculo diferencial.

Errores frecuentes

1. Confundir derivada parcial con derivada total.
2. Utilizar el gradiente con una orientación matricial incorrecta.
3. Suponer que todo punto crítico es un mínimo.
4. Confundir Hessiana semidefinida con definida positiva.
5. Creer que una tasa de aprendizaje mayor siempre acelera la convergencia.
6. Ignorar la escala de las variables en métodos de gradiente.
7. Aplicar Newton cuando la Hessiana es singular o mal condicionada.
8. Suponer que todo problema de aprendizaje es convexo.
9. Confundir máximo de log-verosimilitud con mínimo de pérdida sin cambiar el signo.
10. Ignorar las restricciones al utilizar multiplicadores de Lagrange.

Ejercicios conceptuales

1. Explique la interpretación geométrica del gradiente.
2. ¿Qué información proporciona la Hessiana?
3. ¿Cuál es la diferencia entre una función convexa y una estrictamente convexa?
4. ¿Por qué un punto estacionario de una función convexa es mínimo global?
5. ¿Qué diferencia existe entre descenso por gradiente y método de Newton?
6. ¿Por qué la regla de la cadena es esencial en redes neuronales?
7. ¿Qué función cumplen los multiplicadores de Lagrange?
8. ¿Qué relación existe entre PCA y un problema de optimización restringida?
9. ¿Qué significa minimizar el riesgo empírico?
10. ¿Qué función cumple la regularización?

Ejercicios de derivación

Sea

$$f(x_1, x_2) = 3x_1^2 + 2x_1x_2 + 4x_2^2 - 6x_1 + 2x_2.$$

Calcule:

1. $\frac{\partial f}{\partial x_1}$;
2. $\frac{\partial f}{\partial x_2}$;
3. ∇f ;
4. $\mathbf{H}_f$;
5. los puntos críticos;
6. clasifique cada punto crítico.

Ejercicio de regla de la cadena

Sean

$$z_1 = x_1 + x_2,$$

$$z_2 = x_1x_2,$$

y

$$f(z_1, z_2) = z_1^2 + e^{z_2}.$$

Calcule:

1. $\frac{\partial f}{\partial x_1}$;
2. $\frac{\partial f}{\partial x_2}$;
3. la Jacobiana de (z_1, z_2) ;
4. verifique el resultado mediante la regla de la cadena matricial.

Ejercicio de descenso por gradiente

Considere

$$J(\theta) = (\theta - 5)^2.$$

Use:

$$\theta^{(0)} = 0,$$

y

$$\eta = 0.2.$$

Calcule manualmente las primeras cinco iteraciones.

Ejercicio de Lagrange

Minimice

$$f(x_1, x_2) = x_1^2 + 4x_2^2$$

sujeto a

$$x_1 + x_2 = 3.$$

1. Construya el Lagrangiano.
2. Obtenga las condiciones de primer orden.
3. Resuelva el sistema.
4. Verifique la naturaleza del punto obtenido.

Ejercicio aplicado a regresión

Sea

$$J(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|_2^2.$$

1. Expanda la expresión.
2. Calcule el gradiente respecto de β .
3. Obtenga las ecuaciones normales.
4. Explique bajo qué condición existe una solución única.
5. Interprete geométricamente la solución.

Resumen

En este capítulo se estudiaron funciones de varias variables, derivadas parciales, gradientes, Jacobianas, Hessianas, diferenciales y regla de la cadena.

También se desarrollaron aproximaciones de Taylor, puntos críticos, clasificación mediante la Hessiana, convexidad, descenso por gradiente, métodos de Newton y problemas restringidos mediante multiplicadores de Lagrange y condiciones KKT.

Finalmente, se relacionaron estas herramientas con regresión lineal, regresión logística, PCA, SVM y redes neuronales. Estos conceptos permitirán derivar formalmente los algoritmos de los capítulos posteriores.

Referencias del capítulo

Los fundamentos se apoyan en Apostol (1969), Boyd y Vandenberghe (2004), Bishop (2006) y Hastie et al. (2009).

Parte II

II. Fundamentos del aprendizaje automático

9 Formulación matemática del aprendizaje supervisado

Introducción

El aprendizaje supervisado se formula a partir de una distribución conjunta desconocida sobre entradas y salidas. El conjunto de entrenamiento se interpreta como una muestra de esa distribución, y el algoritmo selecciona una función dentro de una clase de hipótesis (Vapnik 1998; Shalev-Shwartz y Ben-David 2014; Murphy 2022).

El aprendizaje supervisado estudia métodos capaces de construir una regla de predicción a partir de observaciones etiquetadas. Cada observación contiene un conjunto de características y una respuesta conocida. El objetivo consiste en utilizar esa información para predecir correctamente la respuesta de nuevas observaciones.

Desde el punto de vista matemático, el aprendizaje supervisado puede formularse como un problema de selección de funciones. Se dispone de una familia de modelos posibles y se busca aquel que minimice una medida de error, no solamente sobre los datos observados, sino también sobre datos futuros provenientes del mismo proceso generador.

Esta distinción entre ajuste y generalización es central. Un modelo puede describir muy bien la muestra de entrenamiento y, sin embargo, producir predicciones deficientes fuera de ella. Por esta razón, la teoría del aprendizaje automático estudia funciones de pérdida, riesgo esperado, riesgo empírico, complejidad de modelos, regularización y validación.

! Definición esencial

El aprendizaje supervisado utiliza pares entrada-salida para construir una función predictiva.

Objetivos

Al finalizar el capítulo, el lector podrá:

1. formular matemáticamente un problema de aprendizaje supervisado;
2. distinguir entre espacio de entrada y espacio de salida;
3. interpretar una muestra de entrenamiento;
4. definir una función objetivo desconocida;
5. distinguir modelo, hipótesis y espacio de hipótesis;
6. comprender funciones de pérdida;
7. definir riesgo esperado y riesgo empírico;
8. interpretar el principio de minimización del riesgo empírico;
9. distinguir error de entrenamiento y error de generalización;
10. comprender sobreajuste y subajuste;

11. analizar el compromiso entre sesgo y varianza;
12. comprender regularización y complejidad de modelos;
13. interpretar ruido irreducible;
14. relacionar estos conceptos con regresión y clasificación.

! Hipótesis de muestreo

La formulación elemental supone observaciones independientes e idénticamente distribuidas:

$$(\mathbf{X}_i, Y_i) \stackrel{iid}{\sim} P_{X,Y}.$$

Esta hipótesis no siempre es válida. En series temporales, datos espaciales, redes o mediciones repetidas deben utilizarse esquemas de validación y resultados teóricos adaptados a la dependencia.

Espacio de entrada

Definición 9.1. El **espacio de entrada** o espacio de características es el conjunto de todos los posibles vectores de atributos.

Se denota por

$$\mathcal{X}.$$

Frecuentemente,

$$\mathcal{X} \subseteq \mathbb{R}^p.$$

Cada observación se representa mediante

$$\mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_p \end{pmatrix}.$$

Por ejemplo, en un problema ambiental:

$$\mathbf{x} = \begin{pmatrix} \text{PM10} \\ \text{temperatura} \\ \text{humedad} \\ \text{velocidad del viento} \end{pmatrix}.$$

Espacio de salida

Definición 9.2. El **espacio de salida** es el conjunto de posibles respuestas.

Se denota por

$$\mathcal{Y}.$$

En regresión,

$$\mathcal{Y} \subseteq \mathbb{R}.$$

En clasificación binaria,

$$\mathcal{Y} = \{0, 1\}$$

o

$$\mathcal{Y} = \{-1, 1\}.$$

En clasificación multiclase,

$$\mathcal{Y} = \{1, \dots, K\}.$$

Variable aleatoria conjunta

Se considera un par aleatorio

$$(\mathbf{X}, Y)$$

con distribución conjunta desconocida

$$P_{\mathbf{X}, Y}.$$

El vector $\mathbf{X}$ representa las características y Y la respuesta.

La distribución conjunta determina:

- qué observaciones son más probables;
- cómo se relacionan características y respuesta;
- cuánto ruido existe;
- cuál es la mejor regla de predicción posible.

Muestra de entrenamiento

Definición 9.3. Una muestra de entrenamiento es

$$\mathcal{D}_n = \{(\mathbf{x}_i, y_i)\}_{i=1}^n,$$

donde cada par es una realización de $(\mathbf{X}, Y)$.

Bajo el supuesto iid,

$$(\mathbf{x}_i, y_i) \stackrel{\text{iid}}{\sim} P_{\mathbf{X}, Y}.$$

La muestra contiene información parcial sobre la distribución verdadera.

Función objetivo desconocida

Se supone que existe una relación subyacente entre entrada y salida. Idealmente puede representarse mediante una función

$$f^* : \mathcal{X} \rightarrow \mathcal{Y}.$$

Esta función no se conoce directamente.

En regresión se suele escribir

$$Y = f^*(\mathbf{X}) + \varepsilon,$$

donde

$$\mathbb{E}(\varepsilon \mid \mathbf{X}) = 0.$$

El término ε representa ruido o variabilidad no explicada.

Hipótesis

Definición 9.4. Una **hipótesis** es una función candidata

$$f : \mathcal{X} \rightarrow \mathcal{Y}$$

que intenta aproximar la relación verdadera.

Por ejemplo, en regresión lineal,

$$f(\mathbf{x}) = \beta_0 + \beta^\top \mathbf{x}.$$

En clasificación mediante k -NN, la hipótesis se define a partir de las etiquetas de los vecinos más cercanos.

Espacio de hipótesis

Definición 9.5. El **espacio de hipótesis** es la familia de funciones candidatas entre las cuales se seleccionará el modelo.

Se denota por

$$\mathcal{F}.$$

Ejemplos:

Modelos lineales

$$\mathcal{F} = \left\{ f(\mathbf{x}) = \beta_0 + \beta^\top \mathbf{x} : \beta \in \mathbb{R}^p \right\}.$$

Árboles de decisión

$$\mathcal{F} = \{\text{árboles con profundidad máxima } d\}.$$

Redes neuronales

$$\mathcal{F} = \{\text{redes con una arquitectura determinada}\}.$$

La elección de $\mathcal{F}$ determina la complejidad del problema.

Parámetros e hiperparámetros

Los parámetros son cantidades aprendidas a partir de los datos:

$$\theta.$$

Ejemplos:

- coeficientes de regresión;
- pesos de una red neuronal;
- puntos de corte de un árbol.

Los hiperparámetros controlan la estructura del aprendizaje:

- número de vecinos k ;
- profundidad máxima de un árbol;
- parámetro de regularización λ ;
- tasa de aprendizaje;
- número de capas.

Los hiperparámetros no se estiman directamente mediante el mismo criterio utilizado para los parámetros; suelen seleccionarse mediante validación.

Función de pérdida

Definición 9.6. Una función de pérdida es una función

$$L : \mathcal{Y} \times \mathcal{Y} \rightarrow [0, \infty)$$

que cuantifica el costo de predecir $\hat{y}$ cuando la respuesta verdadera es y .

Se escribe

$$L(y, \hat{y}).$$

Pérdida cuadrática

En regresión,

$$L(y, \hat{y}) = (y - \hat{y})^2.$$

Penaliza con mayor intensidad los errores grandes.

Pérdida absoluta

$$L(y, \hat{y}) = |y - \hat{y}|.$$

Es más robusta frente a valores extremos.

Pérdida 0-1

En clasificación,

$$L(y, \hat{y}) = \mathbb{I}(y \neq \hat{y}).$$

La pérdida vale cero si la clasificación es correcta y uno si es incorrecta.

Pérdida logística

Para clasificación binaria,

$$L(y, \pi) = -[y \log \pi + (1 - y) \log(1 - \pi)].$$

Esta pérdida surge de la distribución Bernoulli.

Pérdida hinge

En SVM,

$$L(y, f(\mathbf{x})) = \max\{0, 1 - yf(\mathbf{x})\}.$$

Penaliza observaciones mal clasificadas o clasificadas con margen insuficiente.

Riesgo esperado

Definición 9.7. El riesgo esperado de una función f es

$$R(f) = \mathbb{E}_{(\mathbf{X}, Y)} [L(Y, f(\mathbf{X}))].$$

El riesgo esperado mide el error promedio sobre toda la distribución verdadera.

En forma integral,

$$R(f) = \int L(y, f(\mathbf{x})) dP_{\mathbf{X}, Y}(\mathbf{x}, y).$$

El objetivo ideal es encontrar

$$f_{\mathcal{F}}^* = \arg \min_{f \in \mathcal{F}} R(f).$$

Riesgo de Bayes

Si se permite elegir entre todas las funciones medibles, el menor riesgo posible es el riesgo de Bayes:

$$R^* = \inf_f R(f).$$

Una función que alcanza ese riesgo se denomina regla de Bayes.

Riesgo empírico

Como la distribución verdadera es desconocida, se utiliza la muestra.

Definición 9.8. El riesgo empírico es

$$\widehat{R}_n(f) = \frac{1}{n} \sum_{i=1}^n L(y_i, f(\mathbf{x}_i)).$$

Este riesgo puede calcularse directamente.

i Riesgo esperado y riesgo empírico

El riesgo esperado depende de la distribución desconocida:

$$R(f) = \mathbb{E}[L(Y, f(\mathbf{X}))].$$

El riesgo empírico se calcula con la muestra:

$$\widehat{R}_n(f) = \frac{1}{n} \sum_{i=1}^n L(y_i, f(\mathbf{x}_i)).$$

Minimizar el segundo no garantiza por sí mismo minimizar el primero; la diferencia entre ambos es el problema de generalización.

Minimización del riesgo empírico

Definición 9.9. El principio de minimización del riesgo empírico selecciona

$$\widehat{f}_n = \arg \min_{f \in \mathcal{F}} \widehat{R}_n(f).$$

Esta idea está detrás de numerosos algoritmos.

Regresión lineal

$$\widehat{\beta} = \arg \min_{\beta} \frac{1}{n} \sum_{i=1}^n (y_i - \beta_0 - \beta^\top \mathbf{x}_i)^2.$$

Clasificación

$$\hat{f} = \arg \min_f \frac{1}{n} \sum_{i=1}^n \mathbb{I}(y_i \neq f(\mathbf{x}_i)).$$

Error de entrenamiento

El error de entrenamiento es el riesgo empírico evaluado sobre la muestra utilizada para ajustar el modelo:

$$\text{Err}_{\text{train}} = \widehat{R}_n(\hat{f}).$$

Un error de entrenamiento bajo no garantiza buen desempeño futuro.

Error de prueba

El error de prueba se estima usando observaciones no utilizadas durante el ajuste:

$$\text{Err}_{\text{test}} = \frac{1}{m} \sum_{j=1}^m L(y_j^{\text{test}}, \hat{f}(\mathbf{x}_j^{\text{test}})).$$

El error de prueba aproxima el error de generalización.

Generalización

Definición 9.10. La **generalización** es la capacidad de un modelo para realizar predicciones adecuadas sobre observaciones nuevas.

Un modelo generaliza bien cuando

$$R(\hat{f})$$

es pequeño.

Brecha de generalización

La diferencia

$$R(\hat{f}) - \widehat{R}_n(\hat{f})$$

se denomina brecha de generalización.

Una brecha grande indica que el desempeño observado en entrenamiento es demasiado optimista.

Sobreajuste

Definición 9.11. Existe sobreajuste cuando un modelo se adapta excesivamente a la muestra de entrenamiento y captura ruido o particularidades que no se repiten en datos nuevos.

Características:

- error de entrenamiento muy bajo;
- error de prueba alto;
- elevada complejidad;
- alta sensibilidad a pequeñas variaciones de la muestra.

Subajuste

Definición 9.12. Existe subajuste cuando el modelo es demasiado simple para representar la relación subyacente.

Características:

- error de entrenamiento alto;
- error de prueba alto;
- incapacidad para capturar patrones importantes.

Complejidad del modelo

La complejidad puede asociarse con:

- número de parámetros;
- profundidad de un árbol;
- grado de un polinomio;
- número de capas de una red;
- flexibilidad del espacio de hipótesis;
- dimensión VC;
- norma de los parámetros.

Un espacio de hipótesis demasiado amplio puede reducir el error de entrenamiento, pero aumentar el riesgo de sobreajuste.

Ejemplo polinomial

Considere modelos

$$f_d(x) = \beta_0 + \beta_1 x + \dots + \beta_d x^d.$$

Si d es pequeño, puede existir subajuste.

Si d es muy grande, puede existir sobreajuste.

El objetivo es seleccionar un nivel de complejidad que equilibre ajuste y generalización.

Regularización

Definición 9.13. La regularización añade una penalización a la función objetivo para controlar la complejidad del modelo.

La forma general es

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \left\{ \widehat{R}_n(f) + \lambda \Omega(f) \right\}.$$

Aquí:

- $\Omega(f)$ mide complejidad;
- $\lambda \geq 0$ controla la intensidad de la penalización.

Regularización L2

Para un vector de parámetros,

$$\Omega(\theta) = \|\theta\|_2^2.$$

Entonces,

$$\hat{\theta} = \arg \min_{\theta} \left\{ \widehat{R}_n(\theta) + \lambda \|\theta\|_2^2 \right\}.$$

Esta penalización reduce la magnitud de los parámetros.

Regularización L1

$$\Omega(\theta) = \|\theta\|_1 = \sum_{j=1}^p |\theta_j|.$$

La penalización L1 puede producir parámetros exactamente iguales a cero y favorecer selección de variables.

Sesgo y varianza

El error de predicción puede analizarse mediante sesgo, varianza y ruido irreducible.

Supóngase

$$Y = f^*(\mathbf{X}) + \varepsilon,$$

con

$$\mathbb{E}(\varepsilon) = 0, \quad \text{Var}(\varepsilon) = \sigma^2.$$

Para una observación fija $\mathbf{x}_0$,

$$\mathbb{E} \left[(Y - \hat{f}(\mathbf{x}_0))^2 \right] = \text{Bias}^2 + \text{Var} + \sigma^2.$$

Sesgo del modelo

El sesgo se define como

$$\text{Bias}[\hat{f}(\mathbf{x}_0)] = \mathbb{E}[\hat{f}(\mathbf{x}_0)] - f^*(\mathbf{x}_0).$$

Un modelo muy rígido suele tener sesgo alto.

Varianza del modelo

La varianza es

$$\text{Var}[\hat{f}(\mathbf{x}_0)] = \mathbb{E} \left[\left(\hat{f}(\mathbf{x}_0) - \mathbb{E}[\hat{f}(\mathbf{x}_0)] \right)^2 \right].$$

Un modelo muy flexible suele tener varianza alta.

Ruido irreducible

El término

$$\sigma^2$$

representa variabilidad que no puede eliminarse mediante ningún modelo basado en las características disponibles.

Puede deberse a:

- errores de medición;
- variables omitidas;
- procesos inherentemente aleatorios;
- etiquetas incorrectas.

Compromiso entre sesgo y varianza

Al aumentar la complejidad:

- el sesgo tiende a disminuir;
- la varianza tiende a aumentar.

Al reducir la complejidad:

- el sesgo tiende a aumentar;
- la varianza tiende a disminuir.

La selección de modelos busca un equilibrio.

Error de aproximación

Incluso con infinitos datos, puede ocurrir que

$$f^* \notin \mathcal{F}.$$

El error debido a la limitación del espacio de hipótesis se denomina error de aproximación.

Error de estimación

La muestra es finita, por lo que la función seleccionada puede diferir del mejor elemento de $\mathcal{F}$.

Este componente se denomina error de estimación.

En términos conceptuales:

$$\text{error total} = \text{error de aproximación} + \text{error de estimación} + \text{ruido}.$$

Selección de modelos

La selección de modelos consiste en elegir:

- una familia de hipótesis;
- una estructura;
- hiperparámetros;
- intensidad de regularización.

No debe hacerse utilizando el conjunto de prueba final.

División de datos

Una estrategia común divide los datos en:

1. entrenamiento;
2. validación;
3. prueba.

El conjunto de entrenamiento ajusta parámetros.

El conjunto de validación selecciona hiperparámetros.

El conjunto de prueba evalúa el modelo final.

Validación cruzada

Cuando los datos son limitados, puede emplearse validación cruzada.

La muestra se divide en K subconjuntos:

$$I_1, \dots, I_K.$$

El error de validación cruzada es

$$CV_K = \frac{1}{K} \sum_{k=1}^K \frac{1}{|I_k|} \sum_{i \in I_k} L(y_i, \hat{f}^{(-k)}(\mathbf{x}_i)).$$

Clasificación óptima bajo pérdida 0-1

En clasificación, para una observación $\mathbf{x}$, el riesgo condicional de predecir la clase k es

$$R(k | \mathbf{x}) = P(Y \neq k | \mathbf{x}).$$

Como

$$P(Y \neq k \mid \mathbf{x}) = 1 - P(Y = k \mid \mathbf{x}),$$

la mejor decisión es

$$f^*(\mathbf{x}) = \arg \max_k P(Y = k \mid \mathbf{x}).$$

Esta es la regla de Bayes.

Regresión óptima bajo pérdida cuadrática

Para una observación fija $\mathbf{x}$, se desea minimizar

$$\mathbb{E}[(Y - a)^2 \mid \mathbf{X} = \mathbf{x}].$$

La solución es

$$a = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}].$$

Por tanto, la función óptima bajo pérdida cuadrática es

$$f^*(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}].$$

Regresión óptima bajo pérdida absoluta

Si se minimiza

$$\mathbb{E}[|Y - a| \mid \mathbf{X} = \mathbf{x}],$$

la solución es una mediana condicional de Y dado $\mathbf{X} = \mathbf{x}$.

Esto muestra que diferentes funciones de pérdida conducen a diferentes objetivos estadísticos.

Aprendizaje paramétrico

En un modelo paramétrico,

$$f_\theta \in \mathcal{F}$$

se describe mediante un número finito de parámetros.

Ejemplo:

$$f_\beta(\mathbf{x}) = \beta_0 + \beta^\top \mathbf{x}.$$

Aprendizaje no paramétrico

Los métodos no paramétricos no fijan una forma funcional rígida.

Ejemplos:

- k -NN;
- árboles;
- estimadores kernel.

La complejidad puede crecer con el tamaño de la muestra.

Aprendizaje determinista y probabilístico

Un modelo determinista produce directamente

$$\hat{y} = f(\mathbf{x}).$$

Un modelo probabilístico estima una distribución:

$$P(Y \mid \mathbf{X} = \mathbf{x}).$$

Por ejemplo, regresión logística estima

$$P(Y = 1 \mid \mathbf{x}).$$

Relación con regresión lineal

En regresión lineal se minimiza

$$\widehat{R}_n(\beta) = \frac{1}{n} \sum_{i=1}^n (y_i - \beta_0 - \beta^\top \mathbf{x}_i)^2.$$

El espacio de hipótesis es lineal en los parámetros.

Relación con regresión logística

En regresión logística se minimiza la pérdida logarítmica:

$$\widehat{R}_n(\beta) = -\frac{1}{n} \sum_{i=1}^n [y_i \log \pi_i + (1 - y_i) \log(1 - \pi_i)].$$

Relación con el método de vecinos más cercanos

En k -NN, el espacio de hipótesis depende directamente de la muestra. La complejidad se controla mediante k :

- k pequeño: baja sesgo, alta varianza;
- k grande: mayor sesgo, menor varianza.

Relación con árboles

En árboles de decisión, la profundidad controla complejidad:

- árboles profundos pueden sobreajustar;
- árboles poco profundos pueden subajustar.

La poda actúa como regularización estructural.

Relación con redes neuronales

En redes neuronales, la complejidad depende de:

- número de capas;
- número de neuronas;
- número de parámetros;
- funciones de activación;
- regularización;
- cantidad de datos.

Conexión con R

```
1 set.seed(123)
2
3 # Datos simulados
4 n <- 100
5 x <- runif(n, -2, 2)
6 y <- 1 + 2 * x + rnorm(n, sd = 1)
7
8 datos <- data.frame(x = x, y = y)
9
10 # División entrenamiento-prueba
11 indices <- sample(seq_len(n), size = 0.8 * n)
12
13 entrenamiento <- datos[indices, ]
14 prueba <- datos[-indices, ]
15
16 # Modelo
17 modelo <- lm(y ~ x, data = entrenamiento)
18
19 # Predicciones
20 pred <- predict(modelo, newdata = prueba)
21
22 # Error cuadrático medio de prueba
23 mean((prueba$y - pred)^2)
```

Ejemplo integrado

Supóngase que se comparan tres modelos para predecir una variable continua:

1. modelo constante;

2. modelo lineal;
3. polinomio de grado 12.

Resultados hipotéticos:

Modelo	Error de entrenamiento	Error de prueba
Constante	18.2	18.7
Lineal	5.3	5.8
Polinomio grado 12	0.4	14.9

Interpretación:

- el modelo constante presenta subajuste;
- el modelo lineal logra mejor equilibrio;
- el polinomio de grado 12 presenta sobreajuste.

Errores frecuentes

1. Suponer que menor error de entrenamiento implica mejor modelo.
2. Utilizar el conjunto de prueba para seleccionar hiperparámetros.
3. Confundir parámetros con hiperparámetros.
4. Suponer que toda regularización mejora siempre el modelo.
5. Ignorar el ruido irreducible.
6. Confundir sesgo estadístico con error sistemático de medición.
7. Evaluar un modelo con los mismos datos usados para ajustarlo.
8. Elegir una función de pérdida sin considerar el objetivo real.
9. Comparar modelos sin utilizar la misma partición o procedimiento de validación.
10. Interpretar una brecha pequeña como garantía absoluta de buen desempeño.

Ejercicios conceptuales

1. Explique la diferencia entre $\mathcal{X}$ y $\mathcal{Y}$.
2. ¿Qué diferencia existe entre una hipótesis y el espacio de hipótesis?
3. ¿Qué significa minimizar el riesgo esperado?
4. ¿Por qué se utiliza el riesgo empírico?
5. Explique la diferencia entre error de entrenamiento y error de prueba.
6. ¿Qué es la brecha de generalización?
7. Explique sobreajuste y subajuste.
8. ¿Qué papel cumple la regularización?
9. ¿Qué diferencia existe entre sesgo y varianza?
10. ¿Qué representa el ruido irreducible?

Ejercicio de riesgo empírico

Considere las respuestas verdaderas

$$\mathbf{y} = \begin{pmatrix} 2 \\ 4 \\ 5 \\ 7 \end{pmatrix}$$

y las predicciones

$$\hat{\mathbf{y}} = \begin{pmatrix} 3 \\ 3 \\ 6 \\ 8 \end{pmatrix}.$$

Calcule:

1. la pérdida cuadrática individual;
2. el riesgo empírico cuadrático;
3. la pérdida absoluta individual;
4. el riesgo empírico absoluto.

Ejercicio de clasificación

Sean las etiquetas verdaderas

$$(1, 0, 1, 1, 0, 0, 1, 0)$$

y las predicciones

$$(1, 1, 1, 0, 0, 0, 1, 1).$$

Calcule el riesgo empírico bajo pérdida 0-1.

Ejercicio de regularización

Considere

$$J(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda\|\beta\|_2^2.$$

1. Explique el papel de cada término.
2. Analice qué ocurre cuando $\lambda = 0$.
3. Analice qué ocurre cuando λ es muy grande.
4. Derive el gradiente.
5. Obtenga la solución formal.

Ejercicio de sesgo y varianza

Compare conceptualmente:

1. un modelo lineal;

2. un árbol profundo;
3. un k -NN con $k = 1$;
4. un k -NN con $k = n$.

Indique cuáles tienden a tener mayor sesgo y cuáles mayor varianza.

Ejercicio aplicado

Se desea predecir la concentración diaria de PM10 utilizando temperatura, humedad y velocidad del viento.

1. Defina $\mathcal{X}$.
2. Defina $\mathcal{Y}$.
3. Escriba la muestra de entrenamiento.
4. Proponga una función de pérdida.
5. Defina el riesgo esperado.
6. Defina el riesgo empírico.
7. Explique cómo evaluaría la generalización.
8. Describa una situación de sobreajuste.
9. Describa una situación de subajuste.
10. Proponga una estrategia de regularización o validación.

Resumen

En este capítulo se formuló matemáticamente el aprendizaje supervisado como un problema de selección de funciones. Se definieron espacios de entrada y salida, muestras de entrenamiento, hipótesis, espacios de hipótesis, parámetros e hiperparámetros.

También se estudiaron funciones de pérdida, riesgo esperado, riesgo empírico, minimización del riesgo empírico y generalización.

Finalmente, se analizaron sobreajuste, subajuste, complejidad, regularización, sesgo, varianza, ruido irreducible y selección de modelos. Estos conceptos servirán como base para la teoría de clasificación y para los algoritmos específicos de los capítulos posteriores.

Referencias del capítulo

Los fundamentos se apoyan en Vapnik (1998), Shalev-Shwartz y Ben-David (2014) y Murphy (2022).

10 Teoría matemática de la clasificación

Introducción

La teoría de clasificación estudia cómo asignar una observación a una categoría minimizando una pérdida esperada. La regla de Bayes constituye el referente óptimo bajo la distribución verdadera, mientras que los clasificadores aprendidos intentan aproximarla a partir de datos finitos (Duda et al. 2001; Devroye et al. 1996; Bishop 2006).

La clasificación consiste en asignar una etiqueta discreta a una observación a partir de sus características. En un problema binario, la respuesta puede pertenecer a una de dos clases; en un problema multiclase, puede pertenecer a una de varias categorías.

Desde el punto de vista matemático, un clasificador es una función que divide el espacio de características en regiones de decisión. Cada región se asocia con una clase. La teoría de clasificación estudia cómo construir estas regiones, cómo medir el costo de los errores y cuál es la mejor regla de decisión posible bajo una distribución probabilística dada.

En este capítulo se desarrollan la regla de Bayes, el riesgo condicional, el error de Bayes, las fronteras de decisión y las principales métricas de evaluación.

! Definición esencial

Clasificar consiste en asignar una observación a una categoría minimizando una pérdida esperada.

Objetivos

Al finalizar el capítulo, el lector podrá:

1. formular un problema de clasificación binaria y multiclase;
2. definir una regla de decisión;
3. interpretar regiones y fronteras de decisión;
4. calcular riesgo condicional;
5. derivar la regla de Bayes;
6. interpretar el error de Bayes;
7. comprender pérdidas asimétricas;
8. construir una matriz de confusión;
9. calcular exactitud, error, sensibilidad, especificidad y precisión;
10. interpretar valor predictivo positivo y negativo;
11. comprender curvas ROC y área bajo la curva;
12. analizar el efecto del umbral de decisión;
13. extender la formulación al caso multiclase;
14. relacionar estos conceptos con algoritmos concretos.

Formulación de un problema de clasificación

Sea

$$\mathbf{X} \in \mathcal{X} \subseteq \mathbb{R}^p$$

un vector de características y sea

$$Y \in \mathcal{Y}$$

la etiqueta de clase.

En clasificación binaria,

$$\mathcal{Y} = \{0, 1\}$$

o

$$\mathcal{Y} = \{-1, 1\}.$$

En clasificación multiclase,

$$\mathcal{Y} = \{1, 2, \dots, K\}.$$

Clasificador

Definición 10.1. Un **clasificador** es una función

$$f : \mathcal{X} \rightarrow \mathcal{Y}.$$

Para una observación $\mathbf{x}$, la predicción es

$$\hat{y} = f(\mathbf{x}).$$

Regiones de decisión

Para cada clase k , se define la región

$$R_k = \{\mathbf{x} \in \mathcal{X} : f(\mathbf{x}) = k\}.$$

Las regiones satisfacen:

$$R_i \cap R_j = \emptyset, \quad i \neq j,$$

y

$$\bigcup_{k=1}^K R_k = \mathcal{X}.$$

Frontera de decisión

Definición 10.2. La frontera de decisión es el conjunto de puntos que separa dos o más regiones de clasificación.

En clasificación binaria, si el clasificador se basa en una función discriminante $g(\mathbf{x})$, puede definirse como

$$f(\mathbf{x}) = \begin{cases} 1, & g(\mathbf{x}) \geq 0, \\ 0, & g(\mathbf{x}) < 0. \end{cases}$$

La frontera de decisión es

$$\{\mathbf{x} : g(\mathbf{x}) = 0\}.$$

Frontera lineal

Si

$$g(\mathbf{x}) = \beta_0 + \beta^\top \mathbf{x},$$

entonces la frontera es el hiperplano

$$\beta_0 + \beta^\top \mathbf{x} = 0.$$

Frontera no lineal

Si g contiene términos polinomiales, funciones kernel o composiciones no lineales, la frontera puede ser curva o altamente compleja.

Probabilidades posteriores

Para cada clase k , se define

$$\eta_k(\mathbf{x}) = P(Y = k \mid \mathbf{X} = \mathbf{x}).$$

Estas probabilidades satisfacen

$$\eta_k(\mathbf{x}) \geq 0$$

y

$$\sum_{k=1}^K \eta_k(\mathbf{x}) = 1.$$

Regla de clasificación por máxima probabilidad posterior

Una regla natural es seleccionar

$$f(\mathbf{x}) = \arg \max_k \eta_k(\mathbf{x}).$$

Esta regla será óptima bajo pérdida 0-1.

Función de pérdida general

Sea

$$L(j, k)$$

el costo de predecir la clase j cuando la clase verdadera es k .

En pérdida 0-1,

$$L(j, k) = \begin{cases} 0, & j = k, \\ 1, & j \neq k. \end{cases}$$

Riesgo condicional

Definición 10.3. El riesgo condicional de predecir la clase j dado $\mathbf{x}$ es

$$R(j | \mathbf{x}) = \sum_{k=1}^K L(j, k) P(Y = k | \mathbf{X} = \mathbf{x}).$$

La decisión óptima es

$$f^*(\mathbf{x}) = \arg \min_j R(j | \mathbf{x}).$$

i Probabilidades posteriores

En clasificación binaria se define

$$\eta(\mathbf{x}) = P(Y = 1 | \mathbf{X} = \mathbf{x}).$$

La regla de Bayes bajo pérdida 0-1 predice la clase 1 cuando $\eta(\mathbf{x}) \geq 1/2$. Si los costos son asimétricos, el umbral deja de ser necesariamente 1/2.

Regla de Bayes bajo pérdida 0-1

Con pérdida 0-1,

$$R(j \mid \mathbf{x}) = 1 - P(Y = j \mid \mathbf{X} = \mathbf{x}).$$

Por tanto,

$$f^*(\mathbf{x}) = \arg \max_j P(Y = j \mid \mathbf{X} = \mathbf{x}).$$

Teorema 10.1. *Bajo pérdida 0-1, la regla que asigna a cada observación la clase con mayor probabilidad posterior minimiza el riesgo esperado de clasificación.*

Riesgo de Bayes

El riesgo mínimo posible es

$$R^* = P(f^*(\mathbf{X}) \neq Y).$$

También puede escribirse como

$$R^* = \mathbb{E} \left[1 - \max_k P(Y = k \mid \mathbf{X}) \right].$$

Este riesgo representa el error irreducible de clasificación.

Error de Bayes binario

En clasificación binaria,

$$\eta(\mathbf{x}) = P(Y = 1 \mid \mathbf{X} = \mathbf{x}).$$

La regla de Bayes es

$$f^*(\mathbf{x}) = \begin{cases} 1, & \eta(\mathbf{x}) \geq \frac{1}{2}, \\ 0, & \eta(\mathbf{x}) < \frac{1}{2}. \end{cases}$$

El error condicional mínimo es

$$\min\{\eta(\mathbf{x}), 1 - \eta(\mathbf{x})\}.$$

Regla de Bayes con densidades

Por el teorema de Bayes,

$$P(Y = k \mid \mathbf{x}) = \frac{p(\mathbf{x} \mid Y = k)P(Y = k)}{p(\mathbf{x})}.$$

Como el denominador es común a todas las clases,

$$f^*(\mathbf{x}) = \arg \max_k p(\mathbf{x} | Y = k) P(Y = k).$$

Funciones discriminantes

Se pueden definir funciones

$$g_k(\mathbf{x}) = \log p(\mathbf{x} | Y = k) + \log P(Y = k).$$

Entonces,

$$f^*(\mathbf{x}) = \arg \max_k g_k(\mathbf{x}).$$

El uso del logaritmo transforma productos en sumas.

Pérdidas asimétricas

En muchos problemas, los errores no tienen el mismo costo.

Sea clasificación binaria y considérese:

- C_{10} : costo de predecir 1 cuando la clase verdadera es 0;
- C_{01} : costo de predecir 0 cuando la clase verdadera es 1.

La regla óptima predice 1 si

$$C_{10}P(Y = 0 | \mathbf{x}) < C_{01}P(Y = 1 | \mathbf{x}).$$

Equivalentemente,

$$P(Y = 1 | \mathbf{x}) > \frac{C_{10}}{C_{10} + C_{01}}.$$

Por tanto, el umbral óptimo no siempre es 0.5.

Clasificación sensible al costo

Este enfoque es importante cuando:

- una enfermedad grave no debe pasar inadvertida;
- detectar fraude es más importante que evitar falsas alarmas;
- un accidente severo tiene un costo mucho mayor que uno leve;
- las clases están desbalanceadas.

Clasificación binaria probabilística

Un modelo probabilístico produce

$$\hat{\pi}(\mathbf{x}) = \widehat{P}(Y = 1 | \mathbf{x}).$$

Luego se define

$$\hat{y} = \begin{cases} 1, & \hat{\pi}(\mathbf{x}) \geq t, \\ 0, & \hat{\pi}(\mathbf{x}) < t, \end{cases}$$

donde t es el umbral.

Efecto del umbral

Al disminuir t :

- aumenta el número de positivos predichos;
- aumenta la sensibilidad;
- puede disminuir la especificidad.

Al aumentar t :

- disminuyen los positivos predichos;
- puede aumentar la especificidad;
- puede disminuir la sensibilidad.

Matriz de confusión

Para clasificación binaria:

Clase real / predicha	Positiva	Negativa
Positiva	Verdadero positivo (VP)	Falso negativo (FN)
Negativa	Falso positivo (FP)	Verdadero negativo (VN)

La suma total es

$$n = VP + VN + FP + FN.$$

Exactitud

Definición 10.4. La exactitud es

$$\text{Accuracy} = \frac{VP + VN}{VP + VN + FP + FN}.$$

Tasa de error

$$\text{Error} = \frac{FP + FN}{n}.$$

Además,

$$\text{Error} = 1 - \text{Accuracy}.$$

Sensibilidad

Definición 10.5. La sensibilidad o tasa de verdaderos positivos es

$$\text{Sensibilidad} = \frac{VP}{VP + FN}.$$

Mide la proporción de positivos reales correctamente detectados.

También se denomina:

- recall;
- true positive rate;
- tasa de detección.

Especificidad

Definición 10.6. La especificidad o tasa de verdaderos negativos es

$$\text{Especificidad} = \frac{VN}{VN + FP}.$$

Tasa de falsos positivos

$$\text{FPR} = \frac{FP}{FP + VN} = 1 - \text{Especificidad}.$$

Tasa de falsos negativos

$$\text{FNR} = \frac{FN}{FN + VP} = 1 - \text{Sensibilidad}.$$

Precisión positiva

Definición 10.7. La precisión o valor predictivo positivo es

$$\text{Precision} = \frac{VP}{VP + FP}.$$

Mide qué proporción de las predicciones positivas es correcta.

Valor predictivo negativo

$$\text{VPN} = \frac{VN}{VN + FN}.$$

Medida F1

La medida F1 es la media armónica entre precisión y sensibilidad:

$$F_1 = 2 \frac{\text{Precision} \cdot \text{Sensibilidad}}{\text{Precision} + \text{Sensibilidad}}.$$

Equivalentemente,

$$F_1 = \frac{2VP}{2VP + FP + FN}.$$

Exactitud balanceada

En clases desbalanceadas puede utilizarse

$$\text{Balanced Accuracy} = \frac{\text{Sensibilidad} + \text{Especificidad}}{2}.$$

Prevalencia

La prevalencia observada de la clase positiva es

$$\text{Prev} = \frac{VP + FN}{n}.$$

Los valores predictivos dependen de la prevalencia.

Ejemplo de matriz de confusión

Supóngase:

$$VP = 45, \quad FN = 5, \quad FP = 10, \quad VN = 40.$$

Entonces,

$$\text{Accuracy} = \frac{45 + 40}{100} = 0.85.$$

La sensibilidad es

$$\frac{45}{45 + 5} = 0.90.$$

La especificidad es

$$\frac{40}{40 + 10} = 0.80.$$

La precisión es

$$\frac{45}{45 + 10} \approx 0.818.$$

Limitaciones de la exactitud

Considere una base con:

- 990 observaciones negativas;
- 10 observaciones positivas.

Un clasificador que siempre predice negativo obtiene

$$\text{Accuracy} = \frac{990}{1000} = 0.99.$$

Sin embargo,

$$\text{Sensibilidad} = 0.$$

Por tanto, la exactitud puede ser engañosa en datos desbalanceados.

i Clasificación y calibración

Un clasificador puede tener buena exactitud y probabilidades mal calibradas. La discriminación evalúa orden o separación entre clases; la calibración evalúa si una probabilidad pronosticada de, por ejemplo, 0.8 corresponde aproximadamente a una frecuencia observada de 0.8.

Curva ROC

Definición 10.8. La curva ROC representa la tasa de verdaderos positivos frente a la tasa de falsos positivos para distintos umbrales.

Sus ejes son:

$$x = \text{FPR},$$

$$y = \text{TPR}.$$

Cada umbral produce un punto en la curva.

Interpretación de la curva ROC

Un clasificador ideal se aproxima al punto

$$(0, 1).$$

Un clasificador aleatorio se aproxima a la diagonal

$$\text{TPR} = \text{FPR}.$$

Área bajo la curva

Definición 10.9. El área bajo la curva ROC se denota por AUC.

Puede interpretarse como la probabilidad de que el clasificador asigne una puntuación mayor a una observación positiva que a una negativa elegidas al azar.

Valores típicos:

- 0.5: discriminación aleatoria;
- cercano a 1: excelente discriminación;
- menor que 0.5: orden inverso sistemático.

Curva precisión-recall

En problemas con fuerte desbalance, puede ser más informativa la curva precisión-recall.

Esta curva representa:



Calibración

Un clasificador está bien calibrado si, entre las observaciones con probabilidad predicha cercana a p , aproximadamente una proporción p pertenece realmente a la clase positiva.

Por ejemplo, entre observaciones con predicción 0.8, cerca del 80 % debería ser positiva.

Discriminación y calibración

Un modelo puede:

- discriminar bien pero estar mal calibrado;
- estar bien calibrado pero discriminar poco;
- cumplir ambas propiedades;
- no cumplir ninguna.

La AUC mide discriminación, no calibración.

Función de pérdida logarítmica

Para una observación binaria,

$$L(y, \pi) = -[y \log \pi + (1 - y) \log(1 - \pi)] .$$

La pérdida penaliza con fuerza probabilidades muy confiadas pero incorrectas.

Brier score

El Brier score es

$$\text{Brier} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{\pi}_i)^2.$$

Evalúa predicciones probabilísticas y combina calibración con discriminación.

Clasificación multiclase

Para K clases,

$$\mathcal{Y} = \{1, \dots, K\}.$$

El clasificador produce

$$\hat{y} = \arg \max_k \widehat{P}(Y = k \mid \mathbf{x}).$$

Matriz de confusión multiclase

La matriz contiene $K \times K$ entradas.

La posición (i, j) representa el número de observaciones cuya clase real es i y cuya clase predicha es j .

Métricas por clase

Para cada clase k , puede considerarse:

- clase k como positiva;
- todas las demás como negativas.

Así se calculan sensibilidad, especificidad y precisión por clase.

Promedio macro

El promedio macro asigna el mismo peso a cada clase:

$$M_{\text{macro}} = \frac{1}{K} \sum_{k=1}^K M_k.$$

Promedio ponderado

El promedio ponderado utiliza el tamaño de cada clase:

$$M_{\text{ponderado}} = \sum_{k=1}^K w_k M_k,$$

donde

$$w_k = \frac{n_k}{n}.$$

Promedio micro

El promedio micro agrega primero los conteos de todas las clases y después calcula la métrica. Es más sensible a las clases mayoritarias.

Estrategia uno contra el resto

Para cada clase k se entrena un clasificador binario:

$$k \text{ contra } \mathcal{Y} \setminus \{k\}.$$

Estrategia uno contra uno

Se entrena un clasificador para cada par de clases.

El número de clasificadores es

$$\binom{K}{2} = \frac{K(K-1)}{2}.$$

Regiones de decisión multiclase

Si se utilizan funciones discriminantes

$$g_1(\mathbf{x}), \dots, g_K(\mathbf{x}),$$

la región de la clase k es

$$R_k = \{\mathbf{x} : g_k(\mathbf{x}) \geq g_j(\mathbf{x}) \text{ para todo } j\}.$$

Relación con regresión logística

En regresión logística binaria,

$$\hat{\pi}(\mathbf{x}) = \frac{e^{\beta_0 + \beta^T \mathbf{x}}}{1 + e^{\beta_0 + \beta^T \mathbf{x}}}.$$

La frontera con umbral 0.5 satisface

$$\beta_0 + \beta^T \mathbf{x} = 0.$$

Relación con el método de vecinos más cercanos

En k -NN, las probabilidades posteriores pueden estimarse como

$$\widehat{P}(Y = c \mid \mathbf{x}) = \frac{1}{k} \sum_{i \in N_k(\mathbf{x})} \mathbb{I}(y_i = c).$$

La clase predicha es la de mayor frecuencia local.

Relación con árboles de decisión

En una hoja terminal,

$$\widehat{P}(Y = c \mid \mathbf{x}) = \frac{n_c}{n_{\text{hoja}}}.$$

El árbol asigna la clase más frecuente.

Relación con SVM

SVM produce una función de puntuación

$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b.$$

La clasificación es

$$f(\mathbf{x}) = \text{sign}(g(\mathbf{x})).$$

La distancia a la frontera se relaciona con el margen.

Conexión con R

```

1 real <- factor(
2   c(1, 1, 1, 0, 0, 0, 1, 0),
3   levels = c(0, 1)
4 )
5
6 pred <- factor(
7   c(1, 1, 0, 0, 1, 0, 1, 0),
8   levels = c(0, 1)
9 )
10
11 tabla <- table(
12   Real = real,
13   Predicha = pred
14 )
15
16 tabla
17
18 VP <- tabla["1", "1"]
19 FN <- tabla["1", "0"]
20 FP <- tabla["0", "1"]

```

```

21 VN <- tabla["0", "0"]
22
23 accuracy <- (VP + VN) / sum(tabla)
24 sensibilidad <- VP / (VP + FN)
25 especificidad <- VN / (VN + FP)
26 precision <- VP / (VP + FP)
27
28 accuracy
29 sensibilidad
30 especificidad
31 precision

```

Ejemplo integrado

Considere un modelo para identificar accidentes severos.

La clase positiva es

$$Y = 1 = \text{accidente severo.}$$

Supóngase:

$$VP = 60, \quad FN = 15, \quad FP = 25, \quad VN = 400.$$

La exactitud es

$$\frac{60 + 400}{500} = 0.92.$$

La sensibilidad es

$$\frac{60}{60 + 15} = 0.80.$$

La especificidad es

$$\frac{400}{400 + 25} \approx 0.941.$$

La precisión es

$$\frac{60}{60 + 25} \approx 0.706.$$

Aunque la exactitud es alta, la sensibilidad indica que uno de cada cinco accidentes severos no es detectado.

Errores frecuentes

1. Confundir sensibilidad con precisión.

2. Interpretar exactitud alta como buen desempeño universal.
3. Elegir el umbral únicamente por conveniencia.
4. Ignorar costos distintos entre falsos positivos y falsos negativos.
5. Interpretar AUC como exactitud.
6. Suponer que una AUC alta implica buena calibración.
7. Comparar métricas calculadas con particiones diferentes.
8. Promediar métricas multiclase sin indicar el esquema.
9. Evaluar el modelo final sobre los datos de entrenamiento.
10. Ignorar la prevalencia al interpretar valores predictivos.

Ejercicios conceptuales

1. Explique qué representa una frontera de decisión.
2. ¿Qué diferencia existe entre una regla discriminante y una probabilidad posterior?
3. ¿Por qué la regla de Bayes minimiza la pérdida 0-1?
4. ¿Qué representa el error de Bayes?
5. ¿Por qué el umbral óptimo puede ser distinto de 0.5?
6. Explique la diferencia entre sensibilidad y precisión.
7. ¿Por qué la exactitud puede ser engañosa?
8. ¿Qué mide la curva ROC?
9. ¿Qué mide la AUC?
10. Explique la diferencia entre discriminación y calibración.

Ejercicio de matriz de confusión

Considere:

$$VP = 72, \quad FN = 18, \quad FP = 24, \quad VN = 186.$$

Calcule:

1. exactitud;
2. tasa de error;
3. sensibilidad;
4. especificidad;
5. precisión;
6. valor predictivo negativo;
7. F1;
8. exactitud balanceada.

Ejercicio de pérdidas asimétricas

Supóngase:

$$C_{10} = 1,$$

$$C_{01} = 4.$$

1. Calcule el umbral óptimo.
2. Explique qué tipo de error es más costoso.
3. Determine la decisión para probabilidades posteriores:
 - 0.15;
 - 0.30;
 - 0.60.

Ejercicio de regla de Bayes

Considere dos clases:

$$P(C_1) = 0.65, \quad P(C_2) = 0.35.$$

Para una observación $\mathbf{x}$:

$$p(\mathbf{x} \mid C_1) = 0.12,$$

$$p(\mathbf{x} \mid C_2) = 0.25.$$

1. Calcule las probabilidades posteriores.
2. Determine la clase según la regla de Bayes.
3. Explique el efecto de las probabilidades previas.

Ejercicio de umbral

Un modelo produce las probabilidades:

$$0.92, 0.81, 0.64, 0.48, 0.31, 0.12.$$

1. Determine las clases con umbral 0.5.
2. Determine las clases con umbral 0.3.
3. Explique cómo cambia la sensibilidad esperada.
4. Explique cómo cambia la especificidad esperada.

Ejercicio multiclase

Un problema tiene tres clases:

$$\mathcal{Y} = \{A, B, C\}.$$

Para una observación,

$$P(A \mid \mathbf{x}) = 0.20,$$

$$P(B \mid \mathbf{x}) = 0.55,$$

$$P(C \mid \mathbf{x}) = 0.25.$$

1. Determine la clase de Bayes.
2. Calcule el riesgo condicional bajo pérdida 0-1 para cada decisión.
3. Verifique que la decisión óptima minimiza el riesgo.

Ejercicio aplicado

Se desea clasificar la calidad del aire en:

{buena, regular, mala}.

1. Defina el espacio de salida.
2. Proponga funciones discriminantes.
3. Defina las regiones de decisión.
4. Construya una matriz de confusión hipotética.
5. Explique cómo calcularía sensibilidad por clase.
6. Compare promedio macro y ponderado.
7. Explique qué métrica usaría si la clase “mala” es poco frecuente pero crítica.

Resumen

En este capítulo se formuló la clasificación como una regla de decisión sobre el espacio de características. Se definieron regiones y fronteras de decisión, probabilidades posteriores, riesgo condicional y regla de Bayes.

También se estudiaron pérdidas asimétricas, clasificación sensible al costo, matrices de confusión y métricas como exactitud, sensibilidad, especificidad, precisión, F1 y exactitud balanceada.

Finalmente, se desarrollaron curvas ROC, AUC, calibración y clasificación multiclase. Estos conceptos serán esenciales para evaluar y comparar los algoritmos de clasificación de los capítulos posteriores.

Referencias del capítulo

Los fundamentos se apoyan en Duda et al. (2001), Devroye et al. (1996) y Bishop (2006).

11 Evaluación, validación y selección de modelos

Introducción

La evaluación de modelos intenta estimar el desempeño fuera de muestra. Para que la estimación sea válida, el conjunto de evaluación debe permanecer independiente de las decisiones tomadas durante entrenamiento, selección de variables y ajuste de hiperparámetros (Stone 1974; Efron 1983; Hastie et al. 2009).

La evaluación de modelos tiene como propósito estimar qué tan bien funcionará un algoritmo sobre observaciones nuevas. Esta tarea es distinta del ajuste. Durante el entrenamiento, el modelo utiliza una muestra para estimar parámetros; durante la evaluación, se intenta medir su capacidad de generalización.

Una evaluación incorrecta puede producir conclusiones engañosas. Si se utiliza la misma información para entrenar y evaluar, el error obtenido será optimista. Si el conjunto de prueba interviene en la selección de hiperparámetros, deja de ser una evaluación imparcial. Si el preprocesamiento se realiza antes de dividir los datos, puede existir fuga de información.

En este capítulo se desarrollan formalmente la partición entrenamiento-validación-prueba, la validación cruzada, leave-one-out, bootstrap, validación anidada y selección de hiperparámetros.

! Principio esencial

La evaluación válida requiere datos que no hayan intervenido en el entrenamiento ni en la selección del modelo.

Objetivos

Al finalizar el capítulo, el lector podrá:

1. distinguir entrenamiento, validación y prueba;
2. definir un estimador del error de generalización;
3. comprender el sesgo optimista del error de entrenamiento;
4. aplicar particiones aleatorias y estratificadas;
5. formular validación cruzada de K pliegues;
6. interpretar leave-one-out;
7. comprender métodos bootstrap;
8. comparar sesgo y varianza de estimadores de error;
9. seleccionar hiperparámetros sin contaminar el conjunto de prueba;
10. comprender validación cruzada anidada;
11. detectar fuga de información;
12. evaluar modelos en series de tiempo;
13. comparar modelos de forma estadísticamente válida;

14. diseñar un procedimiento reproducible de evaluación.

Error de generalización

Sea $\hat{f}_D$ un modelo ajustado con una muestra D .

Su error de generalización es

$$R(\hat{f}_D) = \mathbb{E} \left[L(Y, \hat{f}_D(\mathbf{X})) \mid \mathcal{D} \right].$$

La esperanza se toma respecto de una nueva observación $(\mathbf{X}, Y)$ proveniente del mismo proceso generador.

Este riesgo es desconocido porque la distribución $P_{\mathbf{X}, Y}$ es desconocida.

Error de entrenamiento

El error de entrenamiento es

$$\widehat{R}_{train} = \frac{1}{n} \sum_{i=1}^n L(y_i, \hat{f}_D(\mathbf{x}_i)).$$

Como el modelo fue ajustado usando esas mismas observaciones, suele cumplirse

$$\widehat{R}_{train} < R(\hat{f}_D).$$

Esta diferencia se denomina optimismo.

Optimismo de entrenamiento

Definición 11.1. El optimismo es la diferencia entre el error esperado sobre datos nuevos y el error observado sobre los datos de entrenamiento.

Formalmente,

$$\text{Opt} = \mathbb{E} \left[R(\hat{f}_D) - \widehat{R}_{train} \right].$$

Los modelos más flexibles suelen presentar mayor optimismo.

Conjunto de prueba

Sea

$$\mathcal{D}_{test} = \{(\mathbf{x}_j^{test}, y_j^{test})\}_{j=1}^m$$

una muestra independiente del entrenamiento.

El error de prueba es

$$\widehat{R}_{test} = \frac{1}{m} \sum_{j=1}^m L(y_j^{test}, \widehat{f}_{\mathcal{D}}(\mathbf{x}_j^{test})).$$

Condicionado al modelo ajustado,

$$\mathbb{E} [\widehat{R}_{test} \mid \mathcal{D}] = R(\widehat{f}_{\mathcal{D}}).$$

Por tanto, el error de prueba es un estimador insesgado del riesgo del modelo fijo, siempre que el conjunto de prueba sea independiente y no intervenga en decisiones previas.

División entrenamiento-validación-prueba

Una muestra puede dividirse en tres partes:

$$\mathcal{D} = \mathcal{D}_{train} \cup \mathcal{D}_{val} \cup \mathcal{D}_{test},$$

con intersecciones vacías.

Entrenamiento

Se utiliza para estimar parámetros.

Validación

Se utiliza para seleccionar:

- hiperparámetros;
- arquitectura;
- variables;
- umbrales;
- intensidad de regularización.

Prueba

Se utiliza una sola vez para estimar el desempeño final.

Proporciones de partición

No existe una proporción universal. Algunas opciones son:

- 60 % – 20 % – 20 %;
- 70 % – 15 % – 15 %;
- 80 % – 20 %, usando validación cruzada dentro del entrenamiento.

La elección depende de:

- tamaño total;
- complejidad del modelo;
- cantidad de hiperparámetros;
- prevalencia de clases;

- costo de obtener datos.

Partición aleatoria

En una partición aleatoria, cada observación tiene probabilidad de ser asignada a cada subconjunto.

Este procedimiento supone intercambiabilidad de las observaciones.

No debe utilizarse sin cuidado cuando existen:

- series de tiempo;
- datos agrupados;
- mediciones repetidas;
- pacientes con varias observaciones;
- dependencia espacial.

Partición estratificada

Definición 11.2. Una partición estratificada conserva aproximadamente la proporción de clases en cada subconjunto.

Si

$$\hat{p}_k = \frac{n_k}{n},$$

se busca que

$$\hat{p}_{k,train} \approx \hat{p}_{k,val} \approx \hat{p}_{k,test}.$$

Es especialmente importante en clases desbalanceadas.

Partición por grupos

Si varias observaciones pertenecen al mismo individuo, estación, empresa o unidad experimental, todas deben mantenerse dentro del mismo subconjunto.

De lo contrario, el modelo puede aprender características específicas del grupo y producir una evaluación artificialmente optimista.

Método holdout

El método holdout utiliza una sola partición:

$$\mathcal{D} = \mathcal{D}_{train} \cup \mathcal{D}_{test}.$$

Ventajas:

- simple;
- rápido;
- útil con muestras grandes.

Desventajas:

- alta dependencia de una sola partición;
- puede tener alta varianza;
- utiliza menos datos para entrenar.

Validación cruzada de K pliegues

Definición 11.3. La validación cruzada de K pliegues divide la muestra en subconjuntos

$$I_1, \dots, I_K$$

aproximadamente del mismo tamaño.

Para cada pliegue k :

1. se ajusta el modelo sin I_k ;
2. se evalúa sobre I_k .

Sea

$$\hat{f}^{(-k)}$$

el modelo entrenado sin el pliegue k .

El error es

$$CV_K = \frac{1}{n} \sum_{k=1}^K \sum_{i \in I_k} L(y_i, \hat{f}^{(-k)}(\mathbf{x}_i)).$$

Si los pliegues tienen igual tamaño,

$$CV_K = \frac{1}{K} \sum_{k=1}^K \hat{R}_k.$$

Interpretación

Cada observación se utiliza:

- una vez para validación;
- $K - 1$ veces como parte del entrenamiento.

Los valores habituales son

$$K = 5$$

o

$$K = 10.$$

Sesgo de validación cruzada

Cada modelo se entrena con

$$\frac{K-1}{K}n$$

observaciones.

Por tanto, CV_K estima el error de un modelo entrenado con menos observaciones que el modelo final.

Esto puede introducir un sesgo ligeramente pesimista.

Varianza de validación cruzada

Los errores de los pliegues no son independientes porque los conjuntos de entrenamiento se superponen.

Por ello, calcular la varianza como si fueran observaciones independientes puede subestimar la incertidumbre.

Validación cruzada repetida

Se repite la creación de pliegues B veces:

$$CV_{K,B} = \frac{1}{B} \sum_{b=1}^B CV_K^{(b)}.$$

La repetición reduce la dependencia respecto de una sola división.

Leave-one-out

Definición 11.4. Leave-one-out cross-validation corresponde a

$$K = n.$$

Cada modelo se entrena con $n - 1$ observaciones y se evalúa en una sola.

El estimador es

$$CV_{LOO} = \frac{1}{n} \sum_{i=1}^n L(y_i, \hat{f}^{(-i)}(\mathbf{x}_i)).$$

Ventajas y limitaciones de LOOCV

Ventajas:

- casi toda la muestra se usa para entrenar;
- bajo sesgo.

Limitaciones:

- puede tener alta varianza;
- alto costo computacional;
- los modelos ajustados son muy similares;
- no siempre supera a $K = 5$ o $K = 10$.

Validación cruzada estratificada

En clasificación, los pliegues deben preservar la proporción de clases.

Esto evita que algún pliegue carezca de observaciones de una clase minoritaria.

Validación cruzada agrupada

Cuando existen grupos, se dividen grupos completos, no observaciones individuales.

Se utiliza, por ejemplo, cuando hay:

- múltiples mediciones por paciente;
- observaciones por escuela;
- registros por estación;
- datos por empresa.

Validación cruzada para series de tiempo

En series temporales no debe mezclarse aleatoriamente pasado y futuro.

Una estrategia es la ventana creciente.

Para tiempos

$$1, \dots, T,$$

se realizan ajustes como:

$$\{1, \dots, t\} \rightarrow \{t + 1\}.$$

El error temporal es

$$CV_{time} = \frac{1}{M} \sum_{m=1}^M L(y_{t_m+1}, \hat{f}_{1:t_m}(\mathbf{x}_{t_m+1})).$$

Ventana deslizante

Se entrena con una ventana de longitud fija w :

$$\{t - w + 1, \dots, t\} \rightarrow \{t + 1\}.$$

Es útil cuando el proceso cambia con el tiempo.

Bootstrap

Definición 11.5. Una muestra bootstrap se obtiene seleccionando n observaciones con reemplazo de la muestra original.

Se denota por

$$\mathcal{D}^{*(b)}.$$

Cada muestra bootstrap contiene observaciones repetidas y deja fuera algunas observaciones originales.

Probabilidad de exclusión

La probabilidad de que una observación no sea seleccionada en una muestra bootstrap es

$$\left(1 - \frac{1}{n}\right)^n.$$

Cuando n es grande,

$$\left(1 - \frac{1}{n}\right)^n \approx e^{-1} \approx 0.368.$$

Por tanto, aproximadamente el 36.8 % de las observaciones queda fuera de cada muestra bootstrap.

Error out-of-bag

Las observaciones no seleccionadas forman el conjunto out-of-bag.

El modelo bootstrap se evalúa sobre esas observaciones.

Este principio se utiliza en random forest.

Estimador bootstrap del error

Para B muestras bootstrap,

$$\widehat{R}_{boot} = \frac{1}{B} \sum_{b=1}^B \widehat{R}_{OOB}^{(b)}.$$

Estimador .632

El estimador .632 combina error de entrenamiento y error out-of-bag:

$$\widehat{R}_{.632} = 0.368 \widehat{R}_{train} + 0.632 \widehat{R}_{OOB}.$$

La ponderación se relaciona con la proporción esperada de observaciones distintas presentes en una muestra bootstrap.

Bootstrap para incertidumbre

Además de estimar error, bootstrap puede aproximar la distribución de un estadístico.

Sea

$$T = T(\mathcal{D}).$$

Se calculan

$$T^{*(1)}, \dots, T^{*(B)}.$$

La varianza bootstrap es

$$\widehat{\text{Var}}_{boot}(T) = \frac{1}{B-1} \sum_{b=1}^B \left(T^{*(b)} - \bar{T}^* \right)^2.$$

Selección de hiperparámetros

Sea $\lambda \in \Lambda$ un hiperparámetro.

Para cada valor se estima

$$CV_K(\lambda).$$

Se selecciona

$$\hat{\lambda} = \arg \min_{\lambda \in \Lambda} CV_K(\lambda).$$

Después se reajusta el modelo usando toda la muestra de entrenamiento con $\hat{\lambda}$.

Búsqueda en rejilla

Se define una rejilla

$$\Lambda = \{\lambda_1, \dots, \lambda_M\}.$$

Se evalúa cada combinación.

Ventajas:

- sistemática;
- reproducible.

Desventajas:

- costosa en espacios grandes;
- ineficiente si muchos valores son irrelevantes.

Búsqueda aleatoria

Se seleccionan combinaciones aleatorias de hiperparámetros.

Puede ser más eficiente cuando solo algunas dimensiones tienen gran influencia.

Optimización bayesiana

Construye un modelo sustituto de la función

$$\lambda \mapsto CV(\lambda)$$

y utiliza una función de adquisición para elegir nuevas evaluaciones.

Es útil cuando cada entrenamiento es costoso.

Fuga de información

Definición 11.6. Existe fuga de información cuando el proceso de entrenamiento utiliza información que no estaría disponible al momento de realizar una predicción real.

Ejemplos:

- normalizar antes de dividir;
- imputar usando toda la base;
- seleccionar variables con todo el conjunto;
- usar el conjunto de prueba para ajustar el umbral;
- incluir variables creadas después del evento objetivo;
- mezclar observaciones del mismo paciente entre entrenamiento y prueba.

Preprocesamiento correcto

Toda transformación debe aprenderse únicamente en entrenamiento.

Por ejemplo, para estandarizar:

$$\tilde{x}_{ij} = \frac{x_{ij} - \hat{\mu}_{j,train}}{\hat{\sigma}_{j,train}}.$$

Los valores de validación y prueba se transforman usando las estadísticas del entrenamiento.

No deben recalcularse con cada conjunto.

Pipeline

Un pipeline integra:

1. imputación;
2. transformación;
3. selección de variables;
4. ajuste del modelo;
5. predicción.

Durante validación cruzada, todo el pipeline debe reajustarse dentro de cada pliegue.

Selección de variables dentro de la validación

Si la selección de variables se realiza antes de validar, el estimador del error queda sesgado.

El procedimiento correcto para cada pliegue es:

1. seleccionar variables usando solo entrenamiento interno;
2. ajustar el modelo;
3. evaluar en el pliegue retenido.

Validación cruzada anidada

Definición 11.7. La validación cruzada anidada utiliza un ciclo externo para estimar desempeño y un ciclo interno para seleccionar hiperparámetros.

Ciclo externo

Divide los datos en pliegues de evaluación.

Ciclo interno

Dentro del entrenamiento externo, selecciona hiperparámetros.

El error anidado es

$$CV_{nested} = \frac{1}{K_{ext}} \sum_{k=1}^{K_{ext}} \widehat{R}_k^{ext}.$$

Este procedimiento reduce el sesgo de selección.

Sesgo por selección

Si se prueban muchos modelos y se reporta el mejor valor de validación, el resultado tiende a ser optimista.

Esto ocurre porque se selecciona el mínimo entre estimaciones ruidosas:

$$\min_m \widehat{R}_m.$$

La validación anidada separa selección y evaluación.

Regla de un error estándar

Supóngase que λ_{min} minimiza el error medio.

La regla de un error estándar selecciona el modelo más simple cuyo error satisface

$$CV(\lambda) \leq CV(\lambda_{min}) + SE(\lambda_{min}).$$

Esta regla favorece modelos más parsimoniosos.

Comparación de modelos

Supóngase que se comparan modelos A y B .

En cada pliegue se calcula

$$d_k = R_{A,k} - R_{B,k}.$$

Una diferencia promedio negativa favorece a A :

$$\bar{d} = \frac{1}{K} \sum_{k=1}^K d_k.$$

Sin embargo, los pliegues no son independientes, por lo que las pruebas estadísticas deben interpretarse con cautela.

Prueba de McNemar

Para dos clasificadores evaluados sobre las mismas observaciones, se consideran:

- n_{01} : A falla y B acierta;
- n_{10} : A acierta y B falla.

El estadístico aproximado es

$$\chi^2 = \frac{(|n_{01} - n_{10}| - 1)^2}{n_{01} + n_{10}}.$$

Esta prueba analiza si los patrones de error difieren.

Intervalo para error de clasificación

Si el error observado es

$$\hat{p} = \frac{e}{m},$$

una aproximación del error estándar es

$$SE(\hat{p}) = \sqrt{\frac{\hat{p}(1 - \hat{p})}{m}}.$$

Una aproximación normal es

$$\hat{p} \pm z_{\alpha/2} SE(\hat{p}).$$

Para muestras pequeñas o proporciones extremas son preferibles métodos como Wilson.

Incertidumbre del error cuadrático medio

Para pérdidas

$$\ell_1, \dots, \ell_m,$$

el error medio es

$$\bar{\ell} = \frac{1}{m} \sum_{i=1}^m \ell_i.$$

Su error estándar aproximado es

$$SE(\bar{\ell}) = \frac{s_{\ell}}{\sqrt{m}},$$

si las observaciones de prueba son independientes.

Reproducibilidad

Un proceso reproducible debe registrar:

- semilla aleatoria;
- particiones;
- variables;
- transformaciones;
- hiperparámetros;
- métrica principal;
- software y versiones;
- procedimiento de selección.

Métrica principal

La métrica principal debe definirse antes de comparar modelos.

Ejemplos:

- RMSE en regresión;
- sensibilidad en detección médica;
- AUC en discriminación;
- F1 en clases desbalanceadas;
- pérdida logarítmica para probabilidades.

Elegir la métrica después de observar resultados puede introducir sesgo.

Evaluación en regresión

Error cuadrático medio

$$MSE = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2.$$

Raíz del error cuadrático medio

$$RMSE = \sqrt{MSE}.$$

Error absoluto medio

$$MAE = \frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i|.$$

Coeficiente de determinación

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}.$$

En prueba, R^2 puede ser negativo.

Evaluación en clasificación

La selección de métricas depende de:

- balance de clases;
- costo de errores;
- uso de probabilidades;
- objetivo operativo;
- umbral disponible.

No debe evaluarse un clasificador exclusivamente mediante exactitud cuando las clases están desbalanceadas.

Conexión con R

```
1 set.seed(123)
2
3 n <- 150
4 datos <- data.frame(
5   x1 = rnorm(n),
6   x2 = rnorm(n)
7 )
8
9 datos$y <- 2 + 1.5 * datos$x1 - datos$x2 + rnorm(n)
10
11 # Partición holdout
12 id_train <- sample(seq_len(n), size = 0.8 * n)
13
14 train <- datos[id_train, ]
15 test <- datos[-id_train, ]
16
17 modelo <- lm(y ~ x1 + x2, data = train)
```

```

18
19 pred <- predict(modelo, newdata = test)
20
21 rmse <- sqrt(mean((test$y - pred)^2))
22 mae <- mean(abs(test$y - pred))
23
24 rmse
25 mae

```

Ejemplo manual de validación cruzada

Considere seis observaciones divididas en tres pliegues:

$$I_1 = \{1, 2\}, \quad I_2 = \{3, 4\}, \quad I_3 = \{5, 6\}.$$

Los errores de validación son:

$$\widehat{R}_1 = 2.0, \quad \widehat{R}_2 = 3.5, \quad \widehat{R}_3 = 2.5.$$

Entonces,

$$CV_3 = \frac{2.0 + 3.5 + 2.5}{3} = \frac{8}{3} \approx 2.67.$$

Ejemplo de fuga de información

Supóngase que se estandariza una variable usando:

$$\hat{\mu}_{total} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Si esta media incluye observaciones de prueba, el entrenamiento utiliza indirectamente información futura.

La transformación correcta usa:

$$\hat{\mu}_{train} = \frac{1}{n_{train}} \sum_{i \in train} x_i.$$

Diseño recomendado de evaluación

Un procedimiento robusto puede ser:

1. separar un conjunto de prueba final;
2. definir una métrica principal;
3. construir un pipeline;
4. seleccionar hiperparámetros mediante validación cruzada;
5. reajustar con todo el entrenamiento;
6. evaluar una sola vez en prueba;

7. reportar incertidumbre y métricas complementarias.

Errores frecuentes

1. Reportar error de entrenamiento como desempeño final.
2. Usar el conjunto de prueba para seleccionar modelos.
3. Normalizar antes de dividir.
4. Seleccionar variables con toda la base.
5. Mezclar observaciones del mismo grupo entre entrenamiento y prueba.
6. Aleatorizar series de tiempo.
7. Comparar modelos usando particiones distintas.
8. Probar muchas configuraciones y reportar solo la mejor sin validación anidada.
9. Elegir la métrica después de ver resultados.
10. Omitir la incertidumbre de las estimaciones.

Ejercicios conceptuales

1. Explique la diferencia entre entrenamiento, validación y prueba.
2. ¿Por qué el error de entrenamiento es optimista?
3. ¿Qué ventaja ofrece la validación cruzada?
4. ¿Qué diferencia existe entre K -fold y LOOCV?
5. ¿Por qué debe utilizarse estratificación?
6. ¿Qué es fuga de información?
7. ¿Por qué el preprocesamiento debe realizarse dentro de cada pliegue?
8. ¿Qué problema resuelve la validación anidada?
9. ¿Qué significa la regla de un error estándar?
10. ¿Por qué no debe aleatorizarse una serie temporal?

Ejercicio de holdout

Una muestra contiene 1 000 observaciones.

1. Calcule los tamaños para una división 70 % – 15 % – 15 %.
2. Explique el uso de cada subconjunto.
3. Proponga una alternativa usando validación cruzada.
4. Analice qué ocurriría si solo existen 40 observaciones positivas.

Ejercicio de validación cruzada

Los errores de cinco pliegues son:

0.18, 0.22, 0.20, 0.25, 0.15.

Calcule:

1. el error medio;
2. la desviación estándar;

3. el error estándar aproximado;
4. un intervalo descriptivo de dos errores estándar.

Ejercicio bootstrap

Para $n = 100$:

1. calcule aproximadamente la proporción esperada de observaciones no seleccionadas;
2. calcule la cantidad esperada de observaciones out-of-bag;
3. explique cómo se estima el error OOB;
4. relacione este procedimiento con random forest.

Ejercicio de selección

Se obtienen los siguientes errores:

λ	Error CV	Error estándar
0.01	0.245	0.012
0.10	0.228	0.010
1.00	0.231	0.009
10.00	0.260	0.011

1. Seleccione el mínimo.
2. Aplique la regla de un error estándar.
3. Explique cuál modelo sería más simple si una penalización mayor implica mayor regularización.

Ejercicio de fuga de información

Analice los siguientes procedimientos e indique si existe fuga:

1. imputar antes de dividir;
2. seleccionar variables antes de validación cruzada;
3. ajustar el umbral usando prueba;
4. dividir pacientes, pero no observaciones;
5. calcular medias solo en entrenamiento y aplicarlas a prueba;
6. usar registros posteriores al diagnóstico para predecir el diagnóstico.

Ejercicio aplicado

Se desea comparar regresión logística, random forest y SVM para clasificar accidentes severos.

Diseñe un procedimiento que incluya:

1. partición;
2. estratificación;
3. métrica principal;
4. preprocesamiento;
5. selección de hiperparámetros;

6. validación anidada;
7. evaluación final;
8. comparación de errores;
9. reporte de incertidumbre;
10. prevención de fuga de información.

Resumen

En este capítulo se desarrollaron los fundamentos de evaluación y selección de modelos. Se distinguieron error de entrenamiento, validación, prueba y generalización.

También se estudiaron holdout, validación cruzada de K pliegues, leave-one-out, validación repetida, validación agrupada y evaluación temporal.

Finalmente, se introdujeron bootstrap, error out-of-bag, selección de hiperparámetros, validación anidada, fuga de información, pipelines, comparación de modelos y reproducibilidad. Estas herramientas son indispensables para obtener evaluaciones confiables y evitar conclusiones optimistas.

Referencias del capítulo

Los fundamentos se apoyan en Stone (1974), Efron (1983), Hastie et al. (2009) y James et al. (2021).

12 Regularización y control de la complejidad

Introducción

La regularización modifica el problema de ajuste para controlar la complejidad efectiva, estabilizar estimaciones y mejorar el desempeño fuera de muestra. Puede expresarse como penalización, restricción, parada temprana, reducción de dimensión o elección de una clase de hipótesis más pequeña (Tikhonov 1963; Tibshirani 1996; Hastie et al. 2009).

La regularización es una de las ideas centrales del aprendizaje automático moderno. Su propósito es controlar la complejidad de un modelo para mejorar su capacidad de generalización. En lugar de minimizar únicamente el error de entrenamiento, se añade una penalización que desalienta soluciones excesivamente flexibles, inestables o difíciles de interpretar.

La regularización puede entenderse desde distintos puntos de vista:

- como una penalización añadida a la función de pérdida;
- como una restricción sobre el tamaño de los parámetros;
- como una forma de reducir varianza;
- como una estrategia para combatir la multicolinealidad;
- como un mecanismo de selección de variables;
- como una forma de incorporar información previa.

En este capítulo se desarrollan formalmente ridge, LASSO y elastic net, así como sus interpretaciones geométricas y estadísticas.

! Definición esencial

Regularizar significa controlar la complejidad efectiva para reducir sobreajuste.

Objetivos

Al finalizar el capítulo, el lector podrá:

1. explicar por qué se utiliza regularización;
2. formular problemas penalizados;
3. relacionar penalización y restricción;
4. derivar el estimador ridge;
5. interpretar la penalización L_2 ;
6. formular el problema LASSO;
7. interpretar la penalización L_1 ;
8. comprender por qué LASSO produce coeficientes exactamente iguales a cero;
9. formular elastic net;
10. analizar el efecto del parámetro de regularización;
11. comprender la relación entre regularización, sesgo y varianza;

12. interpretar regularización desde un punto de vista bayesiano;
13. seleccionar λ mediante validación;
14. reconocer limitaciones y precauciones prácticas.

Motivación

Considere el modelo lineal

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon.$$

El estimador de mínimos cuadrados es

$$\hat{\beta}_{OLS} = \arg \min_{\beta} \|\mathbf{y} - \mathbf{X}\beta\|_2^2.$$

Si $\mathbf{X}^\top \mathbf{X}$ es invertible,

$$\hat{\beta}_{OLS} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

Sin embargo, este estimador puede presentar problemas cuando:

- existen variables altamente correlacionadas;
- p es grande;
- $p \geq n$;
- hay ruido considerable;
- el modelo tiene demasiada flexibilidad;
- se desea seleccionar variables.

Problemas de multicolinealidad

Cuando algunas columnas de $\mathbf{X}$ están altamente correlacionadas, la matriz

$$\mathbf{X}^\top \mathbf{X}$$

puede estar mal condicionada.

Esto provoca:

- coeficientes inestables;
- gran varianza;
- sensibilidad a pequeñas perturbaciones;
- signos difíciles de interpretar;
- predicciones poco robustas.

Problema penalizado general

Definición 12.1. Un problema de regularización tiene la forma

$$\hat{\beta} = \arg \min_{\beta} \{L(\beta) + \lambda \Omega(\beta)\},$$

donde:

- $L(\beta)$ es la pérdida;
- $\Omega(\beta)$ mide complejidad;
- $\lambda \geq 0$ controla la intensidad de regularización.

Cuando

$$\lambda = 0,$$

se recupera el modelo sin penalización.

Cuando λ aumenta, la penalización adquiere mayor peso.

Interpretación del parámetro de regularización

Un valor pequeño de λ :

- permite mayor flexibilidad;
- reduce sesgo;
- puede aumentar varianza.

Un valor grande:

- reduce la magnitud de los coeficientes;
- aumenta estabilidad;
- puede aumentar sesgo;
- puede producir subajuste.

Formulación restringida

El problema penalizado puede relacionarse con

$$\min_{\beta} L(\beta)$$

sujeto a

$$\Omega(\beta) \leq t.$$

Existe una correspondencia entre λ y t , bajo condiciones regulares.

La forma penalizada utiliza λ ; la forma restringida limita directamente la complejidad.

Regresión ridge

Definición 12.2. La regresión ridge minimiza

$$J_{ridge}(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_2^2.$$

La penalización es

$$\|\beta\|_2^2 = \sum_{j=1}^p \beta_j^2.$$

Habitualmente el intercepto no se penaliza.

Forma matricial de ridge

La función objetivo puede escribirse como

$$J_{ridge}(\beta) = (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta) + \lambda \beta^\top \beta.$$

Derivación del estimador ridge

Derivando respecto de β ,

$$\nabla J_{ridge} = -2\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\beta) + 2\lambda\beta.$$

Igualando a cero,

$$-2\mathbf{X}^\top \mathbf{y} + 2\mathbf{X}^\top \mathbf{X}\beta + 2\lambda\beta = \mathbf{0}.$$

Entonces,

$$(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}) \beta = \mathbf{X}^\top \mathbf{y}.$$

Por tanto,

$$\hat{\beta}_{ridge} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}.$$

Efecto sobre la invertibilidad

Incluso si

$$\mathbf{X}^\top \mathbf{X}$$

es singular, para $\lambda > 0$,

$$\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}$$

es definida positiva y, por tanto, invertible.

Esta es una ventaja fundamental de ridge.

Interpretación espectral

Supóngase que

$$\mathbf{X}^T \mathbf{X} = \mathbf{Q} \Lambda \mathbf{Q}^T,$$

donde

$$\Lambda = \text{diag}(\mu_1, \dots, \mu_p).$$

Entonces,

$$(\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} = \mathbf{Q} \text{diag} \left(\frac{1}{\mu_j + \lambda} \right) \mathbf{Q}^T.$$

Ridge reduce con mayor intensidad las direcciones asociadas a valores propios pequeños.

Factores de contracción

En las coordenadas principales, el factor de contracción es

$$\frac{\mu_j}{\mu_j + \lambda}.$$

Se cumple

$$0 \leq \frac{\mu_j}{\mu_j + \lambda} < 1.$$

Cuando μ_j es pequeño, la contracción es mayor.

Sesgo de ridge

Condicionado a $\mathbf{X}$,

$$\mathbb{E}[\hat{\beta}_{ridge}] = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{X} \beta.$$

Por tanto, ridge es sesgado cuando $\lambda > 0$.

Varianza de ridge

Si

$$\text{Var}(\varepsilon) = \sigma^2 \mathbf{I},$$

entonces

$$\text{Var}(\hat{\beta}_{ridge}) = \sigma^2 (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{X} (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1}.$$

Ridge introduce sesgo, pero puede reducir considerablemente la varianza.

Ridge y el compromiso sesgo-varianza

El error cuadrático medio de los parámetros puede disminuir si la reducción de varianza compensa el aumento de sesgo.

Esta es la razón estadística de la regularización.

Geometría de ridge

La forma restringida es

$$\min_{\beta} \|\mathbf{y} - \mathbf{X}\beta\|_2^2$$

sujeto a

$$\sum_{j=1}^p \beta_j^2 \leq t.$$

La región factible es una esfera o circunferencia L_2 .

La solución aparece donde una curva de nivel de la pérdida toca la región restringida.

Estandarización

Ridge depende de la escala de las variables.

Antes de ajustar, suele utilizarse

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}.$$

Sin estandarización, las variables con escalas grandes reciben una penalización relativa diferente.

LASSO

Definición 12.3. LASSO minimiza

$$J_{lasso}(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_1.$$

La norma L_1 es

$$\|\beta\|_1 = \sum_{j=1}^p |\beta_j|.$$

Forma restringida de LASSO

$$\min_{\beta} \|\mathbf{y} - \mathbf{X}\beta\|_2^2$$

sujeto a

$$\sum_{j=1}^p |\beta_j| \leq t.$$

No diferenciabilidad

La función

$$|\beta|$$

no es diferenciable en

$$\beta = 0.$$

Por tanto, LASSO no posee una solución matricial cerrada análoga a ridge.

Se utilizan métodos como:

- descenso por coordenadas;
- subgradientes;
- LARS;
- métodos proximales.

Subgradiente

Para

$$g(\beta) = |\beta|,$$

el subgradiente es

$$\partial g(\beta) = \begin{cases} \{1\}, & \beta > 0, \\ [-1, 1], & \beta = 0, \\ \{-1\}, & \beta < 0. \end{cases}$$

Las condiciones óptimas se expresan mediante subgradientes.

Operador soft-thresholding

Definición 12.4. El operador de umbral suave se define como

$$S(z, \gamma) = \text{sign}(z) \max\{|z| - \gamma, 0\}.$$

Este operador reduce la magnitud y puede producir exactamente cero.

Caso ortonormal

Si

$$\mathbf{X}^\top \mathbf{X} = \mathbf{I},$$

la solución LASSO tiene la forma

$$\hat{\beta}_j = S\left(\hat{\beta}_{j,OLS}, \frac{\lambda}{2}\right),$$

según la convención de escala utilizada.

Geometría de LASSO

La región

$$\|\beta\|_1 \leq t$$

tiene forma de rombo en dos dimensiones.

Sus vértices están sobre los ejes coordenados. Las curvas de nivel de la pérdida tienen mayor probabilidad de tocar un vértice.

Por ello, LASSO produce coeficientes exactamente iguales a cero.

Selección de variables

Si

$$\hat{\beta}_j = 0,$$

la variable j queda excluida del modelo.

LASSO realiza simultáneamente:

- ajuste;
- contracción;
- selección de variables.

Limitaciones de LASSO

LASSO puede presentar dificultades cuando:

- las variables están fuertemente correlacionadas;
- $p \gg n$;
- existen grupos de variables similares;
- la señal está distribuida entre muchas variables pequeñas.

En grupos correlacionados, puede seleccionar una variable y excluir otras de forma inestable.

Elastic net

Definición 12.5. Elastic net combina penalizaciones L_1 y L_2 :

$$J_{EN}(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda_1 \|\beta\|_1 + \lambda_2 \|\beta\|_2^2.$$

Otra parametrización es

$$J_{EN}(\beta) = L(\beta) + \lambda \left[\alpha \|\beta\|_1 + (1 - \alpha) \|\beta\|_2^2 \right],$$

con

$$0 \leq \alpha \leq 1.$$

Casos particulares

Si

$$\alpha = 1,$$

se obtiene LASSO.

Si

$$\alpha = 0,$$

se obtiene ridge.

Si

$$0 < \alpha < 1,$$

se obtiene elastic net.

Ventaja de elastic net

Elastic net puede:

- seleccionar variables;
- estabilizar grupos correlacionados;
- funcionar mejor cuando $p > n$;
- combinar esparsidad y estabilidad.

Caminos de regularización

Al variar λ , se obtiene una trayectoria

$$\hat{\beta}(\lambda).$$

Cuando $\lambda \rightarrow 0$, la solución se aproxima al modelo no regularizado.

Cuando $\lambda \rightarrow \infty$, los coeficientes tienden a cero.

Valor máximo del parámetro de regularización

En LASSO existe un valor suficientemente grande

$$\lambda_{\max}$$

para el cual todos los coeficientes penalizados son cero.

Los algoritmos suelen construir una secuencia decreciente desde $\lambda_{\max}$.

Selección del parámetro de regularización

La práctica habitual es seleccionar λ mediante validación cruzada:

$$\hat{\lambda} = \arg \min_{\lambda} CV(\lambda).$$

También puede utilizarse la regla de un error estándar para elegir una solución más regularizada y parsimoniosa.

Ridge como estimación bayesiana

Supóngase el modelo gaussiano

$$\mathbf{y} \mid \beta \sim N(\mathbf{X}\beta, \sigma^2 \mathbf{I}).$$

Considérese la previa

$$\beta \sim N(\mathbf{0}, \tau^2 \mathbf{I}).$$

El estimador MAP minimiza

$$\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \frac{1}{2\tau^2} \|\beta\|_2^2.$$

Por tanto, ridge corresponde a una previa normal.

LASSO como estimación bayesiana

Si la previa de cada coeficiente es Laplace,

$$p(\beta_j) \propto \exp\left(-\frac{|\beta_j|}{b}\right),$$

el estimador MAP conduce a una penalización L_1 .

Regularización en regresión logística

La pérdida logística penalizada es

$$J(\beta) = - \sum_{i=1}^n [y_i \log \pi_i + (1 - y_i) \log(1 - \pi_i)] + \lambda \Omega(\beta).$$

Puede utilizarse:

- ridge;
- LASSO;
- elastic net.

Regularización en redes neuronales

Weight decay

Se añade

$$\lambda \sum_l \|\mathbf{w}^{(l)}\|_F^2.$$

Dropout

Durante el entrenamiento, algunas activaciones se eliminan aleatoriamente.

Early stopping

Se detiene el entrenamiento cuando el error de validación deja de mejorar.

Data augmentation

Se generan transformaciones de los datos para reducir sobreajuste.

Regularización en árboles

En árboles, el control de complejidad se realiza mediante:

- profundidad máxima;
- número mínimo de observaciones por nodo;
- poda;
- penalización por número de hojas.

La regularización no siempre adopta la forma de una norma.

Regularización explícita e implícita

La regularización explícita aparece directamente en la función objetivo.

La regularización implícita puede provenir de:

- optimización;
- arquitectura;

- inicialización;
- detención temprana;
- ruido en el entrenamiento.

Grados de libertad efectivos

En ridge, los valores ajustados son

$$\hat{\mathbf{y}} = \mathbf{H}_\lambda \mathbf{y},$$

donde

$$\mathbf{H}_\lambda = \mathbf{X} (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top.$$

Los grados de libertad efectivos son

$$df(\lambda) = \text{tr}(\mathbf{H}_\lambda).$$

Al aumentar λ , disminuyen los grados de libertad efectivos.

Relación con la estabilidad

Un algoritmo es estable si pequeñas modificaciones de la muestra producen cambios pequeños en el modelo.

Ridge suele aumentar estabilidad al evitar coeficientes extremos.

La estabilidad contribuye a reducir la brecha de generalización.

Variables categóricas

Cuando una variable categórica se codifica con varias variables indicadoras, penalizar cada coeficiente por separado puede ser inadecuado.

Pueden utilizarse extensiones como:

- group LASSO;
- sparse group LASSO.

Group LASSO

Si los parámetros se agrupan en G bloques,

$$\beta_1, \dots, \beta_G,$$

la penalización es

$$\sum_{g=1}^G w_g \|\beta_g\|_2.$$

Puede eliminar grupos completos de variables.

Regularización adaptativa

Adaptive LASSO utiliza pesos:

$$\sum_{j=1}^p w_j |\beta_j|.$$

Los pesos pueden depender de estimaciones iniciales.

Esto permite penalizar menos los coeficientes aparentemente importantes.

Regularización y causalidad

La selección de variables predictivas no equivale a identificar variables causales.

Un coeficiente cero puede deberse a:

- correlación con otras variables;
- penalización;
- falta de potencia;
- estructura de la muestra.

La regularización mejora predicción, pero no resuelve por sí sola problemas causales.

Conexión con R

```
1 # Requiere glmnet
2 library(glmnet)
3
4 set.seed(123)
5
6 n <- 100
7 p <- 10
8
9 X <- matrix(rnorm(n * p), nrow = n, ncol = p)
10
11 beta_real <- c(3, -2, 1.5, rep(0, p - 3))
12
13 y <- as.vector(X %*% beta_real + rnorm(n))
14
15 # Ridge: alpha = 0
16 ajuste_ridge <- cv.glmnet(
17   X,
18   y,
19   alpha = 0
20 )
21
22 ajuste_ridge$lambda.min
23
```

```

24 # LASSO: alpha = 1
25 ajuste_lasso <- cv.glmnet(
26   X,
27   y,
28   alpha = 1
29 )
30
31 ajuste_lasso$lambda.min
32
33 coef(ajuste_lasso, s = "lambda.min")
34
35 # Elastic net
36 ajuste_en <- cv.glmnet(
37   X,
38   y,
39   alpha = 0.5
40 )
41
42 coef(ajuste_en, s = "lambda.1se")

```

Ejemplo numérico ridge

Considere

$$\mathbf{X}^T \mathbf{X} = \begin{pmatrix} 4 & 3 \\ 3 & 2.5 \end{pmatrix},$$

y

$$\mathbf{X}^T \mathbf{y} = \begin{pmatrix} 10 \\ 8 \end{pmatrix}.$$

Con

$$\lambda = 1,$$

se obtiene

$$\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I} = \begin{pmatrix} 5 & 3 \\ 3 & 3.5 \end{pmatrix}.$$

La solución ridge es

$$\hat{\beta}_{ridge} = \begin{pmatrix} 5 & 3 \\ 3 & 3.5 \end{pmatrix}^{-1} \begin{pmatrix} 10 \\ 8 \end{pmatrix}.$$

Este sistema es más estable que el sistema sin penalización.

Comparación conceptual

Método	Penalización	Selección de variables	Estabilidad
Ridge	L_2	No exacta	Alta
LASSO	L_1	Sí	Puede ser inestable con correlación
Elastic net	$L_1 + L_2$	Sí	Mayor con variables correlacionadas

Errores frecuentes

1. Penalizar variables sin estandarizarlas.
2. Penalizar el intercepto sin intención.
3. Seleccionar λ usando el conjunto de prueba.
4. Interpretar coeficientes LASSO como evidencia causal.
5. Suponer que LASSO siempre selecciona la variable correcta.
6. Confundir coeficiente pequeño con irrelevancia absoluta.
7. Ignorar la inestabilidad entre variables correlacionadas.
8. Comparar soluciones obtenidas con escalas distintas.
9. Utilizar regularización sin recalibrar el modelo cuando sea necesario.
10. Reportar únicamente λ_{min} sin considerar parsimonia.

Ejercicios conceptuales

1. Explique por qué ridge introduce sesgo.
2. ¿Cómo puede un estimador sesgado tener menor error cuadrático medio?
3. ¿Por qué ridge ayuda con multicolinealidad?
4. ¿Por qué LASSO produce coeficientes cero?
5. Explique la diferencia geométrica entre L_1 y L_2 .
6. ¿Qué ventaja ofrece elastic net?
7. ¿Por qué es necesaria la estandarización?
8. ¿Qué relación existe entre ridge y una previa normal?
9. ¿Qué relación existe entre LASSO y una previa Laplace?
10. Explique la diferencia entre regularización explícita e implícita.

Ejercicio de derivación ridge

Considere

$$J(\beta) = (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta) + \lambda \beta^\top \beta.$$

1. Expanda la expresión.
2. Calcule el gradiente.
3. Iguale a cero.
4. Obtenga la solución ridge.
5. Explique por qué la matriz resultante es invertible para $\lambda > 0$.

Ejercicio de soft-thresholding

Calcule

$$S(z, \gamma)$$

para:

1. $z = 5, \gamma = 2$;
2. $z = -4, \gamma = 1.5$;
3. $z = 1, \gamma = 2$;
4. $z = -0.5, \gamma = 0.5$.

Interprete cuándo el resultado es cero.

Ejercicio de validación

Se obtienen los siguientes errores:

λ	Error CV
0.001	4.80
0.01	4.20
0.10	3.95
1.00	4.05
10.00	5.30

1. Seleccione λ .
2. Explique qué ocurre en valores muy pequeños.
3. Explique qué ocurre en valores muy grandes.
4. Relacione el patrón con sesgo y varianza.

Ejercicio comparativo

Supóngase que existen 50 variables altamente correlacionadas y solo 80 observaciones.

Compare:

1. mínimos cuadrados;
2. ridge;
3. LASSO;
4. elastic net.

Indique ventajas y limitaciones de cada uno.

Ejercicio aplicado

Se desea predecir PM10 utilizando 40 variables meteorológicas y derivadas.

1. Explique por qué puede existir multicolinealidad.
2. Proponga un esquema de estandarización.

3. Defina un modelo ridge.
4. Defina un modelo LASSO.
5. Defina un modelo elastic net.
6. Diseñe la selección de λ y α .
7. Explique qué métricas usaría.
8. Indique cómo evitaría fuga de información.
9. Explique cómo interpretaría los coeficientes.
10. Señale por qué la selección no implica causalidad.

Resumen

En este capítulo se estudió la regularización como mecanismo para controlar complejidad, reducir varianza y mejorar estabilidad.

Se derivó el estimador ridge y se analizó su efecto espectral. También se formuló LASSO mediante penalización L_1 , se introdujeron subgradientes y soft-thresholding, y se explicó su capacidad de selección de variables.

Finalmente, se desarrolló elastic net, la interpretación bayesiana, los caminos de regularización, la selección de λ y extensiones como group LASSO. Estos conceptos serán fundamentales en regresión, clasificación y redes neuronales.

Referencias del capítulo

Los fundamentos se apoyan en Tikhonov (1963), Tibshirani (1996), Hastie et al. (2009) y Bishop (2006).

Parte III

III. Modelos de regresión

13 Regresión lineal simple

Introducción

La regresión lineal simple modela la relación media entre una variable respuesta cuantitativa y un predictor. La recta ajustada describe una asociación estadística; por sí sola no establece causalidad (Montgomery et al. 2021; Seber y Lee 2012; James et al. 2021).

La regresión lineal simple estudia la relación entre una variable explicativa X y una variable respuesta Y . Su propósito es modelar cómo cambia, en promedio, la respuesta cuando cambia la variable explicativa.

Aunque se trata de uno de los modelos más sencillos, constituye la base conceptual de métodos más avanzados. En este capítulo se desarrollan la formulación probabilística, la estimación por mínimos cuadrados, las propiedades de los estimadores, la inferencia sobre los parámetros, los intervalos de confianza y predicción, el coeficiente de determinación y el análisis de residuos.

! Definición esencial

La regresión lineal simple modela la media de una respuesta con un predictor.

Objetivos

Al finalizar el capítulo, el lector podrá:

1. formular el modelo de regresión lineal simple;
2. interpretar los parámetros β_0 y β_1 ;
3. derivar los estimadores de mínimos cuadrados;
4. interpretar geométricamente el ajuste;
5. demostrar propiedades de insesgadez;
6. calcular varianzas de los estimadores;
7. formular pruebas de hipótesis para la pendiente;
8. construir intervalos de confianza;
9. construir intervalos de predicción;
10. interpretar R^2 ;
11. analizar residuos;
12. reconocer violaciones de supuestos;
13. relacionar la regresión lineal con el aprendizaje supervisado.

Formulación del modelo

Sean observaciones

$$(x_i, y_i), \quad i = 1, \dots, n.$$

El modelo de regresión lineal simple es

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i.$$

Aquí:

- β_0 es el intercepto;
- β_1 es la pendiente;
- ε_i es el error aleatorio.

Interpretación de los parámetros

Intercepto

$$\beta_0$$

representa el valor esperado de Y cuando

$$X = 0.$$

Esta interpretación solo es útil si $X = 0$ tiene sentido dentro del contexto del problema.

Pendiente

$$\beta_1$$

representa el cambio promedio esperado en Y por cada unidad adicional de X .

Formalmente,

$$\mathbb{E}(Y \mid X = x) = \beta_0 + \beta_1 x.$$

Por tanto,

$$\frac{d}{dx} \mathbb{E}(Y \mid X = x) = \beta_1.$$

Supuestos clásicos

Se supone:

Linealidad

$$\mathbb{E}(Y_i \mid x_i) = \beta_0 + \beta_1 x_i.$$

Media cero de los errores

$$\mathbb{E}(\varepsilon_i \mid x_i) = 0.$$

Varianza constante

$$\text{Var}(\varepsilon_i \mid x_i) = \sigma^2.$$

Independencia

$$\text{Cov}(\varepsilon_i, \varepsilon_j) = 0, \quad i \neq j.$$

Normalidad

Para inferencia exacta,

$$\varepsilon_i \sim N(0, \sigma^2).$$

La normalidad no es necesaria para obtener los estimadores de mínimos cuadrados, pero sí para ciertas pruebas e intervalos exactos en muestras pequeñas.

Función de regresión

La función de regresión poblacional es

$$m(x) = \mathbb{E}(Y \mid X = x) = \beta_0 + \beta_1 x.$$

La recta ajustada es

$$\widehat{m}(x) = \hat{\beta}_0 + \hat{\beta}_1 x.$$

Criterio de mínimos cuadrados

Los residuos son

$$e_i = y_i - \hat{y}_i,$$

donde

$$\hat{y}_i = \beta_0 + \beta_1 x_i.$$

La suma de cuadrados residual es

$$S(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2.$$

Los estimadores de mínimos cuadrados son

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{\beta_0, \beta_1} S(\beta_0, \beta_1).$$

Derivación de las ecuaciones normales

Derivando respecto de β_0 ,

$$\frac{\partial S}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i).$$

Igualando a cero,

$$\sum_{i=1}^n y_i = n\beta_0 + \beta_1 \sum_{i=1}^n x_i.$$

Derivando respecto de β_1 ,

$$\frac{\partial S}{\partial \beta_1} = -2 \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i).$$

Igualando a cero,

$$\sum_{i=1}^n x_i y_i = \beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2.$$

Estas son las ecuaciones normales.

Estimador de la pendiente

Defina

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2,$$

$$S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

Entonces,

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}.$$

Estimador del intercepto

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

Por tanto, la recta ajustada pasa por el punto

$$(\bar{x}, \bar{y}).$$

Relación con covarianza y varianza

La pendiente puede escribirse como

$$\hat{\beta}_1 = \frac{\widehat{\text{Cov}}(X, Y)}{\widehat{\text{Var}}(X)}.$$

También,

$$\hat{\beta}_1 = r_{XY} \frac{s_Y}{s_X},$$

donde r_{XY} es la correlación muestral.

Interpretación geométrica

El vector de respuestas es

$$\mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}.$$

El espacio generado por

$$\mathbf{1} = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}$$

y

$$\mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$$

es un subespacio de $\mathbb{R}^n$.

El vector ajustado

$$\hat{\mathbf{y}}$$

es la proyección ortogonal de $\mathbf{y}$ sobre ese subespacio.

Por tanto,

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}$$

es ortogonal a $\mathbf{1}$ y a $\mathbf{x}$.

Propiedades de los residuos

De las ecuaciones normales se obtiene:

$$\sum_{i=1}^n e_i = 0,$$

$$\sum_{i=1}^n x_i e_i = 0,$$

y

$$\sum_{i=1}^n \hat{y}_i e_i = 0.$$

Además,

$$\bar{\hat{y}} = \bar{y}.$$

Insesgadez de la pendiente

Como

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x}) Y_i}{S_{xx}},$$

y

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i,$$

se obtiene

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) \varepsilon_i}{S_{xx}}.$$

Tomando esperanza,

$$\mathbb{E}(\hat{\beta}_1) = \beta_1.$$

Por tanto, $\hat{\beta}_1$ es insesgado.

Insesgadez del intercepto

Como

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x},$$

entonces

$$\mathbb{E}(\hat{\beta}_0) = \beta_0.$$

Varianza de la pendiente

Bajo homocedasticidad e independencia,

$$\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}.$$

La varianza disminuye cuando:

- aumenta n ;
- aumenta la dispersión de X ;
- disminuye σ^2 .

Varianza del intercepto

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right].$$

Covarianza entre estimadores

$$\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = -\frac{\bar{x}\sigma^2}{S_{xx}}.$$

Si X se centra, es decir,

$$z_i = x_i - \bar{x},$$

entonces la covarianza entre intercepto y pendiente se reduce a cero.

Teorema de Gauss-Markov

Teorema 13.1. *Bajo linealidad, media cero, homocedasticidad e independencia, los estimadores de mínimos cuadrados son los mejores estimadores lineales insesgados.*

La palabra “mejores” significa que tienen mínima varianza dentro de la clase de estimadores lineales insesgados.

La normalidad no es necesaria para este resultado.

Estimación de la varianza del error

La suma de cuadrados residual es

$$SSE = \sum_{i=1}^n e_i^2.$$

El estimador insesgado de σ^2 es

$$s^2 = MSE = \frac{SSE}{n-2}.$$

Se utilizan $n - 2$ grados de libertad porque se estimaron dos parámetros.

Error estándar residual

$$s = \sqrt{\frac{SSE}{n-2}}.$$

Este valor estima la desviación estándar de los errores.

Distribución de los estimadores

Si los errores son normales,

$$\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{S_{xx}}\right).$$

Además,

$$\frac{\hat{\beta}_1 - \beta_1}{s/\sqrt{S_{xx}}} \sim t_{n-2}.$$

Error estándar de la pendiente

$$SE(\hat{\beta}_1) = \frac{s}{\sqrt{S_{xx}}}.$$

Error estándar del intercepto

$$SE(\hat{\beta}_0) = s\sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}}.$$

Prueba de hipótesis para la pendiente

Se desea contrastar

$$H_0 : \beta_1 = 0$$

contra

$$H_1 : \beta_1 \neq 0.$$

El estadístico es

$$t = \frac{\hat{\beta}_1}{SE(\hat{\beta}_1)}.$$

Bajo H_0 ,

$$t \sim t_{n-2}.$$

Si el valor p es pequeño, existe evidencia de asociación lineal.

Interpretación correcta

Rechazar

$$H_0 : \beta_1 = 0$$

indica evidencia de relación lineal, no necesariamente causalidad.

Una pendiente no significativa no demuestra ausencia total de relación; puede existir:

- relación no lineal;
- poca potencia;
- medición deficiente;
- rango limitado de X .

Intervalo de confianza para la pendiente

Un intervalo de nivel $1 - \alpha$ es

$$\hat{\beta}_1 \pm t_{\alpha/2, n-2} SE(\hat{\beta}_1).$$

Intervalo de confianza para el intercepto

$$\hat{\beta}_0 \pm t_{\alpha/2, n-2} SE(\hat{\beta}_0).$$

Estimación de la respuesta media

En un valor x_0 ,

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0.$$

Su error estándar es

$$SE(\hat{y}_0^{mean}) = s \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}.$$

Intervalo de confianza para la media

$$\hat{y}_0 \pm t_{\alpha/2, n-2} s \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}.$$

Intervalo de predicción

Para una nueva observación,

$$Y_{new} = \beta_0 + \beta_1 x_0 + \varepsilon_{new}.$$

El error estándar es

$$SE(\hat{y}_0^{pred}) = s \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}.$$

El intervalo de predicción es

$$\hat{y}_0 \pm t_{\alpha/2, n-2} s \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}.$$

Es más ancho que el intervalo para la media.

Descomposición de la variabilidad

La suma total de cuadrados es

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2.$$

La suma explicada es

$$SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2.$$

La suma residual es

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

Se cumple

$$SST = SSR + SSE.$$

i Interpretación de la pendiente

La pendiente representa el cambio esperado en la respuesta por una unidad adicional del predictor, dentro del rango observado. No debe extrapolarse automáticamente.

Coeficiente de determinación

Definición 13.1. El coeficiente de determinación es

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}.$$

En regresión lineal simple con intercepto,

$$R^2 = r_{XY}^2.$$

Interpretación del coeficiente de determinación

R^2 representa la proporción de variabilidad de Y explicada por el modelo lineal.

No indica:

- causalidad;
- ausencia de sesgo;
- validez de supuestos;
- capacidad predictiva futura;
- calidad absoluta del modelo.

Tabla ANOVA

La descomposición puede organizarse como:

Fuente	Suma de cuadrados	gl	Cuadrado medio
Regresión	SSR	1	$MSR = SSR$
Error	SSE	$n - 2$	$MSE = SSE/(n - 2)$
Total	SST	$n - 1$	

El estadístico es

$$F = \frac{MSR}{MSE}.$$

En regresión simple,

$$F = t^2$$

para la prueba de la pendiente.

Residuos

Los residuos son

$$e_i = y_i - \hat{y}_i.$$

Se utilizan para evaluar los supuestos.

Residuos estandarizados

Una versión básica es

$$r_i = \frac{e_i}{s}.$$

Sin embargo, las varianzas de los residuos no son iguales porque dependen del apalancamiento.

Matriz sombrero

En forma matricial,

$$\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}.$$

La matriz

$$\mathbf{H} = \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T$$

se denomina matriz sombrero.

Apalancamiento

Los elementos diagonales

$$h_{ii}$$

miden apalancamiento.

En regresión simple,

$$h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}.$$

Observaciones alejadas de $\bar{x}$ tienen mayor apalancamiento.

Varianza de los residuos

$$\text{Var}(e_i) = \sigma^2(1 - h_{ii}).$$

Por ello, los residuos estandarizados internamente son

$$r_i = \frac{e_i}{s\sqrt{1 - h_{ii}}}.$$

Residuos studentizados

Los residuos studentizados externamente utilizan una estimación de σ obtenida sin la observación i .

Son útiles para detectar valores atípicos.

Distancia de Cook

La distancia de Cook mide la influencia de una observación sobre el ajuste:

$$D_i = \frac{e_i^2}{ps^2} \frac{h_{ii}}{(1 - h_{ii})^2},$$

donde $p = 2$ en regresión simple con intercepto.

Una observación puede ser influyente si combina:

- residuo grande;
- apalancamiento alto.

Diagnóstico de linealidad

Se examina la gráfica:

$$e_i \quad \text{contra} \quad \hat{y}_i.$$

Un patrón curvo sugiere relación no lineal.

Diagnóstico de homocedasticidad

Si la dispersión de residuos aumenta o disminuye con $\hat{y}$, puede existir heterocedasticidad.

Diagnóstico de normalidad

Puede utilizarse:

- histograma;
- gráfico Q-Q;
- pruebas formales.

En muestras grandes, pequeñas desviaciones pueden resultar significativas sin ser importantes en la práctica.

Diagnóstico de independencia

En datos ordenados temporalmente se analizan:

- residuos contra tiempo;
- autocorrelaciones;
- prueba de Durbin-Watson.

Heterocedasticidad

Si

$$\text{Var}(\varepsilon_i \mid x_i) = \sigma_i^2,$$

la varianza no es constante.

Los estimadores de mínimos cuadrados pueden seguir siendo insesgados, pero los errores estándar clásicos pueden ser incorrectos.

Errores estándar robustos

Los errores estándar robustos corrigen la estimación de varianza sin modificar los coeficientes.

Son útiles cuando existe heterocedasticidad.

Transformaciones

Una transformación puede ayudar a:

- linealizar;
- estabilizar varianza;
- reducir asimetría.

Ejemplos:

$$\log(Y), \quad \sqrt{Y}, \quad \log(X).$$

La interpretación de los coeficientes cambia.

Extrapolación

Predecir fuera del rango observado de X puede ser peligroso.

Aunque la recta se extienda matemáticamente, la relación real puede cambiar.

Correlación y regresión

En regresión simple,

$$\hat{\beta}_1 = r \frac{s_Y}{s_X}.$$

Sin embargo:

- la correlación es simétrica;
- la regresión distingue respuesta y predictor;
- cambiar unidades afecta la pendiente;
- la correlación no cambia ante cambios lineales de escala positiva.

Regresión y causalidad

Una asociación lineal no implica causalidad.

Pueden existir:

- variables omitidas;
- causalidad inversa;
- confusión;
- selección de muestra;
- coincidencia.

Relación con máxima verosimilitud

Si

$$\varepsilon_i \sim N(0, \sigma^2),$$

la verosimilitud es

$$L(\beta_0, \beta_1, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^2} \right].$$

Maximizar esta verosimilitud respecto de β_0 y β_1 equivale a minimizar

$$\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2.$$

Por tanto, mínimos cuadrados y máxima verosimilitud coinciden bajo normalidad.

Relación con aprendizaje supervisado

El espacio de hipótesis es

$$\mathcal{F} = \{f(x) = \beta_0 + \beta_1 x\}.$$

La pérdida es

$$L(y, f(x)) = (y - f(x))^2.$$

El riesgo empírico es

$$\widehat{R}_n(f) = \frac{1}{n} \sum_{i=1}^n (y_i - f(x_i))^2.$$

La regresión lineal simple es, por tanto, un problema de minimización del riesgo empírico.

Conexión con R

```

1  datos <- data.frame(
2    temperatura = c(18, 20, 22, 24, 26, 28),
3    pm10 = c(35, 39, 44, 50, 57, 63)
4  )
5
6  modelo <- lm(
7    pm10 ~ temperatura,
8    data = datos
9  )
10
11 summary(modelo)
12
13 coef(modelo)
14
15 confint(modelo)
16
17 predict(
18   modelo,
19   newdata = data.frame(temperatura = 25),
20   interval = "confidence"
21 )
22
23 predict(
24   modelo,
25   newdata = data.frame(temperatura = 25),
26   interval = "prediction"
27 )
28
29 par(mfrow = c(2, 2))
30 plot(modelo)

```

Ejemplo numérico

Considere:

x_i	y_i
1	2
2	3
3	5
4	6

Se tiene

$$\bar{x} = 2.5, \quad \bar{y} = 4.$$

Además,

$$S_{xx} = (1 - 2.5)^2 + (2 - 2.5)^2 + (3 - 2.5)^2 + (4 - 2.5)^2 = 5.$$

Y

$$S_{xy} = (1 - 2.5)(2 - 4) + (2 - 2.5)(3 - 4) + (3 - 2.5)(5 - 4) + (4 - 2.5)(6 - 4).$$

Por tanto,

$$S_{xy} = 6.$$

Entonces,

$$\hat{\beta}_1 = \frac{6}{5} = 1.2.$$

Y

$$\hat{\beta}_0 = 4 - 1.2(2.5) = 1.$$

La recta ajustada es

$$\hat{y} = 1 + 1.2x.$$

Errores frecuentes

1. Interpretar el intercepto fuera del rango observado.
2. Concluir causalidad a partir de una pendiente significativa.
3. Utilizar R^2 como único criterio de calidad.
4. Ignorar patrones en los residuos.
5. Extrapolar lejos del rango de los datos.
6. Confundir intervalo de confianza con intervalo de predicción.
7. Ignorar heterocedasticidad.
8. Eliminar observaciones influyentes sin justificación.
9. Suponer que normalidad de Y es requerida; el supuesto se refiere a los errores.
10. Interpretar una pendiente no significativa como prueba de ausencia de relación.

Ejercicios conceptuales

1. Explique la diferencia entre función de regresión y recta ajustada.
2. ¿Qué representa β_1 ?
3. ¿Por qué la recta ajustada pasa por $(\bar{x}, \bar{y})$?

4. ¿Qué significa el teorema de Gauss-Markov?
5. ¿Por qué se utilizan $n - 2$ grados de libertad?
6. ¿Qué diferencia existe entre intervalo de confianza y predicción?
7. ¿Qué mide R^2 ?
8. ¿Qué representa el apalancamiento?
9. ¿Qué diferencia existe entre valor atípico e influencia?
10. ¿Por qué la extrapolación puede ser peligrosa?

Ejercicio de estimación

Considere los datos:

x	2	4	6	8	10
y	5	8	9	13	15

Calcule:

1. $\bar{x}$;
2. $\bar{y}$;
3. S_{xx} ;
4. S_{xy} ;
5. $\hat{\beta}_1$;
6. $\hat{\beta}_0$;
7. los valores ajustados;
8. los residuos.

Ejercicio de inferencia

Supóngase:

$$\hat{\beta}_1 = 2.4,$$

$$SE(\hat{\beta}_1) = 0.6,$$

$$n = 20.$$

1. Calcule el estadístico t .
2. Evalúe $H_0 : \beta_1 = 0$.
3. Construya un intervalo de confianza del 95 %.
4. Interprete el resultado.

Ejercicio de ANOVA

Sean:

$$SST = 200, \quad SSE = 80, \quad n = 12.$$

Calcule:

1. SSR ;
2. R^2 ;
3. MSR ;
4. MSE ;
5. el estadístico F .

Ejercicio de predicción

Supóngase:

$$\hat{y} = 4 + 1.5x,$$

$$s = 2,$$

$$n = 25,$$

$$\bar{x} = 10,$$

$$S_{xx} = 200.$$

Para $x_0 = 12$:

1. calcule la predicción;
2. calcule el error estándar de la media;
3. calcule el error estándar de predicción;
4. compare ambos intervalos.

Ejercicio de diagnóstico

Para cada patrón, explique qué posible problema sugiere:

1. residuos con forma de U;
2. residuos con forma de embudo;
3. un punto con gran apalancamiento y residuo pequeño;
4. un punto con gran apalancamiento y residuo grande;
5. residuos autocorrelacionados.

Ejercicio aplicado

Se desea estudiar la relación entre temperatura y concentración de PM10.

1. Defina el modelo.
2. Interprete β_0 y β_1 .
3. Indique los supuestos.
4. Describa la estimación por mínimos cuadrados.
5. Explique cómo probaría la pendiente.
6. Explique cómo construiría un intervalo para la media.
7. Explique cómo construiría un intervalo para una nueva observación.
8. Proponga gráficos de diagnóstico.
9. Explique por qué la asociación no implica causalidad.
10. Indique cuándo sería necesaria una transformación.

Resumen

En este capítulo se desarrolló la regresión lineal simple desde su formulación probabilística hasta la inferencia y el diagnóstico.

Se derivaron los estimadores de mínimos cuadrados, se estudiaron sus propiedades de insesgadez y varianza, y se presentó el teorema de Gauss-Markov.

También se desarrollaron pruebas para la pendiente, intervalos de confianza y predicción, descomposición ANOVA, coeficiente de determinación, análisis de residuos, apalancamiento e influencia.

La regresión lineal simple constituye la base para la regresión múltiple, la regularización y numerosos modelos de aprendizaje supervisado.

Referencias del capítulo

Los fundamentos se apoyan en Montgomery et al. (2021), Seber y Lee (2012), Hastie et al. (2009) y James et al. (2021).

14 Regresión lineal múltiple

Introducción

La regresión lineal múltiple extiende el modelo lineal a varios predictores. Cada coeficiente tiene una interpretación condicional: representa el cambio esperado en la respuesta al modificar una variable mientras las demás permanecen fijas (Montgomery et al. 2021; Seber y Lee 2012).

La regresión lineal múltiple extiende la regresión lineal simple al estudio simultáneo de varias variables explicativas. Su objetivo es modelar el valor esperado de una respuesta Y mediante una combinación lineal de p características.

Este modelo permite analizar el efecto parcial de cada variable manteniendo constantes las demás, construir predicciones, evaluar hipótesis conjuntas, incorporar variables categóricas, representar interacciones y estudiar problemas de multicolinealidad.

La formulación matricial es especialmente importante porque permite expresar de manera compacta la estimación, la inferencia y la geometría del modelo.

! Definición esencial

La regresión lineal múltiple modela una respuesta mediante varios predictores.

Objetivos

Al finalizar el capítulo, el lector podrá:

1. formular el modelo lineal múltiple;
2. construir la matriz de diseño;
3. interpretar coeficientes parciales;
4. derivar el estimador de mínimos cuadrados;
5. comprender la geometría de la proyección;
6. analizar las propiedades de los estimadores;
7. construir pruebas t individuales;
8. formular la prueba F global;
9. comparar modelos anidados;
10. interpretar R^2 y R^2 ajustado;
11. incorporar variables indicadoras;
12. interpretar interacciones;
13. diagnosticar multicolinealidad;
14. calcular factores de inflación de varianza;
15. analizar residuos, apalancamiento e influencia;
16. reconocer limitaciones predictivas y causales.

Formulación del modelo

Para n observaciones y p variables explicativas, el modelo es

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i,$$

para

$$i = 1, \dots, n.$$

La función de regresión es

$$\mathbb{E}(Y_i \mid \mathbf{x}_i) = \beta_0 + \sum_{j=1}^p \beta_j x_{ij},$$

donde

$$\mathbf{x}_i = \begin{pmatrix} x_{i1} \\ \vdots \\ x_{ip} \end{pmatrix} \in \mathbb{R}^p.$$

Para incorporar el intercepto en la formulación matricial se utilizará el vector aumentado

$$\tilde{\mathbf{x}}_i = \begin{pmatrix} 1 \\ x_{i1} \\ \vdots \\ x_{ip} \end{pmatrix} \in \mathbb{R}^{p+1}.$$

Formulación matricial

El modelo puede escribirse como

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon,$$

donde

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix},$$

$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix},$$

y

$$\beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix} \in \mathbb{R}^{p+1}.$$

Con esta convención,

$$\mathbb{E}(Y_i \mid \mathbf{x}_i) = \tilde{\mathbf{x}}_i^T \beta.$$

La matriz $\mathbf{X}$ tiene dimensión

$$n \times (p + 1).$$

Matriz de diseño

Definición 14.1. La matriz de diseño es la matriz que contiene los valores de las variables explicativas y, cuando existe intercepto, una primera columna de unos.

Cada fila representa una observación.

Cada columna representa:

- el intercepto;
- una variable numérica;
- una variable indicadora;
- una interacción;
- una transformación.

Interpretación de los coeficientes

El coeficiente β_j representa el cambio esperado en Y cuando x_j aumenta una unidad, manteniendo constantes las demás variables.

Formalmente,

$$\frac{\partial}{\partial x_j} \mathbb{E}(Y \mid \mathbf{x}) = \beta_j.$$

Esta interpretación depende de que mantener constantes las demás variables sea conceptualmente posible.

Ejemplo ambiental

Considere

$$\text{PM10} = \beta_0 + \beta_1 \text{ Temperatura} + \beta_2 \text{ Humedad} + \beta_3 \text{ Viento} + \varepsilon.$$

Entonces β_1 representa el cambio promedio esperado en PM10 por cada unidad adicional de temperatura, manteniendo constantes humedad y viento.

Supuestos clásicos

Linealidad en los parámetros

$$\mathbb{E}(\mathbf{y} \mid \mathbf{X}) = \mathbf{X}\beta.$$

Media condicional cero

$$\mathbb{E}(\varepsilon \mid \mathbf{X}) = \mathbf{0}.$$

Homocedasticidad

$$\text{Var}(\varepsilon \mid \mathbf{X}) = \sigma^2 \mathbf{I}.$$

Ausencia de autocorrelación

$$\text{Cov}(\varepsilon_i, \varepsilon_j \mid \mathbf{X}) = 0, \quad i \neq j.$$

Rango completo

$$\text{rank}(\mathbf{X}) = p + 1.$$

Normalidad para inferencia exacta

$$\varepsilon \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}).$$

Criterio de mínimos cuadrados

Se desea minimizar

$$S(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|_2^2.$$

Equivalentemente,

$$S(\beta) = (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta).$$

Expansión de la función objetivo

$$S(\beta) = \mathbf{y}^\top \mathbf{y} - 2\beta^\top \mathbf{X}^\top \mathbf{y} + \beta^\top \mathbf{X}^\top \mathbf{X} \beta.$$

Derivación del estimador

El gradiente es

$$\nabla_{\beta} S = -2\mathbf{X}^T \mathbf{y} + 2\mathbf{X}^T \mathbf{X} \beta.$$

Igualando a cero,

$$\mathbf{X}^T \mathbf{X} \hat{\beta} = \mathbf{X}^T \mathbf{y}.$$

Estas son las ecuaciones normales.

Si $\mathbf{X}^T \mathbf{X}$ es invertible,

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}.$$

Condición de unicidad

La solución es única si las columnas de $\mathbf{X}$ son linealmente independientes.

Si existe dependencia lineal exacta,

$$\mathbf{X}^T \mathbf{X}$$

es singular.

Valores ajustados

$$\hat{\mathbf{y}} = \mathbf{X} \hat{\beta}.$$

Sustituyendo,

$$\hat{\mathbf{y}} = \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}.$$

Matriz sombrero

Definición 14.2. La matriz sombrero es

$$\mathbf{H} = \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T.$$

Entonces,

$$\hat{\mathbf{y}} = \mathbf{H} \mathbf{y}.$$

La matriz $\mathbf{H}$ es:

- simétrica;
- idempotente.

Es decir,

$$\mathbf{H}^T = \mathbf{H},$$

y

$$\mathbf{H}^2 = \mathbf{H}.$$

Residuos

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}.$$

Como

$$\hat{\mathbf{y}} = \mathbf{H}\mathbf{y},$$

entonces

$$\mathbf{e} = (\mathbf{I} - \mathbf{H})\mathbf{y}.$$

Ortogonalidad

Los residuos satisfacen

$$\mathbf{X}^T \mathbf{e} = \mathbf{0}.$$

Por tanto, los residuos son ortogonales a todas las columnas de la matriz de diseño.

Si existe intercepto,

$$\sum_{i=1}^n e_i = 0.$$

Interpretación geométrica

El espacio columna

$$\text{Col}(\mathbf{X})$$

contiene todos los vectores que pueden expresarse como combinaciones lineales de las columnas de $\mathbf{X}$.

El vector ajustado

$$\hat{\mathbf{y}}$$

es la proyección ortogonal de $\mathbf{y}$ sobre $\text{Col}(\mathbf{X})$.

El vector residual pertenece al complemento ortogonal.

Insesgadez

Como

$$\hat{\beta} = \beta + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \varepsilon,$$

entonces

$$\mathbb{E} [\hat{\beta} \mid \mathbf{X}] = \beta.$$

Matriz de covarianza de los estimadores

$$\text{Var}(\hat{\beta} \mid \mathbf{X}) = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}.$$

Los elementos diagonales proporcionan las varianzas de los coeficientes.

Teorema de Gauss-Markov

Teorema 14.1. *Bajo los supuestos clásicos, el estimador de mínimos cuadrados es el mejor estimador lineal insesgado de β .*

En forma abreviada se denomina BLUE:

Best Linear Unbiased Estimator.

Estimación de la varianza del error

La suma de cuadrados residual es

$$SSE = \mathbf{e}^T \mathbf{e}.$$

Los grados de libertad residuales son

$$n - p - 1.$$

El estimador insesgado es

$$s^2 = \frac{SSE}{n - p - 1}.$$

Distribución de los estimadores

Bajo normalidad,

$$\hat{\beta} \sim N_{p+1} \left[\beta, \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1} \right].$$

Error estándar de un coeficiente

Si

$$c_{jj}$$

es el elemento diagonal correspondiente de

$$(\mathbf{X}^\top \mathbf{X})^{-1},$$

entonces

$$SE(\hat{\beta}_j) = s\sqrt{c_{jj}}.$$

Prueba individual

Para contrastar

$$H_0 : \beta_j = \beta_{j,0},$$

se utiliza

$$t = \frac{\hat{\beta}_j - \beta_{j,0}}{SE(\hat{\beta}_j)}.$$

Bajo H_0 ,

$$t \sim t_{n-p-1}.$$

Intervalo de confianza

$$\hat{\beta}_j \pm t_{\alpha/2, n-p-1} SE(\hat{\beta}_j).$$

Prueba global

La hipótesis global es

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0.$$

La alternativa establece que al menos uno es distinto de cero.

El estadístico es

$$F = \frac{SSR/p}{SSE/(n-p-1)}.$$

Bajo H_0 ,

$$F \sim F_{p, n-p-1}.$$

Interpretación de la prueba global

Rechazar H_0 indica que el conjunto de variables explicativas aporta capacidad lineal explicativa respecto del modelo con solo intercepto.

No implica que todos los coeficientes sean significativos.

Descomposición de sumas de cuadrados

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2,$$

$$SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2,$$

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

Con intercepto,

$$SST = SSR + SSE.$$

Coefficiente de determinación

$$R^2 = 1 - \frac{SSE}{SST}.$$

Al agregar variables, R^2 nunca disminuye.

Por esta razón, no debe utilizarse solo para comparar modelos con diferente número de variables.

Coefficiente de determinación ajustado

$$R_{aj}^2 = 1 - \frac{SSE/(n-p-1)}{SST/(n-1)}.$$

Equivalentemente,

$$R_{aj}^2 = 1 - (1 - R^2) \frac{n-1}{n-p-1}.$$

Este coeficiente penaliza la incorporación de variables que no reducen suficientemente el error.

Comparación de modelos anidados

Considere:

- modelo reducido con q parámetros explicativos;
- modelo completo con p parámetros explicativos;
- $q < p$.

La hipótesis es que los parámetros adicionales son cero.

El estadístico es

$$F = \frac{(SSE_R - SSE_C)/(p - q)}{SSE_C/(n - p - 1)}.$$

Hipótesis lineales generales

Puede formularse

$$H_0 : \mathbf{R}\beta = \mathbf{r}.$$

El estadístico general es

$$F = \frac{(\mathbf{R}\hat{\beta} - \mathbf{r})^T [\mathbf{R}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{R}^T]^{-1} (\mathbf{R}\hat{\beta} - \mathbf{r})}{ms^2},$$

donde m es el número de restricciones.

Predicción en una observación nueva

Sea

$$\mathbf{x}_0 = \begin{pmatrix} x_{01} \\ \vdots \\ x_{0p} \end{pmatrix} \in \mathbb{R}^p$$

el vector de características de una observación nueva. Su versión aumentada es

$$\tilde{\mathbf{x}}_0 = \begin{pmatrix} 1 \\ x_{01} \\ \vdots \\ x_{0p} \end{pmatrix} \in \mathbb{R}^{p+1}.$$

La predicción media es

$$\hat{y}_0 = \tilde{\mathbf{x}}_0^T \hat{\beta}.$$

Error estándar de la media

$$SE_{mean} = s\sqrt{\tilde{\mathbf{x}}_0^T(\mathbf{X}^T\mathbf{X})^{-1}\tilde{\mathbf{x}}_0}.$$

Intervalo de confianza para la media

$$\hat{y}_0 \pm t_{\alpha/2, n-p-1} SE_{mean}.$$

Intervalo de predicción

$$SE_{pred} = s\sqrt{1 + \tilde{\mathbf{x}}_0^T(\mathbf{X}^T\mathbf{X})^{-1}\tilde{\mathbf{x}}_0}.$$

Entonces,

$$\hat{y}_0 \pm t_{\alpha/2, n-p-1} SE_{pred}.$$

i Interacciones

Con un término de interacción, el efecto de una variable depende del valor de otra. Los efectos principales dejan de representar efectos globales constantes.

Variables categóricas

Una variable categórica con K niveles se representa mediante $K - 1$ variables indicadoras cuando existe intercepto.

Supóngase:

$$G \in \{A, B, C\}.$$

Tomando A como referencia:

$$D_B = \mathbb{I}(G = B),$$

$$D_C = \mathbb{I}(G = C).$$

El modelo es

$$Y = \beta_0 + \beta_1 D_B + \beta_2 D_C + \varepsilon.$$

Interpretación de indicadores

$$\beta_0$$

es la media esperada del grupo A .

$$\beta_1$$

es la diferencia entre los grupos B y A .

$$\beta_2$$

es la diferencia entre los grupos C y A .

Trampa de las variables indicadoras

Si se incluyen las K variables indicadoras y también intercepto, existe dependencia lineal exacta:

$$D_A + D_B + D_C = 1.$$

Esto se conoce como trampa de variables indicadoras.

Interacciones

Una interacción permite que el efecto de una variable dependa de otra.

Considere

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2 + \varepsilon.$$

El efecto parcial de X_1 es

$$\frac{\partial}{\partial X_1} \mathbb{E}(Y \mid X_1, X_2) = \beta_1 + \beta_3 X_2.$$

Por tanto, β_1 ya no representa un efecto constante.

Interacción entre variable numérica y categórica

Sea D una variable indicadora:

$$Y = \beta_0 + \beta_1 X + \beta_2 D + \beta_3 XD + \varepsilon.$$

Para $D = 0$,

$$\mathbb{E}(Y \mid X, D = 0) = \beta_0 + \beta_1 X.$$

Para $D = 1$,

$$\mathbb{E}(Y \mid X, D = 1) = (\beta_0 + \beta_2) + (\beta_1 + \beta_3)X.$$

Principio jerárquico

Si se incluye una interacción, normalmente también deben incluirse sus efectos principales.

Por ejemplo, si aparece

$$X_1X_2,$$

deben conservarse X_1 y X_2 , salvo que exista una justificación especial.

Transformaciones polinomiales

Puede modelarse curvatura mediante

$$Y = \beta_0 + \beta_1X + \beta_2X^2 + \varepsilon.$$

El modelo sigue siendo lineal en los parámetros, aunque no sea lineal en X .

Centrado de variables

Defina

$$Z_j = X_j - \overline{X}_j.$$

El centrado puede:

- mejorar la interpretación del intercepto;
- reducir correlación entre términos principales e interacciones;
- mejorar estabilidad numérica.

Multicolinealidad

Definición 14.3. Existe multicolinealidad cuando algunas variables explicativas presentan relaciones lineales fuertes.

Puede ser:

- exacta;
- aproximada.

Consecuencias

La multicolinealidad puede producir:

- errores estándar grandes;
- coeficientes inestables;
- cambios de signo;
- pruebas individuales no significativas;
- sensibilidad a pequeñas modificaciones;
- dificultad de interpretación.

Puede existir una prueba F global significativa junto con pruebas t individuales no significativas.

Multicolinealidad

La multicolinealidad no introduce necesariamente sesgo, pero aumenta la varianza de los coeficientes y puede volver inestables sus signos e interpretaciones.

Factor de inflación de varianza

Para la variable X_j , se ajusta una regresión usando las demás variables como predictores.

Sea R_j^2 el coeficiente de determinación obtenido.

El VIF es

$$VIF_j = \frac{1}{1 - R_j^2}.$$

Interpretación del VIF

Si las variables son ortogonales,

$$R_j^2 = 0$$

y

$$VIF_j = 1.$$

Valores grandes indican inflación de varianza.

No existe un umbral universal, aunque se usan reglas prácticas como 5 o 10.

Tolerancia

La tolerancia es

$$\text{Tol}_j = 1 - R_j^2 = \frac{1}{VIF_j}.$$

Valores cercanos a cero sugieren multicolinealidad.

Estrategias frente a multicolinealidad

- eliminar variables redundantes;
- combinar variables;
- usar conocimiento del dominio;
- aumentar el tamaño muestral;
- utilizar PCA;
- usar ridge o elastic net;
- evitar interpretaciones individuales excesivas.

Selección de variables

Métodos comunes:

- selección hacia adelante;
- eliminación hacia atrás;
- selección paso a paso;
- criterios AIC y BIC;
- validación cruzada;
- LASSO;
- selección basada en conocimiento científico.

Limitaciones de selección automática

Los procedimientos paso a paso pueden:

- producir coeficientes sesgados;
- subestimar errores estándar;
- ser inestables;
- aumentar falsos positivos;
- depender fuertemente de la muestra.

La validación y la justificación sustantiva son esenciales.

Criterio AIC

$$AIC = -2\ell(\hat{\theta}) + 2k,$$

donde k es el número de parámetros.

Menor AIC indica mejor equilibrio entre ajuste y complejidad.

Criterio BIC

$$BIC = -2\ell(\hat{\theta}) + k \log n.$$

BIC penaliza más fuertemente la complejidad cuando n es grande.

Apalancamiento

Los elementos diagonales de $\mathbf{H}$ son

$$h_{ii}.$$

Se cumple

$$\sum_{i=1}^n h_{ii} = p + 1.$$

El apalancamiento promedio es

$$\bar{h} = \frac{p+1}{n}.$$

Residuos estandarizados

$$r_i = \frac{e_i}{s\sqrt{1-h_{ii}}}.$$

Distancia de Cook

$$D_i = \frac{e_i^2}{(p+1)s^2} \frac{h_{ii}}{(1-h_{ii})^2}.$$

Una observación influyente combina residuo y apalancamiento.

DFFITS

$$DFFITS_i = \frac{\hat{y}_i - \hat{y}_{i(-i)}}{s_{(-i)}\sqrt{h_{ii}}}.$$

Mide el cambio en el valor ajustado al eliminar la observación.

DFBETAS

DFBETAS cuantifica cuánto cambia cada coeficiente al eliminar una observación.

Para el coeficiente j ,

$$DFBETAS_{ij} = \frac{\hat{\beta}_j - \hat{\beta}_{j(-i)}}{SE_{(-i)}(\hat{\beta}_j)}.$$

Diagnóstico de linealidad

Debe analizarse:

- residuos contra ajustados;
- residuos parciales;
- gráficos componente más residuo;
- posibles términos no lineales.

Diagnóstico de homocedasticidad

Un patrón de embudo puede sugerir varianza no constante.

Pueden utilizarse:

- prueba de Breusch-Pagan;

- prueba de White;
- errores estándar robustos;
- mínimos cuadrados ponderados.

Normalidad

La normalidad afecta principalmente:

- inferencia exacta en muestras pequeñas;
- intervalos;
- pruebas.

No es necesaria para que la relación media sea lineal.

Independencia

Si existen datos temporales o agrupados, puede incumplirse.

Alternativas:

- modelos de series de tiempo;
- modelos mixtos;
- errores estándar agrupados;
- regresión generalizada.

Máxima verosimilitud

Bajo errores normales,

$$\varepsilon \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}),$$

la verosimilitud es

$$L(\beta, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp \left[-\frac{(\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta)}{2\sigma^2} \right].$$

Maximizar respecto de β equivale a minimizar SSE .

Relación con regularización

Ridge resuelve

$$\min_{\beta} \left\{ \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_2^2 \right\}.$$

LASSO sustituye la norma L_2 por L_1 .

Estas técnicas son especialmente útiles cuando p es grande o existe multicolinealidad.

Relación con aprendizaje supervisado

El espacio de hipótesis es

$$\mathcal{F} = \{f(\mathbf{x}) = \beta_0 + \beta^T \mathbf{x}\}.$$

La pérdida es cuadrática:

$$L(y, f(\mathbf{x})) = (y - f(\mathbf{x}))^2.$$

El estimador minimiza el riesgo empírico.

Conexión con R

```
1  datos <- data.frame(  
2    pm10 = c(42, 55, 63, 70, 75, 88),  
3    temperatura = c(18, 20, 22, 24, 26, 28),  
4    humedad = c(65, 60, 56, 50, 46, 40),  
5    viento = c(8, 7, 6, 5, 4, 3)  
6  )  
7  
8  modelo <- lm(  
9    pm10 ~ temperatura + humedad + viento,  
10   data = datos  
11 )  
12  
13 summary(modelo)  
14  
15 anova(modelo)  
16  
17 confint(modelo)  
18  
19 # Matriz de diseño  
20 model.matrix(modelo)  
21  
22 # Valores ajustados y residuos  
23 fitted(modelo)  
24 residuals(modelo)  
25  
26 # Diagnósticos  
27 par(mfrow = c(2, 2))  
28 plot(modelo)  
29  
30 # VIF, requiere car  
31 # library(car)  
32 # vif(modelo)
```

Ejemplo matricial

Considere

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ 1 & 3 & 1 \\ 1 & 4 & 2 \end{pmatrix},$$

y

$$\mathbf{y} = \begin{pmatrix} 2 \\ 4 \\ 5 \\ 8 \end{pmatrix}.$$

La estimación es

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}.$$

El procedimiento manual consiste en:

1. calcular $\mathbf{X}^T \mathbf{X}$;
2. calcular $\mathbf{X}^T \mathbf{y}$;
3. resolver las ecuaciones normales;
4. obtener $\hat{\mathbf{y}}$;
5. calcular los residuos.

Errores frecuentes

1. Interpretar un coeficiente sin considerar las demás variables.
2. Concluir causalidad por significancia estadística.
3. Ignorar multicolinealidad.
4. Comparar coeficientes en escalas muy diferentes.
5. Incluir todas las variables indicadoras con intercepto.
6. Interpretar efectos principales sin considerar interacciones.
7. Seleccionar variables usando el conjunto de prueba.
8. Utilizar R^2 como único criterio.
9. Eliminar observaciones influyentes sin investigación.
10. Ignorar dependencia temporal o agrupada.
11. Extrapolar fuera de la región observada.
12. Confundir significancia estadística con importancia práctica.

Ejercicios conceptuales

1. Explique la diferencia entre regresión simple y múltiple.
2. ¿Qué representa un coeficiente parcial?
3. ¿Qué condición garantiza una solución única?

4. ¿Qué significa geoméricamente el ajuste?
5. ¿Qué representa la prueba F global?
6. ¿Por qué R^2 nunca disminuye al agregar variables?
7. ¿Qué ventaja tiene R^2 ajustado?
8. ¿Qué es la trampa de variables indicadoras?
9. ¿Cómo se interpreta una interacción?
10. ¿Qué representa el VIF?
11. ¿Por qué multicolinealidad puede afectar inferencia sin afectar mucho la predicción?
12. ¿Qué diferencia existe entre apalancamiento e influencia?

Ejercicio de derivación matricial

Parta de

$$S(\beta) = (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta).$$

1. Expanda la expresión.
2. Calcule el gradiente.
3. Obtenga las ecuaciones normales.
4. Derive el estimador.
5. Explique la condición de invertibilidad.

Ejercicio de interpretación

Considere

$$\widehat{Y} = 12 + 1.8X_1 - 0.7X_2 + 3.2X_3.$$

Interprete cada coeficiente suponiendo que:

- Y es PM10;
- X_1 es temperatura;
- X_2 es humedad;
- X_3 es una variable indicadora de temporada seca.

Ejercicio de prueba global

Supóngase:

$$SSR = 480,$$

$$SSE = 120,$$

$$n = 30,$$

$$p = 3.$$

Calcule:

1. MSR ;
2. MSE ;
3. el estadístico F ;
4. los grados de libertad;
5. interprete el contraste.

Ejercicio de modelos anidados

Un modelo reducido tiene

$$SSE_R = 250$$

con dos predictores.

El modelo completo tiene

$$SSE_C = 190$$

con cinco predictores.

Además,

$$n = 50.$$

Calcule la prueba F parcial.

Ejercicio de VIF

Una variable X_j se regresa contra las demás y se obtiene

$$R_j^2 = 0.90.$$

1. Calcule VIF_j .
2. Calcule la tolerancia.
3. Interprete el resultado.
4. Proponga estrategias.

Ejercicio de interacción

Considere

$$Y = 5 + 2X + 4D - 1.5XD.$$

1. Escriba la recta para $D = 0$.

2. Escriba la recta para $D = 1$.
3. Compare interceptos.
4. Compare pendientes.
5. Interprete la interacción.

Ejercicio aplicado

Se desea predecir PM10 usando:

- temperatura;
- humedad;
- velocidad del viento;
- temporada;
- interacción temperatura-temporada.

Diseñe el análisis incluyendo:

1. formulación del modelo;
2. construcción de indicadores;
3. interpretación de coeficientes;
4. prueba global;
5. pruebas individuales;
6. diagnóstico de multicolinealidad;
7. análisis de residuos;
8. validación;
9. predicción;
10. limitaciones causales.

Resumen

En este capítulo se desarrolló la regresión lineal múltiple mediante formulación matricial.

Se derivó el estimador de mínimos cuadrados, se estudiaron sus propiedades, su interpretación geométrica y la matriz sombrero.

También se presentaron pruebas individuales y globales, comparación de modelos anidados, R^2 , R^2 ajustado, predicción, variables categóricas, interacciones y transformaciones.

Finalmente, se analizaron multicolinealidad, VIF, selección de variables, apalancamiento, influencia y diagnóstico. Estos fundamentos preparan el estudio de regresión logística y modelos lineales más avanzados.

Referencias del capítulo

Los fundamentos se apoyan en Montgomery et al. (2021), Seber y Lee (2012), Hastie et al. (2009) y Mardia et al. (1979).

15 Regresión logística

Introducción

La regresión logística modela la probabilidad condicional de una respuesta binaria mediante el logit. Aunque se denomina regresión, se utiliza principalmente para clasificación probabilística (Agresti 2013; Hosmer et al. 2013; Bishop 2006).

La regresión logística es uno de los modelos fundamentales para clasificación binaria. La variable respuesta toma valores discretos,

$$Y \in \{0, 1\},$$

y el modelo estima la probabilidad condicional

$$P(Y = 1 \mid \mathbf{x}).$$

Para garantizar que la predicción permanezca entre 0 y 1 se utiliza la función logística. Los parámetros se estiman por máxima verosimilitud mediante métodos iterativos.

! Definición esencial

La regresión logística modela la probabilidad de una clase mediante el logit.

Objetivos

Al finalizar el capítulo, el lector podrá:

1. formular un modelo de regresión logística;
2. interpretar probabilidades, odds y logit;
3. interpretar coeficientes y odds ratios;
4. construir la verosimilitud Bernoulli;
5. derivar gradiente y Hessiana;
6. comprender Newton-Raphson e IRLS;
7. formular pruebas de Wald y razón de verosimilitud;
8. analizar deviance, discriminación y calibración;
9. seleccionar umbrales;
10. reconocer separación, multicolinealidad e influencia;
11. extender el modelo al caso multiclase.

Variable respuesta binaria

Se considera

$$Y_i \in \{0, 1\}, \quad i = 1, \dots, n.$$

Condicionado al vector de características,

$$Y_i \mid \mathbf{x}_i \sim \text{Bernoulli}(\pi_i),$$

donde

$$\pi_i = P(Y_i = 1 \mid \mathbf{x}_i).$$

i Odds y logit

Un coeficiente implica que, manteniendo los demás predictores constantes, las odds se multiplican por e^{β_j} por cada unidad adicional del predictor.

Función logística

Definición 15.1. La función logística se define como

$$\sigma(z) = \frac{1}{1 + e^{-z}} = \frac{e^z}{1 + e^z}.$$

Se cumple

$$0 < \sigma(z) < 1.$$

Además,

$$\sigma'(z) = \sigma(z) [1 - \sigma(z)].$$

Modelo logístico

Sea

$$\eta_i = \beta_0 + \sum_{j=1}^p \beta_j x_{ij}.$$

Entonces

$$\pi_i = \frac{e^{\eta_i}}{1 + e^{\eta_i}}.$$

Para cada observación se define

$$\mathbf{x}_i = \begin{pmatrix} x_{i1} \\ \vdots \\ x_{ip} \end{pmatrix} \in \mathbb{R}^p,$$

y su versión aumentada

$$\tilde{\mathbf{x}}_i = \begin{pmatrix} 1 \\ x_{i1} \\ \vdots \\ x_{ip} \end{pmatrix} \in \mathbb{R}^{p+1}.$$

El vector de parámetros es

$$\beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix} \in \mathbb{R}^{p+1}.$$

Por tanto,

$$\eta_i = \tilde{\mathbf{x}}_i^\top \beta,$$

y en forma matricial,

$$\eta = \mathbf{X}\beta.$$

Odds

Definición 15.2. Los odds de un evento con probabilidad π son

$$\text{odds} = \frac{\pi}{1 - \pi}.$$

Si $\pi = 0.8$,

$$\text{odds} = 4.$$

Esto significa que el evento es cuatro veces más probable que su complemento.

Logit

Definición 15.3. La función logit es

$$\text{logit}(\pi) = \log\left(\frac{\pi}{1 - \pi}\right).$$

El modelo supone

$$\text{logit}(\pi_i) = \tilde{\mathbf{x}}_i^\top \beta = \beta_0 + \sum_{j=1}^p \beta_j x_{ij}.$$

Por tanto, el logaritmo de los odds es lineal en las características.

Interpretación de los coeficientes

Si x_j aumenta una unidad y las demás variables permanecen constantes,

$$\text{logit}(\pi)$$

cambia en β_j .

En términos de odds,

$$\frac{\text{odds}(\mathbf{x} + \mathbf{e}_j)}{\text{odds}(\mathbf{x})} = e^{\beta_j},$$

donde $\mathbf{e}_j$ incrementa únicamente la característica j en una unidad. Por tanto,

$$e^{\beta_j}$$

es el odds ratio asociado a un incremento unitario de x_j .

Si

$$e^{\beta_j} = 1.5,$$

los odds aumentan 50 por ciento.

Para un incremento de c unidades,

$$OR(c) = e^{c\beta_j}.$$

Variables indicadoras

Sea

$$D = \begin{cases} 1, & \text{grupo expuesto,} \\ 0, & \text{grupo de referencia.} \end{cases}$$

En

$$\text{logit}(\pi) = \beta_0 + \beta_1 D,$$

el valor

$$e^{\beta_1}$$

es el odds ratio del grupo expuesto respecto del grupo de referencia.

Interacciones

Considere

$$\text{logit}(\pi) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2.$$

El efecto de X_1 sobre el logit es

$$\frac{\partial \text{logit}(\pi)}{\partial X_1} = \beta_1 + \beta_3 X_2.$$

Por tanto, el efecto depende de X_2 .

Efecto marginal sobre la probabilidad

El efecto sobre la probabilidad no es constante:

$$\frac{\partial \pi}{\partial x_j} = \beta_j \pi(1 - \pi).$$

Por ello, β_j no debe interpretarse como un cambio directo en probabilidad.

Verosimilitud Bernoulli

Para una observación,

$$P(Y_i = y_i \mid \mathbf{x}_i) = \pi_i^{y_i} (1 - \pi_i)^{1-y_i}.$$

Suponiendo independencia,

$$L(\beta) = \prod_{i=1}^n \pi_i^{y_i} (1 - \pi_i)^{1-y_i}.$$

! Estimación por máxima verosimilitud

No existe en general una fórmula cerrada para los estimadores logísticos. Se utilizan procedimientos iterativos como Newton-Raphson o IRLS.

Log-verosimilitud

$$\ell(\beta) = \sum_{i=1}^n [y_i \log \pi_i + (1 - y_i) \log(1 - \pi_i)].$$

También puede escribirse como

$$\ell(\beta) = \sum_{i=1}^n [y_i \eta_i - \log(1 + e^{\eta_i})].$$

Gradiente

Sea

$$\boldsymbol{\pi} = \begin{pmatrix} \pi_1 \\ \vdots \\ \pi_n \end{pmatrix}.$$

Entonces

$$\nabla \ell(\boldsymbol{\beta}) = \mathbf{X}^\top (\mathbf{y} - \boldsymbol{\pi}).$$

El estimador satisface

$$\mathbf{X}^\top (\mathbf{y} - \hat{\boldsymbol{\pi}}) = \mathbf{0}.$$

Estas ecuaciones no tienen una solución cerrada general.

Hessiana

Defina

$$\mathbf{W} = \text{diag} [\pi_i (1 - \pi_i)].$$

Entonces

$$\nabla^2 \ell(\boldsymbol{\beta}) = -\mathbf{X}^\top \mathbf{W} \mathbf{X}.$$

La Hessiana es semidefinida negativa, por lo que la log-verosimilitud es cóncava.

Newton-Raphson

La actualización es

$$\boldsymbol{\beta}^{(t+1)} = \boldsymbol{\beta}^{(t)} + (\mathbf{X}^\top \mathbf{W}^{(t)} \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{y} - \boldsymbol{\pi}^{(t)}).$$

Mínimos cuadrados ponderados iterativos

Newton-Raphson puede expresarse como IRLS.

Defina

$$\mathbf{z}^{(t)} = \mathbf{X} \boldsymbol{\beta}^{(t)} + (\mathbf{W}^{(t)})^{-1} (\mathbf{y} - \boldsymbol{\pi}^{(t)}).$$

Entonces

$$\boldsymbol{\beta}^{(t+1)} = (\mathbf{X}^\top \mathbf{W}^{(t)} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}^{(t)} \mathbf{z}^{(t)}.$$

Convergencia

El proceso puede detenerse cuando

$$\|\beta^{(t+1)} - \beta^{(t)}\|_2 < \varepsilon,$$

o cuando el cambio en log-verosimilitud es pequeño.

Covarianza asintótica

La matriz de información observada es

$$\mathbf{I}(\hat{\beta}) = \mathbf{X}^\top \widehat{\mathbf{W}} \mathbf{X}.$$

La covarianza aproximada es

$$\text{Var}(\hat{\beta}) \approx (\mathbf{X}^\top \widehat{\mathbf{W}} \mathbf{X})^{-1}.$$

Prueba de Wald

Para

$$H_0 : \beta_j = 0,$$

se utiliza

$$z = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)}.$$

Asintóticamente,

$$z \sim N(0, 1).$$

Intervalos de confianza

Para el coeficiente,

$$\hat{\beta}_j \pm z_{\alpha/2} SE(\hat{\beta}_j).$$

Si el intervalo es $[L_j, U_j]$, el intervalo del odds ratio es

$$[e^{L_j}, e^{U_j}].$$

Razón de verosimilitud

Para comparar un modelo reducido y uno completo,

$$G^2 = 2(\ell_C - \ell_R).$$

Bajo condiciones regulares,

$$G^2 \sim \chi_q^2,$$

donde q es la diferencia en número de parámetros.

Prueba score

La prueba score evalúa el gradiente bajo el modelo restringido y no requiere ajustar el modelo completo.

Las pruebas de Wald, razón de verosimilitud y score suelen ser semejantes en muestras grandes.

Deviance

Definición 15.4. La deviance es

$$D = -2 \left[\ell(\hat{\beta}) - \ell(\text{modelo saturado}) \right].$$

Una deviance menor indica mejor ajuste relativo.

La deviance nula corresponde al modelo con solo intercepto.

Pseudo coeficientes de determinación

En regresión logística no existe un R^2 idéntico al de regresión lineal.

El de McFadden es

$$R_{McF}^2 = 1 - \frac{\ell(\hat{\beta})}{\ell(\hat{\beta}_0)}.$$

No debe interpretarse como proporción de varianza explicada.

Predicción

Para una observación nueva con características

$$\mathbf{x}_0 = \begin{pmatrix} x_{01} \\ \vdots \\ x_{0p} \end{pmatrix} \in \mathbb{R}^p,$$

se utiliza el vector aumentado

$$\tilde{\mathbf{x}}_0 = \begin{pmatrix} 1 \\ x_{01} \\ \vdots \\ x_{0p} \end{pmatrix} \in \mathbb{R}^{p+1}.$$

El predictor lineal es

$$\hat{\eta}_0 = \tilde{\mathbf{x}}_0^T \hat{\beta},$$

y la probabilidad predicha es

$$\hat{\pi}_0 = \frac{e^{\hat{\eta}_0}}{1 + e^{\hat{\eta}_0}}.$$

Clasificación mediante umbral

$$\hat{y} = \begin{cases} 1, & \hat{\pi} \geq t, \\ 0, & \hat{\pi} < t. \end{cases}$$

El valor $t = 0.5$ no siempre es óptimo.

Puede seleccionarse según:

- costo de errores;
- sensibilidad mínima;
- especificidad mínima;
- F1;
- índice de Youden.

Índice de Youden

$$J = \text{Sensibilidad} + \text{Especificidad} - 1.$$

Discriminación

La discriminación mide la capacidad de separar clases.

Puede evaluarse mediante:

- curva ROC;
- AUC;
- curva precisión-recall;
- sensibilidad;
- especificidad.

Calibración

La calibración evalúa si las probabilidades predichas corresponden a las frecuencias observadas.

Puede analizarse mediante:

- gráfico de calibración;
- Brier score;
- pendiente de calibración;
- intercepto de calibración.

Brier score

$$\text{Brier} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{\pi}_i)^2.$$

Pérdida logarítmica

$$\text{LogLoss} = -\frac{1}{n} \sum_{i=1}^n [y_i \log \hat{\pi}_i + (1 - y_i) \log(1 - \hat{\pi}_i)].$$

Residuos de Pearson

$$r_i^P = \frac{y_i - \hat{\pi}_i}{\sqrt{\hat{\pi}_i(1 - \hat{\pi}_i)}}.$$

Residuos de deviance

Para $y_i = 1$,

$$r_i^D = \sqrt{-2 \log(\hat{\pi}_i)}.$$

Para $y_i = 0$,

$$r_i^D = -\sqrt{-2 \log(1 - \hat{\pi}_i)}.$$

Apalancamiento e influencia

La matriz sombrero ponderada es

$$\mathbf{H}_W = \mathbf{W}^{1/2} \mathbf{X} (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}^{1/2}.$$

Los elementos diagonales miden apalancamiento.

La influencia puede estudiarse con distancia de Cook generalizada y DFBETAS.

Multicolinealidad

Puede producir:

- errores estándar grandes;
- coeficientes inestables;
- odds ratios extremos;
- dificultad de convergencia.

Se diagnostica mediante VIF, correlaciones y análisis de condición.

Separación completa

Definición 15.5. Existe separación completa cuando una combinación lineal de las variables separa perfectamente las dos clases.

En ese caso, algunos coeficientes tienden a infinito y el estimador de máxima verosimilitud no existe como valor finito.

Estrategias frente a separación

- combinar categorías escasas;
- aumentar el tamaño de muestra;
- utilizar ridge;
- utilizar corrección de Firth;
- emplear métodos bayesianos.

Clases desbalanceadas

Cuando una clase es poco frecuente:

- la exactitud puede ser engañosa;
- el umbral 0.5 puede ser inadecuado;
- la precisión puede ser baja;
- debe evaluarse sensibilidad y calibración.

Puede utilizarse ponderación:

$$L = - \sum_{i=1}^n w_i [y_i \log \pi_i + (1 - y_i) \log(1 - \pi_i)].$$

Separación completa

Si una combinación lineal separa perfectamente las clases, los estimadores de máxima verosimilitud pueden divergir. Puede utilizarse penalización o correcciones específicas.

Regularización

Ridge

$$J(\beta) = -\ell(\beta) + \lambda \|\beta\|_2^2.$$

LASSO

$$J(\beta) = -\ell(\beta) + \lambda \|\beta\|_1.$$

Elastic net

$$J(\beta) = -\ell(\beta) + \lambda [\alpha \|\beta\|_1 + (1 - \alpha) \|\beta\|_2^2].$$

Regresión logística multinomial

Para K clases y una categoría de referencia,

$$\log \left(\frac{P(Y = k \mid \mathbf{x})}{P(Y = K \mid \mathbf{x})} \right) = \beta_{k0} + \beta_k^\top \mathbf{x}.$$

La forma softmax es

$$P(Y = k \mid \mathbf{x}) = \frac{e^{\eta_k}}{\sum_{j=1}^K e^{\eta_j}}.$$

Frontera de decisión

Con umbral 0.5,

$$\hat{\pi}(\mathbf{x}) \geq 0.5$$

equivale a

$$\tilde{\mathbf{x}}^\top \beta \geq 0.$$

Por tanto, la frontera es lineal:

$$\tilde{\mathbf{x}}^\top \beta = 0.$$

Relación con aprendizaje supervisado

El espacio de hipótesis es

$$\mathcal{F} = \{\pi(\mathbf{x}) = \sigma(\tilde{\mathbf{x}}^\top \beta)\}.$$

La pérdida es logarítmica y el ajuste minimiza el riesgo empírico correspondiente.

Conexión con R

```
1 datos <- data.frame(  
2   severo = c(0, 0, 0, 1, 0, 1, 1, 1),  
3   velocidad = c(35, 42, 48, 70, 55, 80, 75, 90),  
4   noche = c(0, 0, 1, 1, 0, 1, 0, 1)  
5 )  
6  
7 modelo <- glm(  
8   severo ~ velocidad + noche,  
9   data = datos,  
10  family = binomial(link = "logit")  
11 )  
12  
13 summary(modelo)  
14  
15 # Odds ratios  
16 exp(coef(modelo))  
17  
18 # Intervalos de confianza  
19 exp(confint(modelo))  
20  
21 # Probabilidades  
22 prob <- predict(modelo, type = "response")  
23  
24 # Clases  
25 clase <- ifelse(prob >= 0.5, 1, 0)  
26  
27 table(  
28   Real = datos$severo,  
29   Predicha = clase  
30 )  
31  
32 deviance(modelo)  
33 AIC(modelo)
```

Ejemplo numérico

Considere

$$\text{logit}(\pi) = -4 + 0.08X_1 + 1.2X_2,$$

donde X_1 es velocidad y X_2 indica conducción nocturna.

Para velocidad 60 y conducción diurna,

$$\eta = -4 + 0.08(60) = 0.8.$$

Entonces

$$\pi = \frac{e^{0.8}}{1 + e^{0.8}} \approx 0.690.$$

El odds ratio por cada unidad adicional de velocidad es

$$e^{0.08} \approx 1.083.$$

Por cada 10 unidades,

$$e^{0.8} \approx 2.226.$$

Para conducción nocturna,

$$e^{1.2} \approx 3.320.$$

Manteniendo constante la velocidad, los odds de severidad son aproximadamente 3.32 veces mayores durante la noche.

Errores frecuentes

1. Interpretar β_j como cambio directo en probabilidad.
2. Confundir odds con probabilidad.
3. Interpretar odds ratio como riesgo relativo.
4. usar automáticamente un umbral de 0.5;
5. evaluar únicamente exactitud;
6. ignorar calibración;
7. concluir causalidad por significancia;
8. ignorar separación completa;
9. interpretar pseudo- R^2 como varianza explicada;
10. reportar odds ratios sin intervalos;
11. ignorar multicolinealidad;
12. confundir discriminación con calibración.

Ejercicios conceptuales

1. ¿Por qué no se utiliza regresión lineal para probabilidades binarias?
2. Defina odds y logit.
3. ¿Cómo se interpreta e^{β_j} ?
4. ¿Por qué el efecto sobre la probabilidad no es constante?
5. ¿Por qué no existe solución cerrada general?
6. Explique IRLS.
7. Compare Wald y razón de verosimilitud.
8. ¿Qué representa la deviance?
9. ¿Qué diferencia existe entre discriminación y calibración?
10. ¿Qué es separación completa?

11. ¿Por qué el umbral depende del objetivo?
12. ¿Cómo se extiende el modelo a múltiples clases?

Ejercicio de odds y logit

Calcule odds y logit para:

1. $\pi = 0.20$;
2. $\pi = 0.50$;
3. $\pi = 0.80$;
4. $\pi = 0.95$.

Ejercicio de interpretación

Considere

$$\text{logit}(\pi) = -2.5 + 0.4X_1 - 0.7X_2.$$

1. Interprete ambos coeficientes.
2. Calcule sus odds ratios.
3. Calcule la probabilidad para $X_1 = 3$ y $X_2 = 1$.

Ejercicio de verosimilitud

Considere

$$(y_1, y_2, y_3) = (1, 0, 1),$$

y

$$(\pi_1, \pi_2, \pi_3) = (0.8, 0.3, 0.6).$$

Calcule:

1. la verosimilitud;
2. la log-verosimilitud;
3. la pérdida logarítmica media.

Ejercicio de Newton-Raphson

Supóngase:

$$\ell'(\beta^{(t)}) = 2.4,$$

$$\ell''(\beta^{(t)}) = -5.0,$$

$$\beta^{(t)} = 0.8.$$

Calcule la siguiente iteración.

Ejercicio de inferencia

Supóngase:

$$\hat{\beta}_1 = 0.65, \quad SE(\hat{\beta}_1) = 0.20.$$

1. Calcule el estadístico de Wald.
2. Construya un intervalo del 95 por ciento.
3. Transforme el intervalo a odds ratio.
4. Interprete.

Ejercicio de razón de verosimilitud

Un modelo reducido tiene

$$\ell_R = -120.5.$$

El modelo completo tiene

$$\ell_C = -114.0.$$

La diferencia de parámetros es 2.

1. Calcule G^2 .
2. Indique la distribución de referencia.
3. Interprete.

Ejercicio aplicado

Se desea clasificar accidentes severos usando:

- velocidad;
- hora nocturna;
- lluvia;
- tipo de vialidad;
- interacción velocidad-lluvia.

Diseñe el análisis incluyendo:

1. formulación del modelo;
2. codificación de variables;
3. interpretación de coeficientes;
4. estimación;
5. pruebas;

6. odds ratios;
7. diagnóstico de multicolinealidad;
8. análisis de separación;
9. discriminación;
10. calibración;
11. selección de umbral;
12. validación cruzada;
13. regularización;
14. limitaciones causales.

Resumen

En este capítulo se desarrolló la regresión logística como modelo probabilístico para clasificación binaria.

Se estudiaron función logística, odds, logit y odds ratios. También se derivaron verosimilitud, log-verosimilitud, gradiente y Hessiana, y se explicó Newton-Raphson mediante IRLS.

Finalmente, se presentaron inferencia, deviance, pseudo- R^2 , predicción, selección de umbral, discriminación, calibración, separación, influencia, regularización y extensión multinomial.

Referencias del capítulo

Los fundamentos se apoyan en Agresti (2013), Hosmer et al. (2013), Bishop (2006) y James et al. (2021).

Parte IV

IV. Métodos de clasificación

16 Vecinos más cercanos, k-NN

Introducción

El método de vecinos más cercanos es no paramétrico y basa la predicción en observaciones localmente próximas. Su comportamiento depende de la métrica, la escala, el tamaño muestral y el número de vecinos (Cover y Hart 1967; Stone 1977; Duda et al. 2001).

El método de vecinos más cercanos, conocido como k -NN (*k-Nearest Neighbors*), es uno de los algoritmos más sencillos y a la vez más importantes del aprendizaje supervisado. Su idea central consiste en predecir la respuesta de una observación nueva a partir de las respuestas observadas en las muestras más próximas dentro del espacio de características.

A diferencia de modelos paramétricos como la regresión lineal o la regresión logística, k -NN no impone una forma funcional explícita para la relación entre variables. Por ello, se considera un método no paramétrico y basado en instancias.

En clasificación, la clase de una observación nueva se decide mediante voto mayoritario entre sus k vecinos más cercanos. En regresión, la predicción se obtiene promediando las respuestas de esos vecinos. Desde un punto de vista teórico, k -NN puede interpretarse como una aproximación local del riesgo condicional o de la función de regresión.

! Definición esencial

K-NN predice usando las observaciones más cercanas según una métrica.

Objetivos

Al finalizar el capítulo, el lector podrá:

1. formular matemáticamente el algoritmo k -NN;
2. distinguir entre clasificación y regresión mediante vecinos;
3. definir vecindades y distancias en espacios métricos;
4. interpretar el papel del parámetro k ;
5. comprender la relación entre k -NN y la estimación local de probabilidades;
6. analizar el compromiso entre sesgo y varianza;
7. estudiar la consistencia del método;
8. comprender el papel de la dimensionalidad y la normalización;
9. formular variantes ponderadas de k -NN;
10. construir reglas multiclase;
11. analizar complejidad computacional y estructuras de búsqueda;
12. relacionar k -NN con fronteras de decisión, kernels y métodos no paramétricos.

Espacio de entrada y muestra

Considérese una muestra de entrenamiento

$$\mathcal{D}_n = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\},$$

donde

$$\mathbf{x}_i \in \mathcal{X} \subseteq \mathbb{R}^p$$

y la respuesta puede ser:

- binaria, si $y_i \in \{0, 1\}$;
- multiclase, si $y_i \in \{1, \dots, C\}$;
- continua, si $y_i \in \mathbb{R}$.

Se recibe una observación nueva

$$\mathbf{x}_0 \in \mathcal{X},$$

y se desea predecir su respuesta.

Espacio métrico

El algoritmo requiere una noción de cercanía. Matemáticamente, ello se expresa mediante una distancia

$$d : \mathcal{X} \times \mathcal{X} \rightarrow [0, \infty),$$

que satisface, para cualesquiera $\mathbf{x}, \mathbf{z}, \mathbf{w} \in \mathcal{X}$:

1. $d(\mathbf{x}, \mathbf{z}) \geq 0$;
2. $d(\mathbf{x}, \mathbf{z}) = 0$ si y solo si $\mathbf{x} = \mathbf{z}$;
3. $d(\mathbf{x}, \mathbf{z}) = d(\mathbf{z}, \mathbf{x})$;
4. $d(\mathbf{x}, \mathbf{w}) \leq d(\mathbf{x}, \mathbf{z}) + d(\mathbf{z}, \mathbf{w})$.

! Escala y geometría

La noción de cercanía no es absoluta: depende de la representación y de la métrica. Antes de aplicar k-NN deben justificarse el escalamiento, la selección de variables y el tratamiento de variables categóricas.

Distancia euclidiana

La distancia más común en $\mathbb{R}^p$ es la euclidiana:

$$d_2(\mathbf{x}, \mathbf{z}) = \left(\sum_{j=1}^p (x_j - z_j)^2 \right)^{1/2}.$$

Distancia Manhattan

Otra distancia importante es

$$d_1(\mathbf{x}, \mathbf{z}) = \sum_{j=1}^p |x_j - z_j|.$$

Distancia de Minkowski

Una familia general es

$$d_q(\mathbf{x}, \mathbf{z}) = \left(\sum_{j=1}^p |x_j - z_j|^q \right)^{1/q}, \quad q \geq 1.$$

Para $q = 1$ se obtiene Manhattan y para $q = 2$ Euclidiana.

Distancia de Mahalanobis

Cuando las variables presentan escalas distintas o correlación, puede utilizarse

$$d_M(\mathbf{x}, \mathbf{z}) = \sqrt{(\mathbf{x} - \mathbf{z})^T \mathbf{S}^{-1} (\mathbf{x} - \mathbf{z})},$$

donde $\mathbf{S}$ es una matriz de covarianza o dispersión.

Ordenamiento de distancias

Para la observación nueva $\mathbf{x}_0$, se calculan las distancias

$$d_i = d(\mathbf{x}_0, \mathbf{x}_i), \quad i = 1, \dots, n.$$

Ordenándolas de menor a mayor,

$$d_{(1)} \leq d_{(2)} \leq \dots \leq d_{(n)},$$

se obtiene una permutación de índices

$$(i_1), (i_2), \dots, (i_n)$$

tal que $d_{(r)} = d(\mathbf{x}_0, \mathbf{x}_{(i_r)})$.

Definición de los vecinos más cercanos

Definición 16.1. Los k vecinos más cercanos de $\mathbf{x}_0$ son las observaciones de entrenamiento asociadas a las k menores distancias respecto de $\mathbf{x}_0$.

El conjunto de índices correspondientes se denota por

$$N_k(\mathbf{x}_0).$$

Regla de clasificación binaria

Supóngase $Y \in \{0, 1\}$. La probabilidad condicional local puede estimarse mediante

$$\hat{\eta}_k(\mathbf{x}_0) = \frac{1}{k} \sum_{i \in N_k(\mathbf{x}_0)} y_i.$$

Como $y_i \in \{0, 1\}$, esta cantidad representa la proporción de vecinos de clase 1.

La regla de clasificación es

$$\hat{g}_k(\mathbf{x}_0) = \begin{cases} 1, & \hat{\eta}_k(\mathbf{x}_0) \geq 1/2, \\ 0, & \hat{\eta}_k(\mathbf{x}_0) < 1/2. \end{cases}$$

Regla multiclase

Si $Y \in \{1, \dots, C\}$, para cada clase c se estima

$$\hat{p}_c(\mathbf{x}_0) = \frac{1}{k} \sum_{i \in N_k(\mathbf{x}_0)} \mathbb{I}(y_i = c).$$

La predicción se obtiene mediante

$$\hat{g}_k(\mathbf{x}_0) = \arg \max_{c \in \{1, \dots, C\}} \hat{p}_c(\mathbf{x}_0).$$

Regla de regresión

Si la respuesta es continua, la estimación natural es el promedio local:

$$\hat{m}_k(\mathbf{x}_0) = \frac{1}{k} \sum_{i \in N_k(\mathbf{x}_0)} y_i.$$

Esta expresión aproxima la función de regresión

$$m(\mathbf{x}) = \mathbb{E}(Y \mid \mathbf{X} = \mathbf{x}).$$

Interpretación local

El método k -NN aproxima la respuesta en $\mathbf{x}_0$ utilizando únicamente observaciones cercanas. Por ello, puede verse como un estimador local que supone que, en una vecindad suficientemente pequeña de $\mathbf{x}_0$, la respuesta cambia poco.

En clasificación binaria, si

$$\eta(\mathbf{x}) = P(Y = 1 \mid \mathbf{X} = \mathbf{x}),$$

entonces

$$\hat{\eta}_k(\mathbf{x}_0)$$

es una estimación local de dicha probabilidad.

Relación con la regla de Bayes

La regla óptima de Bayes en clasificación binaria es

$$g^*(\mathbf{x}) = \begin{cases} 1, & \eta(\mathbf{x}) \geq 1/2, \\ 0, & \eta(\mathbf{x}) < 1/2. \end{cases}$$

La regla k -NN reemplaza $\eta(\mathbf{x})$ por su estimación local $\hat{\eta}_k(\mathbf{x})$. De esta manera, k -NN puede entenderse como una aproximación empírica y no paramétrica de la regla de Bayes.

Pseudocódigo

Definición 16.2. Dada una observación nueva $\mathbf{x}_0$:

1. calcular $d(\mathbf{x}_0, \mathbf{x}_i)$ para todo $i = 1, \dots, n$;
2. ordenar las distancias;
3. seleccionar los k índices con menor distancia;
4. en clasificación, realizar voto mayoritario;
5. en regresión, promediar las respuestas.

Papel del parámetro k

El parámetro k controla el tamaño de la vecindad local.

- Si $k = 1$, la predicción depende exclusivamente del vecino más próximo.
- Si k es grande, la predicción incorpora una región más amplia del espacio.

Por ello, k regula el compromiso entre flexibilidad y suavizamiento.

Sesgo y varianza

Cuando k es pequeño:

- el modelo es muy flexible;
- el sesgo suele ser bajo;
- la varianza suele ser alta;
- la frontera de decisión puede ser irregular.

Cuando k es grande:

- el modelo es más suave;
- el sesgo aumenta;
- la varianza disminuye;
- la frontera de decisión es más estable.

Casos extremos

Caso k igual a 1

La regla 1-NN memoriza la muestra y produce una frontera muy irregular. Tiende a ser sensible al ruido.

Caso k igual a n

Si $k = n$, toda observación nueva utiliza la muestra completa.

En clasificación, la predicción siempre será la clase mayoritaria global.

En regresión,

$$\widehat{m}_n(\mathbf{x}_0) = \bar{y}.$$

En este caso se pierde toda adaptación local.

Error aparente de entrenamiento

En 1-NN, cada observación de entrenamiento es su propio vecino más cercano si no se excluye de la búsqueda. Por ello, el error aparente de entrenamiento puede ser cero o muy pequeño.

Sin embargo, ese resultado no refleja necesariamente el error de generalización. Para estimar desempeño predictivo es necesario emplear validación cruzada o un conjunto de prueba.

i Compromiso sesgo-varianza

Valores pequeños de k producen fronteras flexibles y alta varianza. Valores grandes suavizan la frontera, pero pueden aumentar el sesgo. El valor de k debe elegirse mediante validación.

Selección de k

La elección de k suele realizarse mediante validación cruzada. Formalmente,

$$\hat{k} = \arg \min_{k \in \mathcal{K}} CV(k),$$

donde $CV(k)$ representa una estimación del error de predicción asociada al valor k .

También puede usarse la regla de un error estándar para seleccionar un valor más grande y estable.

Empates

Pueden aparecer empates en dos sentidos:

1. empate de distancias, cuando varios puntos tienen la misma distancia al punto objetivo;
2. empate de votos, cuando varias clases reciben el mismo número de vecinos.

Las reglas para resolverlos incluyen:

- seleccionar aleatoriamente entre las clases empatadas;
- favorecer la clase del vecino más cercano entre las empatadas;

- elegir k impar en clasificación binaria;
- ponderar por distancia.

Vecinos ponderados

Una variante natural asigna pesos mayores a los vecinos más cercanos. Si $w_i(\mathbf{x}_0) \geq 0$ para $i \in N_k(\mathbf{x}_0)$, con

$$\sum_{i \in N_k(\mathbf{x}_0)} w_i(\mathbf{x}_0) = 1,$$

entonces la estimación de clasificación binaria es

$$\hat{\eta}_{k,w}(\mathbf{x}_0) = \sum_{i \in N_k(\mathbf{x}_0)} w_i(\mathbf{x}_0) y_i.$$

En regresión,

$$\hat{m}_{k,w}(\mathbf{x}_0) = \sum_{i \in N_k(\mathbf{x}_0)} w_i(\mathbf{x}_0) y_i.$$

Ponderación inversa a la distancia

Una elección frecuente es

$$w_i(\mathbf{x}_0) = \frac{1/d(\mathbf{x}_0, \mathbf{x}_i)}{\sum_{j \in N_k(\mathbf{x}_0)} 1/d(\mathbf{x}_0, \mathbf{x}_j)}.$$

Si alguna distancia es cero, debe tratarse por separado para evitar división entre cero.

k-NN como estimador de ventana móvil

El método puede interpretarse como una estimación local sobre una vecindad aleatoria cuyo radio depende de la densidad de datos. En regiones densas, el radio necesario para contener k vecinos es pequeño; en regiones dispersas, el radio es mayor.

Esto contrasta con métodos de ventana fija, donde el radio es constante y el número de observaciones dentro de la vecindad varía.

Relación con kernels

Los estimadores con kernels tienen la forma

$$\hat{m}_h(\mathbf{x}_0) = \frac{\sum_{i=1}^n K_h(\mathbf{x}_0, \mathbf{x}_i) y_i}{\sum_{i=1}^n K_h(\mathbf{x}_0, \mathbf{x}_i)}.$$

En cierto sentido, k -NN corresponde a una vecindad adaptativa con pesos uniformes sobre los k vecinos seleccionados y peso cero fuera de ellos.

Consistencia

Uno de los resultados teóricos clásicos afirma que, bajo condiciones regulares, k -NN es consistente si

$$k \rightarrow \infty$$

y al mismo tiempo

$$\frac{k}{n} \rightarrow 0$$

cuando $n \rightarrow \infty$.

Estas condiciones expresan que:

- el número de vecinos debe crecer para reducir varianza;
- la fracción de la muestra usada localmente debe hacerse pequeña para preservar localización.

Comentario sobre consistencia de clasificación

Bajo hipótesis adecuadas, el riesgo de clasificación de la regla k -NN converge al riesgo de Bayes. El caso 1-NN, aunque no es consistentemente óptimo en el mismo sentido, satisface resultados clásicos como la cota de Cover y Hart.

Resultado de Cover y Hart

Para 1-NN, el error asintótico de clasificación R_{1NN} satisface la desigualdad

$$R^* \leq R_{1NN} \leq 2R^*(1 - R^*),$$

donde R^* es el error de Bayes.

Esta cota muestra que el vecino más cercano puede tener un desempeño competitivo, aunque no sea óptimo.

Fronteras de decisión

La frontera de decisión de k -NN puede ser muy irregular, especialmente para valores pequeños de k . La estructura geométrica depende de la partición inducida por las distancias entre puntos de entrenamiento.

En el caso 1-NN, las regiones de clasificación se relacionan con diagramas de Voronoi.

Celdas de Voronoi

Para cada punto de entrenamiento $\mathbf{x}_i$, la celda de Voronoi asociada es

$$V_i = \{\mathbf{x} \in \mathcal{X} : d(\mathbf{x}, \mathbf{x}_i) \leq d(\mathbf{x}, \mathbf{x}_j) \text{ para todo } j\}.$$

En 1-NN, toda observación dentro de V_i recibe la respuesta del punto i .

Influencia de la escala de las variables

El desempeño de k -NN depende fuertemente de la distancia, y la distancia depende de la escala de las variables. Si una variable tiene magnitudes mucho mayores que otra, dominará la medición de cercanía.

Por ello, casi siempre es necesario estandarizar o normalizar las variables antes de aplicar k -NN.

Estandarización

Una transformación habitual es

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}.$$

Otra posibilidad es reescalar al intervalo $[0, 1]$.

Variables irrelevantes

Las variables irrelevantes pueden deteriorar gravemente el desempeño, pues introducen ruido en la distancia y dificultan la identificación de vecinos realmente informativos.

Por ello, en problemas de alta dimensión es importante considerar:

- selección de variables;
- reducción de dimensionalidad;
- ponderación de características;
- distancias especializadas.

Dimensión alta

Cuando la dimensión crece, las distancias tienden a perder contraste y las vecindades necesitan abarcar regiones amplias para contener suficientes observaciones. La reducción o selección de variables puede ser esencial.

Maldición de la dimensionalidad

A medida que la dimensión p crece, los puntos tienden a parecerse entre sí en términos relativos de distancia. Esto reduce el carácter local de la vecindad y puede degradar severamente el método.

Este fenómeno se conoce como maldición de la dimensionalidad.

Interpretación geométrica de la maldición de la dimensionalidad

En dimensiones altas, para capturar una fracción pequeña de la probabilidad alrededor de un punto, la vecindad debe expandirse notablemente. En consecuencia, los vecinos más cercanos pueden dejar de ser realmente cercanos.

Esto explica por qué k -NN suele funcionar mejor en dimensiones moderadas y con variables informativas bien escaladas.

Reducción de dimensionalidad antes de k-NN

Es frecuente aplicar métodos como PCA antes de k -NN para concentrar la información relevante en pocas dimensiones y reducir ruido. Sin embargo, esta transformación debe aprenderse dentro de cada partición de entrenamiento para evitar fuga de información.

Costos computacionales

Entrenamiento

El costo de entrenamiento de k -NN es bajo, pues esencialmente consiste en almacenar la muestra.

Predicción

La predicción puede ser costosa. Para cada punto nuevo, la búsqueda ingenua requiere calcular distancias a las n observaciones, con un costo del orden de

$$O(np)$$

por predicción, más el costo de identificar los k menores valores.

Estructuras de búsqueda

Para acelerar la búsqueda de vecinos se emplean estructuras como:

- k - d trees;
- ball trees;
- hashing sensible a localidad;
- búsqueda aproximada de vecinos.

Su utilidad depende de la dimensión y de la estructura de los datos.

Distancia para variables mixtas

Cuando existen variables numéricas y categóricas, la distancia euclidiana puede ser inadecuada. En tales casos puede utilizarse:

- codificación apropiada de variables categóricas;
- distancias de Gower;
- métricas mixtas especializadas.

Desbalance de clases

Si una clase es muy frecuente, el voto mayoritario puede sesgarse hacia ella. Algunas estrategias son:

- ponderación por distancia;
- ajuste del umbral sobre probabilidades locales;
- sobre-muestreo o sub-muestreo;
- voto con pesos por clase.

Probabilidades predichas y calibración

En clasificación, la proporción local de vecinos de una clase puede interpretarse como una probabilidad predicha. No obstante, la calibración de esas probabilidades depende del tamaño de la vecindad y de la densidad local de datos.

Por ello, la evaluación del método no debe limitarse a exactitud, sino también a métricas probabilísticas cuando corresponda.

Sensibilidad al ruido y a valores atípicos

Con valores pequeños de k , el método puede ser sensible a:

- etiquetas erróneas;
- observaciones atípicas;
- regiones escasas del espacio.

Aumentar k o ponderar por distancia puede mitigar parcialmente este problema.

Interpretación de la complejidad del modelo

Aunque k -NN no ajusta explícitamente parámetros, su complejidad depende de:

- el valor de k ;
- la métrica utilizada;
- la escala de las variables;
- la dimensión efectiva del problema.

En este sentido, k actúa como parámetro de suavizamiento o regularización.

Relación con regresión local

En regresión, k -NN constituye una forma elemental de regresión local constante. Métodos más avanzados, como la regresión local lineal, mejoran esta aproximación ajustando modelos dentro de la vecindad.

Conexión con el aprendizaje supervisado

El algoritmo define una familia de predictores

$$\mathcal{F} = \{\hat{f}_{k,d} : k \in \mathcal{K}, d \in \mathcal{D}\},$$

determinada por el número de vecinos y la métrica. La selección de estos hiperparámetros se realiza normalmente mediante validación cruzada.

Conexión con R

```
1 # Clasificación con k-NN
2 # Requiere class
```

```

3 library(class)
4
5 x <- data.frame(
6   x1 = c(1, 2, 3, 6, 7, 8),
7   x2 = c(1, 1, 2, 6, 7, 8)
8 )
9
10 y <- factor(c("A", "A", "A", "B", "B", "B"))
11
12 # Escalamiento
13 x_esc <- scale(x)
14
15 nuevo <- data.frame(x1 = 4, x2 = 4)
16 nuevo_esc <- scale(nuevo,
17   center = attr(x_esc, "scaled:center"),
18   scale = attr(x_esc, "scaled:scale"))
19
20 knn(
21   train = x_esc,
22   test = nuevo_esc,
23   cl = y,
24   k = 3,
25   prob = TRUE
26 )
27
28 # Regresión con k-NN aproximada usando FNN
29 # library(FNN)
30 # knn.reg(train = x_esc, y = respuesta, test = nuevo_esc, k = 5)

```

Ejemplo numérico de clasificación

Considérese la muestra:

Observación	x_1	x_2	Clase
1	1	1	A
2	2	1	A
3	2	2	A
4	5	5	B
5	6	5	B
6	6	6	B

Se desea clasificar

$$\mathbf{x}_0 = (4, 4).$$

Con distancia euclidiana, las distancias a los puntos 3 y 4 son las más pequeñas. Si $k = 3$, se incluyen los tres vecinos más cercanos y se realiza voto mayoritario.

La clasificación final dependerá de las distancias exactas y del valor de k , lo cual ilustra la naturaleza local del método.

Ejemplo numérico de regresión

Supóngase que las respuestas asociadas a los 4 vecinos más cercanos de un punto son

8, 10, 11, 15.

Entonces, para $k = 4$,

$$\widehat{m}_4(\mathbf{x}_0) = \frac{8 + 10 + 11 + 15}{4} = 11.$$

Si se usan pesos proporcionales a la cercanía, la predicción puede desplazarse hacia los vecinos más próximos.

Ventajas

1. es conceptualmente simple;
2. no requiere ajuste paramétrico explícito;
3. puede adaptarse a fronteras de decisión complejas;
4. funciona bien en problemas pequeños o medianos con estructura local clara;
5. es flexible tanto para clasificación como para regresión.

Limitaciones

1. depende fuertemente de la escala de variables;
2. puede ser costoso en predicción;
3. es sensible a la dimensionalidad alta;
4. sufre con variables irrelevantes;
5. puede ser sensible al ruido para valores pequeños de k ;
6. su interpretabilidad global es limitada.

Errores frecuentes

1. aplicar k -NN sin estandarizar variables;
2. elegir k sin validación;
3. ignorar empates;
4. usarlo en alta dimensión sin reducción o selección de variables;
5. evaluar únicamente exactitud;
6. preprocesar usando todo el conjunto antes de la validación;
7. utilizar distancia euclidiana con variables categóricas sin tratamiento adecuado;
8. confundir memorizar la muestra con generalizar bien.

Ejercicios conceptuales

1. Explique por qué k -NN es un método no paramétrico.
2. ¿Qué papel cumple la distancia?
3. ¿Cómo se interpreta el parámetro k ?
4. ¿Por qué k pequeño reduce sesgo pero aumenta varianza?
5. ¿Por qué la estandarización es importante?
6. ¿Qué significa que k -NN sea local?
7. Explique la maldición de la dimensionalidad.
8. ¿Qué ventaja ofrece la ponderación por distancia?
9. ¿Por qué se requiere validación cruzada para elegir k ?
10. ¿Qué relación existe entre k -NN y la regla de Bayes?

Ejercicio de distancias

Considere los puntos

$$(1, 1), (2, 3), (4, 4), (6, 5)$$

y el punto nuevo

$$(3, 2).$$

1. Calcule las distancias euclidianas.
2. Ordene los vecinos.
3. Identifique los 2 y 3 vecinos más cercanos.
4. Repita con distancia Manhattan.
5. Compare el orden obtenido.

Ejercicio de clasificación

Considere la siguiente muestra:

x_1	x_2	Clase
1	1	A
2	1	A
3	2	A
5	5	B
6	5	B
7	6	B

Clasifique el punto $(4, 4)$ para:

1. $k = 1$;
2. $k = 3$;
3. $k = 5$.

Interprete cómo cambia la decisión.

Ejercicio de regresión

Las respuestas de los 5 vecinos más cercanos son:

12, 14, 15, 16, 23.

1. Calcule la predicción con promedio simple.
2. Suponga pesos

0.35, 0.25, 0.20, 0.15, 0.05

y calcule la predicción ponderada.

3. Compare ambas estimaciones.

Ejercicio de selección de k

Se obtiene el siguiente error de validación cruzada:

k	Error CV
1	0.18
3	0.14
5	0.12
7	0.13
9	0.15
15	0.19

1. Seleccione el mejor valor de k .
2. Explique por qué no conviene elegir $k = 1$ solo por su flexibilidad.
3. Interprete el patrón en términos de sesgo y varianza.

Ejercicio aplicado

Se desea clasificar accidentes de tránsito como severos o no severos usando:

- velocidad estimada;
- hora del día;
- condición climática;
- tipo de vialidad;
- presencia de peatones.

Diseñe un análisis con k -NN que incluya:

1. preprocesamiento;
2. tratamiento de variables categóricas;
3. escalamiento;
4. división entrenamiento-validación-prueba;
5. selección de k ;

6. elección de la métrica;
7. evaluación con matriz de confusión, sensibilidad y AUC;
8. comparación con regresión logística;
9. análisis del efecto de la dimensionalidad;
10. limitaciones prácticas.

Resumen

En este capítulo se desarrolló el método de vecinos más cercanos como un procedimiento no paramétrico y local para clasificación y regresión.

Se formularon matemáticamente la noción de vecino, las reglas de voto y promedio, las distancias más utilizadas y la interpretación de k como parámetro de suavizamiento. También se analizó el compromiso entre sesgo y varianza, la consistencia, la maldición de la dimensionalidad, la necesidad de escalamiento y las variantes ponderadas.

Finalmente, se estudiaron sus costos computacionales, su relación con la regla de Bayes, con celdas de Voronoi y con estimadores locales. Estos fundamentos preparan el estudio de árboles de decisión, métodos de margen y otros clasificadores no lineales.

Referencias del capítulo

Los fundamentos y resultados desarrollados en este capítulo se apoyan principalmente en Cover y Hart (1967); Stone (1977); Duda et al. (2001).

17 Árboles de decisión

Introducción

Los árboles de decisión particionan recursivamente el espacio predictor mediante reglas simples. Su interpretabilidad es atractiva, pero un árbol profundo puede tener alta varianza y sobreajustar (Breiman et al. 1984; Quinlan 1986, 1993).

Los árboles de decisión son modelos supervisados que dividen recursivamente el espacio de características en regiones cada vez más homogéneas. Cada división se expresa mediante una regla sencilla, por ejemplo,

$$X_j \leq s,$$

donde X_j es una característica y s es un punto de corte.

El modelo final tiene una estructura jerárquica formada por nodos internos, ramas y hojas terminales. En clasificación, cada hoja asigna una clase o una distribución de probabilidades; en regresión, asigna un valor numérico, habitualmente la media de las respuestas que llegan a esa hoja.

Los árboles destacan por su interpretabilidad, su capacidad de representar relaciones no lineales e interacciones, y su escasa necesidad de transformaciones previas. Sin embargo, un árbol profundo puede presentar alta varianza y sobreajuste. Por ello, su construcción requiere criterios de impureza, reglas de parada y procedimientos de poda.

! Definición esencial

Un árbol divide recursivamente el espacio de predictores mediante reglas simples.

Objetivos

Al finalizar el capítulo, el lector podrá:

1. formular un árbol como una partición recursiva del espacio;
2. distinguir nodos, ramas y hojas;
3. definir impureza de Gini y entropía;
4. calcular ganancia de información;
5. formular divisiones para variables numéricas y categóricas;
6. construir árboles de clasificación y regresión;
7. comprender los algoritmos ID3, C4.5 y CART;
8. analizar sobreajuste y profundidad;
9. comprender la poda por complejidad de costo;
10. interpretar probabilidades en hojas;
11. analizar sesgo, varianza e inestabilidad;

12. evaluar importancia de variables;
13. reconocer limitaciones de la importancia basada en impureza;
14. conectar árboles con random forest y boosting.

Estructura de un árbol

Un árbol está formado por:

- **nodo raíz:** contiene todas las observaciones;
- **nodos internos:** aplican reglas de división;
- **ramas:** representan resultados de las reglas;
- **hojas terminales:** producen la predicción.

Cada observación recorre el árbol desde la raíz hasta una hoja.

Representación mediante regiones

Sea el espacio de entrada

$$\mathcal{X} \subseteq \mathbb{R}^p.$$

Un árbol induce una partición

$$\mathcal{X} = R_1 \cup R_2 \cup \dots \cup R_M,$$

donde las regiones son disjuntas:

$$R_m \cap R_\ell = \emptyset, \quad m \neq \ell.$$

Cada hoja corresponde a una región R_m .

Regla de predicción en clasificación

Sea

$$N_m = \{i : \mathbf{x}_i \in R_m\}$$

el conjunto de observaciones de entrenamiento que pertenecen a la hoja m .

La proporción estimada de la clase c es

$$\hat{p}_{mc} = \frac{1}{|N_m|} \sum_{i \in N_m} \mathbb{I}(y_i = c).$$

La clase predicha es

$$\hat{g}(\mathbf{x}) = \arg \max_c \hat{p}_{mc}, \quad \mathbf{x} \in R_m.$$

Regla de predicción en regresión

En regresión, la predicción de la hoja es

$$\hat{c}_m = \frac{1}{|N_m|} \sum_{i \in N_m} y_i.$$

Por tanto,

$$\hat{f}(\mathbf{x}) = \sum_{m=1}^M \hat{c}_m \mathbb{I}(\mathbf{x} \in R_m).$$

El árbol de regresión es una función constante por regiones.

División binaria

En CART, cada nodo se divide en dos hijos. Para una variable numérica X_j , una división tiene la forma

$$R_{\text{izq}}(j, s) = \{\mathbf{x} : x_j \leq s\},$$

$$R_{\text{der}}(j, s) = \{\mathbf{x} : x_j > s\}.$$

El algoritmo busca la pareja (j, s) que produce la mayor reducción de impureza.

Impureza de un nodo

Sea t un nodo y

$$\hat{p}_{tc} = \frac{n_{tc}}{n_t},$$

donde n_{tc} es el número de observaciones de clase c y n_t el total del nodo.

Una medida de impureza cuantifica cuán mezcladas están las clases dentro del nodo.

Error de clasificación

La impureza basada en error de clasificación es

$$I_E(t) = 1 - \max_c \hat{p}_{tc}.$$

Es intuitiva, pero poco sensible a cambios en las probabilidades y por ello se usa menos para construir el árbol.

Impureza de Gini

Definición 17.1. La impureza de Gini de un nodo es

$$I_G(t) = 1 - \sum_{c=1}^C \hat{p}_{tc}^2.$$

También puede escribirse como

$$I_G(t) = \sum_{c=1}^C \hat{p}_{tc} (1 - \hat{p}_{tc}).$$

En clasificación binaria, si p es la proporción de la clase positiva,

$$I_G(t) = 2p(1 - p).$$

i Impureza y error de clasificación

Entropía y Gini se utilizan para construir el árbol porque son más sensibles a cambios en las probabilidades de clase que el error de clasificación. Una menor impureza local no garantiza por sí sola mejor desempeño fuera de muestra.

Entropía

Definición 17.2. La entropía de un nodo es

$$H(t) = - \sum_{c=1}^C \hat{p}_{tc} \log_2 \hat{p}_{tc},$$

con la convención $0 \log 0 = 0$.

La entropía es cero en un nodo puro y alcanza su máximo cuando las clases están distribuidas uniformemente.

Comparación entre Gini y entropía

Ambas medidas:

- valen cero en nodos puros;
- aumentan con la mezcla de clases;
- suelen producir árboles semejantes;
- penalizan más la mezcla que el error de clasificación.

CART utiliza habitualmente Gini; ID3 y C4.5 utilizan entropía.

Impureza ponderada después de una división

Si un nodo t se divide en hijos t_L y t_R , la impureza posterior es

$$I_{\text{div}} = \frac{n_L}{n_t} I(t_L) + \frac{n_R}{n_t} I(t_R).$$

La reducción de impureza es

$$\Delta I = I(t) - I_{\text{div}}.$$

Se elige la división que maximiza ΔI .

Ganancia de información

Cuando se usa entropía,

$$IG = H(t) - \sum_v \frac{n_v}{n_t} H(t_v).$$

La ganancia de información mide la reducción esperada de incertidumbre producida por una división.

Ejemplo de Gini

Supóngase un nodo con 10 observaciones:

- 6 de clase A;
- 4 de clase B.

Entonces,

$$\hat{p}_A = 0.6, \quad \hat{p}_B = 0.4.$$

La impureza es

$$I_G = 1 - (0.6^2 + 0.4^2) = 0.48.$$

Si una división genera dos nodos casi puros, la impureza ponderada disminuirá notablemente.

Árboles de regresión

Para regresión, se busca minimizar la suma de cuadrados dentro de las hojas.

Para una región R_m , el valor óptimo es

$$\hat{c}_m = \arg \min_c \sum_{i: \mathbf{x}_i \in R_m} (y_i - c)^2.$$

La solución es la media:

$$\hat{c}_m = \bar{y}_{R_m}.$$

Criterio de división en regresión

Para una división (j, s) se minimiza

$$\sum_{i:x_{ij} \leq s} (y_i - \bar{y}_L)^2 + \sum_{i:x_{ij} > s} (y_i - \bar{y}_R)^2.$$

Equivalentemente, se maximiza la reducción de suma de cuadrados.

Partición recursiva

El árbol se construye de manera codiciosa:

1. se evalúan todas las divisiones candidatas;
2. se selecciona la mejor división local;
3. se divide el nodo;
4. se repite el proceso en cada nodo hijo.

El procedimiento es codicioso porque no reconsidera globalmente decisiones anteriores.

Variables numéricas

Para una variable numérica ordenada, los puntos de corte candidatos suelen ubicarse entre valores consecutivos distintos:

$$s_r = \frac{x_{(r)} + x_{(r+1)}}{2}.$$

No es necesario evaluar todos los números reales.

Variables categóricas

Para una variable categórica con niveles

$$\{a_1, \dots, a_K\},$$

una división puede separar un subconjunto de categorías del resto.

El número de particiones posibles crece rápidamente, por lo que los algoritmos utilizan estrategias eficientes o codificaciones específicas.

Algoritmo ID3

ID3 construye árboles de clasificación utilizando:

- entropía;
- ganancia de información;
- divisiones generalmente múltiples;
- variables categóricas en su formulación original.

En cada nodo selecciona la variable con mayor ganancia de información.

Sesgo de la ganancia de información

Una variable con muchos niveles puede producir una ganancia artificialmente alta, al crear grupos pequeños o incluso puros.

Este problema motivó el criterio de razón de ganancia de C4.5.

C4.5

C4.5 extiende ID3 mediante:

- manejo de variables continuas;
- tratamiento de valores faltantes;
- razón de ganancia;
- poda posterior;
- conversión opcional a reglas.

Razón de ganancia

La información de división es

$$SplitInfo = - \sum_v \frac{n_v}{n_t} \log_2 \left(\frac{n_v}{n_t} \right).$$

La razón de ganancia es

$$GainRatio = \frac{IG}{SplitInfo}.$$

Este criterio penaliza divisiones que producen demasiados grupos.

CART

CART significa *Classification and Regression Trees*.

Sus características principales son:

- divisiones binarias;
- Gini para clasificación;
- suma de cuadrados para regresión;
- construcción de un árbol grande;
- poda por complejidad de costo.

Profundidad del árbol

La profundidad es el número máximo de divisiones desde la raíz hasta una hoja.

Un árbol profundo:

- se adapta intensamente a la muestra;
- puede representar interacciones complejas;
- suele tener bajo sesgo;

- puede presentar alta varianza.

Un árbol poco profundo:

- es más estable;
- es más fácil de interpretar;
- puede presentar subajuste.

Parámetros de control

Los hiperparámetros comunes incluyen:

- profundidad máxima;
- número mínimo de observaciones para dividir;
- número mínimo de observaciones por hoja;
- reducción mínima de impureza;
- número máximo de hojas;
- parámetro de complejidad.

Crecimiento máximo

Una estrategia consiste en hacer crecer un árbol grande hasta que:

- los nodos sean puros;
- no haya suficientes observaciones;
- no exista mejora apreciable;
- se alcance una restricción de profundidad.

Posteriormente se aplica poda.

Sobreajuste

Un árbol sin control puede aprender particularidades y ruido de la muestra. Esto suele manifestarse como:

- error de entrenamiento muy bajo;
- error de validación alto;
- hojas con pocas observaciones;
- fronteras de decisión extremadamente irregulares.

! Crecimiento y poda

En CART suele crearse un árbol amplio y después podarse mediante complejidad-costo. La poda debe seleccionarse con validación para equilibrar ajuste y complejidad.

Poda

Definición 17.3. La poda elimina ramas de un árbol grande para producir un modelo más simple y mejorar la generalización.

Puede realizarse:

- durante el crecimiento, mediante parada anticipada;
- después del crecimiento, mediante poda posterior.

Poda por complejidad de costo

Para un árbol T , CART define

$$R_\alpha(T) = R(T) + \alpha|T|,$$

donde:

- $R(T)$ es el error o impureza del árbol;
- $|T|$ es el número de hojas;
- $\alpha \geq 0$ controla la penalización por complejidad.

Cuando α aumenta, se favorecen árboles más pequeños.

Secuencia de subárboles

La poda de eslabón más débil produce una secuencia anidada

$$T_0 \supset T_1 \supset \dots \supset T_L,$$

desde el árbol máximo hasta el árbol raíz.

La selección del subárbol se realiza mediante validación cruzada.

Selección mediante validación cruzada

Se estima el error

$$CV(\alpha)$$

para diferentes valores de α .

Se elige

$$\hat{\alpha} = \arg \min_{\alpha} CV(\alpha).$$

También puede utilizarse la regla de un error estándar para seleccionar un árbol más pequeño.

Interpretación de una ruta

Una ruta desde la raíz hasta una hoja representa una conjunción de condiciones.

Por ejemplo:

$$X_1 \leq 20, \quad X_3 > 5, \quad X_2 \in \{A, C\}.$$

La hoja puede traducirse en una regla fácilmente comunicable.

Interacciones automáticas

Los árboles representan interacciones sin introducir explícitamente productos entre variables.

Si una división sobre X_2 aparece únicamente después de una división sobre X_1 , el efecto de X_2 depende de la región definida por X_1 .

No linealidad

Los árboles pueden aproximar relaciones no lineales mediante divisiones escalonadas. En regresión, la función resultante es constante por regiones.

Aunque esto proporciona flexibilidad, puede producir predicciones discontinuas.

Invariancia a transformaciones monótonas

Como las divisiones dependen principalmente del orden de los valores, un árbol es generalmente invariante ante transformaciones estrictamente monótonas de una variable numérica.

Por ejemplo, aplicar logaritmo a una variable positiva puede cambiar los puntos numéricos, pero no necesariamente el orden ni la partición óptima.

Escalamiento

A diferencia de k -NN o SVM, los árboles no suelen requerir estandarización, porque las divisiones se realizan variable por variable.

Esta es una ventaja práctica importante.

Valores faltantes

Según el algoritmo, pueden tratarse mediante:

- imputación;
- divisiones sustitutas;
- categorías especiales;
- distribución probabilística entre ramas.

La estrategia debe aprenderse únicamente con datos de entrenamiento.

Probabilidades en las hojas

Una hoja no solo produce una clase. También puede estimar probabilidades:

$$\widehat{P}(Y = c \mid \mathbf{x} \in R_m) = \hat{p}_{mc}.$$

Sin embargo, hojas pequeñas pueden producir probabilidades extremas e inestables.

Suavizamiento de probabilidades

Puede aplicarse suavizamiento de Laplace:

$$\tilde{p}_{mc} = \frac{n_{mc} + \lambda}{n_m + C\lambda}.$$

Con $\lambda = 1$, se evita obtener probabilidades exactamente cero en hojas pequeñas.

Clases desbalanceadas

En datos desbalanceados, un árbol puede favorecer la clase mayoritaria.

Estrategias:

- pesos por clase;
- costos de error asimétricos;
- muestreo;
- umbral ajustado;
- métricas adecuadas;
- restricciones de tamaño por hoja.

Pérdidas asimétricas

Sea $L(a, c)$ el costo de predecir a cuando la clase real es c .

La decisión óptima en una hoja es

$$\hat{a}_m = \arg \min_a \sum_c L(a, c) \hat{p}_{mc}.$$

Así, la clase predicha no tiene que ser necesariamente la más frecuente.

Importancia por reducción de impureza

La importancia de la variable j puede definirse como la suma de las reducciones de impureza producidas por divisiones sobre esa variable:

$$VI_j = \sum_{t:v(t)=j} \frac{n_t}{n} \Delta I_t.$$

Limitaciones de la importancia por impureza

Esta medida puede favorecer variables:

- continuas;
- con muchos valores distintos;
- categóricas con numerosos niveles.

Por ello, debe interpretarse con cautela.

Importancia por permutación

La importancia por permutación mide cuánto aumenta el error al desordenar los valores de una variable:

$$PI_j = \text{Error}_{perm(j)} - \text{Error}_{base}.$$

Esta medida se relaciona más directamente con el desempeño predictivo, aunque puede verse afectada por variables correlacionadas.

Inestabilidad

Los árboles presentan alta inestabilidad: pequeños cambios en la muestra pueden producir estructuras muy diferentes.

Esto ocurre porque una modificación pequeña puede cambiar la mejor división en un nodo superior y alterar todas las divisiones posteriores.

Sesgo y varianza

Un árbol profundo suele presentar:

- bajo sesgo;
- alta varianza.

Un árbol podado suele presentar:

- mayor sesgo;
- menor varianza.

Esta propiedad motiva los métodos de ensamble, como bagging y random forest.

Complejidad computacional

En una implementación eficiente, el costo depende de:

- número de observaciones;
- número de variables;
- número de puntos de corte;
- profundidad;
- tratamiento de variables categóricas.

La predicción es rápida porque solo requiere recorrer una ruta desde la raíz hasta una hoja.

Fronteras de decisión

Con divisiones univariadas, las fronteras son paralelas a los ejes coordenados.

Esto permite representar regiones rectangulares, pero puede ser ineficiente para fronteras oblicuas.

Árboles oblicuos

Una extensión utiliza divisiones de la forma

$$\mathbf{a}^\top \mathbf{x} \leq s.$$

Estas divisiones pueden representar fronteras inclinadas, aunque son más costosas y menos interpretables.

Relación con minimización del riesgo empírico

Un árbol busca una función por regiones que minimice una pérdida empírica, sujeta a una estructura jerárquica.

La poda añade una penalización de complejidad:

$$\hat{T} = \arg \min_T \{ \widehat{R}(T) + \alpha |T| \}.$$

Relación con random forest

Random forest reduce la varianza mediante:

- múltiples muestras bootstrap;
- crecimiento de muchos árboles;
- selección aleatoria de variables;
- promedio o voto.

El árbol individual es, por tanto, la unidad básica de random forest.

Relación con boosting

Boosting construye árboles secuencialmente, haciendo que cada nuevo árbol corrija errores del conjunto anterior.

Generalmente utiliza árboles pequeños como aprendices débiles.

Conexión con R

```
1 library(rpart)
2 library(rpart.plot)
3
4 datos <- data.frame(
5   severo = factor(c("No", "No", "No", "Sí", "Sí", "Sí", "No", "Sí")),
6   velocidad = c(35, 42, 48, 70, 80, 75, 55, 90),
7   noche = factor(c(0, 0, 1, 1, 1, 0, 0, 1)),
8   lluvia = factor(c(0, 1, 0, 1, 0, 1, 0, 1))
9 )
10
11 modelo <- rpart(
12   severo ~ velocidad + noche + lluvia,
13   data = datos,
14   method = "class",
15   control = rpart.control(
16     cp = 0.01,
17     minsplit = 2,
18     maxdepth = 3
```



```

19   )
20   )
21
22   rpart.plot(modelo)
23
24   # Tabla de complejidad
25   printcp(modelo)
26
27   # Poda
28   cp_optimo <- modelo$cptable[
29     which.min(modelo$cptable[, "xerror"]),
30     "CP"
31   ]
32
33   modelo_podado <- prune(modelo, cp = cp_optimo)
34
35   # Probabilidades
36   predict(modelo_podado, type = "prob")
37
38   # Clases
39   predict(modelo_podado, type = "class")

```

Ejemplo de ganancia de información

Supóngase un nodo con 12 observaciones:

- 7 positivas;
- 5 negativas.

La entropía inicial es

$$H(t) = -\frac{7}{12} \log_2 \left(\frac{7}{12} \right) - \frac{5}{12} \log_2 \left(\frac{5}{12} \right).$$

Una división produce:

- nodo izquierdo: 6 positivas y 1 negativa;
- nodo derecho: 1 positiva y 4 negativas.

La entropía posterior es

$$H_{\text{div}} = \frac{7}{12} H(t_L) + \frac{5}{12} H(t_R).$$

La ganancia es

$$IG = H(t) - H_{\text{div}}.$$

Ejemplo de árbol de regresión

Supóngase que una división genera:

$$R_1 = \{X \leq 10\}, \quad R_2 = \{X > 10\}.$$

Si las respuestas en R_1 son

5, 7, 8,

la predicción de la primera hoja es

$$\hat{c}_1 = \frac{5 + 7 + 8}{3} = \frac{20}{3}.$$

Si las respuestas en R_2 son

15, 18, 21,

la predicción es

$$\hat{c}_2 = 18.$$

Ventajas

1. interpretación sencilla;
2. representación automática de interacciones;
3. modelado de relaciones no lineales;
4. poca necesidad de escalamiento;
5. manejo de variables numéricas y categóricas;
6. predicción rápida;
7. utilidad para clasificación y regresión.

Limitaciones

1. alta varianza;
2. sensibilidad a pequeños cambios;
3. fronteras paralelas a los ejes;
4. predicciones escalonadas en regresión;
5. posible sesgo en importancia de variables;
6. riesgo de sobreajuste;
7. menor precisión que algunos ensambles.

Errores frecuentes

1. hacer crecer el árbol sin poda ni validación;
2. interpretar una hoja pequeña como una regla estable;
3. evaluar únicamente el error de entrenamiento;
4. usar importancia por impureza como evidencia causal;
5. ignorar el desbalance de clases;

6. seleccionar profundidad con el conjunto de prueba;
7. confundir interpretabilidad con validez causal;
8. eliminar observaciones sin estudiar su influencia;
9. ignorar incertidumbre en probabilidades de hojas;
10. suponer que el árbol óptimo global se obtiene mediante decisiones codiciosas.

Ejercicios conceptuales

1. Explique cómo un árbol particiona el espacio de características.
2. ¿Qué diferencia existe entre un nodo interno y una hoja?
3. Compare Gini, entropía y error de clasificación.
4. ¿Qué representa la ganancia de información?
5. ¿Por qué un árbol profundo puede sobreajustar?
6. ¿Qué función cumple la poda?
7. Compare ID3, C4.5 y CART.
8. ¿Cómo representa un árbol una interacción?
9. ¿Por qué los árboles no suelen requerir estandarización?
10. ¿Qué limitación tiene la importancia por impureza?
11. ¿Por qué los árboles son inestables?
12. ¿Cómo se relacionan con random forest?

Ejercicio de impureza

Un nodo contiene:

- 12 observaciones de clase A;
- 5 de clase B;
- 3 de clase C.

Calcule:

1. las proporciones;
2. la impureza de Gini;
3. la entropía;
4. el error de clasificación.

Ejercicio de división

Un nodo padre tiene impureza de Gini igual a 0.48 y 20 observaciones.

Una división genera:

- nodo izquierdo con 8 observaciones e impureza 0.20;
- nodo derecho con 12 observaciones e impureza 0.32.

Calcule:

1. la impureza ponderada;
2. la reducción de impureza;
3. interprete la calidad de la división.

Ejercicio de regresión

Considere una división en dos regiones:

- R_1 : respuestas 4, 6, 8, 10;
- R_2 : respuestas 15, 18, 21.

Calcule:

1. la predicción de cada hoja;
2. la suma de cuadrados dentro de cada hoja;
3. la suma de cuadrados total posterior a la división.

Ejercicio de poda

Se tienen tres subárboles:

Árbol	Error de validación	Número de hojas
T_1	0.18	16
T_2	0.16	9
T_3	0.17	4

1. Seleccione el árbol con menor error.
2. Explique cuándo podría preferirse T_3 .
3. Relacione la decisión con la regla de un error estándar.
4. Interprete el compromiso sesgo-varianza.

Ejercicio aplicado

Se desea construir un árbol para clasificar accidentes severos utilizando:

- velocidad;
- tipo de vialidad;
- hora;
- lluvia;
- iluminación;
- presencia de peatones.

Diseñe el análisis incluyendo:

1. variable objetivo;
2. criterio de impureza;
3. tratamiento de variables categóricas;
4. reglas de parada;
5. poda;
6. validación cruzada;
7. métricas;
8. costos asimétricos;
9. interpretación de hojas;
10. análisis de importancia;

11. comparación con k -NN y regresión logística;
12. limitaciones causales.

Resumen

En este capítulo se desarrolló la teoría matemática de los árboles de decisión para clasificación y regresión.

Se formalizó la partición recursiva del espacio, las reglas de predicción por hojas, los criterios de Gini, entropía, ganancia de información y suma de cuadrados. También se estudiaron ID3, C4.5 y CART.

Finalmente, se analizaron profundidad, sobreajuste, poda por complejidad de costo, validación, probabilidades en hojas, clases desbalanceadas, importancia de variables, inestabilidad y relación con random forest y boosting.

Referencias del capítulo

Los fundamentos y resultados desarrollados en este capítulo se apoyan principalmente en Breiman et al. (1984); Quinlan (1986).

18 Random Forest

Introducción

Random Forest combina árboles contruidos con muestras bootstrap y selección aleatoria de variables. La aleatorización reduce la correlación entre árboles y la promediación disminuye la varianza del ensamble (Breiman 2001; Hastie et al. 2009).

Random Forest es un método de ensamble que combina muchos árboles de decisión contruidos sobre muestras bootstrap y con selección aleatoria de variables en cada división. Su propósito principal es reducir la alta varianza de los árboles individuales sin perder su capacidad para representar relaciones no lineales e interacciones complejas.

Un árbol profundo suele tener bajo sesgo y alta varianza. Random Forest disminuye la varianza mediante promediación. Sin embargo, para que esta reducción sea efectiva, los árboles deben ser no solo precisos, sino también poco correlacionados. La selección aleatoria de variables en cada nodo cumple precisamente esta función: introduce diversidad entre árboles.

El método puede utilizarse tanto en clasificación como en regresión. Además, proporciona estimaciones internas del error mediante observaciones out-of-bag, medidas de importancia de variables y herramientas para analizar proximidad entre observaciones.

! Definición esencial

Random Forest combina muchos árboles aleatorizados para reducir varianza.

Objetivos

Al finalizar el capítulo, el lector podrá:

1. explicar la idea de ensamble;
2. formular el método bagging;
3. comprender el muestreo bootstrap;
4. definir observaciones out-of-bag;
5. formular Random Forest para clasificación y regresión;
6. interpretar el papel del número de árboles;
7. interpretar el hiperparámetro `mtry`;
8. analizar la reducción de varianza;
9. comprender el efecto de la correlación entre árboles;
10. calcular error out-of-bag;
11. interpretar importancia por impureza;
12. interpretar importancia por permutación;
13. reconocer sesgos de las medidas de importancia;
14. analizar proximidades;

15. estudiar consistencia, sesgo y varianza;
16. comparar Random Forest con árboles individuales y boosting.

Ensamblajes

Definición 18.1. Un ensamble combina las predicciones de varios modelos base para producir una predicción final.

Sea

$$\hat{f}^{(1)}(\mathbf{x}), \dots, \hat{f}^{(B)}(\mathbf{x})$$

un conjunto de modelos.

En regresión,

$$\hat{f}_{ens}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{(b)}(\mathbf{x}).$$

En clasificación,

$$\hat{g}_{ens}(\mathbf{x}) = \text{mode} \{ \hat{g}^{(1)}(\mathbf{x}), \dots, \hat{g}^{(B)}(\mathbf{x}) \}.$$

Reducción de varianza

Supóngase que cada predictor tiene varianza σ_f^2 y que la correlación entre dos predictores cualesquiera es ρ . La varianza del promedio es aproximadamente

$$\text{Var} \left[\frac{1}{B} \sum_{b=1}^B \hat{f}^{(b)}(\mathbf{x}) \right] = \rho \sigma_f^2 + \frac{1-\rho}{B} \sigma_f^2.$$

Cuando B crece,

$$\text{Var} \rightarrow \rho \sigma_f^2.$$

Por tanto, aumentar el número de modelos reduce una parte de la varianza, pero la correlación entre modelos limita la reducción total.

Bagging

Bagging significa *Bootstrap Aggregating*. El procedimiento es:

1. generar una muestra bootstrap;
2. ajustar un árbol profundo;
3. repetir el proceso B veces;
4. combinar las predicciones.

En regresión,

$$\hat{f}_{bag}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{(b)}(\mathbf{x}).$$

En clasificación,

$$\hat{g}_{bag}(\mathbf{x}) = \arg \max_c \sum_{b=1}^B \mathbb{I} [\hat{g}^{(b)}(\mathbf{x}) = c] .$$

Muestreo bootstrap

Para cada árbol b , se selecciona una muestra

$$\mathcal{D}^{*(b)}$$

de tamaño n con reemplazo a partir de la muestra original.

La probabilidad de que una observación no sea seleccionada es

$$\left(1 - \frac{1}{n}\right)^n .$$

Cuando n es grande,

$$\left(1 - \frac{1}{n}\right)^n \approx e^{-1} \approx 0.368.$$

Por tanto, aproximadamente el 63.2 por ciento de las observaciones aparece al menos una vez en una muestra bootstrap.

Observaciones out-of-bag

Definición 18.2. Las observaciones que no aparecen en la muestra bootstrap del árbol b se denominan out-of-bag para ese árbol.

El conjunto OOB del árbol b se denota por

$$\mathcal{O}^{(b)}.$$

Cada observación queda fuera de aproximadamente el 36.8 por ciento de los árboles.

Error out-of-bag

En regresión, la predicción OOB de la observación i es

$$\hat{y}_{i,OOB} = \frac{1}{B_i} \sum_{b:i \in \mathcal{O}^{(b)}} \hat{f}^{(b)}(\mathbf{x}_i).$$

El error es

$$MSE_{OOB} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_{i,OOB})^2.$$

En clasificación,

$$Err_{OOB} = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(y_i \neq \hat{y}_{i,OOB}).$$

Limitación de bagging

Aunque bagging reduce varianza, los árboles pueden seguir siendo muy correlacionados. Si una variable es dominante, muchos árboles elegirán esa misma variable en la raíz.

Random Forest introduce aleatoriedad adicional para reducir esta correlación.

Definición de Random Forest

Definición 18.3. Random Forest es un ensamble de árboles construidos mediante muestras bootstrap y selección aleatoria de un subconjunto de variables candidatas en cada nodo.

Para cada árbol:

1. se genera una muestra bootstrap;
2. se inicia un árbol sin podar;
3. en cada nodo se selecciona aleatoriamente un subconjunto de variables;
4. se busca la mejor división únicamente dentro de ese subconjunto;
5. se continúa hasta cumplir una regla de parada;
6. se combina la predicción con la de los demás árboles.

Parámetro mtry

El número de variables consideradas en cada división se denota por

$$m_{try}.$$

Valores iniciales frecuentes son:

- clasificación:

$$m_{try} \approx \sqrt{p};$$

- regresión:

$$m_{try} \approx \frac{p}{3}.$$

Estas son reglas prácticas, no valores universales.

Efecto de mtry

Si $m_{try} = p$, Random Forest se aproxima a bagging.

Si m_{try} es pequeño:

- disminuye la correlación entre árboles;
- puede aumentar el sesgo;
- aumenta la diversidad.

Si m_{try} es grande:

- cada árbol puede ser más fuerte;
- aumenta la correlación;
- puede disminuir el beneficio de la promediación.

Número de árboles

El número de árboles se denota por B . A diferencia de boosting, aumentar B no suele producir sobreajuste importante. El error tiende a estabilizarse, aunque el tiempo y la memoria aumentan.

Clasificación

La predicción es

$$\hat{g}_{RF}(\mathbf{x}) = \arg \max_c \sum_{b=1}^B \mathbb{I} [\hat{g}^{(b)}(\mathbf{x}) = c] .$$

La proporción de votos puede utilizarse como estimación probabilística:

$$\widehat{P}(Y = c \mid \mathbf{x}) = \frac{1}{B} \sum_{b=1}^B \mathbb{I} [\hat{g}^{(b)}(\mathbf{x}) = c] .$$

Regresión

La predicción es

$$\hat{f}_{RF}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{(b)}(\mathbf{x}).$$

Fuerza y correlación

El desempeño del bosque depende de:

- la fuerza predictiva de los árboles;
- la correlación entre ellos.

Un bosque mejora cuando los árboles son suficientemente precisos y al mismo tiempo poco correlacionados.

Margen de clasificación

Defina

$$\widehat{P}_B(c \mid \mathbf{x}) = \frac{1}{B} \sum_{b=1}^B \mathbb{I} [\hat{g}^{(b)}(\mathbf{x}) = c] .$$

El margen es

$$mg(\mathbf{x}, y) = \widehat{P}_B(y | \mathbf{x}) - \max_{c \neq y} \widehat{P}_B(c | \mathbf{x}).$$

Un margen positivo indica clasificación correcta.

Importancia por impureza

La importancia de la variable j puede definirse como

$$MDI_j = \frac{1}{B} \sum_{b=1}^B \sum_{t \in T_b: v(t)=j} \frac{n_t}{n} \Delta I_t.$$

Esta medida se conoce como *Mean Decrease in Impurity*.

Sesgo de la importancia por impureza

MDI puede favorecer variables continuas, con muchos valores distintos o categóricas con muchos niveles. No debe interpretarse como evidencia causal.

Importancia por permutación

La importancia por permutación compara el error OOB antes y después de permutar una variable:

$$MDA_j = Err_{OOB}^{perm(j)} - Err_{OOB}^{base}.$$

También se conoce como *Mean Decrease in Accuracy*.

Variables correlacionadas

Si dos variables contienen información semejante, permutar una puede producir un aumento pequeño del error porque la otra conserva parte de la señal. La importancia puede repartirse entre variables correlacionadas.

Proximidades

Random Forest puede definir una proximidad entre observaciones:

$$Prox(i, j) = \frac{1}{B} \sum_{b=1}^B \mathbb{I} [\mathbf{x}_i \text{ y } \mathbf{x}_j \text{ terminan en la misma hoja}].$$

Puede utilizarse para visualización, detección de valores atípicos, agrupamiento e imputación.

Desbalance de clases

Random Forest puede favorecer la clase mayoritaria. Algunas estrategias son:

- pesos por clase;

- bootstrap balanceado;
- submuestreo de la clase mayoritaria;
- ajuste del umbral;
- Balanced Random Forest.

Probabilidades y calibración

La proporción de votos se interpreta frecuentemente como probabilidad, pero puede no estar bien calibrada. Puede ser necesario aplicar calibración de Platt, regresión isotónica o validación cruzada.

Variables categóricas y datos faltantes

El tratamiento depende de la implementación. Pueden utilizarse imputación, categorías especiales o codificación. Todo preprocesamiento debe aprenderse únicamente con los datos de entrenamiento.

Escalamiento

Random Forest no requiere normalmente estandarización, ya que las divisiones dependen del orden dentro de cada variable.

Interacciones

El bosque representa interacciones automáticamente porque cada ruta de un árbol combina múltiples condiciones. Sin embargo, su interpretación es menos transparente que en un árbol individual.

Dependencia parcial

Para una variable X_j ,

$$PD_j(x_j) = \mathbb{E}_{\mathbf{X}_{-j}} [\hat{f}(x_j, \mathbf{X}_{-j})] .$$

Su estimación es

$$\widehat{PD}_j(x_j) = \frac{1}{n} \sum_{i=1}^n \hat{f}(x_j, \mathbf{x}_{i,-j}).$$

Si las variables están correlacionadas, pueden evaluarse combinaciones poco realistas.

Complejidad computacional

El costo depende del número de árboles, observaciones, variables candidatas y profundidad. Los árboles pueden construirse en paralelo porque son independientes.

Sesgo y varianza

Comparado con un árbol individual:

- el sesgo puede ser semejante o ligeramente mayor;

- la varianza suele disminuir considerablemente;
- la estabilidad aumenta.

Hiperparámetros principales

Los principales son:

- `ntree`;
- `mtry`;
- profundidad máxima;
- tamaño mínimo de hoja;
- tamaño de muestra por árbol;
- criterio de división;
- pesos por clase.

Selección de hiperparámetros

Puede utilizarse error OOB, validación cruzada, búsqueda en rejilla, búsqueda aleatoria u optimización bayesiana. El conjunto de prueba final no debe intervenir.

Pseudocódigo

Definición 18.4. Para $b = 1, \dots, B$:

1. generar una muestra bootstrap;
2. hacer crecer un árbol;
3. seleccionar aleatoriamente m_{try} variables en cada nodo;
4. elegir la mejor división entre esas variables;
5. continuar hasta cumplir una regla de parada.

Finalmente, promediar en regresión o votar en clasificación.

Comparación con bagging

Bagging utiliza todas las variables en cada nodo. Random Forest usa un subconjunto aleatorio para reducir correlación entre árboles.

Comparación con boosting

Random Forest construye árboles independientes y es paralelizable. Boosting construye árboles secuencialmente para corregir errores previos.

Comparación con k-NN

Random Forest no requiere escalamiento, tolera mejor alta dimensión y proporciona medidas de importancia. k -NN depende fuertemente de la métrica y de la escala.

Conexión con R

```
1 library(randomForest)
2
3 set.seed(123)
4
5 datos <- data.frame(
6   severo = factor(c("No", "No", "No", "Sí", "Sí", "Sí", "No", "Sí")),
7   velocidad = c(35, 42, 48, 70, 80, 75, 55, 90),
8   noche = factor(c(0, 0, 1, 1, 1, 0, 0, 1)),
9   lluvia = factor(c(0, 1, 0, 1, 0, 1, 0, 1))
10 )
11
12 modelo <- randomForest(
13   severo ~ velocidad + noche + lluvia,
14   data = datos,
15   ntree = 500,
16   mtry = 2,
17   importance = TRUE,
18   proximity = TRUE
19 )
20
21 modelo
22 modelo$err.rate
23 importance(modelo)
24 varImpPlot(modelo)
25 predict(modelo, type = "response")
26 predict(modelo, type = "prob")
27 modelo$proximity
```

Ejemplo de bootstrap

Para la muestra

$$\{1, 2, 3, 4, 5\},$$

una muestra bootstrap podría ser

$$\{2, 2, 4, 5, 5\}.$$

Las observaciones 1 y 3 son out-of-bag para ese árbol.

Ejemplo de votación

Si siete árboles producen

$$A, A, B, A, B, A, A,$$

la clase predicha es A , con proporción de votos

$$\widehat{P}(A \mid \mathbf{x}) = \frac{5}{7}.$$

Ejemplo de regresión

Si cinco árboles predican

10, 12, 11, 15, 12,

la predicción es

$$\hat{f}_{RF}(\mathbf{x}) = 12.$$

Ventajas

1. reduce la varianza de los árboles;
2. maneja relaciones no lineales;
3. modela interacciones;
4. no requiere escalamiento;
5. proporciona error OOB;
6. funciona en clasificación y regresión;
7. tolera muchas variables;
8. es paralelizable.

Limitaciones

1. menor interpretabilidad que un árbol;
2. mayor costo computacional;
3. importancia sesgada en ciertos casos;
4. probabilidades no siempre calibradas;
5. mayor uso de memoria;
6. extrapolación pobre en regresión.

Errores frecuentes

1. interpretar importancia como causalidad;
2. usar solo importancia por impureza;
3. ignorar variables correlacionadas;
4. seleccionar hiperparámetros con el conjunto de prueba;
5. evaluar únicamente exactitud;
6. ignorar calibración;
7. omitir clases desbalanceadas;
8. preprocesar fuera del ciclo de validación.

Ejercicios conceptuales

1. Explique por qué un bosque reduce varianza.
2. ¿Qué función cumple el bootstrap?
3. ¿Qué son las observaciones OOB?
4. ¿Por qué se seleccionan variables aleatoriamente?
5. ¿Qué ocurre si `mtry = p`?
6. Compare MDI y MDA.
7. ¿Cómo afectan las variables correlacionadas a la importancia?
8. ¿Qué representan las proximidades?
9. Compare Random Forest y boosting.
10. ¿Por qué no suele requerirse estandarización?

Ejercicio bootstrap

Para una muestra de tamaño $n = 200$, calcule aproximadamente:

1. la proporción esperada de observaciones OOB;
2. el número esperado de observaciones OOB por árbol;
3. el número esperado de observaciones distintas en cada muestra bootstrap.

Ejercicio de varianza

Supóngase

$$\sigma_f^2 = 4, \quad \rho = 0.25, \quad B = 100.$$

Calcule la varianza aproximada del promedio y compárela con la varianza de un árbol individual.

Ejercicio de mtry

Para $p = 36$ variables:

1. proponga un valor inicial para clasificación;
2. proponga un valor inicial para regresión;
3. explique qué ocurre si `mtry` es demasiado pequeño;
4. explique qué ocurre si es demasiado grande.

Ejercicio de importancia

Variable	Error base	Error permutado
Velocidad	0.12	0.25
Lluvia	0.12	0.16
Hora	0.12	0.13
Viento	0.12	0.12

1. Calcule la importancia por permutación.

2. Ordene las variables.
3. Interprete los resultados.
4. Explique por qué no implican causalidad.

Ejercicio aplicado

Se desea clasificar accidentes severos usando velocidad, hora, vialidad, clima, iluminación, peatones, entidad y municipio.

Diseñe un análisis que incluya:

1. preparación de datos;
2. variables categóricas;
3. selección de `ntree`;
4. selección de `mtry`;
5. control de profundidad;
6. error OOB;
7. validación cruzada;
8. sensibilidad y especificidad;
9. clases desbalanceadas;
10. importancia por permutación;
11. calibración;
12. comparación con árbol individual y regresión logística;
13. interpretación de proximidades;
14. limitaciones causales.

Resumen

En este capítulo se desarrolló Random Forest como un ensamble de árboles basado en bootstrap y selección aleatoria de variables.

Se explicó bagging, el error out-of-bag, el papel de `mtry`, la relación entre fuerza y correlación, y la reducción de varianza mediante promediación.

También se estudiaron importancia por impureza y por permutación, proximidades, desbalance de clases, calibración, dependencia parcial, complejidad computacional y selección de hiperparámetros.

Finalmente, se comparó Random Forest con árboles individuales, k -NN y boosting.

Referencias del capítulo

Los fundamentos y resultados desarrollados en este capítulo se apoyan principalmente en Breiman (2001); Hastie et al. (2009).

19 Máquinas de vectores de soporte, SVM

Introducción

Las máquinas de vectores de soporte buscan una frontera con margen grande y pueden incorporar transformaciones no lineales mediante kernels. Su formulación conecta optimización convexa, regularización y teoría de generalización (Cortes y Vapnik 1995; Vapnik 1998).

Las máquinas de vectores de soporte, conocidas como SVM por *Support Vector Machines*, son métodos de aprendizaje supervisado diseñados principalmente para clasificación, aunque también existen extensiones para regresión.

La idea fundamental consiste en encontrar una frontera de decisión que separe las clases con el mayor margen posible. En el caso linealmente separable, SVM selecciona entre todos los hiperplanos separadores aquel que maximiza la distancia mínima a las observaciones de entrenamiento. Las observaciones que determinan esta frontera reciben el nombre de vectores de soporte.

Cuando las clases no pueden separarse perfectamente, se introducen variables de holgura y una penalización que permite ciertos errores. Para fronteras no lineales, SVM utiliza funciones kernel, que permiten trabajar implícitamente en espacios de características de dimensión mayor sin calcular explícitamente la transformación.

! Definición esencial

Una SVM busca una frontera de decisión con margen grande.

Objetivos

Al finalizar el capítulo, el lector podrá:

1. formular un clasificador lineal;
2. definir un hiperplano y su margen;
3. derivar el problema de margen máximo;
4. identificar vectores de soporte;
5. formular el margen duro;
6. introducir variables de holgura;
7. formular el margen suave;
8. interpretar el parámetro de costo;
9. comprender la pérdida hinge;
10. derivar el problema dual;
11. interpretar las condiciones KKT;
12. comprender el truco kernel;
13. distinguir kernels lineal, polinomial y radial;
14. formular SVM multiclase;

15. analizar escalamiento, regularización y selección de hiperparámetros;
16. relacionar SVM con minimización del riesgo empírico.

Clasificación binaria

Considérese una muestra

$$\mathcal{D}_n = \{(\mathbf{x}_i, y_i)\}_{i=1}^n,$$

donde

$$\mathbf{x}_i \in \mathbb{R}^p$$

y

$$y_i \in \{-1, +1\}.$$

Se desea construir una función

$$g : \mathbb{R}^p \rightarrow \{-1, +1\}.$$

Hiperplano separador

Un hiperplano en $\mathbb{R}^p$ se define mediante

$$\mathbf{w}^T \mathbf{x} + b = 0,$$

donde:

- $\mathbf{w} \in \mathbb{R}^p$ es el vector normal;
- $b \in \mathbb{R}$ es el intercepto.

La regla de clasificación es

$$g(\mathbf{x}) = \text{sign}(\mathbf{w}^T \mathbf{x} + b).$$

Regiones de decisión

El hiperplano divide el espacio en:

$$\mathbf{w}^T \mathbf{x} + b > 0,$$

correspondiente a la clase +1, y

$$\mathbf{w}^T \mathbf{x} + b < 0,$$

correspondiente a la clase -1.

Separabilidad lineal

Definición 19.1. La muestra es linealmente separable si existen $\mathbf{w}$ y b tales que

$$y_i (\mathbf{w}^\top \mathbf{x}_i + b) > 0$$

para toda observación i .

Esta condición indica que cada punto queda en el lado correcto del hiperplano.

Escala del hiperplano

Los pares

$$(\mathbf{w}, b)$$

y

$$(c\mathbf{w}, cb), \quad c > 0,$$

definen el mismo hiperplano.

Por ello, se necesita fijar una escala para formular el margen.

Distancia de un punto al hiperplano

La distancia perpendicular de $\mathbf{x}_i$ al hiperplano es

$$d_i = \frac{|\mathbf{w}^\top \mathbf{x}_i + b|}{\|\mathbf{w}\|_2}.$$

La distancia firmada es

$$\frac{\mathbf{w}^\top \mathbf{x}_i + b}{\|\mathbf{w}\|_2}.$$

Margen funcional

El margen funcional de la observación i es

$$\hat{\gamma}_i = y_i (\mathbf{w}^\top \mathbf{x}_i + b).$$

Depende de la escala de $\mathbf{w}$ y b .

! Escalamiento de la representación

El margen depende de la escala de las variables. Por ello, SVM suele requerir centrado y estandarización, especialmente con kernels que utilizan distancias.

Margen geométrico

El margen geométrico es

$$\gamma_i = \frac{y_i (\mathbf{w}^T \mathbf{x}_i + b)}{\|\mathbf{w}\|_2}.$$

Este margen no cambia si $\mathbf{w}$ y b se multiplican por una constante positiva.

Margen del clasificador

El margen total respecto de la muestra es

$$\gamma = \min_i \gamma_i.$$

SVM busca maximizar esta cantidad.

Normalización canónica

Se escalan $\mathbf{w}$ y b para que las observaciones más cercanas satisfagan

$$y_i (\mathbf{w}^T \mathbf{x}_i + b) = 1.$$

Entonces todas las observaciones cumplen

$$y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1.$$

Hiperplanos del margen

Los hiperplanos paralelos que contienen las observaciones más cercanas son

$$\mathbf{w}^T \mathbf{x} + b = 1$$

y

$$\mathbf{w}^T \mathbf{x} + b = -1.$$

La distancia entre ambos es

$$\frac{2}{\|\mathbf{w}\|_2}.$$

Problema de margen máximo

Maximizar el margen equivale a minimizar la norma de $\mathbf{w}$:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2$$

sujeto a

$$y_i (\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, \dots, n.$$

Este es un problema de optimización convexa cuadrática.

Vectores de soporte

Definición 19.2. Los vectores de soporte son las observaciones que se encuentran sobre los márgenes o dentro de ellos y que determinan la solución óptima.

En el caso separable, satisfacen

$$y_i (\mathbf{w}^\top \mathbf{x}_i + b) = 1.$$

Las observaciones alejadas del margen no cambian directamente la posición del hiperplano óptimo.

Interpretación geométrica

SVM no intenta simplemente encontrar cualquier frontera que separe las clases. Busca la frontera con mayor espacio libre alrededor.

Un margen grande se asocia con:

- mayor robustez;
- menor sensibilidad a perturbaciones pequeñas;
- mejor capacidad de generalización.

Formulación lagrangiana

Se introducen multiplicadores

$$\alpha_i \geq 0.$$

El Lagrangiano es

$$\mathcal{L}(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|_2^2 - \sum_{i=1}^n \alpha_i [y_i (\mathbf{w}^\top \mathbf{x}_i + b) - 1].$$

Condición respecto del vector normal

Derivando respecto de $\mathbf{w}$,

$$\nabla_{\mathbf{w}} \mathcal{L} = \mathbf{w} - \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i.$$

Igualando a cero,

$$\mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i.$$

Por tanto, el vector normal es una combinación lineal de observaciones de entrenamiento.

Condición respecto del intercepto

Derivando respecto de b ,

$$\frac{\partial \mathcal{L}}{\partial b} = - \sum_{i=1}^n \alpha_i y_i.$$

Por tanto,

$$\sum_{i=1}^n \alpha_i y_i = 0.$$

Problema dual de margen duro

Sustituyendo las condiciones anteriores, se obtiene

$$\max_{\alpha} \left[\sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^{\top} \mathbf{x}_j \right]$$

sujeto a

$$\alpha_i \geq 0$$

y

$$\sum_{i=1}^n \alpha_i y_i = 0.$$

Condiciones de complementariedad

Las condiciones KKT incluyen

$$\alpha_i [y_i (\mathbf{w}^{\top} \mathbf{x}_i + b) - 1] = 0.$$

Si

$$\alpha_i > 0,$$

entonces la observación se encuentra sobre el margen y es vector de soporte.

Función de decisión dual

Como

$$\mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i,$$

la función de decisión es

$$f(\mathbf{x}) = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i^T \mathbf{x} + b.$$

Solo las observaciones con $\alpha_i > 0$ contribuyen.

Datos no separables

En la práctica, las clases pueden solaparse o contener ruido.

El margen duro puede:

- no tener solución;
- depender excesivamente de observaciones atípicas;
- producir una frontera inestable.

Para resolverlo se introduce el margen suave.

Variables de holgura

Se definen

$$\xi_i \geq 0$$

y se permite

$$y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i.$$

Interpretación:

- $\xi_i = 0$: clasificación correcta fuera o sobre el margen;
- $0 < \xi_i < 1$: clasificación correcta dentro del margen;
- $\xi_i = 1$: observación sobre la frontera;
- $\xi_i > 1$: observación mal clasificada.

Problema de margen suave

La formulación primal es

$$\min_{\mathbf{w}, b, \xi} \left\{ \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^n \xi_i \right\}$$

sujeto a

$$y_i (\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i,$$

$$\xi_i \geq 0.$$

Interpretación del parámetro C

El parámetro

$$C > 0$$

controla el costo de violar el margen.

Un valor grande de C :

- penaliza fuertemente errores;
- intenta clasificar correctamente casi todos los puntos;
- puede producir un margen estrecho;
- puede aumentar varianza.

Un valor pequeño:

- permite más violaciones;
- produce mayor regularización;
- puede generar un margen más ancho;
- puede aumentar sesgo.

Pérdida hinge

La pérdida hinge es

$$L_{\text{hinge}}(y, f(\mathbf{x})) = \max\{0, 1 - yf(\mathbf{x})\}.$$

El problema puede escribirse como

$$\min_{\mathbf{w}, b} \left\{ \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^n \max(0, 1 - y_i [\mathbf{w}^\top \mathbf{x}_i + b]) \right\}.$$

Interpretación como riesgo regularizado

Dividiendo por n y reparametrizando,

$$\min_{\mathbf{w}, b} \left\{ \frac{1}{n} \sum_{i=1}^n L_{\text{hinge}}(y_i, \mathbf{w}^\top \mathbf{x}_i + b) + \lambda \|\mathbf{w}\|_2^2 \right\}.$$

SVM es un problema de minimización de riesgo empírico regularizado.

Dual del margen suave

El problema dual es

$$\max_{\alpha} \left[\sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \right]$$

sujeto a

$$0 \leq \alpha_i \leq C$$

y

$$\sum_{i=1}^n \alpha_i y_i = 0.$$

La cota superior C aparece como consecuencia de las variables de holgura.

Interpretación de los multiplicadores

En el margen suave:

- $\alpha_i = 0$: observación fuera del margen;
- $0 < \alpha_i < C$: observación sobre el margen;
- $\alpha_i = C$: observación dentro del margen o mal clasificada.

Fronteras no lineales

Un hiperplano en el espacio original puede ser insuficiente.

Se introduce una transformación

$$\phi : \mathbb{R}^p \rightarrow \mathcal{H},$$

donde $\mathcal{H}$ es un espacio de características, posiblemente de dimensión muy alta.

El clasificador lineal en $\mathcal{H}$ es

$$f(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) + b.$$

Truco kernel

En el problema dual, las observaciones aparecen únicamente mediante productos internos.

Se define un kernel

$$K(\mathbf{x}, \mathbf{z}) = \phi(\mathbf{x})^T \phi(\mathbf{z}).$$

Así, no es necesario calcular explícitamente $\phi(\mathbf{x})$.

La función de decisión se convierte en

$$f(\mathbf{x}) = \sum_{i=1}^n \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}) + b.$$

Kernel lineal

$$K(\mathbf{x}, \mathbf{z}) = \mathbf{x}^\top \mathbf{z}.$$

Corresponde a una frontera lineal en el espacio original.

Kernel polinomial

$$K(\mathbf{x}, \mathbf{z}) = (\gamma \mathbf{x}^\top \mathbf{z} + r)^d.$$

Parámetros:

- d : grado;
- γ : escala;
- r : término independiente.

Permite representar interacciones polinomiales.

Kernel radial

El kernel radial gaussiano es

$$K(\mathbf{x}, \mathbf{z}) = \exp(-\gamma \|\mathbf{x} - \mathbf{z}\|_2^2).$$

También puede parametrizarse mediante

$$\gamma = \frac{1}{2\sigma^2}.$$

Interpretación del parámetro gamma

Un valor grande de γ :

- produce influencia muy local;
- permite fronteras complejas;
- puede aumentar sobreajuste.

Un valor pequeño:

- produce influencia más amplia;
- genera fronteras suaves;
- puede aumentar subajuste.

Kernel sigmoidal

$$K(\mathbf{x}, \mathbf{z}) = \tanh(\gamma \mathbf{x}^\top \mathbf{z} + r).$$

No todos los valores de parámetros garantizan que sea un kernel válido.

Condición de Mercer

Para representar un producto interno válido, el kernel debe generar una matriz de Gram semidefinida positiva.

Para una muestra,

$$\mathbf{K}_{ij} = K(\mathbf{x}_i, \mathbf{x}_j).$$

Debe cumplirse

$$\mathbf{a}^\top \mathbf{K} \mathbf{a} \geq 0$$

para todo vector $\mathbf{a}$.

Matriz de Gram

La matriz

$$\mathbf{K} = \begin{pmatrix} K(\mathbf{x}_1, \mathbf{x}_1) & \cdots & K(\mathbf{x}_1, \mathbf{x}_n) \\ \vdots & \ddots & \vdots \\ K(\mathbf{x}_n, \mathbf{x}_1) & \cdots & K(\mathbf{x}_n, \mathbf{x}_n) \end{pmatrix}$$

resume todos los productos internos en el espacio transformado.

Cálculo del intercepto

Para un vector de soporte con

$$0 < \alpha_i < C,$$

se cumple

$$y_i \left[\sum_{j=1}^n \alpha_j y_j K(\mathbf{x}_j, \mathbf{x}_i) + b \right] = 1.$$

Por tanto,

$$b = y_i - \sum_{j=1}^n \alpha_j y_j K(\mathbf{x}_j, \mathbf{x}_i).$$

Habitualmente se promedia entre varios vectores de soporte.

Escalamiento de variables

SVM depende de productos internos y distancias.

Si las variables presentan escalas distintas, una puede dominar el kernel.

Por ello, suele utilizarse

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}.$$

El escalamiento debe aprenderse únicamente con datos de entrenamiento.

Selección de hiperparámetros

Los principales hiperparámetros son:

- C ;
- tipo de kernel;
- γ ;
- grado polinomial;
- coeficiente independiente.

La selección se realiza mediante validación cruzada.

Búsqueda conjunta

Para kernel radial, deben seleccionarse conjuntamente

$$(C, \gamma).$$

Una rejilla habitual utiliza escalas logarítmicas, por ejemplo:

$$C \in \{2^{-5}, 2^{-3}, \dots, 2^{15}\},$$

$$\gamma \in \{2^{-15}, 2^{-13}, \dots, 2^3\}.$$

Estas rejillas son orientativas.

Número de vectores de soporte

El número de vectores de soporte influye en:

- complejidad del modelo;
- tiempo de predicción;
- sensibilidad al ruido.

Una solución con muchos vectores de soporte suele ser más compleja.

Probabilidades

SVM produce una puntuación

$$f(\mathbf{x}),$$

no una probabilidad directa.

Para obtener probabilidades se utilizan métodos de calibración, como la calibración de Platt:

$$P(Y = 1 \mid f) = \frac{1}{1 + \exp(Af + B)}.$$

También puede utilizarse regresión isotónica.

Clasificación multiclase

SVM es esencialmente binario.

Las estrategias comunes son:

- uno contra el resto;
- uno contra uno.

Uno contra el resto

Para C clases se entrenan C clasificadores:

$$c \text{ contra } \mathcal{Y} \setminus \{c\}.$$

La predicción utiliza la mayor puntuación.

Uno contra uno

Se entrena un clasificador por cada par de clases.

El número de clasificadores es

$$\binom{C}{2} = \frac{C(C-1)}{2}.$$

La clase final se decide mediante votación.

SVM para regresión

La regresión por vectores de soporte se denomina SVR.

Se utiliza la pérdida insensible ε :

$$L_\varepsilon(y, f(\mathbf{x})) = \max\{0, |y - f(\mathbf{x})| - \varepsilon\}.$$

Los errores dentro de un tubo de anchura ε no reciben penalización.

Formulación de SVR

La formulación primal es

$$\min_{\mathbf{w}, b, \xi, \xi^*} \left\{ \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) \right\}$$

sujeto a

$$y_i - (\mathbf{w}^T \phi(\mathbf{x}_i) + b) \leq \varepsilon + \xi_i,$$

$$(\mathbf{w}^T \phi(\mathbf{x}_i) + b) - y_i \leq \varepsilon + \xi_i^*,$$

$$\xi_i, \xi_i^* \geq 0.$$

Ventajas de SVM

1. fundamento matemático sólido;
2. optimización convexa;
3. solución global;
4. buen desempeño en alta dimensión;
5. capacidad para fronteras no lineales;
6. control explícito de regularización;
7. dependencia solo de vectores de soporte.

Limitaciones de SVM

1. requiere escalamiento;
2. selección de kernel e hiperparámetros puede ser costosa;
3. menor interpretabilidad;
4. entrenamiento costoso con muestras muy grandes;
5. probabilidades requieren calibración;
6. sensible a clases desbalanceadas;
7. puede ser difícil explicar fronteras no lineales.

Maldición de la dimensionalidad

SVM puede funcionar bien cuando p es grande, especialmente con regularización adecuada.

Sin embargo, variables irrelevantes y ruido pueden deteriorar el margen y aumentar la complejidad.

La selección de variables sigue siendo importante.

Clases desbalanceadas

Puede utilizarse una penalización diferente por clase:

$$C_+$$

para la clase positiva y

$$C_-$$

para la negativa.

La función objetivo se modifica para asignar mayor costo a errores en la clase crítica.

Robustez frente a valores atípicos

El margen suave permite tolerar errores, pero valores atípicos pueden influir fuertemente cuando C es grande.

Reducir C aumenta regularización y puede mejorar robustez.

Relación con regresión logística

Ambos modelos lineales utilizan

$$f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b.$$

Regresión logística:

- minimiza pérdida logarítmica;
- modela probabilidades directamente;
- utiliza todas las observaciones.

SVM:

- minimiza pérdida hinge;
- maximiza margen;
- depende principalmente de vectores de soporte.

Relación con perceptrón

El perceptrón actualiza parámetros cuando una observación es mal clasificada.

SVM añade:

- maximización del margen;
- regularización explícita;
- optimización convexa;
- kernels.

Relación con redes neuronales

SVM utiliza una transformación fija determinada por el kernel.

Las redes neuronales aprenden representaciones internas mediante sus parámetros.

SVM suele ser competitivo en muestras medianas; las redes profundas dominan problemas con grandes cantidades de datos no estructurados.

Complejidad computacional

El entrenamiento clásico requiere resolver un problema cuadrático.

El costo puede crecer entre

$$O(n^2)$$

y

$$O(n^3),$$

dependiendo del algoritmo y los datos.

La memoria puede requerir almacenar una matriz de Gram de tamaño

$$n \times n.$$

Métodos de optimización

Entre los algoritmos utilizados se encuentran:

- programación cuadrática;
- SMO;
- descenso por subgradiente;
- Pegasos;
- aproximaciones lineales;
- métodos distribuidos.

SMO

El algoritmo SMO resuelve iterativamente pequeños subproblemas que involucran dos multiplicadores α_i a la vez.

Esto evita resolver directamente un gran problema cuadrático.

SVM lineal para grandes datos

Cuando el kernel es lineal, pueden utilizarse algoritmos especializados que operan directamente en el espacio primal.

Estos métodos son más eficientes cuando:

- n es grande;
- p es alto;
- no se necesita una frontera no lineal.

Interpretación del margen como confianza

La magnitud

$$|f(\mathbf{x})|$$

indica distancia funcional respecto de la frontera.

Un valor grande sugiere una decisión más alejada del hiperplano, pero no constituye una probabilidad calibrada.

Conexión con R

```

1 library(e1071)
2
3 datos <- data.frame(
4   severo = factor(c("No", "No", "No", "Sí", "Sí", "Sí", "No", "Sí")),
5   velocidad = c(35, 42, 48, 70, 80, 75, 55, 90),
6   humedad = c(60, 55, 58, 40, 35, 42, 50, 30)
7 )
8
9 modelo_lineal <- svm(
10   severo ~ velocidad + humedad,
11   data = datos,
12   kernel = "linear",
13   cost = 1,
14   scale = TRUE,
15   probability = TRUE
16 )
17
18 summary(modelo_lineal)
19
20 predict(
21   modelo_lineal,
22   datos,
23   probability = TRUE
24 )
25
26 modelo_radial <- svm(
27   severo ~ velocidad + humedad,
28   data = datos,
29   kernel = "radial",
30   cost = 10,
31   gamma = 0.5,
32   scale = TRUE
33 )

```

```

34
35 # Selección de hiperparámetros
36 ajuste <- tune(
37   svm,
38   severo ~ velocidad + humedad,
39   data = datos,
40   kernel = "radial",
41   ranges = list(
42     cost = c(0.1, 1, 10, 100),
43     gamma = c(0.01, 0.1, 0.5, 1)
44   )
45 )
46
47 ajuste$best.parameters
48 ajuste$best.model

```

Ejemplo de hiperplano

Considere

$$\mathbf{w} = \begin{pmatrix} 2 \\ -1 \end{pmatrix}, \quad b = -3.$$

La frontera es

$$2x_1 - x_2 - 3 = 0.$$

Para el punto

$$\mathbf{x} = \begin{pmatrix} 3 \\ 1 \end{pmatrix},$$

la puntuación es

$$f(\mathbf{x}) = 2(3) - 1 - 3 = 2.$$

Por tanto, se clasifica como +1.

La distancia al hiperplano es

$$\frac{|2|}{\sqrt{2^2 + (-1)^2}} = \frac{2}{\sqrt{5}}.$$

Ejemplo de pérdida hinge

Supóngase

$$y = +1.$$

Si

$$f(\mathbf{x}) = 1.5,$$

entonces

$$L_{\text{hinge}} = \max(0, 1 - 1.5) = 0.$$

Si

$$f(\mathbf{x}) = 0.4,$$

entonces

$$L_{\text{hinge}} = 1 - 0.4 = 0.6.$$

Si

$$f(\mathbf{x}) = -0.8,$$

entonces

$$L_{\text{hinge}} = 1 - (-0.8) = 1.8.$$

Errores frecuentes

1. aplicar SVM sin escalar variables;
2. seleccionar C y γ con el conjunto de prueba;
3. interpretar la puntuación como probabilidad;
4. usar un kernel complejo sin validación;
5. ignorar el desbalance de clases;
6. confundir un valor grande de C con mayor regularización;
7. interpretar vectores de soporte como observaciones necesariamente atípicas;
8. ignorar variables irrelevantes;
9. utilizar una rejilla lineal en lugar de logarítmica;
10. concluir causalidad a partir de la frontera.

Ejercicios conceptuales

1. Explique qué representa un hiperplano.
2. ¿Qué diferencia existe entre margen funcional y geométrico?
3. ¿Por qué maximizar el margen equivale a minimizar $\|\mathbf{w}\|_2^2$?
4. ¿Qué son los vectores de soporte?
5. Compare margen duro y margen suave.
6. ¿Qué función cumple C ?
7. Explique la pérdida hinge.

8. ¿Por qué el problema dual permite utilizar kernels?
9. ¿Qué efecto tiene γ en un kernel radial?
10. ¿Por qué SVM requiere escalamiento?
11. Compare SVM y regresión logística.
12. ¿Cómo se extiende SVM a múltiples clases?

Ejercicio de distancia al hiperplano

Sea

$$\mathbf{w} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad b = -4.$$

Para los puntos

$$\mathbf{x}_1 = (2, 1), \quad \mathbf{x}_2 = (0, 3),$$

calcule:

1. la puntuación;
2. la clase predicha;
3. la distancia al hiperplano.

Ejercicio de margen

Supóngase que el vector normal satisface

$$\|\mathbf{w}\|_2 = 4.$$

1. Calcule la anchura total del margen.
2. Calcule la distancia de cada hiperplano marginal a la frontera central.
3. Repita para $\|\mathbf{w}\|_2 = 2$.
4. Interprete el cambio.

Ejercicio de pérdida hinge

Calcule la pérdida para:

y	$f(\mathbf{x})$
1	2.0
1	0.5
1	-0.4
-1	-1.5
-1	0.2

Ejercicio de kernel radial

Considere

$$\mathbf{x} = (1, 2), \quad \mathbf{z} = (3, 1), \quad \gamma = 0.5.$$

1. Calcule $\|\mathbf{x} - \mathbf{z}\|_2^2$.
2. Calcule el kernel radial.
3. Repita con $\gamma = 2$.
4. Interprete el efecto de γ .

Ejercicio de selección

Se obtienen los siguientes errores de validación:

C	γ	Error CV
0.1	0.01	0.22
1	0.01	0.17
10	0.01	0.15
1	0.1	0.13
10	0.1	0.11
100	0.1	0.14
10	1	0.18

1. Seleccione la mejor combinación.
2. Explique por qué C y γ deben elegirse conjuntamente.
3. Describa un posible patrón de sobreajuste.

Ejercicio aplicado

Se desea clasificar accidentes severos mediante SVM usando:

- velocidad;
- hora;
- condiciones meteorológicas;
- tipo de vialidad;
- iluminación;
- presencia de peatones.

Diseñe un análisis que incluya:

1. codificación de variables;
2. escalamiento;
3. partición de datos;
4. comparación entre kernel lineal y radial;
5. selección de C y γ ;
6. validación cruzada anidada;
7. ajuste por desbalance;

8. matriz de confusión;
9. sensibilidad y especificidad;
10. AUC;
11. calibración;
12. número de vectores de soporte;
13. comparación con Random Forest y regresión logística;
14. limitaciones interpretativas.

Resumen

En este capítulo se desarrolló la formulación matemática de las máquinas de vectores de soporte.

Se estudió el hiperplano separador, el margen geométrico, el problema de margen máximo y los vectores de soporte. También se derivaron las formulaciones primal y dual, las condiciones KKT y el margen suave mediante variables de holgura.

Posteriormente se introdujeron la pérdida hinge, el parámetro de costo, el truco kernel, los kernels lineal, polinomial y radial, así como la selección de hiperparámetros.

Finalmente, se analizaron clasificación multiclase, SVR, escalamiento, calibración, desbalance de clases, complejidad computacional y comparación con regresión logística y Random Forest.

Referencias del capítulo

Los fundamentos y resultados desarrollados en este capítulo se apoyan principalmente en Cortes y Vapnik (1995); Vapnik (1998).

20 Redes neuronales artificiales

Introducción

Las redes neuronales componen transformaciones afines y activaciones no lineales. Su entrenamiento moderno se apoya en retropropagación, optimización estocástica, inicialización controlada y regularización (Rumelhart et al. 1986; Glorot y Bengio 2010; He et al. 2015; Srivastava et al. 2014,).

Las redes neuronales artificiales son modelos de aprendizaje supervisado y no supervisado formados por unidades computacionales simples organizadas en capas. Cada unidad combina linealmente sus entradas, aplica una función de activación y transmite el resultado a la siguiente capa.

Su poder proviene de la composición de múltiples transformaciones no lineales. Mientras un modelo lineal representa fronteras planas, una red profunda puede aproximar funciones altamente complejas, extraer representaciones internas y modelar interacciones de gran orden.

En este capítulo se desarrolla la formulación matemática de la neurona artificial, el perceptrón, las redes multicapa, la propagación hacia adelante, las funciones de pérdida, la retropropagación y los métodos de optimización utilizados para entrenarlas.

! Definición esencial

Una red neuronal compone transformaciones afines y activaciones no lineales.

Objetivos

Al finalizar el capítulo, el lector podrá:

1. formular una neurona artificial;
2. interpretar pesos, sesgo y activación;
3. comprender el perceptrón;
4. distinguir funciones de activación;
5. representar una red multicapa;
6. realizar propagación hacia adelante;
7. definir pérdidas para clasificación y regresión;
8. derivar gradientes mediante regla de la cadena;
9. comprender retropropagación;
10. analizar descenso por gradiente y mini-lotes;
11. identificar problemas de gradientes desvanecientes y explosivos;
12. interpretar regularización y dropout;
13. comprender normalización por lotes;
14. analizar inicialización de pesos;
15. relacionar profundidad, capacidad y generalización;

16. conectar redes neuronales con regresión logística y aprendizaje profundo.

Neurona artificial

Una neurona recibe un vector de entrada

$$\mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_p \end{pmatrix} \in \mathbb{R}^p,$$

un vector de pesos

$$\mathbf{w} = \begin{pmatrix} w_1 \\ \vdots \\ w_p \end{pmatrix},$$

y un sesgo

$$b \in \mathbb{R}.$$

Primero calcula la combinación lineal

$$z = \mathbf{w}^\top \mathbf{x} + b.$$

Después aplica una función de activación ϕ :

$$a = \phi(z).$$

Interpretación de los pesos

Cada peso w_j controla la influencia de la característica x_j .

- si $w_j > 0$, aumentar x_j tiende a aumentar z ;
- si $w_j < 0$, aumentar x_j tiende a disminuir z ;
- si $|w_j|$ es grande, la influencia local es mayor.

El sesgo desplaza el umbral de activación.

Perceptrón

El perceptrón utiliza la función escalón:

$$\phi(z) = \begin{cases} 1, & z \geq 0, \\ 0, & z < 0. \end{cases}$$

La predicción es

$$\hat{y} = \phi(\mathbf{w}^\top \mathbf{x} + b).$$

Frontera del perceptrón

La frontera de decisión es

$$\mathbf{w}^T \mathbf{x} + b = 0.$$

Por tanto, el perceptrón es un clasificador lineal.

Regla de aprendizaje del perceptrón

Para una observación $(\mathbf{x}_i, y_i)$, una actualización simple es

$$\mathbf{w} \leftarrow \mathbf{w} + \eta (y_i - \hat{y}_i) \mathbf{x}_i,$$

$$b \leftarrow b + \eta (y_i - \hat{y}_i),$$

donde $\eta > 0$ es la tasa de aprendizaje.

Limitación del perceptrón

El perceptrón converge si las clases son linealmente separables. No puede resolver problemas como XOR mediante una sola capa lineal.

Esta limitación motivó el uso de capas ocultas y activaciones no lineales.

! Necesidad de no linealidad

Si todas las activaciones fueran lineales, la composición de múltiples capas sería equivalente a una sola transformación lineal. La capacidad no lineal proviene de las funciones de activación.

Red multicapa

Una red multicapa contiene:

- capa de entrada;
- una o más capas ocultas;
- capa de salida.

Sea una red con L capas parametrizadas.

Para la capa ℓ :

$$\mathbf{z}^{(\ell)} = \mathbf{W}^{(\ell)} \mathbf{a}^{(\ell-1)} + \mathbf{b}^{(\ell)},$$

$$\mathbf{a}^{(\ell)} = \phi^{(\ell)}(\mathbf{z}^{(\ell)}).$$

La entrada es

$$\mathbf{a}^{(0)} = \mathbf{x}.$$

Dimensiones

Si la capa $\ell - 1$ tiene $n_{\ell-1}$ unidades y la capa ℓ tiene n_ℓ , entonces

$$\mathbf{W}^{(\ell)} \in \mathbb{R}^{n_\ell \times n_{\ell-1}},$$

$$\mathbf{b}^{(\ell)} \in \mathbb{R}^{n_\ell}.$$

Propagación hacia adelante

La propagación hacia adelante consiste en calcular secuencialmente:

$$\mathbf{a}^{(0)} \rightarrow \mathbf{z}^{(1)} \rightarrow \mathbf{a}^{(1)} \rightarrow \dots \rightarrow \mathbf{z}^{(L)} \rightarrow \mathbf{a}^{(L)}.$$

La salida de la red es

$$\hat{\mathbf{y}} = \mathbf{a}^{(L)}.$$

Función identidad

Para regresión puede usarse

$$\phi(z) = z.$$

La salida no queda restringida.

Función sigmoideal

$$\sigma(z) = \frac{1}{1 + e^{-z}}.$$

Su derivada es

$$\sigma'(z) = \sigma(z) (1 - \sigma(z)).$$

Se utiliza frecuentemente en clasificación binaria.

Tangente hiperbólica

$$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}.$$

Su derivada es

$$\frac{d}{dz} \tanh(z) = 1 - \tanh^2(z).$$

Su rango es $(-1, 1)$.

ReLU

La función ReLU es

$$\text{ReLU}(z) = \max(0, z).$$

Su derivada es

$$\text{ReLU}'(z) = \begin{cases} 1, & z > 0, \\ 0, & z < 0. \end{cases}$$

En $z = 0$ se utiliza un subgradiente.

Leaky ReLU

$$\text{LReLU}(z) = \begin{cases} z, & z \geq 0, \\ \alpha z, & z < 0, \end{cases}$$

con $\alpha > 0$ pequeño.

Reduce el problema de neuronas muertas.

Softmax

Para clasificación multiclase, si la salida lineal es

$$\mathbf{z} = (z_1, \dots, z_C)^T,$$

la probabilidad de la clase c es

$$\text{softmax}_c(\mathbf{z}) = \frac{e^{z_c}}{\sum_{r=1}^C e^{z_r}}.$$

Se cumple

$$\sum_{c=1}^C \text{softmax}_c(\mathbf{z}) = 1.$$

Estabilidad numérica de softmax

Para evitar desbordamiento se utiliza

$$\text{softmax}_c(\mathbf{z}) = \frac{e^{z_c - z_{\text{máx}}}}{\sum_{r=1}^C e^{z_r - z_{\text{máx}}}},$$

donde

$$z_{\text{máx}} = \max_r z_r.$$

Función de pérdida

El entrenamiento busca minimizar una función de pérdida sobre la muestra.

Sea el conjunto de parámetros

$$\Theta = \{\mathbf{W}^{(\ell)}, \mathbf{b}^{(\ell)}\}_{\ell=1}^L.$$

El riesgo empírico es

$$J(\Theta) = \frac{1}{n} \sum_{i=1}^n L(y_i, \hat{y}_i).$$

Error cuadrático medio

Para regresión:

$$J(\Theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

Entropía cruzada binaria

Para clasificación binaria:

$$J(\Theta) = -\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)].$$

Entropía cruzada multiclase

Con codificación one-hot:

$$J(\Theta) = -\frac{1}{n} \sum_{i=1}^n \sum_{c=1}^C y_{ic} \log \hat{p}_{ic}.$$

Entrenamiento

El objetivo es encontrar

$$\hat{\Theta} = \arg \min_{\Theta} J(\Theta).$$

Como la función suele ser no convexa, se utilizan métodos iterativos.

Descenso por gradiente

La actualización es

$$\Theta \leftarrow \Theta - \eta \nabla_{\Theta} J(\Theta),$$

donde η es la tasa de aprendizaje.

Descenso por lotes

Utiliza toda la muestra para calcular cada gradiente:

$$\nabla_{\Theta} J(\Theta) = \frac{1}{n} \sum_{i=1}^n \nabla_{\Theta} L_i(\Theta).$$

Es estable, pero puede ser costoso.

Descenso estocástico

Actualiza con una observación:

$$\Theta \leftarrow \Theta - \eta \nabla_{\Theta} L_i(\Theta).$$

Introduce ruido, pero puede avanzar rápidamente.

Mini-lotes

Para un mini-lote $\mathcal{B}$:

$$J_{\mathcal{B}}(\Theta) = \frac{1}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} L_i(\Theta).$$

La actualización usa

$$\nabla_{\Theta} J_{\mathcal{B}}(\Theta).$$

Es el enfoque más utilizado.

i Retropropagación no es el optimizador

La retropropagación calcula gradientes eficientemente. El optimizador —SGD, momentum, Adam u otro— utiliza esos gradientes para actualizar los parámetros.

Retropropagación

Definición 20.1. La retropropagación es un algoritmo eficiente para calcular los gradientes de la pérdida respecto de todos los parámetros mediante la regla de la cadena.

El procedimiento tiene dos fases:

1. propagación hacia adelante;
2. propagación hacia atrás de los errores.

Derivación para una neurona de salida

Supóngase

$$z = \mathbf{w}^T \mathbf{a} + b,$$

$$\hat{y} = \phi(z),$$

y pérdida

$$L(y, \hat{y}).$$

Entonces,

$$\frac{\partial L}{\partial w_j} = \frac{\partial L}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial z} \frac{\partial z}{\partial w_j}.$$

Como

$$\frac{\partial z}{\partial w_j} = a_j,$$

se obtiene

$$\frac{\partial L}{\partial w_j} = \delta a_j,$$

donde

$$\delta = \frac{\partial L}{\partial z}.$$

Error local de salida

Para la capa final,

$$\delta^{(L)} = \frac{\partial L}{\partial \mathbf{z}^{(L)}}.$$

Con softmax y entropía cruzada,

$$\delta^{(L)} = \hat{\mathbf{y}} - \mathbf{y}.$$

Esta simplificación es muy importante.

Propagación hacia capas ocultas

Para una capa oculta ℓ :

$$\delta^{(\ell)} = \left(\mathbf{W}^{(\ell+1)} \right)^{\top} \delta^{(\ell+1)} \odot \phi'^{(\ell)} \left(\mathbf{z}^{(\ell)} \right),$$

donde $\odot$ representa producto elemento a elemento.

Gradientes respecto de pesos

$$\frac{\partial L}{\partial \mathbf{W}^{(\ell)}} = \delta^{(\ell)} \left(\mathbf{a}^{(\ell-1)} \right)^{\top}.$$

Gradientes respecto de sesgos

$$\frac{\partial L}{\partial \mathbf{b}^{(\ell)}} = \delta^{(\ell)}.$$

Retropropagación completa

Para cada mini-lote:

1. calcular activaciones hacia adelante;
2. evaluar la pérdida;
3. calcular el error de salida;
4. propagar errores hacia atrás;
5. obtener gradientes;
6. actualizar parámetros.

Ejemplo de una red de una capa oculta

Sea

$$\mathbf{h} = \phi \left(\mathbf{W}^{(1)} \mathbf{x} + \mathbf{b}^{(1)} \right),$$

$$\hat{\mathbf{y}} = \psi \left(\mathbf{W}^{(2)} \mathbf{h} + \mathbf{b}^{(2)} \right).$$

La red compone dos transformaciones:

$$\hat{\mathbf{y}} = \psi \left[\mathbf{W}^{(2)} \phi \left(\mathbf{W}^{(1)} \mathbf{x} + \mathbf{b}^{(1)} \right) + \mathbf{b}^{(2)} \right].$$

Regla de la cadena

La derivada de la pérdida respecto de $\mathbf{W}^{(1)}$ depende de todas las capas posteriores.

Esto explica por qué la retropropagación recorre la red desde la salida hasta la entrada.

Problema de gradiente desvaneciente

En redes profundas, el gradiente implica productos repetidos de derivadas.

Si estas derivadas tienen magnitud menor que uno, el gradiente puede tender a cero:

$$\prod_{\ell=1}^L \phi'(z^{(\ell)}) \rightarrow 0.$$

Las primeras capas aprenden muy lentamente.

Problema de gradiente explosivo

Si los factores tienen magnitud grande, el producto puede crecer rápidamente:

$$\|\nabla_{\Theta} J\| \rightarrow \infty.$$

Esto produce inestabilidad numérica.

Estrategias de estabilización

Se utilizan:

- ReLU y variantes;
- inicialización adecuada;
- normalización por lotes;
- recorte de gradiente;
- conexiones residuales;
- optimizadores adaptativos.

Inicialización de pesos

Inicializar todos los pesos en cero produce simetría: las neuronas de una misma capa aprenden lo mismo.

Por ello, se utilizan valores aleatorios con varianza controlada.

Inicialización Xavier

Para activaciones como tanh:

$$\text{Var}(W_{ij}^{(\ell)}) \approx \frac{2}{n_{\ell-1} + n_{\ell}}.$$

Una forma simplificada usa

$$\text{Var}(W) \approx \frac{1}{n_{\text{entrada}}}.$$

Inicialización He

Para ReLU:

$$\text{Var}(W_{ij}^{(\ell)}) \approx \frac{2}{n_{\ell-1}}.$$

Tasa de aprendizaje

La tasa η es uno de los hiperparámetros más importantes.

Si es demasiado grande:

- la pérdida puede oscilar;
- el entrenamiento puede divergir.

Si es demasiado pequeña:

- el aprendizaje es lento;
- puede quedar atrapado en regiones planas.

Momentum

Momentum acumula una velocidad:

$$\mathbf{v}_t = \beta \mathbf{v}_{t-1} + \nabla_{\Theta} J_t,$$

$$\Theta_t = \Theta_{t-1} - \eta \mathbf{v}_t.$$

Ayuda a suavizar oscilaciones y acelerar en direcciones persistentes.

RMSProp

RMSProp mantiene un promedio móvil de cuadrados de gradientes:

$$\mathbf{s}_t = \rho \mathbf{s}_{t-1} + (1 - \rho) \mathbf{g}_t^2.$$

La actualización es

$$\Theta_t = \Theta_{t-1} - \eta \frac{\mathbf{g}_t}{\sqrt{\mathbf{s}_t} + \varepsilon}.$$

Adam

Adam combina momentum y escalamiento adaptativo:

$$\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1 - \beta_1) \mathbf{g}_t,$$

$$\mathbf{v}_t = \beta_2 \mathbf{v}_{t-1} + (1 - \beta_2) \mathbf{g}_t^2.$$

Después corrige sesgo y actualiza los parámetros.

Regularización L2

Se agrega

$$\lambda \sum_{\ell=1}^L \|\mathbf{w}^{(\ell)}\|_F^2.$$

La función objetivo es

$$J_\lambda(\Theta) = J(\Theta) + \lambda \sum_{\ell=1}^L \|\mathbf{w}^{(\ell)}\|_F^2.$$

Weight decay

En muchos optimizadores, la regularización L2 se implementa como decaimiento de pesos:

$$\mathbf{W} \leftarrow (1 - \eta\lambda)\mathbf{W} - \eta\nabla_{\mathbf{W}}J.$$

Regularización L1

Puede usarse

$$\lambda \sum_{\ell} \|\mathbf{w}^{(\ell)}\|_1.$$

Favorece pesos exactamente cero, aunque es menos común que L2.

i Dropout durante entrenamiento y predicción

Dropout introduce máscaras aleatorias durante entrenamiento. En inferencia se utiliza la red completa con el escalamiento correspondiente; no deben eliminarse neuronas aleatoriamente en una predicción ordinaria.

Dropout

Durante entrenamiento, cada activación puede eliminarse aleatoriamente.

Sea

$$m_j \sim \text{Bernoulli}(q),$$

donde q es la probabilidad de retención.

La activación modificada es

$$\tilde{a}_j = \frac{m_j}{q} a_j.$$

Durante predicción no se eliminan unidades.

Interpretación de dropout

Dropout:

- reduce coadaptación;
- introduce ruido;
- actúa como regularización;
- puede interpretarse como aproximación a un ensamble de subredes.

Parada temprana

Se monitorea la pérdida de validación.

El entrenamiento se detiene cuando:

- la pérdida de entrenamiento sigue disminuyendo;
- la pérdida de validación deja de mejorar.

Esto limita el sobreajuste.

Normalización por lotes

Para activaciones de un mini-lote:

$$\mu_{\mathcal{B}} = \frac{1}{m} \sum_{i=1}^m z_i,$$
$$\sigma_{\mathcal{B}}^2 = \frac{1}{m} \sum_{i=1}^m (z_i - \mu_{\mathcal{B}})^2.$$

Se normaliza:

$$\hat{z}_i = \frac{z_i - \mu_{\mathcal{B}}}{\sqrt{\sigma_{\mathcal{B}}^2 + \varepsilon}}.$$

Después:

$$y_i = \gamma \hat{z}_i + \beta.$$

Capacidad del modelo

La capacidad depende de:

- número de capas;
- número de unidades;
- funciones de activación;
- conectividad;
- regularización.

Una red con demasiada capacidad puede memorizar la muestra.

Alcance del teorema universal

El teorema garantiza capacidad de aproximación bajo determinadas condiciones, pero no asegura entrenamiento eficiente, buena generalización ni una arquitectura pequeña (Hornik et al. 1989).

Teorema de aproximación universal

Bajo condiciones adecuadas, una red con una capa oculta y suficientes unidades puede aproximar arbitrariamente bien funciones continuas sobre conjuntos compactos.

Este resultado no garantiza:

- entrenamiento eficiente;
- buena generalización;
- número razonable de unidades;
- estabilidad numérica.

Profundidad frente a anchura

Una red ancha puede aproximar muchas funciones, pero una red profunda puede representar ciertas estructuras con menos unidades.

La profundidad permite reutilizar composiciones jerárquicas.

Interpretación probabilística

En clasificación binaria, una salida sigmoideal puede interpretarse como

$$\widehat{P}(Y = 1 \mid \mathbf{x}).$$

En clasificación multiclase, softmax produce

$$\widehat{P}(Y = c \mid \mathbf{x}).$$

Estas probabilidades pueden necesitar calibración.

Clases desbalanceadas

Puede utilizarse una entropía cruzada ponderada:

$$J(\Theta) = -\frac{1}{n} \sum_{i=1}^n w_{y_i} \log \hat{p}_{i, y_i}.$$

También pueden ajustarse umbrales o emplearse técnicas de muestreo.

Etiquetas suaves

En lugar de codificación one-hot exacta, puede usarse *label smoothing*:

$$y_{ic}^{LS} = (1 - \varepsilon)y_{ic} + \frac{\varepsilon}{C}.$$

Esto evita predicciones excesivamente confiadas.

Sobreajuste

Indicadores comunes:

- pérdida de entrenamiento muy baja;
- pérdida de validación creciente;
- gran diferencia entre entrenamiento y validación;
- predicciones extremadamente confiadas.

Estrategias:

- regularización;
- dropout;
- parada temprana;
- más datos;
- aumento de datos;
- simplificación de arquitectura.

Validación

La selección de arquitectura y de hiperparámetros debe realizarse con validación.

El conjunto de prueba final se reserva para una sola evaluación.

Hiperparámetros principales

- número de capas;
- unidades por capa;
- activaciones;
- tasa de aprendizaje;
- tamaño de mini-lote;
- optimizador;
- regularización;
- dropout;
- número de épocas.

Época

Una época corresponde a una pasada completa por la muestra de entrenamiento.

Si el tamaño del mini-lote es m , el número aproximado de actualizaciones por época es

$$\left\lceil \frac{n}{m} \right\rceil.$$

Complejidad computacional

Para una capa densa, el costo de propagación es aproximadamente

$$O(n_{\ell-1}n_{\ell}).$$

Para toda la red:

$$O\left(\sum_{\ell=1}^L n_{\ell-1}n_{\ell}\right)$$

por observación.

Predicción

Una vez entrenada, la predicción requiere solo propagación hacia adelante.

No necesita almacenar toda la muestra, a diferencia de k -NN.

Interpretabilidad

Las redes profundas suelen ser difíciles de interpretar globalmente.

Herramientas:

- importancia por permutación;
- gradientes;
- mapas de saliencia;
- valores SHAP;
- activaciones internas;
- análisis de sensibilidad.

Relación con regresión logística

Una red sin capas ocultas, con salida sigmoideal, es equivalente a una regresión logística:

$$\hat{p} = \sigma(\mathbf{w}^T \mathbf{x} + b).$$

Las capas ocultas permiten aprender transformaciones no lineales.

Relación con perceptrón

El perceptrón usa una activación escalón y actualizaciones basadas en errores de clasificación.

Las redes modernas utilizan activaciones diferenciables y optimización basada en gradientes.

Relación con SVM

SVM maximiza margen y utiliza pérdida hinge.

Las redes neuronales minimizan pérdidas diferenciables y aprenden representaciones internas.

SVM suele ser competitivo en muestras medianas; las redes profundas sobresalen en problemas con grandes volúmenes de datos y estructuras complejas.

Relación con aprendizaje profundo

El aprendizaje profundo estudia redes con múltiples capas y arquitecturas especializadas:

- convolucionales;
- recurrentes;
- transformers;
- autoencoders;
- redes generativas.

Conexión con R

```
1 library(keras)
2
3 modelo <- keras_model_sequential() |>
4   layer_dense(
5     units = 16,
6     activation = "relu",
7     input_shape = 4
8   ) |>
9   layer_dropout(rate = 0.2) |>
10  layer_dense(
11    units = 8,
12    activation = "relu"
13  ) |>
14  layer_dense(
15    units = 1,
16    activation = "sigmoid"
17  )
18
19 modelo |>
20   compile(
21     optimizer = optimizer_adam(
22       learning_rate = 0.001
23     ),
24     loss = "binary_crossentropy",
25     metrics = c("accuracy")
26   )
27
28 historial <- modelo |>
29   fit(
30     x = x_entrenamiento,
```



```

31     y = y_entrenamiento,
32     epochs = 100,
33     batch_size = 32,
34     validation_split = 0.2,
35     callbacks = list(
36         callback_early_stopping(
37             patience = 10,
38             restore_best_weights = True
39         )
40     )
41 )
42
43 predict(modelo, x_prueba)

```

Ejemplo numérico de propagación

Considérese una neurona con

$$\mathbf{x} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad \mathbf{w} = \begin{pmatrix} 0.5 \\ -1 \end{pmatrix}, \quad b = 0.2.$$

La combinación lineal es

$$z = 0.5(2) - 1(1) + 0.2 = 0.2.$$

Con activación sigmoidal:

$$a = \frac{1}{1 + e^{-0.2}} \approx 0.5498.$$

Ejemplo de ReLU

Si

$$z = -2.5,$$

entonces

$$\text{ReLU}(z) = 0.$$

Si

$$z = 3.2,$$

entonces

$$\text{ReLU}(z) = 3.2.$$

Ejemplo de softmax

Considérese

$$\mathbf{z} = \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix}.$$

Entonces

$$\hat{p}_1 = \frac{e^2}{e^2 + e^1 + e^0},$$

$$\hat{p}_2 = \frac{e^1}{e^2 + e^1 + e^0},$$

$$\hat{p}_3 = \frac{e^0}{e^2 + e^1 + e^0}.$$

La clase predicha es la primera.

Ventajas

1. gran capacidad de aproximación;
2. aprendizaje automático de representaciones;
3. manejo de relaciones no lineales;
4. adaptación a datos estructurados y no estructurados;
5. flexibilidad arquitectónica;
6. predicción rápida después del entrenamiento.

Limitaciones

1. entrenamiento costoso;
2. numerosos hiperparámetros;
3. menor interpretabilidad;
4. riesgo de sobreajuste;
5. sensibilidad a inicialización y tasa de aprendizaje;
6. necesidad frecuente de grandes conjuntos de datos;
7. optimización no convexa.

Errores frecuentes

1. no escalar variables;
2. usar demasiadas capas para pocos datos;
3. seleccionar épocas con el conjunto de prueba;
4. omitir validación;
5. usar una tasa de aprendizaje inadecuada;
6. confundir salida con probabilidad calibrada;

7. inicializar todos los pesos igual;
8. ignorar desbalance de clases;
9. evaluar únicamente exactitud;
10. concluir causalidad a partir de pesos o activaciones.

Ejercicios conceptuales

1. Explique el papel de pesos y sesgo.
2. ¿Por qué una activación no lineal es necesaria?
3. Compare sigmoidal, tanh y ReLU.
4. ¿Qué diferencia existe entre propagación hacia adelante y retropropagación?
5. Explique el gradiente desvaneciente.
6. ¿Por qué se usan mini-lotes?
7. ¿Qué función cumple dropout?
8. Compare inicialización Xavier y He.
9. ¿Qué representa una época?
10. ¿Cómo se relaciona una red sin capa oculta con regresión logística?
11. ¿Qué ventaja ofrece la profundidad?
12. ¿Por qué la optimización no es convexa?

Ejercicio de neurona

Considere

$$\mathbf{x} = \begin{pmatrix} 1 \\ 3 \\ -2 \end{pmatrix}, \quad \mathbf{w} = \begin{pmatrix} 0.4 \\ -0.2 \\ 0.5 \end{pmatrix}, \quad b = 0.1.$$

1. Calcule z .
2. Calcule la salida sigmoidal.
3. Calcule la salida ReLU.
4. Interprete el resultado.

Ejercicio de dimensiones

Una red tiene:

- 5 variables de entrada;
- primera capa oculta con 10 neuronas;
- segunda capa oculta con 4 neuronas;
- salida con 3 clases.

Determine las dimensiones de:

1. $\mathbf{W}^{(1)}$;
2. $\mathbf{b}^{(1)}$;
3. $\mathbf{W}^{(2)}$;
4. $\mathbf{b}^{(2)}$;

5. $\mathbf{W}^{(3)}$;
6. $\mathbf{b}^{(3)}$.

Ejercicio de parámetros

Para la red anterior, calcule el número total de parámetros entrenables.

Ejercicio de softmax

Calcule softmax para

$$\mathbf{z} = \begin{pmatrix} 1.5 \\ 0.5 \\ -1 \end{pmatrix}.$$

Verifique que las probabilidades suman uno.

Ejercicio de retropropagación

Para una neurona sigmoideal con entropía cruzada binaria:

1. escriba z ;
2. escriba $\hat{p}$;
3. escriba la pérdida;
4. derive $\partial L / \partial z$;
5. derive $\partial L / \partial w_j$.

Ejercicio aplicado

Se desea clasificar pacientes según riesgo cardiovascular utilizando:

- edad;
- presión arterial;
- colesterol;
- glucosa;
- frecuencia cardiaca;
- índice de masa corporal;
- actividad física.

Diseñe una red neuronal que incluya:

1. arquitectura;
2. activaciones;
3. salida;
4. función de pérdida;
5. escalamiento;
6. partición de datos;
7. mini-lotes;
8. optimizador;

9. regularización;
10. parada temprana;
11. manejo de desbalance;
12. sensibilidad y especificidad;
13. calibración;
14. comparación con regresión logística, SVM y Random Forest;
15. limitaciones clínicas.

Resumen

En este capítulo se desarrollaron los fundamentos matemáticos de las redes neuronales artificiales.

Se formuló la neurona artificial, el perceptrón y las redes multicapa. Se estudiaron funciones de activación como sigmoideal, tanh, ReLU y softmax, así como pérdidas para regresión y clasificación.

También se derivó la retropropagación mediante la regla de la cadena, junto con los gradientes respecto de pesos y sesgos. Posteriormente se analizaron descenso por gradiente, mini-lotes, momentum, RMSProp y Adam.

Finalmente, se estudiaron inicialización, regularización, dropout, normalización por lotes, parada temprana, capacidad, aproximación universal, interpretabilidad y conexión con regresión logística, SVM y aprendizaje profundo.

Referencias del capítulo

Los fundamentos y resultados desarrollados en este capítulo se apoyan principalmente en Rumelhart et al. (1986); Bishop (2006).

Parte V

V. Aprendizaje no supervisado

21 Análisis de Componentes Principales, PCA

Introducción

El Análisis de Componentes Principales, conocido como PCA por *Principal Component Analysis*, es uno de los métodos más importantes de reducción de dimensionalidad.

Su objetivo consiste en transformar un conjunto de variables posiblemente correlacionadas en un nuevo conjunto de variables no correlacionadas llamadas componentes principales. Estas componentes se ordenan de acuerdo con la cantidad de variabilidad que explican.

PCA no utiliza una variable objetivo. Por ello, es un método no supervisado. Su propósito no es clasificar ni predecir directamente, sino representar los datos en un espacio de menor dimensión conservando la mayor cantidad posible de información.

! Definición esencial

PCA transforma variables correlacionadas en componentes ortogonales ordenadas por la varianza que explican. Es una transformación lineal no supervisada y su interpretación depende del centrado, la escala y las cargas.

Objetivos

Al finalizar el capítulo, el lector podrá:

1. formular PCA a partir de una matriz de datos;
2. centrar y estandarizar variables;
3. construir la matriz de covarianza;
4. interpretar valores y vectores propios;
5. derivar la primera componente principal;
6. obtener componentes sucesivas;
7. demostrar la ortogonalidad entre componentes;
8. interpretar varianza explicada;
9. construir el gráfico scree;
10. seleccionar el número de componentes;
11. interpretar cargas y puntuaciones;
12. formular PCA mediante SVD;
13. comprender reconstrucción y error;
14. diferenciar PCA sobre covarianza y correlación;
15. analizar limitaciones;
16. conectar PCA con regresión, clasificación y agrupamiento.

Matriz de datos

Considérese una matriz

$$\mathbf{X} = \begin{pmatrix} x_{11} & \cdots & x_{1p} \\ \vdots & \ddots & \vdots \\ x_{n1} & \cdots & x_{np} \end{pmatrix} \in \mathbb{R}^{n \times p}.$$

Cada fila representa una observación y cada columna una variable.

Centrado

La media de la variable j es

$$\bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}.$$

La matriz centrada es

$$\mathbf{X}_c = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top,$$

donde

$$\bar{\mathbf{x}} = \begin{pmatrix} \bar{x}_1 \\ \vdots \\ \bar{x}_p \end{pmatrix}.$$

Cada columna de $\mathbf{X}_c$ tiene media cero.

Estandarización

Cuando las variables tienen escalas distintas, se utiliza

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j},$$

donde s_j es la desviación estándar de la variable j .

La matriz estandarizada se denota por

$$\mathbf{Z}.$$

Covarianza y correlación

Si se trabaja con datos centrados, la matriz de covarianza es

$$\mathbf{S} = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c.$$

Si se trabaja con datos estandarizados,

$$\mathbf{R} = \frac{1}{n-1} \mathbf{Z}^T \mathbf{Z}$$

es la matriz de correlación.

Interpretación geométrica

PCA busca nuevas direcciones en el espacio de variables.

La primera dirección es aquella sobre la cual la proyección de los datos tiene la mayor varianza posible.

La segunda dirección maximiza la varianza restante y debe ser ortogonal a la primera.




Figura 21.1: La primera componente sigue la dirección de máxima variabilidad; la segunda es ortogonal a ella.

Primera componente principal

Sea

$$\mathbf{a}_1 = \begin{pmatrix} a_{11} \\ \vdots \\ a_{p1} \end{pmatrix}$$

un vector unitario.

La primera componente es

$$Z_1 = \mathbf{a}_1^T \mathbf{X}.$$

En notación matricial, las puntuaciones son

$$\mathbf{t}_1 = \mathbf{X}_c \mathbf{a}_1.$$

Varianza de una componente

La varianza de la proyección es

$$\text{Var}(Z_1) = \mathbf{a}_1^T \mathbf{S} \mathbf{a}_1.$$

PCA busca maximizar

$$\mathbf{a}_1^T \mathbf{S} \mathbf{a}_1$$

sujeto a

$$\mathbf{a}_1^T \mathbf{a}_1 = 1.$$

Derivación mediante multiplicadores de Lagrange

La función lagrangiana es

$$\mathcal{L} = \mathbf{a}_1^T \mathbf{S} \mathbf{a}_1 - \lambda_1 (\mathbf{a}_1^T \mathbf{a}_1 - 1).$$

Derivando respecto de $\mathbf{a}_1$:

$$2\mathbf{S} \mathbf{a}_1 - 2\lambda_1 \mathbf{a}_1 = \mathbf{0}.$$

Por tanto,

$$\mathbf{S} \mathbf{a}_1 = \lambda_1 \mathbf{a}_1.$$

La primera dirección principal es el vector propio asociado al mayor valor propio.

Primera varianza principal

Como

$$\mathbf{S} \mathbf{a}_1 = \lambda_1 \mathbf{a}_1,$$

entonces

$$\text{Var}(Z_1) = \mathbf{a}_1^T \mathbf{S} \mathbf{a}_1 = \lambda_1.$$

Componentes sucesivas

La componente k maximiza

$$\mathbf{a}_k^\top \mathbf{S} \mathbf{a}_k$$

sujeto a

$$\mathbf{a}_k^\top \mathbf{a}_k = 1$$

y

$$\mathbf{a}_k^\top \mathbf{a}_r = 0, \quad r < k.$$

La solución es el vector propio asociado a λ_k .

Descomposición espectral

Como $\mathbf{S}$ es simétrica,

$$\mathbf{S} = \mathbf{A} \mathbf{\Lambda} \mathbf{A}^\top,$$

donde

$$\mathbf{A} = (\mathbf{a}_1 \quad \cdots \quad \mathbf{a}_p)$$

y

$$\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_p).$$

Los valores propios se ordenan como

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0.$$

Puntuaciones

Las puntuaciones principales son

$$\mathbf{T} = \mathbf{X}_c \mathbf{A}.$$

La columna k de $\mathbf{T}$ contiene las coordenadas de las observaciones en la componente k .

Cargas

Los coeficientes del vector propio se denominan cargas:

$$a_{jk}.$$

Indican la contribución de la variable j a la componente k .

Una carga grande en magnitud indica fuerte asociación con la componente.

Signo de las componentes

Si $\mathbf{a}_k$ es vector propio, también lo es

$$-\mathbf{a}_k.$$

Por ello, el signo de una componente es arbitrario.

La interpretación debe basarse en relaciones relativas, no en el signo absoluto.

Varianza explicada

La varianza total es

$$\sum_{j=1}^p \lambda_j.$$

La proporción explicada por la componente k es

$$PVE_k = \frac{\lambda_k}{\sum_{j=1}^p \lambda_j}.$$

La proporción acumulada por las primeras m componentes es

$$CPVE_m = \frac{\sum_{k=1}^m \lambda_k}{\sum_{j=1}^p \lambda_j}.$$

Gráfico scree

El gráfico scree muestra

$$\lambda_k$$

o

$$PVE_k$$

frente al número de componente.

Se busca un punto de inflexión o codo a partir del cual la ganancia adicional sea pequeña.

Selección del número de componentes

Criterios comunes:

- proporción acumulada;
- criterio del codo;
- criterio de Kaiser;
- análisis paralelo;
- validación cruzada;
- desempeño posterior.

Criterio de Kaiser

Cuando PCA se realiza sobre la matriz de correlación, se retienen componentes con

$$\lambda_k > 1.$$

Este criterio es simple, pero no debe usarse de forma automática.

Análisis paralelo

Compara los valores propios observados con los obtenidos en datos aleatorios de la misma dimensión.

Se retienen componentes cuyos valores propios exceden los valores esperados bajo aleatoriedad.

Decisión crítica: estandarizar o no

PCA sobre la matriz de covarianza conserva las diferencias originales de escala. PCA sobre la matriz de correlación asigna varianza unitaria a cada variable. Las dos decisiones pueden producir componentes muy distintas y deben justificarse con el significado de las unidades (Jolliffe 2002; Jolliffe y Cadima 2016).

Covarianza o correlación

Usar covarianza es apropiado cuando:

- las variables están en unidades comparables;
- la escala tiene significado;
- las diferencias de varianza son relevantes.

Usar correlación es apropiado cuando:

- las variables tienen unidades distintas;
- las escalas son muy diferentes;
- se desea dar peso comparable a cada variable.

Reconstrucción

Si se retienen m componentes,

$$\mathbf{T}_m = \mathbf{X}_c \mathbf{A}_m,$$

donde

$$\mathbf{A}_m = \begin{pmatrix} \mathbf{a}_1 & \cdots & \mathbf{a}_m \end{pmatrix}.$$

La reconstrucción aproximada es

$$\widehat{\mathbf{X}}_c = \mathbf{T}_m \mathbf{A}_m^\top.$$

Error de reconstrucción

El error cuadrático es

$$\|\mathbf{X}_c - \widehat{\mathbf{X}}_c\|_F^2.$$

PCA produce la mejor aproximación lineal de rango m en norma de Frobenius.

La reconstrucción truncada no es únicamente una aproximación intuitiva: entre todas las matrices de rango a lo sumo m , la obtenida mediante las primeras componentes minimiza el error de Frobenius (Eckart y Young 1936).

Teorema de Eckart-Young

La aproximación truncada basada en las primeras m componentes minimiza

$$\|\mathbf{X}_c - \mathbf{M}\|_F$$

entre todas las matrices $\mathbf{M}$ de rango a lo sumo m .

Formulación mediante SVD

La descomposición en valores singulares es

$$\mathbf{X}_c = \mathbf{U} \mathbf{D} \mathbf{V}^\top.$$

Entonces

$$\mathbf{S} = \frac{1}{n-1} \mathbf{V} \mathbf{D}^2 \mathbf{V}^\top.$$

Por tanto:

- las columnas de $\mathbf{V}$ son las direcciones principales;
- los valores propios son

$$\lambda_k = \frac{d_k^2}{n-1}.$$

Ventaja de SVD

SVD evita formar explícitamente la matriz de covarianza y suele ser más estable numéricamente.

Es especialmente útil cuando:

- p es grande;
- n es grande;
- existen problemas de rango;
- se requiere PCA truncado.

Componentes no correlacionadas

La covarianza de las puntuaciones es

$$\text{Cov}(\mathbf{T}) = \Lambda.$$

Por tanto, las componentes principales son incorrelacionadas.

Incorrelación no implica independencia

Si los datos no son normales multivariados, componentes no correlacionadas no necesariamente son independientes.

PCA elimina correlación lineal, no toda dependencia.

Interpretación de biplot

Un biplot representa simultáneamente:

- observaciones mediante puntuaciones;
- variables mediante vectores de carga.

La dirección de un vector indica asociación con las componentes.

El ángulo aproximado entre vectores refleja correlación:

- ángulo pequeño: correlación positiva;
- ángulo cercano a 180° : correlación negativa;
- ángulo cercano a 90° : correlación cercana a cero.

Efecto de valores atípicos

PCA depende de medias y covarianzas.

Por ello, puede ser muy sensible a valores atípicos.

Una observación extrema puede alterar:

- medias;
- varianzas;
- covarianzas;
- direcciones principales.

PCA robusto

Existen variantes robustas que utilizan:

- estimadores robustos de covarianza;
- proyecciones resistentes;
- pérdidas robustas;
- métodos de baja dimensión robustos.

Linealidad

PCA identifica estructura lineal.

Si los datos se encuentran sobre una variedad no lineal, PCA puede requerir muchas componentes.

Alternativas:

- kernel PCA;
- Isomap;
- LLE;
- autoencoders;
- UMAP.

Kernel PCA

Kernel PCA aplica PCA en un espacio de características definido por un kernel.

La matriz de Gram es

$$K_{ij} = K(\mathbf{x}_i, \mathbf{x}_j).$$

Después de centrar la matriz kernel, se calculan sus vectores propios.

PCA y distancia

Al reducir dimensión, las distancias pueden aproximarse usando las primeras componentes.

Esto puede mejorar métodos como k -NN cuando las variables originales contienen ruido.

PCA antes de clasificación

PCA puede utilizarse antes de:

- regresión logística;
- k -NN;
- SVM;
- clustering;
- redes neuronales.

Sin embargo, PCA maximiza varianza, no separación entre clases.

Una componente con baja varianza podría ser muy discriminante.

Fuga de información

PCA debe aprenderse únicamente con los datos de entrenamiento.

En validación cruzada, el centrado, escalamiento y cálculo de componentes deben repetirse dentro de cada partición de entrenamiento.

Regresión por componentes principales

En PCR se ajusta una regresión usando las primeras componentes:

$$Y = \beta_0 + \sum_{k=1}^m \gamma_k Z_k + \varepsilon.$$

Esto reduce multicolinealidad, pero la selección de componentes no utiliza Y .

PCA y multicolinealidad

Las componentes son ortogonales, por lo que no presentan multicolinealidad entre sí.

Esto puede estabilizar modelos posteriores.

Datos de alta dimensión

Cuando

$$p \gg n,$$

la matriz de covarianza tiene rango máximo

$$n - 1.$$

Por tanto, como máximo hay $n - 1$ componentes con varianza positiva.

Datos faltantes

PCA clásico requiere una matriz completa.

Estrategias:

- imputación previa;
- PCA iterativo;
- métodos EM;
- PCA probabilístico;
- métodos de baja-rango con faltantes.

PCA probabilístico

PCA probabilístico modela

$$\mathbf{x} = \mathbf{W}\mathbf{z} + \mu + \varepsilon,$$

donde

$$\mathbf{z} \sim N(\mathbf{0}, \mathbf{I}),$$

$$\varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I}).$$

Proporciona una interpretación generativa.

Estandarización y variables constantes

Una variable con desviación estándar cero no puede estandarizarse.

Debe eliminarse o tratarse antes de PCA.

Complejidad computacional

El costo depende de n y p .

Formar la covarianza cuesta aproximadamente

$$O(np^2).$$

Descomponer una matriz $p \times p$ cuesta aproximadamente

$$O(p^3).$$

SVD truncada puede reducir el costo cuando solo se requieren pocas componentes.

PCA incremental

Cuando los datos son muy grandes o llegan secuencialmente, puede utilizarse PCA incremental.

Este método actualiza progresivamente la representación sin almacenar toda la muestra.

Interpretabilidad

Las componentes son combinaciones lineales y pueden ser difíciles de interpretar.

Una componente como

$$Z_1 = 0.45X_1 + 0.44X_2 - 0.10X_3$$

requiere analizar magnitudes, signos y contexto de las variables.

Rotaciones

En análisis factorial se utilizan rotaciones para facilitar interpretación.

En PCA también pueden rotarse componentes, aunque la varianza explicada se redistribuye y se modifica la interpretación original.

Conexión con R

```
1  datos <- data.frame(  
2    pm10 = c(45, 52, 60, 38, 70, 65),  
3    no2 = c(30, 35, 42, 28, 50, 47),  
4    temperatura = c(22, 24, 26, 20, 28, 27),  
5    humedad = c(60, 55, 50, 70, 45, 48)  
6  )  
7  
8  modelo_pca <- prcomp(  
9    datos,  
10   center = TRUE,  
11   scale. = TRUE  
12 )  
13  
14 summary(modelo_pca)  
15  
16 # Desviaciones estándar  
17 modelo_pca$sdev  
18  
19 # Cargas  
20 modelo_pca$rotation  
21  
22 # Puntuaciones  
23 modelo_pca$x  
24  
25 # Gráfico scree  
26 plot(  
27   modelo_pca,  
28   type = "l"  
29 )  
30  
31 # Biplot  
32 biplot(modelo_pca)
```

Ejemplo con dos variables

Considérese la matriz centrada

$$\mathbf{X}_c = \begin{pmatrix} -2 & -1 \\ -1 & 0 \\ 1 & 0 \\ 2 & 1 \end{pmatrix}.$$

La matriz de covarianza es

$$\mathbf{S} = \frac{1}{3} \mathbf{X}_c^\top \mathbf{X}_c.$$

Se calculan sus valores y vectores propios.

La primera componente será la dirección asociada al mayor valor propio.

Ejemplo de varianza explicada

Supóngase que los valores propios son

$$\lambda_1 = 5, \quad \lambda_2 = 2, \quad \lambda_3 = 1.$$

La varianza total es

$$5 + 2 + 1 = 8.$$

Las proporciones son

$$PVE_1 = \frac{5}{8} = 0.625,$$

$$PVE_2 = \frac{2}{8} = 0.25,$$

$$PVE_3 = \frac{1}{8} = 0.125.$$

Las dos primeras componentes explican

$$0.625 + 0.25 = 0.875.$$

Ejemplo de reconstrucción

Con dos variables y una sola componente,

$$\hat{\mathbf{x}}_c = t_1 \mathbf{a}_1.$$

Después se suma la media original:

$$\hat{\mathbf{x}} = \hat{\mathbf{x}}_c + \bar{\mathbf{x}}.$$

Ventajas

1. reduce dimensionalidad;
2. elimina correlación lineal;
3. facilita visualización;

4. puede reducir ruido;
5. mejora eficiencia computacional;
6. ayuda frente a multicolinealidad;
7. tiene formulación matemática clara.

Limitaciones

1. es lineal;
2. es sensible a escala;
3. es sensible a valores atípicos;
4. las componentes pueden ser difíciles de interpretar;
5. maximiza varianza, no relevancia predictiva;
6. requiere datos numéricos;
7. puede ocultar variables importantes de baja varianza.

Errores frecuentes

1. aplicar PCA sin centrar;
2. no estandarizar variables de escalas distintas;
3. interpretar componentes como variables originales;
4. seleccionar componentes solo por el criterio de Kaiser;
5. usar PCA antes de dividir entrenamiento y prueba;
6. concluir independencia a partir de incorrelación;
7. ignorar valores atípicos;
8. asumir que mayor varianza significa mayor poder predictivo;
9. interpretar el signo absoluto de una carga;
10. usar PCA con variables categóricas sin transformación adecuada.

Ejercicios conceptuales

1. Explique el objetivo de PCA.
2. ¿Por qué se centra la matriz?
3. ¿Cuándo debe estandarizarse?
4. ¿Qué representa un vector propio?
5. ¿Qué representa un valor propio?
6. ¿Por qué las componentes son ortogonales?
7. ¿Qué diferencia existe entre cargas y puntuaciones?
8. ¿Cómo se selecciona el número de componentes?
9. ¿Qué relación existe entre PCA y SVD?
10. ¿Por qué PCA puede fallar en estructuras no lineales?
11. ¿Cómo afecta un valor atípico?
12. ¿Por qué debe calcularse dentro de cada partición de entrenamiento?

Ejercicio de matriz de covarianza

Considere

$$\mathbf{X} = \begin{pmatrix} 1 & 2 \\ 2 & 3 \\ 3 & 5 \\ 4 & 6 \end{pmatrix}.$$

1. Calcule las medias.
2. Centre la matriz.
3. Calcule la matriz de covarianza.
4. Obtenga valores y vectores propios.
5. Identifique la primera componente.

Ejercicio de varianza explicada

Considere

$$\lambda_1 = 6, \quad \lambda_2 = 3, \quad \lambda_3 = 1, \quad \lambda_4 = 0.5.$$

1. Calcule la varianza total.
2. Calcule cada proporción explicada.
3. Calcule la proporción acumulada.
4. Determine cuántas componentes se necesitan para explicar al menos 90 por ciento.

Ejercicio de cargas

La primera componente es

$$Z_1 = 0.60X_1 + 0.58X_2 - 0.10X_3 - 0.54X_4.$$

1. Identifique las variables con mayor contribución.
2. Interprete los signos.
3. Explique por qué cambiar todos los signos no modifica la componente.
4. Proponga una interpretación sustantiva.

Ejercicio de reconstrucción

Sea

$$\mathbf{a}_1 = \begin{pmatrix} 0.8 \\ 0.6 \end{pmatrix}$$

y la puntuación

$$t_1 = 2.$$

1. Reconstruya la observación centrada.
2. Si la media es $(10, 5)$, reconstruya la observación original.

Ejercicio aplicado

Se desea analizar calidad del aire con variables:

- PM10;
- PM2.5;
- NO2;
- ozono;
- temperatura;
- humedad;
- velocidad del viento.

Diseñe un análisis PCA que incluya:

1. limpieza;
2. manejo de faltantes;
3. detección de valores atípicos;
4. decisión entre covarianza y correlación;
5. cálculo de componentes;
6. gráfico scree;
7. varianza acumulada;
8. interpretación de cargas;
9. biplot;
10. reconstrucción;
11. agrupamiento posterior;
12. comparación con variables originales;
13. validación;
14. limitaciones ambientales.

Resumen

En este capítulo se desarrolló el Análisis de Componentes Principales como método lineal de reducción de dimensionalidad.

Se derivó la primera componente mediante maximización de varianza y multiplicadores de Lagrange. Se mostró que las direcciones principales son vectores propios de la matriz de covarianza y que sus varianzas son los valores propios correspondientes.

También se estudiaron puntuaciones, cargas, varianza explicada, selección del número de componentes, reconstrucción, error de aproximación y formulación mediante SVD.

Finalmente, se analizaron estandarización, valores atípicos, fuga de información, PCA probabilístico, kernel PCA, aplicaciones predictivas y limitaciones interpretativas.

Referencias del capítulo

Los fundamentos se apoyan en Pearson (1901), Hotelling (1933), Jolliffe (2002), Jolliffe y Cadima (2016), Eckart y Young (1936) y Mardia et al. (1979).

22 Agrupamiento mediante K-means

Introducción

K-means es uno de los algoritmos más conocidos de aprendizaje no supervisado. Su objetivo consiste en dividir un conjunto de observaciones en K grupos de manera que las observaciones dentro de cada grupo sean lo más semejantes posible y los grupos entre sí sean diferentes.

El método representa cada grupo mediante un centroide. La asignación de observaciones y la actualización de centroides se realizan de forma iterativa hasta alcanzar una solución estable.

K-means es conceptualmente sencillo, computacionalmente eficiente y ampliamente utilizado en segmentación, compresión, análisis exploratorio y preprocesamiento. Sin embargo, su desempeño depende de la escala de las variables, de la inicialización, de la forma de los grupos y de la elección del número de conglomerados.

! Definición esencial

K-means divide las observaciones en K grupos y representa cada grupo por su media. El algoritmo alterna asignaciones y actualización de centroides para reducir la suma de cuadrados intragrupo.

Objetivos

Al finalizar el capítulo, el lector podrá:

1. formular el problema de agrupamiento;
2. definir centroides y asignaciones;
3. derivar la función objetivo de K-means;
4. comprender el algoritmo de Lloyd;
5. demostrar la disminución monótona de la función objetivo;
6. interpretar la convergencia local;
7. analizar el efecto de la inicialización;
8. comprender K-means++;
9. seleccionar el número de grupos;
10. interpretar inercia, silueta y separación;
11. reconocer limitaciones geométricas;
12. analizar sensibilidad a escala y valores atípicos;
13. relacionar K-means con mezcla de gaussianas;
14. aplicar el método en R.

Formulación del problema

Considérese una muestra no etiquetada

$$\mathcal{D}_n = \{\mathbf{x}_1, \dots, \mathbf{x}_n\},$$

donde

$$\mathbf{x}_i \in \mathbb{R}^p.$$

Se desea dividir las observaciones en K grupos:

$$C_1, \dots, C_K.$$

Estos grupos deben formar una partición:

$$C_k \cap C_\ell = \emptyset, \quad k \neq \ell,$$

y

$$\bigcup_{k=1}^K C_k = \{1, \dots, n\}.$$

Centroides

El centroide del grupo C_k es

$$\mu_k = \frac{1}{|C_k|} \sum_{i \in C_k} \mathbf{x}_i.$$

Cada centroide representa la media vectorial de las observaciones asignadas al grupo.

Función objetivo

K-means minimiza la suma de cuadrados dentro de los grupos:

$$J = \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \mu_k\|_2^2.$$

Esta cantidad también se conoce como:

- inercia;
- suma de cuadrados intragrupo;
- within-cluster sum of squares.

Variables indicadoras

Defínase




Figura 22.1: Los centroides resumen cada grupo y determinan regiones de asignación por proximidad.

$$r_{ik} = \begin{cases} 1, & \mathbf{x}_i \in C_k, \\ 0, & \text{en otro caso.} \end{cases}$$

Entonces

$$\sum_{k=1}^K r_{ik} = 1$$

para toda observación i .

La función objetivo puede escribirse como

$$J(\mathbf{R}, \mu) = \sum_{i=1}^n \sum_{k=1}^K r_{ik} \|\mathbf{x}_i - \mu_k\|_2^2.$$

Optimización alternante

El problema es difícil de resolver globalmente porque las asignaciones son discretas.

K-means utiliza optimización alternante:

1. fijar centroides y optimizar asignaciones;
2. fijar asignaciones y optimizar centroides;
3. repetir.

Paso de asignación

Dados los centroides, cada observación se asigna al centroide más cercano:

$$r_{ik} = \begin{cases} 1, & k = \arg \min_{\ell} \|\mathbf{x}_i - \mu_{\ell}\|_2^2, \\ 0, & \text{en otro caso.} \end{cases}$$

Paso de actualización

Dadas las asignaciones, el centroide óptimo es la media:

$$\mu_k = \frac{\sum_{i=1}^n r_{ik} \mathbf{x}_i}{\sum_{i=1}^n r_{ik}}.$$

Derivación del centroide

Para un grupo fijo, se minimiza

$$J_k(\mu_k) = \sum_{i \in C_k} \|\mathbf{x}_i - \mu_k\|_2^2.$$

Derivando:

$$\nabla_{\mu_k} J_k = -2 \sum_{i \in C_k} (\mathbf{x}_i - \mu_k).$$

Igualando a cero:

$$\sum_{i \in C_k} \mathbf{x}_i = |C_k| \mu_k.$$

Por tanto,

$$\mu_k = \frac{1}{|C_k|} \sum_{i \in C_k} \mathbf{x}_i.$$

La formulación moderna de K-means se relaciona con los trabajos de MacQueen (1967) y Lloyd (1982). Cada paso reduce o mantiene la función objetivo, pero la solución final depende de la inicialización.

Algoritmo de Lloyd

Definición 22.1. El algoritmo clásico de K-means es:

1. seleccionar K centroides iniciales;
2. asignar cada observación al centroide más cercano;
3. recalcular cada centroide como la media de su grupo;
4. repetir hasta que las asignaciones o centroides dejen de cambiar.

Pseudocódigo

Dado K :

1. inicializar $\mu_1, \dots, \mu_K$;
2. para cada i , asignar $\mathbf{x}_i$ al centroide más cercano;
3. actualizar cada μ_k ;
4. calcular J ;
5. detener si la reducción de J es menor que una tolerancia;
6. de otro modo, volver al paso 2.

Convergencia

Cada paso de asignación no aumenta la función objetivo.

Cada paso de actualización tampoco aumenta la función objetivo.

Por tanto,

$$J^{(t+1)} \leq J^{(t)}.$$

Como $J \geq 0$, la secuencia converge.

Convergencia local

La convergencia no garantiza alcanzar el mínimo global.

K-means puede quedar atrapado en un mínimo local dependiendo de:

- centroides iniciales;
- estructura de los datos;
- número de grupos;
- presencia de valores atípicos.

Inicialización aleatoria

Una estrategia simple consiste en seleccionar aleatoriamente K observaciones como centroides.

Esta estrategia puede producir:

- grupos vacíos;
- soluciones pobres;
- alta variabilidad entre ejecuciones.

Reinicios múltiples

Para reducir dependencia de la inicialización:

1. ejecutar K-means varias veces;
2. calcular la función objetivo final;
3. conservar la solución con menor valor de J .

En R, este comportamiento se controla con `nstart`.

K-means++

K-means++ mejora la selección inicial:

1. seleccionar el primer centroide al azar;
2. calcular la distancia de cada observación al centroide más cercano ya elegido;
3. seleccionar el siguiente centroide con probabilidad proporcional al cuadrado de esa distancia;
4. repetir hasta obtener K centroides.

Esto favorece centroides iniciales bien separados.

Cota de K-means++

K-means++ proporciona una garantía esperada de aproximación del orden de

$$O(\log K)$$

respecto del óptimo global.

Distancia euclidiana

K-means está ligado a la distancia euclidiana cuadrática:

$$d^2(\mathbf{x}, \mu) = \|\mathbf{x} - \mu\|_2^2.$$

Cambiar la distancia requiere modificar también la definición del representante del grupo.

Relación entre media y distancia cuadrática

La media es el punto que minimiza la suma de distancias euclidianas cuadráticas.

Por ello, K-means no puede reemplazar arbitrariamente la distancia euclidiana por otra sin cambiar el algoritmo.

K-medians

Si se utiliza distancia Manhattan, el representante adecuado es la mediana.

El método resultante se denomina K-medians.

K-medoids

K-medoids representa cada grupo mediante una observación real del conjunto.

Es más robusto frente a valores atípicos y permite distancias más generales.

Geometría de los grupos

K-means funciona mejor cuando los grupos son:

- aproximadamente esféricos;

- de tamaño semejante;
- de densidad semejante;
- bien separados;
- describibles mediante centroides.

Regiones de Voronoi

Dados los centroides, el espacio se divide en regiones:

$$V_k = \left\{ \mathbf{x} : \|\mathbf{x} - \mu_k\|_2 \leq \|\mathbf{x} - \mu_\ell\|_2 \text{ para todo } \ell \right\}.$$

Cada región es una celda de Voronoi.

Fronteras entre grupos

La frontera entre dos centroides satisface

$$\|\mathbf{x} - \mu_k\|_2^2 = \|\mathbf{x} - \mu_\ell\|_2^2.$$

Al simplificar, se obtiene un hiperplano.

Escalamiento

K-means depende fuertemente de la escala.

Si una variable tiene varianza muy grande, dominará la función objetivo.

Por ello, suele utilizarse estandarización:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}.$$

Valores atípicos

La media y la distancia cuadrática son sensibles a valores extremos.

Un valor atípico puede:

- desplazar centroides;
- formar un grupo aislado;
- alterar asignaciones;
- aumentar la inercia.

Grupos vacíos

Durante una actualización, un grupo puede quedar sin observaciones.

Estrategias:

- reinicializar el centroide;
- usar una observación alejada;

- dividir el grupo con mayor dispersión;
- reiniciar el algoritmo.

Elección del número de grupos

El valor de K es un hiperparámetro.

No existe un criterio universal.

Se utilizan:

- método del codo;
- silueta;
- índice Gap;
- estabilidad;
- conocimiento del dominio;
- desempeño posterior.

Método del codo

Se calcula

$$W_K = \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \mu_k\|_2^2.$$

Como W_K disminuye al aumentar K , se busca un punto donde la mejora adicional se vuelve pequeña.

El coeficiente de silueta combina compactación y separación y permite comparar particiones con distintos valores de K (Rousseeuw 1987). No reemplaza la interpretación sustantiva ni la evaluación de estabilidad.

Coeficiente de silueta

Para la observación i :

- $a(i)$ es la distancia promedio dentro de su grupo;
- $b(i)$ es la menor distancia promedio a otro grupo.

La silueta es

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}.$$

Se cumple

$$-1 \leq s(i) \leq 1.$$

Interpretación de la silueta

- valor cercano a 1: buena asignación;

- valor cercano a 0: observación en frontera;
- valor negativo: posible asignación incorrecta.

La silueta promedio resume la calidad global.

Índice Gap

El índice Gap compara la dispersión observada con la esperada bajo una distribución de referencia sin estructura de grupos.

Se selecciona un valor de K cuya mejora sea significativa respecto del caso aleatorio.

Estabilidad del agrupamiento

Un agrupamiento es estable si pequeñas modificaciones en los datos producen grupos semejantes.

Puede evaluarse mediante:

- bootstrap;
- submuestreo;
- perturbaciones;
- índices de concordancia.

Índice de Rand ajustado

Si se comparan dos particiones, el índice de Rand ajustado mide su concordancia corrigiendo el acuerdo esperado por azar.

Su valor máximo es 1.

Evaluación sin etiquetas

Sin etiquetas verdaderas se utilizan criterios internos:

- inercia;
- silueta;
- separación;
- compactación;
- estabilidad.

Evaluación con etiquetas externas

Si existen etiquetas de referencia, pueden utilizarse:

- Rand ajustado;
- información mutua normalizada;
- pureza;
- homogeneidad;
- completitud.

Las etiquetas no intervienen en el ajuste, solo en la evaluación.

Relación con mezcla de gaussianas

K-means puede interpretarse como un caso límite de una mezcla de gaussianas con:

- covarianzas esféricas;
- igual varianza;
- asignación dura;
- probabilidades uniformes.

Mezclas gaussianas

Una mezcla gaussiana modela

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} \mid \mu_k, \Sigma_k).$$

A diferencia de K-means, produce asignaciones probabilísticas.

Asignación dura y blanda

K-means usa

$$r_{ik} \in \{0, 1\}.$$

Una mezcla gaussiana usa responsabilidades

$$0 \leq \gamma_{ik} \leq 1,$$

con

$$\sum_{k=1}^K \gamma_{ik} = 1.$$

K-means como cuantización vectorial

K-means puede utilizarse para representar cada observación mediante su centroide más cercano.

Esto se denomina cuantización vectorial.

Aplicaciones:

- compresión de imágenes;
- reducción de colores;
- diccionarios visuales;
- compresión de señales.

K-means en imágenes

Cada píxel puede representarse por un vector RGB.

K-means agrupa colores y reemplaza cada píxel por el color de su centroide.

K-means en datos grandes

Para grandes volúmenes se utiliza mini-batch K-means.

En cada iteración se actualizan centroides con un subconjunto pequeño de observaciones.

Mini-batch K-means

Reduce el costo computacional y permite trabajar con datos masivos.

Puede sacrificar algo de precisión a cambio de velocidad.

Complejidad computacional

El costo aproximado por iteración es

$$O(nKp).$$

Si se realizan T iteraciones:

$$O(nKpT).$$

Memoria

La implementación básica necesita almacenar:

- la matriz de datos;
- los centroides;
- las asignaciones;
- distancias temporales.

Datos categóricos

K-means no es adecuado directamente para variables categóricas.

Alternativas:

- K-modes;
- K-prototypes;
- distancias de Gower;
- clustering jerárquico.

K-modes

K-modes utiliza:

- moda como representante;
- discrepancia categórica;
- datos nominales.

K-prototypes

K-prototypes combina:

- medias para variables numéricas;
- modas para categóricas;
- una función de costo mixta.

Reducción de dimensionalidad previa

PCA puede aplicarse antes de K-means para:

- reducir ruido;
- disminuir costo;
- facilitar visualización;
- mitigar correlación.

Pero también puede eliminar componentes importantes para separar grupos.

Fuga de información

En un análisis predictivo posterior, cualquier escalamiento o PCA debe aprenderse con los datos de entrenamiento.

En clustering puramente exploratorio, debe documentarse claramente el conjunto utilizado.

Interpretación de centroides

Los centroides pueden describirse mediante perfiles:

$$\mu_k = \begin{pmatrix} \mu_{k1} \\ \vdots \\ \mu_{kp} \end{pmatrix}.$$

Cada componente representa la media de una variable dentro del grupo.

Etiquetas de los grupos

Los números de grupo son arbitrarios.

Cambiar las etiquetas no cambia la solución.

Por ejemplo, los grupos 1 y 2 pueden intercambiarse sin modificar la partición.

No identificabilidad de etiquetas

Este fenómeno se conoce como permutación de etiquetas.

La interpretación debe basarse en centroides y características, no en el número asignado.

Sensibilidad al orden

Una implementación determinista con inicialización fija no depende del orden.

Sin embargo, algoritmos en línea o mini-batch pueden verse afectados por el orden de llegada.

Reproducibilidad

Debe fijarse una semilla aleatoria y reportarse:

- número de reinicios;
- método de inicialización;
- valor de K ;
- escalamiento;
- criterio de selección.

Conexión con R

```
1  datos <- data.frame(  
2    pm10 = c(45, 52, 60, 38, 70, 65, 30, 28),  
3    no2 = c(30, 35, 42, 28, 50, 47, 20, 18),  
4    temperatura = c(22, 24, 26, 20, 28, 27, 18, 17),  
5    humedad = c(60, 55, 50, 70, 45, 48, 75, 78)  
6  )  
7  
8  datos_esc <- scale(datos)  
9  
10 set.seed(123)  
11  
12 modelo <- kmeans(  
13   datos_esc,  
14   centers = 3,  
15   nstart = 50,  
16   iter.max = 100  
17 )  
18  
19 modelo$cluster  
20 modelo$centers  
21 modelo$tot.withinss  
22 modelo$betweenss  
23 modelo$size  
24  
25 # Método del codo  
26 wss <- sapply(1:8, function(k) {  
27   kmeans(  
28     datos_esc,  
29     centers = k,  
30     nstart = 30  
31   )$tot.withinss  
32 })  
33
```

```

34 plot(
35     1:8,
36     wss,
37     type = "b",
38     xlab = "Número de grupos",
39     ylab = "Suma de cuadrados intragrupo"
40 )

```

Ejemplo numérico

Considérese el conjunto unidimensional:

$$1, 2, 3, 8, 9, 10.$$

Con $K = 2$ y centroides iniciales

$$\mu_1 = 2, \quad \mu_2 = 9,$$

las asignaciones son:

$$C_1 = \{1, 2, 3\},$$

$$C_2 = \{8, 9, 10\}.$$

Los centroides actualizados son

$$\mu_1 = \frac{1 + 2 + 3}{3} = 2,$$

$$\mu_2 = \frac{8 + 9 + 10}{3} = 9.$$

El algoritmo converge inmediatamente.

Ejemplo de función objetivo

Para el primer grupo:

$$(1 - 2)^2 + (2 - 2)^2 + (3 - 2)^2 = 2.$$

Para el segundo:

$$(8 - 9)^2 + (9 - 9)^2 + (10 - 9)^2 = 2.$$

Por tanto,

$$J = 4.$$

Ejemplo de sensibilidad a escala

Supóngase que una variable se mide entre 0 y 1 y otra entre 0 y 10000.

Sin estandarización, la segunda variable dominará la distancia.

Esto puede producir grupos definidos casi exclusivamente por ella.

El agrupamiento no descubre automáticamente grupos verdaderos

Un algoritmo siempre puede producir una partición cuando se le solicita. La existencia matemática de grupos no implica que estos sean estables, naturales o útiles. El resultado debe evaluarse mediante geometría, estabilidad y conocimiento del dominio (Jain 2010).

Ventajas

1. sencillo;
2. eficiente;
3. escalable;
4. fácil de implementar;
5. útil para exploración;
6. centroides interpretables;
7. apropiado para grupos compactos y esféricos.

Limitaciones

1. requiere elegir K ;
2. depende de inicialización;
3. converge a mínimos locales;
4. sensible a escala;
5. sensible a valores atípicos;
6. no maneja bien grupos no convexos;
7. supone estructura aproximadamente esférica;
8. no es adecuado directamente para datos categóricos.

Errores frecuentes

1. no estandarizar;
2. usar un solo inicio;
3. elegir K solo por intuición;
4. interpretar etiquetas como ordenadas;
5. asumir que los grupos son verdaderos o naturales;
6. usar K-means con variables categóricas;
7. ignorar valores atípicos;
8. usar el codo como criterio único;

9. confundir compactación con utilidad práctica;
10. concluir causalidad a partir de grupos.

Ejercicios conceptuales

1. Explique la función objetivo de K-means.
2. ¿Por qué el centroide es la media?
3. ¿Por qué el algoritmo disminuye la función objetivo?
4. ¿Por qué no garantiza el óptimo global?
5. ¿Qué función cumple K-means++?
6. ¿Por qué es importante estandarizar?
7. ¿Qué representa la silueta?
8. Compare K-means y K-medoids.
9. ¿Qué relación existe con mezclas gaussianas?
10. ¿Por qué las etiquetas de grupos son arbitrarias?
11. ¿Qué ocurre con grupos no esféricos?
12. ¿Cómo se evalúa estabilidad?

Ejercicio de asignación

Considere los puntos

$$(1, 1), (2, 1), (5, 4), (6, 5)$$

y centroides iniciales

$$\mu_1 = (1, 1), \quad \mu_2 = (6, 5).$$

1. Calcule las distancias.
2. Asigne cada punto.
3. Recalcule los centroides.
4. Calcule la función objetivo.

Ejercicio de centroides

Los puntos de un grupo son

$$(2, 1), (4, 3), (6, 5).$$

1. Calcule el centroide.
2. Calcule la suma de cuadrados respecto del centroide.
3. Compare con el punto $(3, 3)$ como representante.

Ejercicio de silueta

Para una observación:

$$a(i) = 2.5, \quad b(i) = 6.$$

1. Calcule $s(i)$.
2. Interprete el resultado.

Repita con:

$$a(i) = 5, \quad b(i) = 4.$$

Ejercicio del codo

Se obtiene:

K	Inercia
1	950
2	520
3	290
4	230
5	200
6	185

1. Grafique conceptualmente la curva.
2. Proponga un valor de K .
3. Justifique la elección.
4. Explique por qué el criterio no es concluyente.

Ejercicio aplicado

Se desea agrupar estaciones de calidad del aire usando:

- PM10;
- PM2.5;
- NO2;
- ozono;
- temperatura;
- humedad;
- viento.

Diseñe un análisis que incluya:

1. limpieza;
2. manejo de faltantes;
3. valores atípicos;
4. estandarización;
5. selección de K ;
6. reinicios múltiples;
7. K-means++;

8. silueta;
9. estabilidad;
10. interpretación de centroides;
11. visualización con PCA;
12. comparación con clustering jerárquico;
13. análisis temporal;
14. limitaciones ambientales.

Resumen

En este capítulo se desarrolló K-means como método de agrupamiento basado en centroides.

Se formuló la función objetivo, se derivó la media como centroide óptimo y se explicó el algoritmo de Lloyd mediante pasos alternantes de asignación y actualización.

También se analizaron convergencia local, inicialización, K-means++, selección de K , método del codo, silueta, índice Gap, estabilidad y complejidad computacional.

Finalmente, se estudiaron sensibilidad a escala, valores atípicos, grupos no esféricos, relación con mezclas gaussianas, cuantización vectorial y variantes para datos grandes o mixtos.

Referencias del capítulo

Los fundamentos se apoyan en MacQueen (1967), Lloyd (1982), Arthur y Vassilvitskii (2007), Rousseeuw (1987) y Jain (2010).

23 Agrupamiento jerárquico

Introducción

El agrupamiento jerárquico construye una sucesión de grupos anidados y representa el resultado mediante un **dendrograma**. A diferencia de K-means, no exige fijar el número de conglomerados antes de iniciar el análisis.

Existen dos estrategias:

- **aglomerativa:** comienza con una observación por grupo y realiza fusiones;
- **divisiva:** comienza con un solo grupo y realiza separaciones.

El resultado depende de dos decisiones fundamentales: la distancia entre observaciones y el criterio de enlace utilizado para medir distancia entre grupos.

! Definición esencial

El agrupamiento jerárquico construye una secuencia de particiones anidadas. El dendrograma resume las fusiones, pero su forma depende de la distancia y del criterio de enlace.

Objetivos

Al finalizar el capítulo, el lector podrá:

1. distinguir agrupamiento aglomerativo y divisivo;
2. construir e interpretar una matriz de distancias;
3. definir enlace simple, completo, promedio y Ward;
4. interpretar un dendrograma y sus alturas;
5. seleccionar el número de grupos;
6. calcular distancias cofenéticas;
7. evaluar estabilidad;
8. comparar agrupamiento jerárquico con K-means;
9. reconocer sus ventajas y limitaciones;
10. aplicarlo en R.

Formulación

Considérese una muestra no etiquetada

$$\mathcal{D}_n = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}, \quad \mathbf{x}_i \in \mathbb{R}^p.$$

Una partición de las observaciones es una colección

$$\mathcal{P} = \{C_1, \dots, C_K\}$$

tal que

$$C_k \cap C_\ell = \emptyset \quad (k \neq \ell),$$

y

$$\bigcup_{k=1}^K C_k = \{1, \dots, n\}.$$

El método jerárquico genera varias particiones relacionadas entre sí.

Matriz de distancias

La información inicial se resume en

$$\mathbf{D} = (d_{ij}),$$

donde

$$d_{ij} = d(\mathbf{x}_i, \mathbf{x}_j).$$

La matriz satisface

$$d_{ij} = d_{ji}, \quad d_{ii} = 0.$$

Distancias frecuentes

Euclidiana

$$d_2(\mathbf{x}_i, \mathbf{x}_j) = \left[\sum_{r=1}^p (x_{ir} - x_{jr})^2 \right]^{1/2}.$$

Manhattan

$$d_1(\mathbf{x}_i, \mathbf{x}_j) = \sum_{r=1}^p |x_{ir} - x_{jr}|.$$

Minkowski

$$d_q(\mathbf{x}_i, \mathbf{x}_j) = \left[\sum_{r=1}^p |x_{ir} - x_{jr}|^q \right]^{1/q}.$$

Para datos mixtos puede utilizarse la distancia de Gower.

Escalamiento

Cuando las variables tienen escalas distintas, suele emplearse

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}.$$

Sin estandarización, una variable con valores grandes puede dominar las fusiones.

Agrupamiento aglomerativo

El algoritmo inicia con

$$C_i^{(0)} = \{i\}, \quad i = 1, \dots, n.$$

En cada paso se fusionan los dos grupos más cercanos. Después de $n - 1$ fusiones queda un solo grupo.

Definición 23.1.

1. iniciar con n grupos unitarios;
2. calcular distancias entre grupos;
3. fusionar el par más cercano;
4. actualizar las distancias;
5. repetir hasta formar un único grupo.

Agrupamiento divisivo

El método divisivo inicia con

$$C^{(0)} = \{1, \dots, n\}$$

y divide sucesivamente los grupos. DIANA es un algoritmo divisivo clásico.

Criterios de enlace

Sean A y B dos grupos.

Enlace simple

$$d_{\text{simple}}(A, B) = \min_{i \in A, j \in B} d(\mathbf{x}_i, \mathbf{x}_j).$$

Detecta estructuras alargadas, pero puede sufrir **encadenamiento**, donde grupos distintos se unen por una cadena de puntos intermedios.

Enlace completo

$$d_{\text{completo}}(A, B) = \max_{i \in A, j \in B} d(\mathbf{x}_i, \mathbf{x}_j).$$

Favorece grupos compactos, aunque puede ser sensible a valores extremos.

Enlace promedio

$$d_{\text{promedio}}(A, B) = \frac{1}{|A||B|} \sum_{i \in A} \sum_{j \in B} d(\mathbf{x}_i, \mathbf{x}_j).$$

Representa un compromiso entre enlace simple y completo.

Enlace por centroides

$$d_{\text{centroide}}(A, B) = \|\mu_A - \mu_B\|_2.$$

Puede producir inversiones en el dendrograma.

Método de Ward

Ward fusiona los grupos que producen el menor aumento en la suma de cuadrados intragrupo.

Para un grupo C :

$$W(C) = \sum_{i \in C} \|\mathbf{x}_i - \mu_C\|_2^2.$$

El costo de fusionar A y B es

$$\Delta(A, B) = W(A \cup B) - W(A) - W(B).$$

También puede escribirse como

$$\Delta(A, B) = \frac{|A||B|}{|A| + |B|} \|\mu_A - \mu_B\|_2^2.$$

Se fusiona el par con menor incremento.

Relación entre Ward y K-means

Ambos métodos buscan grupos compactos mediante suma de cuadrados.

- K-means optimiza directamente una partición con K fijo.
- Ward construye una jerarquía completa y permite elegir K después.

Dendrograma

El dendrograma representa las fusiones:




Figura 23.1: El dendrograma registra las fusiones y la altura a la que ocurren.

- el eje horizontal contiene observaciones o ramas;
- el eje vertical muestra la altura de fusión;
- una fusión alta indica mayor diferencia entre grupos.

Corte del dendrograma

Al cortar a una altura h , las ramas interceptadas forman los grupos.

Otra opción es fijar directamente el número de grupos:

$$K.$$

Selección del número de grupos

Puede utilizarse:

- saltos grandes entre alturas;
- silueta;
- índice Gap;
- estabilidad por remuestreo;
- conocimiento del problema.

La inspección visual debe complementarse con criterios cuantitativos.

Distancia cofenética

La distancia cofenética entre dos observaciones es la altura a la que se fusionan por primera vez.

Se denota por

$$d_{ij}^{coph}.$$

Correlación cofenética

Compara las distancias originales con las representadas por el dendrograma:

$$r_{coph} = \text{cor} \left(d_{ij}, d_{ij}^{coph} \right).$$

Un valor alto indica que el dendrograma conserva bien la estructura de distancias.

La actualización recursiva de distancias puede expresarse mediante la familia de Lance-Williams (Lance y Williams 1967). Esta formulación permite comparar distintos enlaces dentro de una estructura algebraica común.

Fórmula de Lance-Williams

Las distancias pueden actualizarse mediante

$$d(A \cup B, C) = \alpha_A d(A, C) + \alpha_B d(B, C) + \beta d(A, B) + \gamma |d(A, C) - d(B, C)|.$$

Los coeficientes dependen del enlace.

Para enlace simple:

$$\alpha_A = \alpha_B = \frac{1}{2}, \quad \beta = 0, \quad \gamma = -\frac{1}{2}.$$

Para enlace completo:

$$\alpha_A = \alpha_B = \frac{1}{2}, \quad \beta = 0, \quad \gamma = \frac{1}{2}.$$

Inversiones

Una inversión ocurre cuando una fusión posterior aparece a menor altura que una anterior. Puede presentarse con el enlace por centroides y dificulta la interpretación.

Estabilidad

Una solución es estable si pequeñas perturbaciones producen grupos semejantes.

Puede evaluarse mediante:

- bootstrap;
- submuestreo;
- comparación de dendrogramas;
- coeficiente de Jaccard;
- índice de Rand ajustado.

Jaccard de grupos

Para un grupo original C y uno remuestreado C^* :

$$J(C, C^*) = \frac{|C \cap C^*|}{|C \cup C^*|}.$$

Valores altos indican estabilidad.

Comparación de dendrogramas

Pueden utilizarse:

- correlación cofenética;
- tanglegrams;
- entanglement;
- comparación de ramas.

Los algoritmos jerárquicos clásicos son apropiados sobre todo para muestras pequeñas o medianas. Revisiones modernas describen variantes eficientes y los compromisos entre exactitud, memoria y tiempo (Murtagh y Contreras 2012).

Complejidad computacional

La matriz de distancias requiere memoria del orden de

$$O(n^2).$$

El tiempo puede variar entre

$$O(n^2)$$

y

$$O(n^3),$$

dependiendo del algoritmo.

Esto limita el método en muestras muy grandes.

Métodos escalables

Para grandes volúmenes pueden utilizarse:

- muestreo;
- preagrupamiento;
- aproximaciones;
- BIRCH;
- clustering híbrido.

Valores atípicos

Una observación extrema puede:

- formar una rama aislada;
- aumentar las alturas;
- cambiar fusiones posteriores;
- distorsionar el número de grupos.

Debe analizarse antes de interpretar el dendrograma.

Variables categóricas y mixtas

La distancia euclidiana no es adecuada directamente para variables categóricas.

Pueden utilizarse:

- Gower;
- Jaccard;
- coincidencia simple;
- transformaciones apropiadas.

Distancia de Jaccard

Para presencia o ausencia:

$$d_J(A, B) = 1 - \frac{|A \cap B|}{|A \cup B|}.$$

Es útil cuando la presencia es más informativa que la ausencia.

Visualización

Además del dendrograma:

- heatmap con dendrogramas;
- proyección PCA;
- gráficos de silueta;
- perfiles de grupos;
- tanglegrams.

Relación con grafos

El enlace simple está relacionado con el árbol de expansión mínima. Cortar sus aristas más largas puede producir la misma partición que un corte del dendrograma de enlace simple.

Comparación con K-means

Aspecto	Jerárquico	K-means
Resultado	Jerarquía	Una partición
Número de grupos	Puede elegirse después	Se fija antes
Distancias	Variadas	Euclidiana cuadrática
Escalabilidad	Menor	Mayor
Forma de grupos	Depende del enlace	Compactos y esféricos
Reversibilidad	Fusiones irreversibles	Reasignaciones iterativas

Comparación con DBSCAN

DBSCAN detecta grupos por densidad y puede identificar ruido. El agrupamiento jerárquico produce una jerarquía completa, pero no identifica ruido de manera natural.

Conexión con R

```

1  datos <- data.frame(
2    pm10 = c(45, 52, 60, 38, 70, 65, 30, 28),
3    no2 = c(30, 35, 42, 28, 50, 47, 20, 18),
4    temperatura = c(22, 24, 26, 20, 28, 27, 18, 17),
5    humedad = c(60, 55, 50, 70, 45, 48, 75, 78)
6  )
7
8  datos_esc <- scale(datos)
9
10 distancias <- dist(
11   datos_esc,
12   method = "euclidean"
13 )
14
15 modelo_completo <- hclust(
16   distancias,
17   method = "complete"
18 )
19
20 plot(
21   modelo_completo,
22   main = "Agrupamiento jerárquico",
23   xlab = "",
24   sub = ""
25 )
26
27 grupos <- cutree(
28   modelo_completo,
29   k = 3
30 )
31
32 grupos
33

```

```

34 modelo_ward <- hclust(
35     distancias,
36     method = "ward.D2"
37 )
38
39 plot(modelo_ward)
40
41 dist_coph <- cophenetic(modelo_ward)
42
43 cor(
44     as.vector(distancias),
45     as.vector(dist_coph)
46 )

```

Ejemplo numérico

Considérese:

$$1, 2, 5, 9.$$

La primera fusión ocurre entre 1 y 2 porque

$$d(1, 2) = 1.$$

Con enlace simple, la distancia entre $\{1, 2\}$ y $\{5\}$ es

$$\min\{4, 3\} = 3.$$

Ejemplo de enlaces

Sean

$$A = \{1, 2\}, \quad B = \{5, 9\}.$$

Las distancias cruzadas son

$$4, 8, 3, 7.$$

Por tanto:

$$d_{\text{simple}}(A, B) = 3,$$

$$d_{\text{completo}}(A, B) = 8,$$

$$d_{\text{promedio}}(A, B) = \frac{4 + 8 + 3 + 7}{4} = 5.5.$$

Ejemplo de Ward

Sean

$$|A| = 3, \quad |B| = 2,$$

y

$$\|\mu_A - \mu_B\|_2 = 4.$$

Entonces

$$\Delta(A, B) = \frac{3(2)}{3+2}(4^2) = 19.2.$$

Ventajas

1. produce una jerarquía completa;
2. no exige fijar K inicialmente;
3. admite distintas métricas;
4. proporciona una visualización interpretativa;
5. detecta estructuras anidadas;
6. puede trabajar con datos mixtos usando distancias adecuadas.

Limitaciones

1. costo elevado;
2. sensibilidad a escala;
3. sensibilidad a valores atípicos;
4. dependencia del enlace;
5. fusiones irreversibles;
6. selección del corte potencialmente subjetiva;
7. dificultad con muestras grandes.

Errores frecuentes

1. no estandarizar;
2. elegir el enlace sin justificarlo;
3. interpretar el dendrograma como una verdad única;
4. ignorar valores extremos;
5. usar Euclidiana con variables mixtas;
6. seleccionar grupos solo visualmente;
7. no evaluar estabilidad;
8. confundir altura de fusión con tamaño;
9. interpretar etiquetas como ordenadas;
10. inferir causalidad a partir de los grupos.

Ejercicios conceptuales

1. Compare métodos aglomerativos y divisivos.
2. ¿Qué representa el dendrograma?
3. Explique enlace simple, completo y promedio.
4. ¿Qué es el encadenamiento?
5. ¿Por qué Ward se relaciona con K-means?
6. ¿Qué representa la altura de fusión?
7. ¿Qué es la distancia cofenética?
8. ¿Cómo se selecciona el número de grupos?
9. ¿Por qué afectan los valores atípicos?
10. Compare agrupamiento jerárquico y K-means.

Ejercicio de distancias

Considere

$$(1, 1), (2, 1), (5, 4), (6, 5).$$

1. Calcule la matriz euclidiana.
2. Identifique la primera fusión.
3. Continúe con enlace simple.
4. Repita con enlace completo.
5. Compare los resultados.

Ejercicio de Ward

Considere

$$|A| = 4, \quad |B| = 6,$$

y

$$\|\mu_A - \mu_B\|_2^2 = 9.$$

Calcule el incremento de Ward.

Ejercicio aplicado

Agrupe estaciones de calidad del aire utilizando:

- PM10;
- PM2.5;
- NO2;
- ozono;
- temperatura;
- humedad;

- viento.

Incluya:

1. limpieza;
2. faltantes;
3. valores atípicos;
4. estandarización;
5. elección de distancia;
6. comparación de enlaces;
7. dendrogramas;
8. correlación cofenética;
9. selección de grupos;
10. silueta;
11. estabilidad por bootstrap;
12. perfiles;
13. comparación con K-means;
14. limitaciones ambientales.

Resumen

En este capítulo se desarrolló el agrupamiento jerárquico como método para construir grupos anidados.

Se estudiaron los enfoques aglomerativo y divisivo, las matrices de distancia, los enlaces simple, completo, promedio, por centroides y Ward.

También se analizaron dendrogramas, alturas, cortes, distancias cofenéticas, fórmula de Lance-Williams, estabilidad, valores atípicos, complejidad y comparación con K-means.

Referencias del capítulo

Los fundamentos se apoyan en Ward (1963), Lance y Williams (1967), Murtagh y Contreras (2012) y Mardia et al. (1979).

24 Reglas de asociación

Introducción

Las reglas de asociación permiten descubrir relaciones de coocurrencia en bases de datos transaccionales. Su formulación clásica surgió en el análisis de compras, pero se aplica también a diagnósticos, navegación web, incidentes, síntomas, fallas y patrones ambientales.

Una regla tiene la forma

$$X \Rightarrow Y,$$

donde X y Y son conjuntos de elementos disjuntos. La regla no expresa causalidad; indica que las transacciones que contienen X tienden a contener también Y .

El algoritmo Apriori explota una propiedad de antimonotonidad para evitar evaluar todos los subconjuntos posibles (Agrawal y Srikant 1994). Otros métodos, como FP-growth, eliminan la generación explícita de candidatos mediante una estructura comprimida (Han et al. 2000).

! Definición esencial

Una regla $X \Rightarrow Y$ resume una coocurrencia entre conjuntos de elementos. Soporte, confianza y lift describen frecuencia, probabilidad condicional y desviación respecto de la independencia.

Objetivos

Al finalizar el capítulo, el lector podrá:

1. representar una base transaccional;
2. definir itemsets y reglas;
3. calcular soporte, confianza y lift;
4. interpretar leverage y conviction;
5. comprender la propiedad Apriori;
6. generar conjuntos frecuentes;
7. producir reglas a partir de itemsets;
8. distinguir reglas redundantes;
9. aplicar restricciones;
10. comprender Apriori, Eclat y FP-growth;
11. evaluar significancia y utilidad;
12. aplicar reglas de asociación en R.

Base transaccional

Sea

$$\mathcal{I} = \{i_1, \dots, i_m\}$$

el universo de elementos.

Una transacción es un subconjunto

$$T_r \subseteq \mathcal{I}.$$

La base de datos es

$$\mathcal{D} = \{T_1, \dots, T_n\}.$$

Itemset

Un itemset es cualquier subconjunto

$$X \subseteq \mathcal{I}.$$

Su tamaño es

$$|X|.$$

Si $|X| = k$, se denomina k -itemset.

Regla de asociación

Una regla es una implicación

$$X \Rightarrow Y,$$

con

$$X \cap Y = \emptyset.$$

X es el antecedente y Y el consecuente.

Soporte de un itemset

El soporte absoluto es

$$\sigma(X) = |\{T_r : X \subseteq T_r\}|.$$

El soporte relativo es

$$supp(X) = \frac{\sigma(X)}{n}.$$

Puede interpretarse como una probabilidad empírica:

$$supp(X) = \widehat{P}(X).$$

Elementos y medidas de una regla de asociación




Figura 24.1: Una regla relaciona antecedente y consecuente y se evalúa mediante soporte, confianza y lift.

Soporte de una regla

El soporte de

$$X \Rightarrow Y$$

es

$$supp(X \Rightarrow Y) = supp(X \cup Y).$$

Mide la frecuencia conjunta del antecedente y el consecuente.

Confianza

La confianza es

$$conf(X \Rightarrow Y) = \frac{supp(X \cup Y)}{supp(X)}.$$

Equivale a la probabilidad condicional empírica:

$$conf(X \Rightarrow Y) = \widehat{P}(Y | X).$$

Limitación de la confianza

Una confianza alta puede deberse simplemente a que Y es muy frecuente.

Por ello, debe compararse con el soporte marginal del consecuente.

Lift

El lift es

$$lift(X \Rightarrow Y) = \frac{conf(X \Rightarrow Y)}{supp(Y)}.$$

Equivalentemente,

$$lift(X \Rightarrow Y) = \frac{supp(X \cup Y)}{supp(X)supp(Y)}.$$

Interpretación:

- $lift > 1$: asociación positiva;
- $lift = 1$: independencia empírica;
- $lift < 1$: asociación negativa.

Leverage

El leverage es

$$lev(X \Rightarrow Y) = supp(X \cup Y) - supp(X)supp(Y).$$

Mide la diferencia absoluta respecto de la independencia.

Conviction

La conviction se define como

$$conv(X \Rightarrow Y) = \frac{1 - supp(Y)}{1 - conf(X \Rightarrow Y)}.$$

Valores grandes indican que la regla comete menos errores de los esperados bajo independencia.

Cobertura

La cobertura de la regla es

$$coverage(X \Rightarrow Y) = supp(X).$$

Mide qué proporción de transacciones satisface el antecedente.

Ejemplo básico

Considérese:

Transacción	Elementos
1	pan, leche
2	pan, pañales, cerveza
3	leche, pañales, cerveza
4	pan, leche, pañales, cerveza
5	pan, leche, pañales

Para la regla

$$\{\text{pañales}\} \Rightarrow \{\text{cerveza}\},$$

el antecedente aparece en 4 transacciones y la unión en 3.

Entonces

$$supp = \frac{3}{5} = 0.6,$$

$$conf = \frac{3}{4} = 0.75.$$

Como la cerveza aparece en 3 de 5 transacciones,

$$lift = \frac{0.75}{0.6} = 1.25.$$

Conjuntos frecuentes

Dado un umbral mínimo

$$s_{min},$$

un itemset es frecuente si

$$supp(X) \geq s_{min}.$$

El problema central consiste en encontrar todos los itemsets frecuentes.

Explosión combinatoria

Con m elementos existen

$$2^m - 1$$

itemsets no vacíos.

Una búsqueda exhaustiva se vuelve inviable cuando m es grande.

Propiedad Apriori

Teorema 24.1. *Si un itemset es frecuente, todos sus subconjuntos también son frecuentes.*

Equivalentemente, si un itemset no es frecuente, ninguno de sus superconjuntos puede ser frecuente.

Demostración

Si

$$A \subseteq B,$$

toda transacción que contiene B contiene también A . Por tanto,

$$\sigma(B) \leq \sigma(A),$$

y

$$\text{supp}(B) \leq \text{supp}(A).$$

Si A no alcanza el soporte mínimo, ningún superconjunto B puede alcanzarlo.

El problema de minería de reglas fue formalizado por Agrawal et al. (1993). Apriori aprovecha la antimonotonía del soporte para podar candidatos, mientras FP-growth evita su generación explícita (Agrawal y Srikant 1994; Han et al. 2000).

Algoritmo Apriori

Apriori procede por niveles:

1. encontrar itemsets frecuentes de tamaño 1;
2. generar candidatos de tamaño 2;
3. podar candidatos con subconjuntos infrecuentes;
4. contar soportes;
5. repetir para tamaños sucesivos.

Generación de candidatos

A partir de

$$L_{k-1},$$

el conjunto de itemsets frecuentes de tamaño $k - 1$, se construye

$$C_k.$$

Después se eliminan candidatos que contienen algún subconjunto no frecuente.

Pseudocódigo de Apriori

1. calcular L_1 ;
2. para $k = 2, 3, \dots$:
 - generar C_k mediante unión de elementos de L_{k-1} ;
 - podar candidatos;
 - recorrer las transacciones y contar soportes;
 - conservar itemsets con soporte mínimo;
3. detener cuando L_k sea vacío.

Generación de reglas

Para cada itemset frecuente Z y cada subconjunto no vacío

$$X \subset Z,$$

se forma

$$X \Rightarrow Z \setminus X.$$

La regla se conserva si alcanza la confianza mínima.

Monotonidad de la confianza

La confianza no es antimonótona en general. Sin embargo, durante la generación de reglas puede aprovecharse que, para un itemset fijo, ampliar el consecuente no aumenta la confianza.

Eclat

Eclat utiliza una representación vertical.

Para cada elemento se almacena el conjunto de identificadores de transacción:

$$TID(X).$$

El soporte de una unión se obtiene mediante intersección:

$$TID(X \cup Y) = TID(X) \cap TID(Y).$$

FP-growth

FP-growth comprime la base en un árbol de patrones frecuentes y extrae itemsets sin generar candidatos explícitos (Han et al. 2000).

Sus pasos generales son:

1. contar frecuencias;
2. eliminar elementos infrecuentes;
3. ordenar elementos;
4. construir el FP-tree;
5. extraer bases condicionales;
6. generar patrones frecuentes.

Reglas redundantes

Una regla puede ser redundante si otra regla más general tiene igual o mejor desempeño.

Por ejemplo, si

$$A \Rightarrow C$$

y

$$A, B \Rightarrow C$$

tienen la misma confianza, añadir B no aporta información predictiva.

Itemsets cerrados

Un itemset frecuente X es cerrado si no existe un superconjunto con el mismo soporte.

Los itemsets cerrados proporcionan una representación más compacta.

Itemsets maximales

Un itemset frecuente es maximal si ningún superconjunto suyo es frecuente.

Los maximales son aún más compactos, pero pierden información exacta de soportes de subconjuntos.

Restricciones

El espacio de búsqueda puede reducirse imponiendo:

- elementos obligatorios;
- elementos excluidos;
- longitud mínima o máxima;

- consecuente fijo;
- soporte o confianza mínimos;
- restricciones de categorías.

Discretización

Variables numéricas deben convertirse normalmente en intervalos:

$$X_j \in [a, b).$$

La discretización puede ser:

- por amplitud;
- por frecuencia;
- basada en conocimiento;
- supervisada.

Los resultados dependen fuertemente de los cortes.

Interés estadístico y utilidad práctica

Un lift elevado con soporte mínimo puede corresponder a muy pocas transacciones. Las reglas deben evaluarse por frecuencia, estabilidad, significancia, novedad y posibilidad de acción; ninguna medida aislada es suficiente.

Significancia estadística

Lift alto no garantiza significancia, especialmente con soporte bajo.

Puede utilizarse una tabla 2×2 y aplicar:

- prueba chi-cuadrada;
- prueba exacta de Fisher;
- intervalos;
- corrección por comparaciones múltiples.

Tabla de contingencia

Para dos eventos X y Y :

	Y	no Y
X	n_{11}	n_{10}
no X	n_{01}	n_{00}

Las medidas de asociación se derivan de estas frecuencias.

Múltiples comparaciones

La minería puede producir miles de reglas. Evaluar cada una al nivel usual genera falsos positivos.

Deben considerarse:

- Bonferroni;
- Holm;
- control de FDR;
- validación en una muestra independiente.

Asociación no es causalidad

La regla

$$X \Rightarrow Y$$

no implica que X cause Y .

La coocurrencia puede deberse a:

- variables confusoras;
- selección;
- temporalidad;
- patrones de consumo;
- artefactos de discretización.

Reglas negativas

También pueden estudiarse reglas como

$$X \Rightarrow \neg Y.$$

Su análisis requiere considerar cuidadosamente soportes y universo de elementos.

Reglas secuenciales

Las reglas de asociación tradicionales ignoran el orden temporal.

Cuando interesa la secuencia se utilizan patrones secuenciales, por ejemplo:

$$A \rightarrow B \rightarrow C.$$

Reglas ponderadas

En algunos problemas los elementos tienen importancia, utilidad o costo diferentes.

Las reglas ponderadas incorporan:

- cantidad;
- precio;
- riesgo;
- utilidad;
- severidad.

Evaluación práctica

Una buena regla debe equilibrar:

- frecuencia;
- precisión;
- novedad;
- utilidad;
- simplicidad;
- estabilidad;
- posibilidad de acción.

Reglas y predicción

Las reglas pueden utilizarse como características o como clasificadores.

En clasificación asociativa, el consecuente es una clase:

$$X \Rightarrow Y = c.$$

Complejidad

El costo depende de:

- número de elementos;
- longitud de transacciones;
- soporte mínimo;
- densidad;
- número de patrones frecuentes.

Un soporte demasiado bajo puede generar una explosión de resultados.

Conexión con R

El paquete `arules` proporciona infraestructura para transacciones, itemsets y reglas (Hahsler et al. 2005).

```
1 library(arules)
2
3 transacciones <- list(
4   c("pan", "leche"),
5   c("pan", "pañales", "cerveza"),
6   c("leche", "pañales", "cerveza"),
7   c("pan", "leche", "pañales", "cerveza"),
8   c("pan", "leche", "pañales")
9 )
10
11 tr <- as(transacciones, "transactions")
12
13 reglas <- apriori(
```

```

14   tr,
15   parameter = list(
16     supp = 0.40,
17     conf = 0.60,
18     minlen = 2
19   )
20 )
21
22 inspect(
23   sort(
24     reglas,
25     by = "lift",
26     decreasing = TRUE
27   )
28 )
29
30 reglas_filtradas <- subset(
31   reglas,
32   lift > 1.1
33 )

```

Aplicación ambiental

Una transacción puede representar un día o una estación. Los elementos podrían ser:

- PM10_alto;
- temperatura_alta;
- humedad_baja;
- viento_bajo;
- ozono_alto.

Una regla posible sería

$$\{\text{temperatura alta, viento bajo}\} \Rightarrow \{\text{ozono alto}\}.$$

Debe interpretarse como asociación empírica, no como mecanismo causal probado.

Ventajas

1. produce patrones fáciles de comunicar;
2. no requiere variable objetivo;
3. permite explorar interacciones;
4. funciona con datos transaccionales;
5. ofrece medidas intuitivas;
6. admite restricciones de dominio.

Limitaciones

1. explosión combinatoria;

2. muchas reglas triviales;
3. sensibilidad a umbrales;
4. discretización subjetiva;
5. soporte bajo produce inestabilidad;
6. asociación no implica causalidad;
7. múltiples comparaciones;
8. dificultad para evaluar utilidad real.

Errores frecuentes

1. interpretar confianza sin considerar soporte;
2. ignorar el soporte del consecuente;
3. usar lift como prueba causal;
4. fijar soporte demasiado bajo;
5. no eliminar reglas redundantes;
6. discretizar arbitrariamente;
7. reportar miles de reglas sin síntesis;
8. no validar estabilidad;
9. ignorar múltiples comparaciones;
10. confundir coocurrencia con secuencia temporal.

Ejercicios conceptuales

1. Defina transacción, itemset y regla.
2. Compare soporte y confianza.
3. ¿Por qué se utiliza lift?
4. Demuestre la propiedad Apriori.
5. Compare Apriori, Eclat y FP-growth.
6. Distinga itemset cerrado y maximal.
7. ¿Por qué una regla frecuente puede ser trivial?
8. ¿Cómo afecta la discretización?
9. ¿Por qué deben corregirse múltiples comparaciones?
10. Explique por qué asociación no es causalidad.

Ejercicio de medidas

En 1,000 transacciones:

- X aparece en 300;
- Y aparece en 400;
- $X \cup Y$ aparece en 180.

Calcule:

1. soporte de X ;
2. soporte de Y ;
3. soporte de la regla;
4. confianza;

5. lift;
6. leverage.

Ejercicio Apriori

Considere:

$$T_1 = \{A, B, C\},$$

$$T_2 = \{A, B\},$$

$$T_3 = \{A, C\},$$

$$T_4 = \{B, C\},$$

$$T_5 = \{A, B, C\}.$$

Con soporte mínimo 0.4:

1. determine L_1 ;
2. genere C_2 ;
3. determine L_2 ;
4. genere C_3 ;
5. obtenga las reglas con confianza mínima 0.7.

Ejercicio aplicado

Diseñe un análisis de reglas para accidentes de tránsito donde cada accidente se represente por elementos como:

- nocturno;
- lluvia;
- velocidad_alta;
- motocicleta;
- peatón;
- accidente_severo.

Incluya:

1. transformación transaccional;
2. discretización;
3. soporte mínimo;
4. confianza;
5. lift;
6. consecuente severidad;

7. poda de redundancia;
8. significancia;
9. validación;
10. limitaciones causales.

Resumen

En este capítulo se desarrollaron los fundamentos matemáticos de las reglas de asociación.

Se definieron transacciones, itemsets, soporte, confianza, lift, leverage y conviction. Se demostró la propiedad Apriori y se explicó la generación de conjuntos frecuentes y reglas.

También se estudiaron Eclat, FP-growth, itemsets cerrados y maximales, restricciones, discretización, significancia, múltiples comparaciones y aplicaciones predictivas.

Referencias del capítulo

Los fundamentos se apoyan en Agrawal et al. (1993), Agrawal y Srikant (1994), Han et al. (2000) y Hahsler et al. (2005).

Parte VI

VI. Temas avanzados

25 Teoría de generalización

Introducción

La finalidad del aprendizaje automático es construir modelos que funcionen con observaciones nuevas. La teoría de generalización estudia cuándo el desempeño observado en la muestra representa adecuadamente el riesgo sobre la población y cómo influyen el tamaño muestral, la complejidad del modelo y la regularización (Vapnik y Chervonenkis 1971; Valiant 1984; Shalev-Shwartz y Ben-David 2014).

Riesgo esperado y riesgo empírico

Para una función f y una pérdida L , el riesgo esperado es

$$R(f) = \mathbb{E}[L(Y, f(\mathbf{X}))].$$

Dada una muestra de tamaño n , el riesgo empírico es

$$\widehat{R}_n(f) = \frac{1}{n} \sum_{i=1}^n L(y_i, f(\mathbf{x}_i)).$$

La diferencia

$$R(f) - \widehat{R}_n(f)$$

se denomina brecha de generalización.

Minimización del riesgo empírico

El estimador ERM es

$$\widehat{f}_{ERM} = \arg \min_{f \in \mathcal{F}} \widehat{R}_n(f).$$

Si el riesgo empírico aproxima uniformemente al riesgo esperado, entonces ERM generaliza.

Exceso de riesgo

Sea f^* el predictor óptimo y $f_{\mathcal{F}}^*$ el mejor predictor dentro de $\mathcal{F}$. Entonces

$$R(\widehat{f}) - R(f^*) = [R(\widehat{f}) - R(f_{\mathcal{F}}^*)] + [R(f_{\mathcal{F}}^*) - R(f^*)].$$

El primer término es error de estimación y el segundo error de aproximación.

Convergencia uniforme

Se busca controlar

$$\sup_{f \in \mathcal{F}} |R(f) - \widehat{R}_n(f)|.$$

Si esta cantidad es menor que ε , entonces

$$R(\widehat{f}_{ERM}) \leq R(f_{\mathcal{F}}^*) + 2\varepsilon.$$

Desigualdad de Hoeffding

Si $0 \leq L \leq 1$, para un predictor fijo,

$$P(|R(f) - \widehat{R}_n(f)| \geq \varepsilon) \leq 2e^{-2n\varepsilon^2}.$$

Con probabilidad al menos $1 - \delta$,

$$R(f) \leq \widehat{R}_n(f) + \sqrt{\frac{\log(2/\delta)}{2n}}.$$

Clases finitas

Si $|\mathcal{F}| = M$, una unión de eventos produce

$$R(f) \leq \widehat{R}_n(f) + \sqrt{\frac{\log(2M/\delta)}{2n}}$$

simultáneamente para todos los modelos. La penalización aumenta con $\log M$ y disminuye con n .

Aprendizaje PAC

PAC significa *Probably Approximately Correct*. Un algoritmo aprende una clase si para todo $\varepsilon > 0$ y $\delta > 0$ devuelve, con probabilidad al menos $1 - \delta$, un predictor cuyo error está a lo sumo ε del objetivo.

En el caso realizable, la complejidad muestral para una clase finita es del orden de

$$\frac{\log M + \log(1/\delta)}{\varepsilon}.$$

En el caso agnóstico es del orden de

$$\frac{\log M + \log(1/\delta)}{\varepsilon^2}.$$

Dimensión VC

La dimensión VC es el mayor número de puntos que una clase puede fragmentar, es decir, etiquetar de todas las formas binarias posibles.

- umbrales en la recta: VC igual a 1;
- intervalos: VC igual a 2;
- hiperplanos en $\mathbb{R}^p$: VC igual a $p + 1$.

Función de crecimiento y lema de Sauer

La función de crecimiento $\Pi_{\mathcal{F}}(n)$ cuenta el máximo número de etiquetaciones inducidas por la clase. Si la dimensión VC es d ,

$$\Pi_{\mathcal{F}}(n) \leq \sum_{j=0}^d \binom{n}{j} \leq \left(\frac{en}{d}\right)^d.$$

Una cota típica es

$$R(f) \leq \widehat{R}_n(f) + C \sqrt{\frac{d \log(n/d) + \log(1/\delta)}{n}}.$$

Complejidad de Rademacher

La complejidad empírica es

$$\widehat{\mathfrak{R}}_n(\mathcal{F}) = \mathbb{E}_{\sigma} \left[\sup_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^n \sigma_i f(\mathbf{x}_i) \right],$$

donde $\sigma_i \in \{-1, +1\}$. Mide la capacidad de la clase para ajustarse a ruido aleatorio (Bartlett y Mendelson 2002).

Una cota típica es

$$R(f) \leq \widehat{R}_n(f) + 2\mathfrak{R}_n(\mathcal{F}) + \sqrt{\frac{\log(1/\delta)}{2n}}.$$

Regularización, norma y margen

La regularización restringe la clase efectiva. En modelos lineales, limitar $\|\mathbf{w}\|_2$ reduce capacidad. En SVM, un margen grande puede producir cotas que dependen aproximadamente de

$$\frac{R^2}{\gamma^2},$$

donde R acota la norma de las entradas y γ es el margen.

Estabilidad algorítmica

Un algoritmo es estable si reemplazar una observación cambia poco la pérdida. Si

$$|L(z, A(\mathcal{D}_n)) - L(z, A(\mathcal{D}_n^{(i)}))| \leq \beta_n,$$

y $\beta_n \rightarrow 0$, la influencia de una observación disminuye con n . Los algoritmos regularizados suelen ser más estables.

PAC-Bayes

Las cotas PAC-Bayes consideran una distribución previa P y una posterior Q sobre modelos. La penalización depende de

$$\sqrt{\frac{KL(Q\|P) + \log(1/\delta)}{n}}.$$

Un posterior cercano a una prior simple puede obtener una mejor garantía (McAllester 1999).

Selección de modelos

Comparar muchos modelos usando la misma validación puede sobreajustar el conjunto de validación. La validación cruzada anidada separa selección de hiperparámetros y estimación final del desempeño.

Cambio de distribución

Las garantías clásicas suelen suponer

$$P_{train} = P_{test}.$$

Cuando esta igualdad falla pueden aparecer *covariate shift*, *concept drift* o cambios estructurales. En esos casos se requieren validación temporal, reponderación, monitoreo y actualización.

Modelos sobreparametrizados

Las redes modernas pueden tener más parámetros que observaciones y aun así generalizar. La complejidad efectiva depende también de normas, margen, optimización implícita, estructura de los datos y arquitectura.

Doble descenso

El error de prueba puede disminuir, aumentar cerca del umbral de interpolación y volver a disminuir en el régimen sobreparametrizado. Este comportamiento se denomina doble descenso.

Cotas vacías

Una cota puede ser matemáticamente válida pero numéricamente inútil si supera el máximo posible del riesgo. Deben distinguirse validez formal y utilidad práctica.

Conexión con los algoritmos

- K-NN controla complejidad mediante k .
- Árboles mediante profundidad y poda.
- Random Forest reduce varianza por promediación.
- SVM utiliza margen y norma.
- Redes neuronales emplean arquitectura, regularización, dropout y parada temprana.

Ejemplo en R

```
1 set.seed(123)
2 simular <- function(n, B=1000) {
3   mean(replicate(B, abs(mean(rbinom(n,1,0.3))-0.3)))
4 }
5 sapply(c(50,100,500,1000), simular)
```

Ejercicios

1. Distinga riesgo esperado y empírico.
2. Calcule la cota de Hoeffding para $n = 500$ y $\delta = 0.05$.
3. Explique la diferencia entre caso realizable y agnóstico.
4. Determine la dimensión VC de umbrales, intervalos e hiperplanos.
5. Explique qué mide la complejidad de Rademacher.
6. Analice cómo la regularización mejora estabilidad.
7. Diseñe una validación anidada para comparar regresión logística, SVM, Random Forest y una red neuronal.
8. Explique por qué una cota puede ser vacía.

Resumen

Se estudiaron riesgo esperado, riesgo empírico, convergencia uniforme, Hoeffding, aprendizaje PAC, dimensión VC, complejidad de Rademacher, estabilidad y PAC-Bayes. También se analizaron regularización, selección de modelos, cambio de distribución y sobreparametrización.

Referencias del capítulo

Los fundamentos se apoyan en Vapnik y Chervonenkis (1971), Valiant (1984), Vapnik (1998), Shalev-Shwartz y Ben-David (2014), Mohri et al. (2018), Bartlett y Mendelson (2002) y McAllester (1999).

26 Series de tiempo y aprendizaje automático

Introducción

Una serie de tiempo es una secuencia de observaciones ordenadas cronológicamente. A diferencia de una muestra transversal, el orden contiene información y las observaciones pueden presentar dependencia temporal.

El análisis de series de tiempo busca describir, modelar y pronosticar esta dependencia. Los enfoques clásicos utilizan estructuras como tendencia, estacionalidad, autocorrelación y modelos ARIMA. Los métodos de aprendizaje automático transforman la historia temporal en variables predictoras y utilizan árboles, ensambles, redes neuronales u otros algoritmos.

La evaluación correcta exige respetar el orden cronológico. Una partición aleatoria puede mezclar pasado y futuro, producir fuga de información y generar estimaciones excesivamente optimistas.

Objetivos

Al finalizar el capítulo, el lector podrá:

1. representar una serie temporal;
2. identificar tendencia y estacionalidad;
3. definir estacionariedad;
4. interpretar autocovarianza y autocorrelación;
5. comprender procesos AR, MA y ARMA;
6. formular modelos ARIMA;
7. interpretar diferenciación;
8. construir variables rezagadas;
9. evitar fuga temporal;
10. diseñar validación temporal;
11. evaluar pronósticos;
12. comprender pronósticos probabilísticos;
13. aplicar árboles, Random Forest y redes neuronales;
14. comparar enfoques estadísticos y de aprendizaje automático.

Definición

Una serie de tiempo es una colección

$$\{Y_t : t \in \mathcal{T}\},$$

donde t representa tiempo.

En tiempo discreto:

$$t = 1, 2, \dots, T.$$

Una realización observada es

$$y_1, y_2, \dots, y_T.$$

Componentes

Una descomposición aditiva es

$$Y_t = T_t + S_t + C_t + \varepsilon_t,$$

donde:

- T_t : tendencia;
- S_t : estacionalidad;
- C_t : ciclo;
- ε_t : componente irregular.

Modelo multiplicativo

Cuando la amplitud estacional aumenta con el nivel:

$$Y_t = T_t S_t C_t \varepsilon_t.$$

Aplicando logaritmos se obtiene una forma aditiva.

Tendencia

La tendencia describe el comportamiento de largo plazo.

Puede ser:

- creciente;
- decreciente;
- lineal;
- no lineal;
- localmente cambiante.

Estacionalidad

La estacionalidad es un patrón que se repite con periodo conocido:

$$S_{t+m} = S_t.$$

Ejemplos:

- 12 meses;

- 7 días;
- 24 horas;
- 4 trimestres.

Estacionariedad débil

Un proceso es débilmente estacionario si:

$$\mathbb{E}(Y_t) = \mu$$

es constante y

$$\text{Cov}(Y_t, Y_{t+h}) = \gamma(h)$$

depende solo del rezago h .

Autocovarianza

$$\gamma(h) = \text{Cov}(Y_t, Y_{t-h}).$$

Para $h = 0$:

$$\gamma(0) = \text{Var}(Y_t).$$

Autocorrelación

$$\rho(h) = \frac{\gamma(h)}{\gamma(0)}.$$

Se cumple

$$-1 \leq \rho(h) \leq 1.$$

ACF muestral

$$\hat{\rho}(h) = \frac{\sum_{t=h+1}^T (y_t - \bar{y})(y_{t-h} - \bar{y})}{\sum_{t=1}^T (y_t - \bar{y})^2}.$$

La ACF ayuda a detectar dependencia y estacionalidad.

Ruido blanco

Un proceso de ruido blanco satisface:

$$\mathbb{E}(\varepsilon_t) = 0,$$

$$\text{Var}(\varepsilon_t) = \sigma^2,$$

$$\text{Cov}(\varepsilon_t, \varepsilon_s) = 0 \quad (t \neq s).$$

Caminata aleatoria

$$Y_t = Y_{t-1} + \varepsilon_t.$$

No es estacionaria porque su varianza crece con el tiempo.

Diferenciación

La primera diferencia es

$$\nabla Y_t = Y_t - Y_{t-1}.$$

La diferencia estacional es

$$\nabla_m Y_t = Y_t - Y_{t-m}.$$

Se utilizan para eliminar tendencia o estacionalidad.

Operador rezago

Defínase

$$BY_t = Y_{t-1}.$$

Entonces

$$\nabla Y_t = (1 - B)Y_t.$$

La diferencia de orden d es

$$\nabla^d Y_t = (1 - B)^d Y_t.$$

Modelo autorregresivo AR(p)

$$Y_t = c + \phi_1 Y_{t-1} + \cdots + \phi_p Y_{t-p} + \varepsilon_t.$$

El valor presente depende de sus propios rezagos.

AR(1)

$$Y_t = c + \phi Y_{t-1} + \varepsilon_t.$$

Para estacionariedad se requiere

$$|\phi| < 1.$$

Su media es

$$\mu = \frac{c}{1 - \phi}.$$

Modelo MA(q)

$$Y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}.$$

El valor depende de perturbaciones actuales y pasadas.

Modelo ARMA(p,q)

$$Y_t = c + \sum_{i=1}^p \phi_i Y_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}.$$

Se utiliza para series estacionarias.

Modelo ARIMA(p,d,q)

Una serie se diferencia d veces y se ajusta un ARMA:

$$\phi(B)(1 - B)^d Y_t = c + \theta(B)\varepsilon_t.$$

Los parámetros son:

- p : orden autorregresivo;
- d : diferenciación;
- q : media móvil.

ARIMA estacional

$$ARIMA(p, d, q)(P, D, Q)_m.$$

Incluye componentes estacionales con periodo m .

Identificación

Se utilizan:

- gráfica temporal;
- ACF;
- PACF;
- pruebas de raíz unitaria;
- criterios AIC y BIC;
- diagnóstico de residuos.

PACF

La autocorrelación parcial en rezago h mide la relación entre Y_t y Y_{t-h} controlando rezagos intermedios.

Es útil para identificar órdenes autorregresivos.

Prueba de raíz unitaria

La prueba Dickey-Fuller aumentada contrasta una raíz unitaria.

No rechazar no demuestra estacionariedad; indica evidencia insuficiente contra la raíz unitaria.

Suavizamiento exponencial

El nivel simple se actualiza mediante

$$\ell_t = \alpha y_t + (1 - \alpha)\ell_{t-1},$$

con

$$0 < \alpha < 1.$$

El pronóstico es

$$\hat{y}_{t+h|t} = \ell_t.$$

Método de Holt

Incluye nivel y tendencia:

$$\ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1}),$$

$$b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1}.$$

Holt-Winters

Añade una componente estacional y puede formularse en versión aditiva o multiplicativa.

Pronóstico h pasos adelante

Se denota por

$$\widehat{Y}_{t+h|t},$$

la predicción de Y_{t+h} usando información disponible hasta t .

Error de pronóstico

$$e_{t+h|t} = Y_{t+h} - \widehat{Y}_{t+h|t}.$$

MAE

$$MAE = \frac{1}{n} \sum_{i=1}^n |e_i|.$$

RMSE

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n e_i^2}.$$

MAPE

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{e_i}{y_i} \right|.$$

Es problemático si y_i es cero o cercano a cero.

MASE

$$MASE = \frac{\frac{1}{n} \sum |e_i|}{\frac{1}{T-m} \sum_{t=m+1}^T |y_t - y_{t-m}|}.$$

Permite comparación entre series.

Pronósticos probabilísticos

Un pronóstico completo puede ser una distribución:

$$P(Y_{t+h} \mid \mathcal{F}_t).$$

Puede resumirse mediante:

- intervalos;
- cuantiles;
- densidades;
- simulaciones.

Cobertura de intervalos

Un intervalo nominal del 95 por ciento debe contener aproximadamente el 95 por ciento de observaciones futuras bajo calibración correcta.

Variables rezagadas

Para aprendizaje automático se construyen:

$$X_{t,1} = Y_{t-1},$$

$$X_{t,2} = Y_{t-2},$$

y así sucesivamente.

También pueden incluirse:

- medias móviles;
- máximos;
- mínimos;
- calendario;
- variables externas.

Ventanas móviles

Una media de ventana w es

$$M_t^{(w)} = \frac{1}{w} \sum_{j=1}^w Y_{t-j}.$$

Debe calcularse usando únicamente información anterior a t .

Variables de calendario

Pueden incluir:

- hora;
- día de semana;
- mes;

- trimestre;
- festivos;
- temporada.

Para variables cíclicas puede utilizarse:

$$\sin\left(\frac{2\pi t}{m}\right), \quad \cos\left(\frac{2\pi t}{m}\right).$$

Variables exógenas

Un modelo puede incluir

$$\mathbf{X}_t.$$

Por ejemplo:

$$Y_t = f(Y_{t-1}, \dots, Y_{t-p}, \mathbf{X}_t).$$

Para pronosticar se necesitan valores futuros o pronósticos de las variables exógenas.

Fuga temporal

Existe fuga si una variable usa información futura.

Ejemplos:

- media móvil centrada;
- escalamiento con toda la serie;
- imputación usando valores posteriores;
- selección de variables con el periodo de prueba;
- partición aleatoria.

División temporal

La partición correcta respeta:

$$\text{entrenamiento} < \text{validación} < \text{prueba}.$$

El futuro nunca debe utilizarse para construir el pasado.

Validación con origen móvil

En cada iteración se entrena con información hasta un tiempo y se evalúa en periodos posteriores.

Puede usarse:

- ventana expansiva;
- ventana deslizante.

Ventana expansiva

El conjunto de entrenamiento crece:

$$\{1, \dots, t\} \rightarrow \{1, \dots, t+1\}.$$

Ventana deslizando

Se mantiene una longitud fija:

$$\{t-w+1, \dots, t\}.$$

Es útil cuando existe cambio de distribución.

Pronóstico recursivo

Para múltiples pasos, la predicción anterior se utiliza como entrada:

$$\widehat{Y}_{t+2|t} = f(\widehat{Y}_{t+1|t}, Y_t, \dots).$$

Los errores pueden acumularse.

Pronóstico directo

Se entrena un modelo diferente para cada horizonte:

$$f_1, f_2, \dots, f_H.$$

Reduce acumulación, pero requiere más modelos.

Estrategia multioutput

Un modelo produce simultáneamente:

$$(\widehat{Y}_{t+1}, \dots, \widehat{Y}_{t+H}).$$

Árboles y bosques

Random Forest puede usar:

- rezagos;
- estadísticas móviles;
- variables calendario;
- variables meteorológicas.

Ventajas:

- no linealidad;

- interacciones;
- poca transformación.

Limitación: extrapola mal tendencias fuera del rango de entrenamiento.

Gradient boosting

Los modelos boosting suelen ser muy competitivos en series tabulares con variables rezagadas. Requieren validación temporal y control de sobreajuste.

Redes neuronales recurrentes

Una RNN actualiza un estado:

$$\mathbf{h}_t = \phi(\mathbf{W}_x \mathbf{x}_t + \mathbf{W}_h \mathbf{h}_{t-1} + \mathbf{b}).$$

El estado resume información pasada.

Gradientes en RNN

La retropropagación a través del tiempo multiplica Jacobianas repetidamente, lo cual puede producir gradientes desvanecientes o explosivos.

LSTM

Las redes LSTM introducen compuertas para controlar el flujo de información (Hochreiter y Schmidhuber 1997).

Incluyen:

- compuerta de olvido;
- compuerta de entrada;
- estado de celda;
- compuerta de salida.

Atención y transformers

Los transformers modelan dependencias mediante atención:

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V.$$

Permiten relacionar posiciones distantes sin recurrencia estricta.

Modelos híbridos

Puede combinarse:

- ARIMA para estructura lineal;

- aprendizaje automático para residuos;
- descomposición estacional;
- modelos separados por componentes.

Pronóstico jerárquico

En datos agregados, los pronósticos deben ser coherentes:

$$Y_{\text{total}} = \sum_j Y_j.$$

Se emplean métodos de reconciliación.

Series múltiples

Una colección de series puede compartir información.

Se distinguen:

- modelos locales: uno por serie;
- modelos globales: un modelo común.

Concept drift

La relación temporal puede cambiar.

Se requiere monitorear:

- error;
- distribución;
- residuos;
- importancia de variables;
- calibración.

Residuos

Un modelo adecuado debe dejar residuos aproximadamente:

- centrados en cero;
- sin autocorrelación;
- con varianza estable;
- sin estructura sistemática.

Prueba Ljung-Box

Contrasta autocorrelaciones conjuntas de residuos.

Rechazar sugiere dependencia temporal no modelada.

Selección de modelos

AIC:

$$AIC = -2 \log L + 2k.$$

BIC:

$$BIC = -2 \log L + k \log n.$$

En aprendizaje automático debe priorizarse desempeño fuera de muestra mediante validación temporal.

Línea base

Todo modelo debe compararse con referencias simples:

- último valor;
- media;
- tendencia;
- pronóstico estacional ingenuo.

Un modelo complejo que no supera la línea base no agrega valor.

Pronóstico ingenuo

$$\widehat{Y}_{t+h|t} = Y_t.$$

Ingenuo estacional

$$\widehat{Y}_{t+h|t} = Y_{t+h-m}.$$

Intervalos y aprendizaje automático

Puede utilizarse:

- regresión cuantílica;
- conformal prediction;
- bootstrap temporal;
- ensambles;
- modelos probabilísticos.

Evaluación por horizonte

El error debe analizarse para cada horizonte:

$$MAE(h), \quad RMSE(h).$$

Un modelo puede ser bueno a corto plazo y malo a largo plazo.

Aplicación ambiental

Para pronosticar PM10 pueden utilizarse:

- PM10 rezagado;
- temperatura;
- humedad;
- viento;
- hora;
- día;
- estacionalidad;
- variables de otras estaciones.

La validación debe simular el uso operativo real.

Conexión con R

```
1 library(forecast)
2
3 serie <- ts(
4   c(45, 48, 50, 47, 55, 60, 58, 62, 65, 63, 68, 70),
5   frequency = 12
6 )
7
8 modelo <- auto.arima(serie)
9
10 pronostico <- forecast(
11   modelo,
12   h = 6
13 )
14
15 plot(pronostico)
16
17 # Variables rezagadas para aprendizaje automático
18 crear_rezagos <- function(x, p = 3) {
19   resultado <- data.frame(y = x)
20
21   for (j in seq_len(p)) {
22     resultado[[paste0("lag_", j)]] <- dplyr::lag(x, j)
23   }
24
25   na.omit(resultado)
26 }
```

Ejemplo AR(1)

Sea

$$Y_t = 2 + 0.7Y_{t-1} + \varepsilon_t.$$

La media estacionaria es

$$\mu = \frac{2}{1 - 0.7} = \frac{20}{3}.$$

Ejemplo de diferencia

Para:

100, 105, 111, 115,

las primeras diferencias son:

5, 6, 4.

Ejemplo de variable rezagada

Para predecir Y_t con tres rezagos:

$$\mathbf{x}_t = (Y_{t-1}, Y_{t-2}, Y_{t-3}).$$

La primera fila utilizable aparece en $t = 4$.

Ventajas de los enfoques clásicos

1. interpretación;
2. intervalos probabilísticos;
3. buen desempeño con pocos datos;
4. teoría desarrollada;
5. diagnóstico de residuos.

Ventajas del aprendizaje automático

1. no linealidad;
2. numerosas variables;
3. interacciones;
4. series múltiples;
5. flexibilidad.

Limitaciones

1. dependencia temporal;
2. riesgo de fuga;
3. cambio de distribución;

4. incertidumbre futura;
5. horizontes múltiples;
6. necesidad de validación realista;
7. extrapolación limitada en árboles.

Errores frecuentes

1. dividir aleatoriamente;
2. calcular rezagos con información futura;
3. ajustar escalamiento con toda la serie;
4. evaluar solo un horizonte;
5. omitir una línea base;
6. usar MAPE con ceros;
7. ignorar autocorrelación residual;
8. seleccionar modelos con prueba final;
9. confundir ajuste histórico con pronóstico;
10. usar variables exógenas futuras desconocidas.

Ejercicios conceptuales

1. Defina estacionariedad.
2. Distinga tendencia y estacionalidad.
3. Interprete ACF y PACF.
4. Compare AR y MA.
5. Explique ARIMA.
6. ¿Qué es fuga temporal?
7. Compare ventana expansiva y deslizando.
8. Compare pronóstico recursivo y directo.
9. ¿Por qué se necesitan líneas base?
10. Compare modelos clásicos y aprendizaje automático.

Ejercicio AR(1)

Sea:

$$Y_t = 1 + 0.5Y_{t-1} + \varepsilon_t.$$

1. Verifique estacionariedad.
2. Calcule la media.
3. Pronostique un paso si $Y_t = 10$ y $\mathbb{E}(\varepsilon) = 0$.

Ejercicio de métricas

Observados:

10, 12, 15, 20.

Pronósticos:

11, 10, 14, 22.

Calcule:

1. errores;
2. MAE;
3. RMSE;
4. MAPE.

Ejercicio de validación

Diseñe una validación de origen móvil para 60 meses:

- 36 meses iniciales;
- horizonte de 3 meses;
- ventana expansiva.

Indique las particiones sucesivas.

Ejercicio aplicado

Diseñe un sistema para pronosticar PM10 diario que incluya:

1. limpieza;
2. imputación temporal;
3. tendencia;
4. estacionalidad;
5. rezagos;
6. variables meteorológicas;
7. línea base;
8. ARIMA;
9. Random Forest;
10. boosting;
11. validación temporal;
12. métricas por horizonte;
13. intervalos;
14. monitoreo de drift;
15. limitaciones ambientales.

Resumen

En este capítulo se desarrollaron los fundamentos de las series de tiempo y su relación con aprendizaje automático.

Se estudiaron tendencia, estacionalidad, estacionariedad, autocorrelación, ruido blanco, diferenciación y modelos AR, MA, ARMA y ARIMA.

También se analizaron suavizamiento exponencial, pronósticos probabilísticos, métricas, rezagos, ventanas móviles y variables exógenas.

Finalmente, se desarrollaron validación temporal, estrategias multihorizonte, árboles, ensambles, RNN, LSTM, transformers, modelos híbridos, monitoreo y prevención de fuga temporal.

Referencias del capítulo

Los fundamentos se apoyan en Box et al. (2015), Hamilton (1994), Hyndman y Athanasopoulos (2021) y Hochreiter y Schmidhuber (1997).

Referencias

- Agrawal, Rakesh, Tomasz Imieliński, y Arun Swami. 1993. «Mining Association Rules Between Sets of Items in Large Databases». *Proceedings of the 1993 ACM SIGMOD International Conference on Management of Data*, 207-16. <https://doi.org/10.1145/170035.170072>.
- Agrawal, Rakesh, y Ramakrishnan Srikant. 1994. «Fast Algorithms for Mining Association Rules in Large Databases». *Proceedings of the 20th International Conference on Very Large Data Bases*, 487-99.
- Agresti, Alan. 2013. *Categorical Data Analysis*. 3.^a ed. Wiley.
- Apostol, Tom M. 1969. *Calculus, Volume II: Multi-Variable Calculus and Linear Algebra with Applications*. 2.^a ed. Wiley.
- Arthur, David, y Sergei Vassilvitskii. 2007. «K-means++: The Advantages of Careful Seeding». *Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms*, 1027-35.
- Axler, Sheldon. 2015. *Linear Algebra Done Right*. 3.^a ed. Springer. <https://doi.org/10.1007/978-3-319-11080-6>.
- Bartlett, Peter L., y Shahar Mendelson. 2002. «Rademacher and Gaussian Complexities: Risk Bounds and Structural Results». *Journal of Machine Learning Research* 3: 463-82.
- Bishop, Christopher M. 2006. *Pattern Recognition and Machine Learning*. Springer.
- Box, George E. P., Gwilym M. Jenkins, Gregory C. Reinsel, y Greta M. Ljung. 2015. *Time Series Analysis: Forecasting and Control*. 5.^a ed. Wiley.
- Boyd, Stephen, y Lieven Vandenberghe. 2004. *Convex Optimization*. Cambridge University Press. <https://doi.org/10.1017/CBO9780511804441>.
- Breiman, Leo. 2001. «Random Forests». *Machine Learning* 45: 5-32. <https://doi.org/10.1023/A:1010933404324>.
- Breiman, Leo, Jerome H. Friedman, Richard A. Olshen, y Charles J. Stone. 1984. *Classification and Regression Trees*.
- Casella, George, y Roger L. Berger. 2002. *Statistical Inference*. 2.^a ed. Duxbury.

- Cortes, Corinna, y Vladimir Vapnik. 1995. «Support-Vector Networks». *Machine Learning* 20: 273-97. <https://doi.org/10.1007/BF00994018>.
- Cover, Thomas M., y Peter E. Hart. 1967. «Nearest Neighbor Pattern Classification». *IEEE Transactions on Information Theory* 13 (1): 21-27. <https://doi.org/10.1109/TIT.1967.1053964>.
- Devroye, Luc, László Györfi, y Gábor Lugosi. 1996. *A Probabilistic Theory of Pattern Recognition*. Springer. <https://doi.org/10.1007/978-1-4612-0711-5>.
- Duda, Richard O., Peter E. Hart, y David G. Stork. 2001. *Pattern Classification*. 2.^a ed. Wiley.
- Eckart, Carl, y Gale Young. 1936. «The Approximation of One Matrix by Another of Lower Rank». *Psychometrika* 1: 211-18. <https://doi.org/10.1007/BF02288367>.
- Efron, Bradley. 1983. «Estimating the Error Rate of a Prediction Rule: Improvement on Cross-Validation». *Journal of the American Statistical Association* 78 (382): 316-31. <https://doi.org/10.1080/01621459.1983.10477973>.
- Glorot, Xavier, y Yoshua Bengio. 2010. «Understanding the Difficulty of Training Deep Feedforward Neural Networks». *Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics*, 249-56.
- Hahsler, Michael, Bettina Grün, y Kurt Hornik. 2005. «arules: A Computational Environment for Mining Association Rules and Frequent Item Sets». *Journal of Statistical Software* 14 (15): 1-25. <https://doi.org/10.18637/jss.v014.i15>.
- Hamilton, James D. 1994. *Time Series Analysis*. Princeton University Press.
- Han, Jiawei, Jian Pei, y Yiwen Yin. 2000. «Mining Frequent Patterns without Candidate Generation». *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, 1-12. <https://doi.org/10.1145/335191.335372>.
- Hastie, Trevor, Robert Tibshirani, y Jerome Friedman. 2009. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2.^a ed. Springer. <https://doi.org/10.1007/978-0-387-84858-7>.
- He, Kaiming, Xiangyu Zhang, Shaoqing Ren, y Jian Sun. 2015. «Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification». *Proceedings of the IEEE International Conference on Computer Vision*, 1026-34. <https://doi.org/10.1109/ICCV.2015.123>.
- Hochreiter, Sepp, y Jürgen Schmidhuber. 1997. «Long Short-Term Memory». *Neural Computation* 9 (8): 1735-80. <https://doi.org/10.1162/neco.1997.9.8.1735>.

- Hornik, Kurt, Maxwell Stinchcombe, y Halbert White. 1989. «Multilayer Feedforward Networks Are Universal Approximators». *Neural Networks* 2 (5): 359-66. [https://doi.org/10.1016/0893-6080\(89\)90020-8](https://doi.org/10.1016/0893-6080(89)90020-8).
- Hosmer, David W., Stanley Lemeshow, y Rodney X. Sturdivant. 2013. *Applied Logistic Regression*. 3.^a ed. Wiley.
- Hotelling, Harold. 1933. «Analysis of a Complex of Statistical Variables into Principal Components». *Journal of Educational Psychology* 24: 417-41. <https://doi.org/10.1037/h0071325>.
- Hyndman, Rob J., y George Athanasopoulos. 2021. *Forecasting: Principles and Practice*. 3.^a ed. OTexts.
- Jain, Anil K. 2010. «Data Clustering: 50 Years Beyond K-means». *Pattern Recognition Letters* 31 (8): 651-66. <https://doi.org/10.1016/j.patrec.2009.09.011>.
- James, Gareth, Daniela Witten, Trevor Hastie, y Robert Tibshirani. 2021. *An Introduction to Statistical Learning*. 2.^a ed. Springer. <https://doi.org/10.1007/978-1-0716-1418-1>.
- Jolliffe, Ian T. 2002. *Principal Component Analysis*. 2.^a ed. Springer. <https://doi.org/10.1007/b98835>.
- Jolliffe, Ian T., y Jorge Cadima. 2016. «Principal Component Analysis: A Review and Recent Developments». *Philosophical Transactions of the Royal Society A* 374 (2065): 20150202. <https://doi.org/10.1098/rsta.2015.0202>.
- Lance, G. N., y W. T. Williams. 1967. «A General Theory of Classificatory Sorting Strategies: 1. Hierarchical Systems». *The Computer Journal* 9 (4): 373-80. <https://doi.org/10.1093/comjnl/9.4.373>.
- Lloyd, Stuart P. 1982. «Least Squares Quantization in PCM». *IEEE Transactions on Information Theory* 28 (2): 129-37. <https://doi.org/10.1109/TIT.1982.1056489>.
- MacQueen, James. 1967. «Some Methods for Classification and Analysis of Multivariate Observations». *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability* 1: 281-97.
- Mardia, Kanti V., John T. Kent, y John M. Bibby. 1979. *Multivariate Analysis*. Academic Press.
- McAllester, David A. 1999. «PAC-Bayesian Model Averaging». *Proceedings of the Twelfth Annual Conference on Computational Learning Theory*, 164-70.
- Mohri, Mehryar, Afshin Rostamizadeh, y Ameet Talwalkar. 2018. *Foundations of Machine Learning*. 2.^a ed. MIT Press.

- Montgomery, Douglas C., Elizabeth A. Peck, y G. Geoffrey Vining. 2021. *Introduction to Linear Regression Analysis*. 6.^a ed. Wiley.
- Murphy, Kevin P. 2022. *Probabilistic Machine Learning: An Introduction*. MIT Press.
- Murtagh, Fionn, y Pedro Contreras. 2012. «Algorithms for Hierarchical Clustering: An Overview». *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery* 2 (1): 86-97. <https://doi.org/10.1002/widm.53>.
- Pearson, Karl. 1901. «On Lines and Planes of Closest Fit to Systems of Points in Space». *Philosophical Magazine* 2 (11): 559-72. <https://doi.org/10.1080/14786440109462720>.
- Quinlan, J. Ross. 1986. «Induction of Decision Trees». *Machine Learning* 1: 81-106. <https://doi.org/10.1007/BF00116251>.
- Quinlan, J. Ross. 1993. *C4.5: Programs for Machine Learning*. Morgan Kaufmann.
- Ross, Sheldon M. 2019. *A First Course in Probability*. 10.^a ed. Pearson.
- Rousseeuw, Peter J. 1987. «Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis». *Journal of Computational and Applied Mathematics* 20: 53-65. [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7).
- Rumelhart, David E., Geoffrey E. Hinton, y Ronald J. Williams. 1986. «Learning Representations by Back-Propagating Errors». *Nature* 323: 533-36. <https://doi.org/10.1038/323533a0>.
- Seber, George A. F., y Alan J. Lee. 2012. *Linear Regression Analysis*. 2.^a ed. Wiley.
- Shalev-Shwartz, Shai, y Shai Ben-David. 2014. *Understanding Machine Learning: From Theory to Algorithms*. Cambridge University Press.
- Srivastava, Nitish, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, y Ruslan Salakhutdinov. 2014. «Dropout: A Simple Way to Prevent Neural Networks from Overfitting». *Journal of Machine Learning Research* 15: 1929-58.
- Stone, Charles J. 1977. «Consistent Nonparametric Regression». *The Annals of Statistics* 5 (4): 595-620. <https://doi.org/10.1214/aos/1176343886>.
- Stone, Mervyn. 1974. «Cross-Validatory Choice and Assessment of Statistical Predictions». *Journal of the Royal Statistical Society: Series B* 36 (2): 111-47. <https://doi.org/10.1111/j.2517-6161.1974.tb00994.x>.
- Strang, Gilbert. 2016. *Introduction to Linear Algebra*. 5.^a ed. Wellesley-Cambridge Press.

- Tibshirani, Robert. 1996. «Regression Shrinkage and Selection via the Lasso». *Journal of the Royal Statistical Society: Series B* 58 (1): 267-88. <https://doi.org/10.1111/j.2517-6161.1996.tb02080.x>.
- Tikhonov, Andrey N. 1963. «Solution of Incorrectly Formulated Problems and the Regularization Method». *Soviet Mathematics Doklady* 4: 1035-38.
- Valiant, Leslie G. 1984. «A Theory of the Learnable». *Communications of the ACM* 27 (11): 1134-42.
- Vapnik, Vladimir N. 1998. *Statistical Learning Theory*. Wiley.
- Vapnik, Vladimir N., y Alexey Y. Chervonenkis. 1971. «On the Uniform Convergence of Relative Frequencies of Events to Their Probabilities». *Theory of Probability and Its Applications* 16 (2): 264-80.
- Ward, Joe H. 1963. «Hierarchical Grouping to Optimize an Objective Function». *Journal of the American Statistical Association* 58 (301): 236-44. <https://doi.org/10.1080/01621459.1963.10500845>.

Índice temático

Índice alfabético

Agrupamiento jerárquico, [353](#)
Análisis de componentes principales, [318](#)
Aprendizaje PAC, [383](#)
ARIMA, [387](#)
Autocorrelación, [387](#)

Biplot, [326](#)

Centroides, [335](#)
Confianza, [366](#)
Conjuntos, [13](#)
Convexidad, [73](#)

Dendrograma, [353](#)
Descomposición en valores singulares, [28](#)
Dimensión VC, [384](#)
Dominio, [13](#)
Dropout, [295](#)

Entropía, [243](#)

Función, [13](#)

Generalización, [382](#)
Gradiente, [73](#)

Hessiana, [73](#)

K-means, [335](#)
K-NN, [227](#)
Kernels, [273](#)

Lasso, [149](#)
Lift, [366](#)

Maldición de la dimensionalidad, [235](#)
Margen, [273](#)

Matrices, [29](#)
Multicolinealidad, [187](#)
Máquinas de vectores de soporte, [273](#)
Máxima verosimilitud, [50](#)
Método de Ward, [353](#)

Odds, [209](#)

Probabilidad, [50](#)
Pérdida 0-1, [116](#)

Random Forest, [261](#)
Redes neuronales, [295](#)
Regla de Bayes, [113](#)
Reglas de asociación, [366](#)
Regresión lineal múltiple, [187](#)
Regresión lineal simple, [167](#)
Regresión logística, [209](#)
Regularización, [149](#)
Retropropagación, [295](#)
Ridge, [149](#)
Riesgo empírico, [95](#)
Riesgo esperado, [95](#)

Series de tiempo, [387](#)
Silueta, [335](#)
Soporte, [366](#)

Validación cruzada, [131](#)
Valores propios, [41](#)
Variables aleatorias, [55](#)
Varianza explicada, [318](#)
Vectores, [28](#)

Árboles de decisión, [243](#)
Índice de Gini, [243](#)